



FACULTAD DE INGENIERÍA Y ARQUITECTURA

**EVALUACIÓN COMPARATIVA DE MÉTODOS QUERY
PERFORMANCE PREDICTION (QPP) PARA BÚSQUEDAS AD-HOC
UTILIZANDO MÉTRICAS DE CORRELACIÓN.**

Trabajo de memoria para obtener el título de:

INGENIERO CIVIL EN COMPUTACIÓN E INFORMÁTICA

**Alumno: José Emmanuel Raúl Sandoval Vega.
Luis Emersson Brain Fredes.**

Profesor Patrocinante: Dr. Mauricio Andrés Oyarzún Silva.

IQUIQUE - CHILE

2025

[Dedicatoria...]

AGRADECIMIENTOS

[Agradezco...]

ÍNDICE DE MATERIAS

CAPÍTULO I: INTRODUCCIÓN	1
1.1 Contexto del proyecto	1
1.2 Objetivo General	1
1.3 Objetivos Específicos	2
1.4 Estructura del trabajo de título	2
CAPÍTULO II: ANTECEDENTES	4
2.1 Marco teórico	4
2.1.1 Sistemas de Information Retrieval (IR)	4
2.1.2 Predicción de Rendimiento de Consultas (QPP)	4
2.1.3 Métricas Clasicas de Evaluación en IR	4
2.1.4 Métricas de Correlación para Evaluar Métodos QPP	4
2.2 Herramientas utilizadas	4
2.2.1 Pyterrier	4
2.2.2 ir_datasets	4
2.2.3 ir_measures	4
2.2.4 Docker	4
CAPÍTULO III: TRABAJOS RELACIONADOS	5
3.1 Metodos de Query Performance Prediction (QPP)	5
3.1.1 IDF (Inverse Document Frequency)	5
3.1.2 SCQ (Similarity Between Query and Collection)	7
3.1.3 NQC (Normalized Query Commitment)	8
3.1.4 Clarity Score (CS)	9
3.1.5 WIG (Weighted Information Gain)	10
3.1.6 UEF (Utility Estimation Framework)	11
3.2 Estudios comparativos similares	12
3.2.1 QPPTK en TIREx	12
3.2.2 An Enhanced Evaluation Framework for Query Performance Prediction (2021)	13
CAPÍTULO IV: DISEÑO DE LA EVALUACIÓN COMPARATIVA	15
4.1 Selección de métodos de QPP	15
4.1.1 Criterios de selección	16
4.1.2 Métodos seleccionados	18
4.2 Selección de conjuntos de datos	20
4.2.1 Criterios de inclusión	21

- 4.2.2 Justificación de los conjuntos de datos seleccionados 23
- 4.3 Entorno experimental 25
 - 4.3.1 Flujo del sistema 25
 - 4.3.2 Configuración técnica 26
- 4.4 Relación entre diseño experimental y objetivos 29
- CAPÍTULO V: IMPLEMENTACIÓN 30**
 - 5.1 Configuración del entorno experimental 31
 - 5.1.1 Docker y dependencias 32
 - 5.1.2 Integración de conjuntos de datos 34
 - 5.1.3 Indexación y consultas 35
 - 5.2 Implementación de métodos QPP 35
 - 5.2.1 Métodos pre-retrieval 37
 - 5.2.2 Métodos post-retrieval 37
 - 5.3 Implementación de la evaluación 38
 - 5.3.1 Cálculo de correlaciones 38
 - 5.3.2 Visualización de resultados 38
 - 5.4 Pruebas de validación 39
- CAPÍTULO VI: ANÁLISIS DE RESULTADOS 40**
 - 6.1 Resultados obtenidos en conjuntos de datos 40
 - 6.2 Comparación de métodos QPP 44
 - 6.3 Discusión de los resultados 47
- CAPÍTULO VII: CONCLUSIONES Y TRABAJO FUTURO 48**
 - 7.1 Principales conclusiones 48
 - 7.2 Recomendaciones para investigaciones futuras 48
 - 7.3 Trabajo Futuro 48

ÍNDICE DE TABLAS

Tabla 4.1: Parámetros principales de BM25 27

Tabla 4.2: Parámetros principales de configuración 28

Tabla 4.3: Configuración de métricas por dataset 29

Tabla 5.4: Configuración del entorno experimental 32

Tabla 5.5: Componentes principales del Dockerfile 33

Tabla 5.6: Tipos de visualizaciones implementadas 39

Tabla 6.7: Muestra de terminos Porter vs Snowball Stemmers 44

ÍNDICE DE FIGURAS

Figura 5.1: Diagrama de componentes del entorno de evaluación 31

Figura 5.2: Dockerfile para la configuración del entorno experimental 33

Figura 5.3: Configuración de formato de dataset 34

Figura 5.4: Código de implementación del factory de métodos QPP 36

Figura 5.5: Diagrama de la capa de métodos QPP 36

Figura 5.6: Implementación del método WIG 37

Figura 6.7: Diagrama de flujo del análisis de resultados 40

Figura 6.8: Boxplot de las métricas nDCG y AP 41

Figura 6.9: Media de las métricas nDCG y AP 42

Figura 6.10: Histogramas de las métricas nDCG y AP 42

Figura 6.11: Grafico de dispersión de nDCG@10 vs AP 43

Figura 6.12: Correlación de los métodos QPP - tau de Kendall 45

Figura 6.13: Boxplot de las correlaciones de los métodos QPP - tau de Kendall 45

Figura 6.14: Grafico de dispersión de nDCG@10 vs IDF-avg 46

Figura 6.15: Grafico de dispersión de nDCG@10 vs IDF-max - tau de Kendall 46

Figura 6.16: Grafico de dispersión de nDCG@10 vs NQC 47

Figura 6.17: Grafico de dispersión de nDCG@10 vs UEF-NQC - tau de Kendall .. 47

NOMENCLATURA

RESUMEN

En la actualidad, los métodos de Query Performance Prediction (QPP) son fundamentales en sistemas de recuperación de información (IR) para predecir la calidad de los resultados y optimizar búsquedas. Sin embargo, su eficacia varía según dominios y tipos de consultas, especialmente en búsquedas ad-hoc, derivando en respuestas subóptimas y tiempo desperdiciado en búsquedas poco eficaces. Es así, que se resalta la necesidad de una evaluación robusta y benchmarking a los métodos QPP más utilizados, para asegurar su fiabilidad en diversos entornos a la vez que se establece una base sólida para facilitar el desarrollo de nuevos enfoques. El presente proyecto se enfocará en implementar y evaluar métodos QPP no basados en inteligencia artificial (IA) para búsquedas ad-hoc utilizando medidas de correlación estandarizadas, como, por ejemplo, tau de Kendall y el coeficiente de correlación de Pearson. Este enfoque implica una revisión exhaustiva de la literatura existente para identificar los métodos QPP claves, seguida de una cuidadosa implementación de ellos, para luego evaluarlos rigurosamente utilizando un conjunto de datos estandarizados y un marco de evaluación común, lo que asegurará la comparabilidad y reproducibilidad de los resultados.

El objetivo del proyecto es evaluar al menos 5 métodos QPP diferentes y lograr un benchmarking que replique el rendimiento de los métodos QPP descritos en el estado del arte. Estos resultados servirán como línea base para comparar nuevos modelos QPP, proporcionando un punto de referencia claro para evaluar las mejoras de su investigación futura. Además, se busca identificar fortalezas y debilidades de diferentes enfoques, potencialmente descubriendo ideas que podrían guiar futuras direcciones de investigación en métodos QPP.

CAPÍTULO I: INTRODUCCIÓN

1.1 Contexto del proyecto

La predicción del rendimiento de consultas (QPP) ha emergido como una herramienta prometedora en los sistemas de recuperación de información (IR). La capacidad de predecir la calidad de los resultados de búsqueda antes de la ejecución de la consulta permite tanto optimizar los recursos como al mismo tiempo mejorar la experiencia de los usuarios. Sin embargo, la eficacia de los métodos QPP varía significativamente según el dominio, el tipo de consulta, e incluso los modelos de recuperación de información utilizados, algo que se evidencia especialmente en búsquedas ad-hoc. Esta variabilidad subraya la necesidad de evaluaciones robustas y reproducibles, que permitan comparar y contrastar diferentes enfoques de tal forma que se pueda establecer una línea base clara para futuras investigaciones.

La complejidad del problema de QPP se magnifica por la diversidad de escenarios de aplicación y la heterogeneidad de los datos en diferentes dominios. Los sistemas de recuperación de información modernos deben manejar consultas que varían desde preguntas simples hasta construcciones complejas en lenguaje natural, cada una con sus propios desafíos de predicción de rendimiento. Además, la calidad de los resultados puede verse afectada por factores como la ambigüedad del lenguaje, la especificidad de la consulta, y la cobertura del tema en la colección de documentos.

La motivación sobre el campo de Query Performance Prediction (QPP) ha aumentado en los últimos años debido a los avances en el campo de la inteligencia artificial, específicamente en el área del procesado de lenguaje natural (NLP), donde nuevos modelos de lenguaje como BERT, GPT entre otros han demostrado ser muy efectivos en tareas de recuperación de información mediante el uso de técnicas especializadas como RAG (Retrieval augmented generation). Bajo esta premisa se abre un nuevo paradigma de métodos QPP basados en consultas conversacionales, donde la interacción entre el usuario y el sistema de recuperación de información se da de forma más natural. Es por esto por lo que es relevante establecer una línea base sobre los enfoques tradicionales para asegurar un avance en las futuras investigaciones de métodos QPP basados en inteligencia artificial.

1.2 Objetivo General

Evaluar comparativamente métodos de Query Performance Prediction (QPP) para búsquedas Ad-hoc utilizando métricas de correlación.

1.3 Objetivos Específicos

1. Revisar la literatura sobre métodos de QPP en búsquedas ad-hoc sin el uso de inteligencia artificial.
2. Identificar y describir los principales métodos QPP utilizados en la actualidad.
3. Implementar y evaluar métodos QPP no basados en inteligencia artificial utilizando un conjunto de datos estandarizados y un marco de evaluación común.
4. Analizar y documentar el rendimiento de los métodos QPP implementados para establecer una línea base para futuras comparaciones.
5. Identificar fortalezas y debilidades de diferentes enfoques, proporcionando ideas para futuras investigaciones en métodos QPP.

1.4 Estructura del trabajo de título

El presente trabajo está organizado en siete capítulos, además de incluir las referencias bibliográficas que detallan todos los documentos citados y utilizados en su elaboración. Los capítulos son los siguientes:

Capítulo I: Introducción. Presenta el contexto y motivación del proyecto, junto con los objetivos general y específicos planteados para su realización. Se describe la importancia de la predicción del rendimiento de consultas (QPP) en sistemas de recuperación de información y la necesidad de una evaluación comparativa robusta.

Capítulo II: Antecedentes. Proporciona el marco teórico necesario para comprender el trabajo, incluyendo conceptos fundamentales sobre sistemas de recuperación de información, predicción del rendimiento de consultas, métricas de evaluación y las herramientas utilizadas en el proyecto.

Capítulo III: Trabajos Relacionados. Revisa y analiza los principales métodos QPP desarrollados en la literatura, enfocándose en aquellos no basados en inteligencia artificial. Se examinan sus características, fortalezas y limitaciones, estableciendo el estado del arte en el campo.

Capítulo IV: Diseño de la Evaluación Comparativa. Define la metodología experimental, incluyendo la selección de métodos QPP, datasets, métricas de evaluación y el entorno experimental. Se detalla la configuración técnica y los procedimientos para garantizar la reproducibilidad de los experimentos.

Capítulo V: Implementación. Describe en detalle la implementación de los métodos QPP seleccionados, la configuración del entorno experimental y los procesos de validación. Se incluyen aspectos técnicos sobre la integración de herramientas y la ejecución de experimentos.

Capítulo VI: Análisis de Resultados. Presenta y analiza los resultados obtenidos en la evaluación comparativa, examinando el rendimiento de cada método QPP en diferentes escenarios y datasets. Se discuten las implicaciones de los hallazgos y se comparan con resultados previos de la literatura.

Capítulo VII: Conclusiones y Trabajo Futuro. Resume los principales hallazgos y contribuciones del proyecto, estableciendo la línea base para futuras investigaciones en QPP. Se identifican limitaciones del estudio y se proponen direcciones para investigaciones futuras.

Finalmente, se incluyen las referencias bibliográficas que sustentan el trabajo realizado, asegurando la trazabilidad y reproducibilidad de la investigación.

CAPÍTULO II: ANTECEDENTES

2.1 Marco teórico

Conceptos básicos y principios fundamentales...

2.1.1 Sistemas de Information Retrieval (IR)

2.1.2 Predicción de Rendimiento de Consultas (QPP)

2.1.3 Métricas Clasicas de Evaluación en IR

2.1.4 Métricas de Correlación para Evaluar Métodos QPP

2.2 Herramientas utilizadas

2.2.1 Pyterrier

2.2.2 ir_datasets

2.2.3 ir_measures

2.2.4 Docker

CAPÍTULO III: TRABAJOS RELACIONADOS

Como se ha mencionado anteriormente, la predicción del rendimiento de consultas (QPP) es un área importante dentro de los sistemas de recuperación de información, ya que permite anticipar la calidad de los resultados de una consulta sin necesidad de ejecutarla de forma completa. Es así, que a lo largo de los años se han desarrollado numerosos métodos QPP con diferentes características y aptos para distintas situaciones, los que han sido evaluados exhaustivamente en una larga cantidad de estudios. Estos estudios no solo han definido métricas y herramientas para medir la efectividad de los métodos QPP, sino que también han desarrollado análisis comparativos (benchmarks) que sirven como referencia en el estado del arte dentro del área.

A continuación, se revisan estudios relevantes relacionados con la predicción del rendimiento de consultas, presentando los principales métodos utilizados en la literatura, para posteriormente, analizar el uso de datasets y entornos de experimentación para la comparación de métodos, destacando investigaciones previas que han servido como base para el diseño experimental de este proyecto.

3.1 Metodos de Query Performance Prediction (QPP)

En el contexto de este proyecto, se priorizó la revisión de métodos de Query Performance Prediction que no dependen de enfoques basados en inteligencia artificial (IA), los cuales, clasificados como pre-retrieval y post-retrieval, son altamente valorados por su simplicidad y robustez en la predicción del rendimiento de consulta sirviendo como base para métodos QPP más complejos.

Es así como, durante la revisión de la literatura, se identificaron trabajos claves que evaluaron y desarrollaron diferentes métodos QPP en diferentes contextos, como búsquedas ad-hoc y benchmarks de recuperación de información, proporcionando métricas importantes para evaluar la calidad de las consultas, los cuales se presentan a continuación.

3.1.1 IDF (Inverse Document Frequency)

El término Inverse Document Frequency (IDF), ampliamente utilizado como predictor pre-retrieval en sistemas de recuperación de información, mide la especi-

ficidad de un término dentro de un corpus. En el documento [1], se profundiza su relevancia como un componente clave en la predicción del rendimiento de consultas (QPP), específicamente su capacidad para identificar términos altamente selectivos, es decir, aquellos que aparecen en pocos documentos (menos comunes) y, por ende, aportan mayor discriminación en la búsqueda. El IDF también es empleado en modelos como MaxIDF, donde el término con la mayor frecuencia inversa dentro de una consulta sirve como indicador principal de su efectividad. Esta metodología, que se basa en heurísticas, se adoptó rápidamente como una herramienta esencial en la predicción del rendimiento de consultas (QPP) pre-retrieval en los sistemas de recuperación de información, siendo incorporada en otros esquemas y modelos probabilísticos de búsqueda.

La fórmula comúnmente utilizada del IDF en sistemas modernos, debido a su suavizado y estabilidad matemática, se define como:

$$IDF(t) = \ln \left(1 + \frac{N}{f_t} \right) \quad (3.1)$$

Donde N es el número total de documentos en el corpus y f_t es el número de documentos que contienen el término t , y se añade 1 para evitar divisiones por cero o valores indefinidos.

En el artículo [2], el autor señala que el IDF asigna pesos más bajos a los términos frecuentes debido a su limitado poder discriminatorio, mientras que otorga pesos más altos a los términos menos comunes, los cuales poseen mayor capacidad para distinguir documentos relevantes, asegurando que los términos poco frecuentes, pero informativos, tengan un mayor impacto en el cálculo de relevancia. Además, se destaca que, aunque la formulación exacta del algoritmo puede variar según los autores, su utilidad general permanece sólida en una amplia gama de aplicaciones prácticas, incluyendo la recuperación de información y otros contextos relacionados con el análisis de datos.

De esta forma, el IDF ha sido ampliamente utilizado debido a su robustez y simplicidad. En el artículo [2], el autor argumenta que el IDF equilibra de forma eficaz la especificidad y la relevancia, permitiendo su aplicación en diferentes contextos, tales como recuperación de textos, análisis de lenguaje natural e incluso en recuperación de medios no textuales.

En cuanto a su relevancia para el presente proyecto de evaluación de métodos de QPP, el IDF resulta crucial, ya que su capacidad para capturar la especificidad de los términos es clave para analizar la predictibilidad de las consultas y, además, como se menciona en el artículo [3], su integración en distintas métricas proporciona una línea base confiable para la comparación con métodos más avanzados, validando

su referencia tanto de forma heurística como de herramienta teórica sólida y bien fundamentada.

3.1.2 SCQ (Similarity Between Query and Collection)

El método SCQ (Similarity Between a Query and a Collection), es un predictor pre-retrieval propuesto por Ying Zhao, Falk Scholer y Yohannes Tsegay. En el artículo [1] los autores explican que el SCQ calcula un puntaje de similitud entre una consulta y la colección de documentos, utilizando la frecuencia de términos y la frecuencia inversa de documentos como evidencias para determinar la relevancia. Siendo una de sus principales ventajas que se basa en estadísticas disponibles durante el proceso de indexado, eliminando la necesidad de realizar búsquedas previas.

La fórmula matemática que define al SCQ es la siguiente:

$$SCQ = \sum_{t \in Q} \left(1 + \ln(f_{c,t}) \cdot \ln \left(1 + \frac{N}{f_t} \right) \right) \quad (3.2)$$

Donde Q es el conjunto de términos de la consulta, $f_{c,t}$ corresponde a la frecuencia del término t en la colección, f_t es el número de documentos en los que aparece el término t , y finalmente N es el número total de documentos de la colección.

Como se menciona, el SCQ mide la similitud mediante una representación vectorial, donde tanto las consultas como los documentos son tratados como vectores. La proximidad entre estos vectores se interpreta como un indicador de relevancia que permite identificar consultas que potencialmente obtendrán un mejor rendimiento en la recuperación de información. Además, este predictor puede ajustarse mediante la normalización por longitud de la consulta o evaluarse en función del valor máximo de SCQ alcanzado por los términos individuales.

Es así como, gracias a su balance entre la simplicidad y precisión, el SCQ se ha consolidado como una herramienta útil para sistemas de recuperación de información que manejan grandes volúmenes de datos en tiempo real, en donde su capacidad para establecer relaciones entre las características de las consultas y su rendimiento lo convierte en una contribución importante para tareas que involucran una alta variabilidad en las consultas, posicionándose como un estándar en evaluaciones pre-retrieval.

Por lo tanto, para el presente proyecto, el SCQ es particularmente relevante porque permite analizar consultas en dominios complejos y heterogéneos, estableciendo una relación clara entre las características de las consultas y su rendimiento esperado, lo que facilita una evaluación comparativa de métodos.

3.1.3 NQC (Normalized Query Commitment)

El método NQC (Normalized Query Commitment) fue propuesto por Anna Shtok, Oren Kurland y David Carmel como un predictor post-retrieval que evalúa la efectividad de una consulta midiendo la dispersión de los puntajes de recuperación entre los documentos más relevantes. En el artículo [4], los autores destacan que una menor dispersión temática en los documentos recuperados está asociada con una mayor efectividad de las consultas, lo cual se refleja en la distribución de los puntajes de recuperación.

Por lo tanto, el enfoque de NQC se centra en medir la desviación estándar de los puntajes de recuperación normalizados por el promedio del corpus, lo que permite identificar consultas cuyos documentos recuperados son consistentes en términos de relevancia, sugiriendo un buen desempeño de la consulta. Además, los autores explican que los documentos con puntajes significativamente superiores al promedio son menos propensos a exhibir desviaciones temáticas, lo que se traduce en un menor grado de “query drift” y un mejor rendimiento de recuperación.

El método NQC se define matemáticamente como:

$$NQC(q, M) = \frac{\sqrt{\frac{1}{k} \sum_{d \in D[k]_q} (Score(d) - \mu)^2}}{Score(D)} \quad (3.3)$$

En donde q corresponde a la consulta, M al modelo de recuperación, $D[k]_q$ a la lista de los k documentos mejor rankeados, μ al promedio de los puntajes de recuperación en $D[k]_q$ y $Score[D]$ al puntaje de recuperación del corpus considerado como un único documento.

NQC resulta especialmente útil en el ámbito de la recuperación de información debido a su capacidad para capturar la consistencia en documentos relevantes y su adaptabilidad a diferentes modelos de recuperación, siendo su diseño simple lo que permite aplicarlo de manera eficiente, incluso en escenarios complejos donde se requiere alta precisión en los resultados.

Para el presente proyecto, NQC es relevante al proporcionar una métrica que permite evaluar la calidad de las consultas al correlacionar la dispersión de los puntajes con la efectividad esperada, lo que es fundamental para analizar consultas en dominios con alta variabilidad y establecer comparaciones confiables entre los diferentes métodos de predicción.

3.1.4 Clarity Score (CS)

El método Clarity Score (CS) fue desarrollado por Steve Cronen-Townsend, Yun Zhou y W. Bruce Croft como un predictor post-retrieval que analiza la claridad o coherencia de las consultas en sistemas de recuperación de información. En el artículo [3], los autores explican que el CS se basa en la comparación entre un modelo de lenguaje generado a partir de una consulta y el modelo de lenguaje global del corpus, utilizando la divergencia de Kullback-Leibler como herramienta matemática que permite calcular la distancia entre ambos modelos.

Este enfoque permite evaluar la calidad de las consultas antes de realizar una recuperación completa de documentos, lo que es particularmente útil para identificar consultas que podrían resultar problemáticas debido a su ambigüedad.

El cálculo del CS implica que consultas con términos más claros y específicos generarán modelos de lenguaje que se alinean mejor con el modelo del corpus, obteniendo puntajes más altos, estos términos, al estar menos expuestos a interpretaciones ambiguas, tienden a recuperar documentos más relevantes y precisos. Por otro lado, las consultas con puntajes más bajos suelen reflejar una mayor ambigüedad o dispersión temática, lo que puede afectar negativamente la precisión de los resultados recuperados.

Como se menciona, el CS se calcula como la divergencia de Kullback-Leibler entre el modelo de lenguaje de la consulta y el modelo de lenguaje de la colección:

$$CS(Q) = \sum_{w \in V} \left(P(w | Q) \log 2 \frac{P(w | Q)}{P_{coll}(w)} \right) \quad (3.4)$$

En donde w es un término en el vocabulario V , $P(w | Q)$ es la probabilidad del término w en el modelo de lenguaje de la consulta y $P_{coll}(w)$ es la probabilidad del término w en el modelo de lenguaje de la colección.

Es así que, en términos prácticos, el CS demuestra ser una herramienta eficaz para predecir el rendimiento de consultas en diversos dominios, desde búsquedas de texto hasta tareas más complejas como recuperación de información en grandes volúmenes de datos. Además, su capacidad para identificar consultas problemáticas antes de que se ejecute la búsqueda completa lo convierte en una solución eficiente y adaptable para optimizar los sistemas de recuperación de información.

Finalmente, en el contexto del presente proyecto, el Clarity Score es relevante por su capacidad para proporcionar un indicador temprano sobre la calidad de las consultas, permitiendo evaluar cómo estas interactúan con el corpus y qué tan bien pueden desempeñarse en términos de recuperación efectiva, resultando crucial en escenarios donde la variabilidad y complejidad de las consultas pueden influir significativamente en los resultados esperados.

3.1.5 WIG (Weighted Information Gain)

El método Weighted Information Gain (WIG) fue desarrollado por Yun Zhou y W. Bruce Croft como un predictor post-retrieval diseñado para abordar los desafíos de la predicción del rendimiento de consultas en entornos de búsqueda web. En el artículo [5], los autores destacan que WIG mide la contribución promedio de los documentos mejor clasificados a la calidad del rendimiento de la consulta, basándose en el análisis de las características individuales de los términos y su proximidad, lo que permite evaluar la efectividad de las consultas en colecciones grandes y heterogéneas.

El cálculo de WIG se realiza comparando el cambio en la información entre un estado inicial, representado por un documento promedio del corpus, y el estado posterior, que corresponde a los resultados obtenidos tras la recuperación de los documentos relevantes. Este enfoque utiliza conceptos como la ganancia de información ponderada y distribuciones de probabilidad para estimar la calidad de la consulta, lo que lo convierte en una herramienta robusta para analizar el desempeño en escenarios complejos.

En cuanto a su fórmula, WIG se define como la diferencia entre la entropía ponderada de los documentos mejor clasificados y la entropía del modelo de lenguaje de la colección, lo que es igual a:

$$WIG(Q) = \frac{1}{k} \sum_{d \in D_k} \left(P(Q | d) \log \frac{P(Q | d)}{P(Q | C)} \right) \quad (3.5)$$

En donde Q es la consulta, D_k es el conjunto de los k documentos mejor clasificados, $P(Q | d)$ es la probabilidad de la consulta Q dado el documento d , y $P(Q | C)$ es la probabilidad de la consulta Q dado el modelo de lenguaje de la colección.

Es así que, WIG es especialmente relevante debido a su capacidad para adaptarse a distintos tipos de consultas y colecciones, incluyendo aquellas con gran diversidad en calidad y estilo de los documentos, resultando crucial para evaluar la efectividad de las consultas, proporcionando una métrica sólida para comparar métodos avan-

zados de predicción del rendimiento y asegurando un análisis confiable en dominios variados.

3.1.6 UEF (Utility Estimation Framework)

El Utility Estimation Framework (UEF) fue desarrollado por Anna Shtok, Oren Kurland y David Carmel como un enfoque post-retrieval que utiliza principios de la teoría estadística de decisiones para predecir el rendimiento de consultas. En el artículo [6] los autores explican que este método evalúa la calidad de un ranking de documentos basándose en su utilidad estimada con respecto a la necesidad de información representada en la consulta, proceso que se realiza al medir la similitud esperada entre el ranking generado y los rankings incluidos por modelos de relevancia.

El marco UEF permite una gran flexibilidad al emplear diferentes métricas de similitud, como el coeficiente de Pearson, y al estimar modelos de relevancia utilizando pseudo-feedback, lo que proporciona una base sólida para predecir el rendimiento de consultas, ya que combina la precisión de los modelos de relevancia con un enfoque estructurado que captura las características del ranking generado por la consulta.

A continuación se observa la fórmula general del UEF:

$$U(\pi_M(q; D)) = \int_{R_q} Sim(\pi_M(R_q; D))p(R_q | I_q)dR_q \quad (3.6)$$

En donde, $\pi_M(q; D)$ corresponde al ranking generado por el modelo M , R_q al modelo de relevancia estimado basado en la consulta q , Sim es la medida de similitud entre ranking y $p(R_q | I_q)$ a la probabilidad de que R_q represente la necesidad de información subyacente I_q .

El UEF es particularmente útil porque permite integrar diversos paradigmas de predicción, lo que mejora la adaptabilidad a diferentes dominios y tareas específicas, además, enfocarse en la utilidad de los documentos mejor clasificados, permite a este método ofrecer una perspectiva precisa sobre cómo las consultas interactúan con el corpus y qué tan efectivas podrían ser en términos de recuperación de información. Es así que, finalmente, para este proyecto el UEF es fundamental para analizar y comparar la efectividad de diferentes métodos de predicción del rendimiento de consultas, en donde su diseño flexible y su capacidad para adaptarse a múltiples escenarios lo posicionan como una herramienta clave en la evaluación de consultas en dominios complejos y heterogéneos.

3.2 Estudios comparativos similares

En cuanto a la investigación de trabajos relacionados, también se identificaron estudios comparativos que evaluaron diferentes métodos QPP en escenarios diversos, los cuales son claves para establecer un marco comparativo que permita validar los resultados finales de este proyecto, además estos trabajos no solo permiten identificar fortalezas y debilidades de cada enfoque, sino que también establecen líneas base estandarizadas para validar nuevos métodos y enfoques más experimentales.

A continuación, se presentan los estudios relevantes que evaluaron métodos QPP como IDF, SCQ, Clarity Score, entre otros, destacando sus aportes al estado del arte del área y su influencia en el diseño de este proyecto.

3.2.1 QPPTK en TIREx

Un reciente estudio relevante para el presente proyecto es el desarrollado por Zendel, Fröbe y Faggioli en 2024, que proporciona una referencia fundamental al implementar y evaluar un marco de predicción del rendimiento de consultas (QPP) utilizando el Query Performance Prediction Toolkit (QPPTK) dentro de la plataforma TIREx. En este trabajo [7], los autores analizaron el desempeño de 12 métodos de predicción en combinación con diversos modelos de recuperación de información y 23 conjuntos de datos, incluyendo benchmarks reconocidos como TREC Robust04 y MS MARCO, por lo que, la amplitud de la evaluación y su enfoque en la reproducibilidad de los experimentos lo convierten en un recurso valioso para este proyecto.

Como se menciona, el estudio incluye una evaluación exhaustiva de métodos pre-retrieval, como IDF y SCQ, y post-retrieval, como NQC y Clarity Score, además, se demuestra cómo la evaluación cruzada en múltiples benchmarks permite identificar patrones de rendimiento y validar la generalización de los métodos seleccionados, enfoque que se destaca por la importancia de utilizar plataformas estandarizadas, como TIREx, que no solo permiten configurar entornos experimentales reproducibles, sino que también minimizan los sesgos potenciales en los resultados al estandarizar la configuración y los parámetros de los experimentos.

Una de las contribuciones clave del trabajo es la integración de QPPTK en TIREx, lo que facilita la realización de experimentos reproducibles, lo que se logra mediante la utilización de índices preconstruidos y configuraciones consistentes que garantizan

estabilidad en las pruebas. Así mismo, los resultados generados son compartidos abiertamente, promoviendo su reutilización en futuros estudios, enfoque que resulta relevante para este proyecto, donde la reproducibilidad y la estandarización son fundamentales para garantizar la validez de las comparaciones entre métodos.

Es así que, los hallazgos de los autores, proporcionan métricas clave, como correlaciones entre predictores y métricas clásicas de recuperación, esenciales para validar los métodos implementados en este proyecto, además, su metodología y diseño experimental sirven como referencia directa para configurar los experimentos, asegurando que las evaluaciones sigan estándares establecidos en la literatura.

En resumen, este estudio no solo se destaca por la profundidad de su análisis, sino también por su contribución al establecimiento de prácticas experimentales reproducibles, que es en donde radica su relevancia para el proyecto presentado, ya que propone un diseño experimental y proporciona un marco sólido para evaluar métodos de predicción del rendimiento de consultas en entornos complejos.

3.2.2 An Enhanced Evaluation Framework for Query Performance Prediction (2021)

Otro estudio destacado y relevante para el presente proyecto es el realizado por Guglielmo Faggioli et al. en 2021, quienes desarrollaron un marco de evaluación mejorado para la predicción del rendimiento de consultas (QPP), el cual aborda limitaciones clave de los enfoques tradicionales mediante la integración de análisis estadísticos avanzados y métricas diseñadas para evaluar, no solo la precisión, sino también la variabilidad y robustez de los métodos QPP en diferentes escenarios.

Es así que, en el artículo [8], los autores proponen un enfoque innovador que incluye métricas basadas en errores, análisis de varianza y pruebas post hoc para evaluar las diferencias entre métodos con mayor detalle.

Como se menciona, el artículo se destaca por su enfoque en la medición de errores distribuidos por consulta, lo que permite un análisis más granular del desempeño de los métodos, en donde se realizaron experimentos en conjuntos de datos estándar como TREC Robust-04, utilizando métodos pre-retrieval, como MaxIDF y SCQ, y post-retrieval, como NQC y Clarity Score, cuyos resultados revelaron que factores como el modelo de recuperación, la configuración y otros factores influyen significativamente en el rendimiento del QPP, proporcionando información valiosa para optimizar estos sistemas.

En el contexto del presente proyecto, el marco propuesto por los autores es importante, ya que introduce prácticas de evaluación reproducibles y detalladas, alineadas con estándares modernos, además de que, sus hallazgos sobre la interacción de factores experimentales y el rendimiento del QPP sirven como guía directa para configurar experimentos que sean estadísticamente sólidos y representativos en escenarios reales.

CAPÍTULO IV: DISEÑO DE LA EVALUACIÓN COMPARATIVA

En este capítulo se presenta el diseño experimental desarrollado para llevar a cabo la evaluación comparativa de métodos de Query Performance Prediction (QPP).

El diseño no solo tiene como propósito validar la implementación técnica de los métodos QPP seleccionados, sino también establecer líneas base que permitan analizar sus fortalezas y limitaciones en contextos variados propios de los sistemas de recuperación de información. Para ello, se consideraron criterios sólidos y alineados con las mejores prácticas del estado del arte, garantizando la representatividad y el rigor del análisis comparativo.

La necesidad de un diseño comparativo sólido radica en la creciente complejidad de los sistemas de recuperación de información y la diversidad de escenarios en los que estos se aplican, y es en este contexto que es importante métodos QPP adecuados para poder optimizar recursos y mejorar la precisión de los resultados, por lo que adoptar criterios cuidadosamente definidos basados en las mejores prácticas del estado del arte es crucial para garantizar que cada componente del diseño cumpla con los estándares de calidad y reproducibilidad.

Además, en el presente proyecto, el diseño de la evaluación comparativa no solo busca responder preguntas específicas sobre el rendimiento de los métodos seleccionados, sino también contribuir al avance del estado del arte en QPP, estableciendo un marco que promueva prácticas experimentales reproducibles, transparentes y aplicables a diversos contextos, garantizando que los hallazgos obtenidos sean relevantes tanto para la comunidad científica como para la práctica en sistemas de recuperación de información.

4.1 Selección de métodos de QPP

La selección de métodos QPP resulta crucial en el diseño de este proyecto, ya que determina la relevancia y la validez del análisis comparativo.

Para garantizar que los enfoques evaluados sean representativos y estén alineados con los objetivos del estudio, se establecieron criterios rigurosos basados en la literatura científica revisada, los cuales priorizan la inclusión de métodos reconocidos en el estado del arte, con fundamentos estadísticos sólidos y un alto grado de reproducibilidad.

A continuación, se describen los criterios aplicados en el proceso de selección, así como los métodos QPP finalmente escogidos para la posterior evaluación comparativa.

4.1.1 Criterios de selección

Como se ha mencionado, la selección de métodos de Query Performance Prediction (QPP) es un proceso fundamental para garantizar que los métodos evaluados sean representativos, robustos y relevantes en el contexto de los sistemas de recuperación de información. Con este propósito, se definieron criterios específicos que permiten abordar el problema desde una perspectiva teórica sólida y práctica aplicable, los que aseguran la validez de la evaluación comparativa y su alineación con los objetivos del proyecto.

Criterio	Descripción	Importancia para el proyecto
Base estadística y simplicidad	Métodos con fundamentos sólidos y fácilmente comprensibles.	Facilita la reproducibilidad y asegura resultados confiables.
Uso en estudios previos	Métodos comúnmente implementados en investigaciones recientes.	Garantiza relevancia científica y comparabilidad con investigaciones previas
Diversidad de enfoques	Cobertura de métodos pre-retrieval y post-retrieval, cada uno enfocado en aspectos distintos del rendimiento.	Permite una evaluación integral que abarca múltiples aspectos del rendimiento de consultas.
Relevancia en el estado del arte	Métodos no basados en inteligencia artificial y ampliamente reconocidos por su efectividad teórica y práctica.	Asegura un marco comparativo que no depende de tecnologías supervisadas y promueve análisis no sesgados.

La tabla resume los criterios definidos para la selección de los métodos de QPP, en donde cada criterio cumple un rol específico para garantizar que los métodos seleccionados no solo sean estadísticamente sólidos, sino también relevantes y diversificados en su enfoque, asegurando que el análisis comparativo resultante sea exhaustivo y útil para evaluar las fortalezas y limitaciones de los métodos elegidos.

- Base estadística y simplicidad: Se seleccionan métodos que se basan en conceptos matemáticos fundamentales, como la frecuencia de términos en el corpus y su relación con la consulta, ya que estos métodos son ampliamente reconocidos por su sencillez y su capacidad para ser implementados y replicados sin necesidad de recursos computacionales avanzados. Este criterio asegura que los métodos elegidos puedan ser utilizados como referencia en investigaciones futuras, promoviendo la reproducibilidad de los experimentos y el entendimiento teórico de los predictores.
- Uso en estudios previos: Se buscan métodos que han sido recurrentemente evaluados en trabajos recientes que analizan sistemas de recuperación de información, ya que no solo garantiza que los resultados del proyecto sean comparables con investigaciones previas, sino que también asegura que los métodos seleccionados representen soluciones probadas y bien documentadas.
- Diversidad de enfoques: Se seleccionan métodos tanto pre-retrieval como post-retrieval para capturar diferentes aspectos del problema, mientras que unos se enfocan en estimar la calidad de una consulta basándose únicamente en estadísticas del corpus, los otros evalúan la calidad considerando los documentos recuperados. Este enfoque integral permite analizar el rendimiento de consultas desde múltiples perspectivas, proporcionando una visión más completa de sus fortalezas y debilidades.
- Relevancia en el estado del arte: Se priorizan métodos no basados en inteligencia artificial, ya que estos garantizan un análisis más transparente y menos sesgado en comparación con tecnologías supervisadas, además, de esta forma, los métodos seleccionados han sido ampliamente reconocidos en la literatura por su aplicabilidad en sistemas de recuperación de información y su capacidad para ser implementados sin depender de datasets de entrenamiento o modelos complejos.

Por otra parte, la decisión de priorizar métodos no basados en inteligencia artificial tiene varias razones claves:

- **Transparencia y simplicidad:** Los métodos no basados en inteligencia artificial, ofrecen interpretaciones claras de cómo se calculan y qué factores influyen en su desempeño, esto contrasta con los métodos supervisados, cuya complejidad en ocasiones dificulta la comprensión de su funcionamiento interno.
- **Reproducibilidad:** Al no depender de datasets de entrenamiento o modelos complejos, los métodos no basados en IA pueden ser implementados en cualquier entorno sin necesidad de recursos adicionales, lo que asegura que los experimentos realizados sean replicables por otros investigadores.
- **Independencia del contexto:** Los métodos seleccionados son independientes de los dominios específicos y los cambios en las colecciones de datos, mientras que los métodos supervisados tienden a ser altamente sensibles a las características del dataset de entrenamiento.
- **Contribución al estado del arte:** Este enfoque se alinea con el objetivo de establecer líneas base sólidas para evaluar nuevos métodos, permitiendo que futuros desarrollos en QPP se comparen con estándares bien establecidos.

4.1.2 Métodos seleccionados

Siguiendo los criterios establecidos en la sección anterior y tras un análisis exhaustivo de la literatura, se seleccionaron seis métodos de Query Performance Prediction (QPP) para la evaluación comparativa, los cuales representan enfoques diversos e incluyen estrategias pre-retrieval y post-retrieval, lo que asegura una cobertura de los aspectos clave del rendimiento de consultas en sistemas de recuperación de información. Además, como se ha mencionado, cada método fue elegido por su relevancia en el estado del arte, su fundamento teórico y su impacto demostrado en investigaciones previas, ofreciendo un marco robusto para analizar su efectividad y aplicabilidad en contextos variados.

Método QPP	Clasificación	Descripción
1. IDF (Inverse Document Frequency)	Pre-retrieval	Mide la rareza de los términos en un corpus mediante la frecuencia inversa de documentos.
2. SCQ (Similarity between a Query and a Collection)	Pre-retrieval	Calcula la similitud entre los términos de la consulta y la

Método QPP	Clasificación	Descripción
		colección basándose en frecuencias y pesos.
3. NQC (Normalized Query Commitment)	Post-retrieval	Evalúa la dispersión de los puntajes de relevancia en los documentos recuperados para predecir la calidad de la consulta.
4. Clarity Score (SC)	Post-retrieval	Mide la divergencia entre el modelo de lenguaje de los documentos recuperados y el modelo de la colección.
5. WIG (Weighted Information Gain)	Post-retrieval	Estima la calidad de la consulta mediante la ganancia de información ponderada basada en los documentos recuperados.
6. UEF (Utility Estimation Framework)	Post-retrieval	Utiliza modelos de relevancia y teoría de decisión estadística para estimar la utilidad de los rankings generados.

En cuanto al análisis de las fortalezas y debilidades de cada método seleccionado:

- IDF (Inverse Document Frequency): Es un método simple, eficiente y ampliamente utilizado, su capacidad para medir la especificidad de los términos lo convierte en una herramienta básica para estimar la calidad de las consultas. Por otra parte, depende exclusivamente de estadísticas del corpus, lo que limita su precisión en escenarios donde la calidad de los documentos recuperados influye de forma significativa.
- SCQ (Similarity between a Query and a Collection): Proporciona una evaluación más detallada al considerar la similitud entre la consulta y la colección en su conjunto, lo que resulta útil en contextos con consultas de longitud variada. Por otro lado, puede ser menos efectivo en colecciones con alta heterogeneidad temática debido a su dependencia de estadísticas globales.

- NQC (Normalized Query Commitment): Evalúa la consistencia de los puntajes de relevancia en los documentos recuperados, lo que lo hace efectivo para identificar consultas problemáticas, pero requiere ejecutar consultas y recuperar documentos, lo que implica un costo computacional más alto en comparación con métodos pre-retrieval.
- Clarity Score (SC): Mide la coherencia del lenguaje de los documentos recuperados, lo que lo hace efectivo en consultas específicas con temas bien definidos, pero es sensible a consultas cortas o ambiguas, donde la divergencia entre el modelo de lenguaje y el corpus puede ser menos clara.
- WIG (Weighted Information Gain): Integra múltiples características de los documentos recuperados, como términos y proximidad, proporcionando una evaluación integral, aunque puede ser afectado por colecciones con sesgos en los documentos más relevantes, disminuyendo su precisión en escenarios específicos.
- UEF (Utility Estimation Framework): Ofrece un marco flexible y adaptable, utilizando modelos de relevancia para capturar tanto la utilidad como la precisión de los rankings generados, pero su complejidad estadística puede dificultar su implementación en sistemas con recursos limitados o en contextos donde se prioriza la simplicidad.

Los métodos seleccionados abarcan una gama de enfoques y fundamentos teóricos, lo que garantiza una evaluación comparativa exhaustiva y representativa, en donde la inclusión de métodos tanto pre-retrieval como post-retrieval asegura que se cubran múltiples facetas del problema, proporcionando una base sólida para analizar su desempeño en diferentes contextos, resultando en un diseño experimental robusto que refuerza la validez del estudio y su contribución al avance del estado del arte en predicción de rendimiento de consultas.

4.2 Selección de conjuntos de datos

La selección de datasetes es parte fundamental para garantizar una evaluación comparativa robusta y representativa de los métodos de Query Performance Prediction (QPP), es por ello, que se seleccionaron datasetes reconocidos en la literatura, priorizando los que ofrecen juicios de relevancia (qrels) y métricas estandarizadas, permitiendo así validar el desempeño de los métodos seleccionados en escenarios variados.

Estos datasets fueron cuidadosamente seleccionados para abarcar una amplia diversidad de tipos de consultas y dominios, asegurando que los resultados obtenidos sean aplicables y relevantes para diferentes contextos de recuperación de información. Este enfoque garantiza no solo la robustez de los resultados, sino también su generalización a futuros trabajos relacionados con QPP.

4.2.1 Criterios de inclusión

A continuación, se presentan los criterios aplicados en la selección de datasets, detallando su importancia en el contexto del proyecto.

Criterio	Descripción	Importancia para el proyecto
Disponibilidad pública	Datasets de acceso abierto y bien documentados, sin restricciones para su uso.	Garantiza la reproducibilidad y facilita la implementación en diversos contextos.
Diversidad de escenarios	Representación de diferentes tipos de consultas (informacionales, navegacionales y transaccionales) y dominios.	Asegura la evaluación integral de los métodos en múltiples contextos.
Uso en el estado del arte	Amplio uso en investigaciones previas de recuperación de información y QPP.	Respalda la validez y comparabilidad de los resultados obtenidos.
Tamaño adecuado	Incluye tanto datasets pequeños como grandes.	Permite evaluar el comportamiento de los métodos en diferentes escalas de datos.
Relevancias conocidas (qrels)	Incluyen juicios de relevancia establecidos previamente.	Facilitan la evaluación precisa y objetiva del desempeño de los métodos QPP.

- Disponibilidad pública: Es fundamental seleccionar datasets de acceso abierto que estén bien documentados, ya que esto garantiza la transparencia y la reproducibilidad de los experimentos, la disponibilidad pública también asegura que los resultados puedan ser validados por otros investigadores, fomentando la colaboración y el avance en el campo del QPP.
- Diversidad de escenarios: Incluir datasets con diferentes tipos de consultas es crucial para evaluar cómo se desempeñan los métodos QPP en escenarios reales, por ejemplo de consultas informacionales: preguntas abiertas donde el usuario busca adquirir conocimiento general; consultas navegacionales: consultas donde el objetivo es encontrar una página específica; y consultas transaccionales: consultas orientadas a completar una acción. Esta diversidad asegura que los métodos sean efectivos en una variedad de tareas de recuperación, desde búsquedas generales hasta necesidades específicas.
- Uso en el estado del arte: Seleccionar datasets ampliamente utilizados en investigaciones previas permite que los resultados del proyecto sean comparables con estudios existentes, lo que refuerza la validez del análisis comparativo y asegura que las metodologías empleadas cumplan con estándares científicos.
- Tamaño adecuado: La inclusión de datasets de diferentes tamaños permite evaluar el comportamiento de los métodos en escenarios con distintos volúmenes de datos, en donde los datasets pequeños son ideales para pruebas controladas y rápidas, mientras que los grandes, son útiles para analizar la escalabilidad y robustez de los métodos. Este enfoque asegura que los métodos QPP seleccionados sean evaluados en condiciones que reflejen tanto la simplicidad como la complejidad de los sistemas de recuperación de información modernos.
- Relevancias conocidas (qrels): Los juicios de relevancia son esenciales para evaluar el desempeño de los métodos de manera objetiva, al incluir datasets con qrels bien establecidos, se garantiza que los resultados estén basados en un marco estandarizado, facilitando su interpretación y comparación

Es así como la aplicación de estos criterios garantiza que los datasets seleccionados sean adecuados para el análisis comparativo de los métodos QPP, de igual forma, al priorizar la diversidad, relevancia y representatividad, este proyecto establece una base sólida para evaluar el desempeño de los métodos en diferentes contextos y escalas, contribuyendo al avance del estado del arte en predicción del rendimiento de consultas.

4.2.2 Justificación de los conjuntos de datos seleccionados

Como se ha mencionado, los datasets seleccionados para el proyecto fueron escogidos cuidadosamente para garantizar que cubran una amplia gama de escenarios y dominios representativos, por lo que se alinean con los criterios de inclusión previamente establecidos, aportando características únicas que permiten evaluar el rendimiento de QPP en contextos diversos, asegurando resultados generalizables y relevantes para investigaciones futuras, además de contribuir al avance del estado del arte.

A continuación, se presenta una tabla con los datasets seleccionados, seguida de un análisis más detallado de su contribución al presente proyecto.

Dataset	Descripción	Contribución al proyecto	Razón de inclusión
Cranfield	Dataset clásico con resúmenes científicos y consultas predefinidas de tamaño reducido.	Facilita pruebas rápidas y controladas para la comparación directa de métodos QPP.	Simplicidad y diseño compacto lo hacen ideal para experimentos iniciales y controlados.
MS MARCO (Passage)	Contiene pasajes derivados de consultas reales con relevancias asignadas por evaluadores humanos.	Proporciona un entorno realista y variado para probar la aplicabilidad práctica de los métodos.	Refleja el contexto de búsqueda cotidiana, crucial para evaluar escenarios reales de recuperación
Antique/Test	Dataset centrado en la recuperación de preguntas y respuestas subjetivas basadas en opiniones.	Evalúa el desempeño de los métodos frente a consultas subjetivas y no factuales.	Introduce complejidad adicional al incorporar preguntas subjetivas difíciles de modelar.
BEIR-TREC-COVID	Parte del benchmark BEIR, cen-	Permite evaluar los métodos QPP	Su enfoque en consultas cientí-

Dataset	Descripción	Contribución al proyecto	Razón de inclusión
	trado en la recuperación de información médica sobre COVID-19.	en un dominio altamente especializado y relevante.	ficas lo hace adecuado para escenarios de alta especificidad.
CAR (Complex Answer Retrieval, Fold 0)	Subconjunto del TREC CAR enfocado en consultas complejas derivadas de la estructura de Wikipedia.	Permite probar los métodos en escenarios con alta complejidad semántica sin sobrecargar el análisis.	Representa consultas avanzadas que requieren modelado detallado, ampliando la diversidad de pruebas.

- Cranfield: Este dataset es ideal para experimentos iniciales debido a su tamaño reducido y estructura sencilla, al contener resúmenes científicos y consultas predeterminadas, facilita una evaluación controlada de los métodos QPP, permitiendo identificar rápidamente patrones de comportamiento y limitaciones. Su simplicidad permite analizar la precisión básica de los métodos y sirve como línea base para experimentos más complejos.
- MS MARCO (Passage): Proporciona un entorno realista donde las consultas derivan de necesidades cotidianas de usuarios reales, sus relevancias asignadas por evaluadores humanos lo convierten en un recurso clave para probar la aplicabilidad práctica de los métodos QPP. Evalúa la capacidad de los métodos para manejar consultas informacionales y transaccionales en contextos cotidianos.
- Antique/Test: Este dataset introduce complejidad al centrarse en preguntas y respuestas subjetivas basadas en opiniones, lo que plantea un desafío adicional para los métodos QPP al modelar consultas no factuales. Analiza cómo los métodos manejan preguntas subjetivas y abiertas, evaluando su capacidad para predecir el rendimiento en dominios con alta variabilidad semántica.
- BEIR-TREC-COVID: Su enfoque en consultas científicas relacionadas con COVID-19 lo hace altamente relevante para escenarios especializados donde la precisión y la especificidad son esenciales. Evalúa el rendimiento de los métodos en un dominio crítico donde la información relevante es escasa y de alta relevancia.

- **CAR (Complex Answer Retrieval):** Al estar enfocado en consultas complejas derivadas de la estructura de Wikipedia, este dataset permite analizar cómo los métodos QPP manejan escenarios con alta complejidad semántica. Mide la capacidad de los métodos para predecir el rendimiento en consultas que requieren una interpretación profunda y modelado avanzado.

Además, todos los datasets utilizados son de acceso abierto en repositorios públicos y están bien documentados debido a que son ampliamente reconocidos en la comunidad de recuperación de información, lo que asegura que cualquier investigador pueda acceder a ellos sin restricciones para replicar los experimentos. Es así que, la utilización de datasets de acceso abierto garantiza que los resultados del proyecto sean reproducibles y accesibles para futuras investigaciones, fomentando el entorno colaborativo y transparente, evitando problemas legales o éticos relacionados con el uso de datos restringidos o privados.

De esta forma, la selección de datasets con características bien definidas asegura una evaluación diversa y representativa de los métodos QPP seleccionados, ya que este enfoque cubre dominios especializados, tareas cotidianas y casos complejos, estableciendo una base sólida para validar la efectividad y aplicabilidad de los métodos en diferentes contextos de recuperación de información.

4.3 Entorno experimental

En esta sección se describe la configuración del entorno experimental desarrollado para llevar a cabo la evaluación comparativa de los métodos de Query Performance Prediction (QPP), incluyendo el flujo de los experimentos, las configuraciones técnicas específicas, y las métricas empleadas para la evaluación.

El entorno experimental está diseñado para garantizar la reproducibilidad, flexibilidad y transparencia. Para lograrlo, se ha implementado un entorno basado en Docker, que permite ejecutar los experimentos de manera consistente y controlada, sin depender de configuraciones específicas de hardware o software.

4.3.1 Flujo del sistema

El diseño experimental sigue un flujo bien definido para garantizar la reproducibilidad y el análisis riguroso de los resultados. El flujo incluye los siguientes pasos principales:

- **Preparación de Datasets:** Los datasets seleccionados, como Cranfield o MS MARCO, se descargan utilizando la librería `ir_datasets` y se preprocesan en el

entorno Docker, este proceso incluye la extracción de consultas, preparación de los juicios de relevancia (qrels) y el formateo adecuado para su uso con PyTerrier.

- **Indexado de Datasets:** Los datasets se indexan utilizando PyTerrier, creando estructuras de datos eficientes para la recuperación de información. Es también en este paso donde se guardan metadatos de los datasets, como la frecuencia de los términos en los documentos como la frecuencia de estos en la colección.
- **Configuración de Modelos de Recuperación:** Configuración de modelos de recuperación como estándar como BM25 en PyTerrier con parámetros predefinidos, asegurando una base consistente para la evaluación de los métodos QPP.
- **Implementación de los métodos QPP:** Los métodos seleccionados, como, por ejemplo, IDF, SCQ o NQC, se implementan mediante scripts en Python dentro del contenedor Docker, todos estos utilizan una interfaz similar dentro del sistema, permitiendo una ejecución estandarizada de los métodos.
- **Ejecución de los métodos de predicción:** Los experimentos se realizan mediante un script principal que realiza múltiples iteraciones por método y dataset, asegurando estabilidad y fiabilidad de los resultados.
- **Evaluación utilizando juicios de relevancia (qrels):** Se realiza una evaluación del rendimiento de las consultas utilizando la librería de `ir_measures`, esto es el «ground truth» o «verdadero valor» del rendimiento de la consulta en el sistema de recuperación implementado. Posteriormente los resultados se almacenan en formato estructurado para su posterior análisis.
- **Documentación y Almacenamiento:** Los resultados, configuraciones y scripts de ejecución se almacenan en directorios organizados dentro del contenedor Docker, garantizando su fácil acceso y análisis.

4.3.2 Configuración técnica

- **Entorno Docker:** Al permitir encapsular todas las dependencias necesarias en un entorno reproducible, se evitan problemas de compatibilidad y configuración entre máquinas, asegurando que los experimentos puedan ser ejecutados de manera uniforme y reproducible.

El sistema utiliza una imagen base de Python 3.9 con Java 11 instalado para soportar PyTerrier.

- **Párametros del Modelo de Recuperación:**

El sistema utiliza el modelo de recuperación BM25 (Best Match 25) como método principal de recuperación. Los parámetros han sido cuidadosamente seleccionados basándose en la literatura y experimentación previa:

Tabla 4.1: Parámetros principales de BM25

Parámetro	Descripción	Justificación de Aplicación	Valor
k1	Factor de saturación de término. Controla cómo el score de un documento aumenta con cada ocurrencia adicional de un término de la consulta. Un valor más alto significa que se da más importancia a la frecuencia del término.	Crucial para colecciones con documentos que contienen repeticiones significativas de términos. Afecta directamente el cálculo de scores en métodos QPP post-recuperación como WIG.	1.2
b	Factor de normalización de longitud del documento. Determina cuánto se penalizan los documentos más largos. Un valor más alto significa una normalización más agresiva de la longitud.	Especialmente importante en colecciones heterogéneas como ANTIQUE donde la longitud de los documentos varía significativamente. Impacta el cálculo de NQC al normalizar los scores.	0.75

• **Ejecución de los metodos y scripts de evaluación:**

El sistema permite una configuración flexible de la ejecución de la evaluación a través de diversos parámetros que controlan tanto el proceso de recuperación como la evaluación QPP. La configuración se realiza principalmente mediante argumentos de línea de comandos y variables de entorno.

Tabla 4.2: Parámetros principales de configuración

Parámetro	Descripción	Valor por defecto
–datasets	Datasets a evaluar (e.g., antique_test, iquique_small)	Todos los datasets
–max-queries	Límite de consultas a procesar	None (todas)
–list-size	Tamaño de lista para métricas de ranking	10
–num-results	Número máximo de resultados por consulta	1000
–metrics	Métricas de evaluación (e.g., ndcg@10, ap)	nDCG@10, AP
–correlations	Coeficientes de correlación a calcular	τ
–use-uef	Habilita el método UEF (Utility Estimation Framework)	False
–skip-plots	Omite la generación de visualizaciones	False

La ejecución se puede realizar tanto directamente a través de Python como mediante contenedores Docker, donde los parámetros se configuran a través de variables de entorno. El sistema utiliza valores por defecto seleccionados para garantizar una evaluación robusta incluso con configuración mínima.

• **Almacenamiento de Resultados:**

Los resultados de la evaluación se almacenan en una estructura organizada dentro del directorio del proyecto. Las métricas de IR (nDCG, AP) se guardan por consulta en archivos de texto plano, mientras que las correlaciones entre predictores QPP y métricas se almacenan en formato tabular, acompañadas de visualizaciones (box-plots y diagramas de dispersión) generadas automáticamente.

La evaluación final integra estos resultados mediante un análisis bidimensional: (1), midiendo la efectividad del sistema de recuperación base, medida a través de las métricas IR por consulta, y (2), midiendo la capacidad predictiva de los métodos QPP, cuantificada mediante coeficientes de correlación por rangos entre los puntajes de los predictores y las métricas IR. Una mayor correlación significa que los puntajes de los predictores son confiables para predecir el rendimiento del sistema de recuperación.

• **Métricas Utilizadas:**

Las métricas de evaluación IR se deben configurar específicamente para cada dataset, considerando sus características particulares en los juicios de relevancia (qrels).

Tabla 4.3: Configuración de métricas por dataset

Dataset	Configuración	Justificación
ANTIQUE	• Relevancia: 4 niveles (1-4) • Binary threshold: ≥ 3 • Gain values: {1:0, 2:0, 3:0.5, 4:1.0}	Escala más granular que permite distinguir entre documentos marginalmente relevantes (3) y altamente relevantes (4). Los niveles 1-2 se consideran no relevantes para métricas binarias.
Iquique Dataset	• Relevancia: 3 niveles (0-2) • Binary threshold: ≥ 1 • Gain values: {0:0, 1:1, 2:2}	Escala más simple que diferencia entre no relevante (0), relevante (1) y altamente relevante (2). Utiliza una escala lineal para el cálculo de nDCG.

Para el análisis de correlación, el sistema implementa tres coeficientes (τ -Kendall, ρ -Spearman, r-Pearson), pero prioriza τ -Kendall por:

- **Interpretabilidad:** Mide directamente la proporción de pares concordantes vs discordantes
- **Robustez:** Menos sensible a valores atípicos y transformaciones monótonas
- **Normalización:** Rango consistente $[-1,1]$ independiente de la distribución
- **Significancia:** Mejor comportamiento con muestras pequeñas

La implementación utiliza `ir_measures` para garantizar cálculos estandarizados de las métricas IR, mientras que `scipy.stats` proporciona implementaciones eficientes de los coeficientes de correlación. El sistema maneja automáticamente casos especiales como queries sin resultados o scores QPP indefinidos, asegurando una evaluación robusta incluso en condiciones no ideales.

4.4 Relación entre diseño experimental y objetivos

CAPÍTULO V: IMPLEMENTACIÓN

Para iniciar la implementación del entorno de evaluación se precisa de una serie de componentes para realizar tanto el procesado de consultas como el manejo de documentos que respondan y tengan relevancia ante estas. Tradicionalmente esto se ha realizado mediante el uso de sistemas de recuperación de información (IR) que permiten la recuperación de documentos relevantes para una consulta de manera eficiente.

Sin embargo, y debido a la antigüedad del campo, existe una amplia gama de métodos que varían en su grado de complejidad y en su rendimiento, por ende, se optó implementar un sistema de recuperación de información basado en el algoritmo BM25, que es un algoritmo de recuperación de información que se basa en la teoría de la probabilidad, el cual cuenta con un amplio historial, no solo en el campo de la recuperación de información, sino que también en la evaluación de métodos de rendimiento de consultas (QPP).

Adicionalmente, y de manera separada se encuentra la necesidad de implementar un sistema de indexación de documentos, que permita la recuperación de documentos relevantes para una consulta de manera eficiente. Estos dos últimos requisitos, justifican la utilización de la librería Pyterrier, la cual permite la implementación de sistemas de recuperación de información y de indexación de documentos, en un solo entorno unificado e integrado.




Figura 5.1: Diagrama de componentes del entorno de evaluación

En la Figura 5.1 se puede observar el diagrama de componentes general del entorno de evaluación propuesto, en el cual se puede apreciar la interacción entre los distintos componentes de recuperación de información clásicos como el BM25, indexación de documentos, procesamiento de consultas y evaluación de métodos de QPP. Es relevante resaltar que el acceso a los conjuntos de datos también es realizado mediante la librería pyTerrier, la cual cuenta con una integración con otra librería, IR-datasets, la cual permite el acceso a una amplia gama de conjuntos de datos clásicos de recuperación de información junto a sus consultas y respectivos juicios de relevancia.

En si, el protocolo estándar de evaluación de métodos de QPP, como se puede apreciar en la Figura 5.1, cuenta de una relativa complejidad, con muchas partes sujetas a modificaciones y ajustes que pueden repercutir en los resultados finales de la evaluación.

5.1 Configuración del entorno experimental

El entorno experimental se encuentra configurado para ser ejecutado en un variedad de entornos debido a la utilización de Docker, el cual permite la ejecución de entornos virtuales en diferentes sistemas operativos. De manera general y para preservar la reproducibilidad de los resultados, se ha configurado el entorno experimental para

ser ejecutado en un sistema operativo Linux, utilizando Python 3.9.21 y PyTerrier 0.13.0.

Tabla 5.4: Configuración del entorno experimental

Componente	Descripción	Versión
Docker	Contenedor de entornos virtuales	25.0.5
Python	Lenguaje de programación	3.9.21
PyTerrier	Librería de recuperación de información	0.13.0
IR-datasets	Librería de conjuntos de datos	0.5.9

Como se puede apreciar en la Tabla 5.4, se ha optado por implementar el entorno experimental en componentes de software con versiones específicas y estables, esperando lograr la mayor reproducibilidad posible de los resultados. La ejecución también es posible en sistemas operativos Windows y MacOS, pero estas cuentan con procesos de instalación y configuración más complejos.

5.1.1 Docker y dependencias

Docker es la principal herramienta que permite la ejecución del entorno experimental, esta cuenta con una amplia gama de herramientas que permiten la ejecución de entornos virtuales en diferentes sistemas operativos. Para los propósitos de este trabajo, se ha optado por imágenes de docker basados en la versión Slim Buster de Debian, la cual destaca en su ligereza y velocidad de ejecución.

Dockerfile

```
1 # Imagen Debian optimizada para Python
2 FROM python:3.9-slim-buster
3
4 # Configuraciones de entorno
5 ENV LANG=C.UTF-8
6 ENV LC_ALL=C.UTF-8
7 ENV JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
8 ENV PATH="$JAVA_HOME/bin:$PATH"
9
10 # Instalación de Java y otras dependencias
11 RUN apt-get update && \
12     apt-get install -y openjdk-11-jdk && \
13     apt-get install -y --no-install-recommends \
14     build-essential \
15     && apt-get clean && \
16     rm -rf /var/lib/apt/lists/*
17 ...
```

Figura 5.2: Dockerfile para la configuración del entorno experimental

La Figura 5.2 muestra el archivo Docker utilizado para la configuración del entorno experimental, este Dockerfile se encuentra disponible en el repositorio de GitHub del proyecto. En este se especifican las principales dependencias y configuraciones de entorno necesarias para la ejecución del entorno experimental.

Tabla 5.5: Componentes principales del Dockerfile

Componente	Descripción
Imagen base	Python 3.9 slim-buster - Versión ligera de Debian optimizada para Python
Configuración UTF-8	Establece codificación UTF-8 para el manejo correcto de caracteres especiales y términos en diferentes idiomas presentes en los datasets
JDK 11	Java Development Kit necesario para PyTerrier, ya que este utiliza componentes Java para el procesamiento e indexación de documentos
Build essentials	Herramientas básicas de compilación necesarias para algunas dependencias de Python

La Tabla 5.5 muestra los componentes esenciales para la configuración y ejecución del entorno experimental. Diversos errores fueron enfrentados debido a la codificación de caracteres durante las primeras pruebas del entorno, especialmente al procesar términos con caracteres especiales o diacríticos presentes en los datasets. La configuración explícita de UTF-8 en el contenedor Docker resultó fundamental

para asegurar el correcto procesamiento de los documentos y consultas, evitando problemas de codificación que podrían afectar la calidad de la indexación y, por ende, los resultados de la evaluación.

5.1.2 Integración de conjuntos de datos

Como se explico anteriormente, los conjuntos de datos utilizados en este trabajo se encuentran disponibles en la libreria IR-datasets, la cual cuenta con una amplia gama de conjuntos de datos tanto clasicos como modernos de recuperación de información junto a sus consultas y respectivos juicios de relevancia.

Cada dataset cuenta con una cantidad de documentos y consultas disponibles para realizar la evaluación, por otro lado los juicios de relevancia o Qrels suponen un desafío extra para la implementación de la evaluación, puesto que cada dataset cuenta con distintos niveles de relevancia para las consultas, lo cual si no se maneja adecuadamente puede alterar drasticamente los resultados de la correlación.

Esto es asi puesto a que la evaluación clasica de metodos IR se basa en el calculo de metricas como nDCG, AP, MAP, etc, las cuales dependen de los juicios de relevancia actuando como *ground truth* para su calculo.

1

DATASET_FORMATS = {

Python

2

"antique_test": {

3

"relevance_levels": {

4

1: "Out of context/nonsensical",

5

2: "Not relevant but on topic",

6

3: "Marginally relevant",

7

4: "Highly relevant"

8

},

9

"binary_threshold": 3, # Puntajes >= 3 son

considerados relevantes para las metricas binarias

10

"gain_values": { # Valores de ganancia para nDCG

11

1: 0.0,

12

2: 0.0,

13

3: 0.5,

14

4: 1.0

15

}

16

}

Figura 5.3: Configuración de formato de dataset

La Figura 5.3 muestra la configuración específica para el dataset antique_test, donde se definen cuatro niveles de relevancia (1-4) con sus respectivas descripciones semánticas. Esta configuración es importante por dos razones principales: primero, establece un umbral binario en 3 para las métricas que requieren juicios binarios

(como Precision y Recall), considerando como relevantes solo los documentos con puntuaciones de 3 o 4. Segundo, define valores de ganancia específicos para el cálculo de nDCG, donde se asigna diferentes valores de ganancia en cada nivel.

Esta diferenciación en el manejo de los niveles de relevancia es fundamental para obtener evaluaciones precisas, ya que un manejo inadecuado de estos valores podría llevar a distorsiones significativas en el cálculo de las métricas de evaluación y, consecuentemente, afectar la correlación con los predictores QPP. Por ejemplo, si no se estableciera el umbral binario adecuadamente o se asignaran valores de ganancia incorrectos, documentos marginalmente relevantes podrían tener el mismo peso que documentos altamente relevantes en el cálculo de las métricas, lo que no reflejaría fielmente la calidad real de los resultados de búsqueda.

5.1.3 Indexación y consultas

El proceso de indexación utilizado para la evaluación es el estandar de PyTerrier mediante la construcción de un índice invertido a partir de un corpus de documentos. Este índice invertido es utilizado para la recuperación de documentos relevantes para una consulta, utilizando el algoritmo BM25. Durante el tiempo de indexado, se realiza la tokenización de los documentos y consultas, aplicando un algoritmo de stemming y eliminación de stopwords para la normalización de los datos.

5.2 Implementación de métodos QPP

La implementación de los métodos QPP difiere en las dos categorías en la que se dividen los metodos, pre-retrieval y post-retrieval, el primer caso solo cuenta con una dependencia para su implementación, la cual es el índice invertido generado a partir de un corpus de documentos. Mientras que en el segundo caso, cuenta con dos, el índice invertido generado a partir de un corpus de documentos y los resultados de un sistema de recuperación de información en respuesta a una consulta.

```

1  # Creación del factory de métodos QPP
2  qpp_factory = QPPMethodFactory(
3      index_builder=index_builder,
4      retrieval_results=retrieval_results,
5      rm_results=rm_results_df,
6      dataset_name=dataset_path
7  )
8
9  # Computo de los puntajes de los métodos QPP
10 qpp_scores = qpp_factory.compute_all_scores(
11     queries=queries,
12     list_size_param=args.list_size
13 )

```

Figura 5.4: Código de implementación del factory de métodos QPP




Figura 5.5: Diagrama de la capa de métodos QPP

Para cumplir con los requisitos de los métodos QPP, se ha implementado un factory, el cual se encarga de la creación y computo de los puntajes de los métodos QPP. Este factory se encarga de tomar las dependencias necesarias y entregarlas a los métodos QPP, para que estos puedan ser computados.

Para la implementación de los métodos QPP, se ha utilizado un enfoque mixto, tanto utilizando código abierto como propio, para la satisfacer las necesidades de la evaluación a realizar. Todo el código utilizado se encuentra disponible en el repositorio de GitHub de este trabajo, el cual se puede encontrar en el repositorio¹ de el usuario Zendelo en GitHub.

¹<https://github.com/Zendelo/QPP-EnhancedEval/tree/qpptk-dev>

5.2.1 Métodos pre-retrieval

En esta categoría se implementaron dos de los métodos más utilizados en las evaluaciones de la lituratura, por un lado se encuentra el método IDF, el cual se basa en la frecuencia de los términos en los documentos, y por otro lado se encuentra el método SCQ, el cual se basa en la similitud de la consulta a los documentos de la colección.

Ambos metodos cuentan con variaciones, ya sea el valor promedio de los términos de la consulta, o alternativamente el valor maximo de los términos de la consulta. Estas variaciones son utilizadas en diferentes evaluaciones y se ha optado por implementar ambas en el entorno experimental.

5.2.2 Métodos post-retrieval

En esta categoría se considuro una mayor gama de predictores, desde metodos seminales del campo como Clarity, hasta frameworks mas recientes como UEF. Estos metodos requieren de una dependencia extra, la cual es el resultado de un sistema de recuperación de información en respuesta a una consulta.

```
1 def calc_wig(self, list_size_param):
2     """
3     Calculates the WIG score following Zhou and Croft's method.
4     Y. Zhou and W. B. Croft. Query performance prediction in
5     web search environments
6     """
7     scores_vec = self.scores_vec[:list_size_param]
8     if self.corpus_score == 0:
9         print("Corpus score is zero; returning WIG score as 0.0
10             to avoid division by zero.")
11         return 0.0
12     wig_score = (scores_vec.mean() - self.ql_corpus_score) /
13     np.sqrt(len(self.query_terms))
14     return wig_score
```

Figura 5.6: Implementación del método WIG

La Figura 5.6 muestra la implementación del método post-retrieval WIG, en este podemos identificar tanto el uso del indice invertido como el resultado de el puntaje del modelo de recuperación de información frente a toda la colección como se puede apreciar en la Ecuación (3.5). Adicionalmente se puede observar parametros como el tamaño de la lista de documentos a considerar, el cual fue definido como 10 para WIG y en 100 para NQC bajo la recomendación de la literatura. [4, 5, 9]

Para finalizar, también cabe mencionar que todos los puntajes fueron considerando el puntaje promedio de los 1000 primeros documentos de la lista de resultados.

5.3 Implementación de la evaluación

La implementación de la evaluación de los métodos QPP se realiza mediante un analizador de correlaciones que permite calcular y visualizar las relaciones entre los puntajes de predicción y las métricas de rendimiento real del sistema. Este analizador está diseñado para procesar los resultados de múltiples métodos QPP y métricas de recuperación, generando análisis estadísticos y visualizaciones que facilitan la interpretación de los resultados.

5.3.1 Cálculo de correlaciones

El análisis se basa principalmente en el cálculo de coeficientes de correlación entre los puntajes QPP y las métricas de recuperación (nDCG y AP). Se implementaron tres tipos de correlaciones:

- Correlación de Pearson: Mide la relación lineal entre las variables
- Correlación de Spearman: Evalúa la relación monótona entre variables usando rangos
- Correlación de Kendall (τ): Mide la ordinalidad entre pares de observaciones

La significancia estadística de las correlaciones se verifica mediante pruebas de hipótesis, considerando un nivel de significancia de $\alpha = 0.05$. Las correlaciones no significativas son registradas pero marcadas apropiadamente en los reportes.

5.3.2 Visualización de resultados

Para facilitar la interpretación de los resultados, se implementaron tres tipos principales de visualizaciones como se puede observar en la Tabla 5.6, siguiendo la línea de otras evaluaciones. [7, 8, 10]

Tabla 5.6: Tipos de visualizaciones implementadas

Tipo de gráfico	Descripción
Mapas de calor	Muestran la matriz de correlaciones entre todos los métodos QPP y las métricas de evaluación, utilizando una escala de colores para representar la fuerza y dirección de las correlaciones
Diagramas de dispersión	Visualizan la relación entre cada método QPP y una métrica específica, incluyendo líneas de regresión para mejor interpretación
Diagramas de caja	Presentan la distribución de las correlaciones para cada método QPP, permitiendo comparar su estabilidad y rendimiento general

5.4 Pruebas de validación

CAPÍTULO VI: ANÁLISIS DE RESULTADOS

A traves de la literatura se ha establecido de manera casi unanime el análisis del rendimiento de los métodos QPP mediante el uso de métricas de correlación. Seminalmente se puede encontrar el trabajo de Voorhees en la conferencia TREC-6, donde se presenta el primer análisis de la capacidad de expertos en predecir el rendimiento de las consultas, donde se pudo observar que la mayor correlación lineal entre los resultados de los expertos fue de solo 0.26. [11].

El campo de la predicción del rendimiento de consultas se ha desarrollado a lo largo de los años, y se ha establecido el uso de juicios de relevancia y métricas como el tau de Kendall para la evaluación de los predictores. En este sentido, se encuentran dos puntos de interes, por un lado la evaluación del sistema de recuperación subyacente, y por otro la evaluación de los predictores utilizando como pre-requisito la evaluación del sistema de recuperación.

La configuración utilizada para el experimento se presenta en el diagrama Figura 6.7




Figura 6.7: Diagrama de flujo del análisis de resultados

Donde se puede observar que el proceso de evaluación involucra métricas de evaluación de recuperación clásicas como nDCG y AP, y métricas de correlación de predictores como el tau de Kendall, el cual debido a su naturaleza no lineal, se presenta como una métrica más fuerte frente a otras métricas como el coeficiente de Pearson.

6.1 Resultados obtenidos en conjuntos de datos

Como se menciona anteriormente, previo a la evaluación de los métodos QPP, es

necesario evaluar el sistema de recuperación subyacente, en este caso BM25 utilizando el conjunto de datos *antique test* y sus 4 niveles de juicios de relevancia en sus 200 consultas proporcionadas.




Figura 6.8: Boxplot de las métricas nDCG y AP

En un primer vistazo a los resultados del experimento tenemos que la Figura 6.8 muestra que el sistema de recuperación BM-25 presenta un rendimiento mayor en la métrica nDCG@10 frente a las métrica AP. Ambos experimentos presentan un rango de resultados similar, desde el 0 y sin sobrepasar el 0.8 en ninguno de los casos.

Es posible observar la existencia de *outliers* en los resultados de la métrica AP, los cuales sobresalen muy por encima en comparación del ultimo cuartil de los resultados. Esto se puede interpretar a que ciertas consultas consiguen resultados muy altos en comparación a las demás, debido a ser frecuentemente representadas en los juicios de relevancia y en la colección de documentos.

La media de las métricas nDCG y AP se puede observar en la Figura 6.9, donde se puede observar que el sistema de recuperación BM-25 presenta un rendimiento mucho mayor en la métrica nDCG@10 frente a los resultados de AP. Específicamente tenemos una media de 0.36 para nDCG@10 y 0.18 para AP, lo que evidencia la capacidad del sistema para rankear documentos en las 10 primeras posiciones sobre la precisión de la completitud de los documentos recuperados.




Figura 6.9: Media de las métricas nDCG y AP

La Figura 6.10 sirve para complementar la información anterior dando una perspectiva más detallada de los resultados obtenidos. Se puede observar que para nDCG@10 tenemos una distribución ligeramente bimodal, una en 0.2-0.3 y otra en 0.5-0.7, esto se puede interpretar como dos grupos intrínsecamente distintos de consultas, el primero de ellos muestra un rendimiento de nuestro sistema de recuperación más bajo, mientras que el segundo es satisfactoriamente rankeado. Estos hallazgos pueden llevar evaluar que características de las consultas en estos grupos las hacen más fácil o difícil de rankear.




Figura 6.10: Histogramas de las métricas nDCG y AP

La Figura 6.11 muestra el grafico de dispersión de los valores de nDCG@10 y AP, donde principalmente se puede apreciar la fuerte correlación ($r=0.84$) que existe entre ambas métricas, lo cual sugiere una calidad de recuperación similar entre ambos experimentos. Sin embargo algo interesante a tener en cuenta es el patron «palo de hockey» que se forma entre las dos métricas. Esto sugiere que:

- En el rango inferior($nDCG@10 < 0.4$) tenemos rendimientos mas dispersos, donde una valor de nDCG@10 alto no necesariamente implica un valor de AP alto.
- En el rango superior($nDCG@10 > 0.6$) la relación se vuelve mas predecible. Cuando nuestro sistema de recuperación presenta un rendimiento alto en nDCG@10, el rendimiento en AP tiende a ser alto igualmente.

Finalmente el rango intermedio tenemos la ocurrencia de algunos *outliers*, como se menciono anteriormente, nDCG@10 presenta resultados mayores a AP, y en algunos casos estos pueden llegar a contar una diferencia significativa (0.6 vs 0.1).




Figura 6.11: Grafico de dispersión de nDCG@10 vs AP

6.2 Comparación de métodos QPP

Los metodos QPP evaluados en está sección fueron contrastados directamente con los resultados de la evaluación de la sección anterior realizada en el dataset *antique test* utilizando el coeficiente de correlación tau de Kendall.

La Figura 6.12 muestra el resultado general de la correlación de los métodos QPP a traves de las dos metricas nDCG@10 y AP. Empezando por el lado izquierdo del mapa de correlación tenemos los dos métodos pre-retrieval IDF y SCQ en sus variantes promedio y máximo, a posteriori, el resto de los métodos son de tipo post-retrieval, terminando por las variantes UEF de estos.

Se observa que la menor de las correlaciones la presenta el método IDF, el cual presenta una correlación no mayor de 0.05 en todas sus variantes. Este resultado viene fuertemente ligado al preprocesado tanto de los documentos como de las consultas, puesto que anteriormente el pipeline de procesado utilizaba el *stemmer* incorporado por pyterrier, el cual es el clasico *Porter Stemmer*. Los resultados de este fueron puestos bajo la lupa para corroborar su buen funcionamiento dando los siguientes resultados:

Tabla 6.7: Muestra de terminos Porter vs Snowball Stemmers

Porter(pyterrier)	Frecuencia	Snowball(nltk)	Frecuencia
0	753	small	5891
00	45	group	3578
000	50	politician	625
0001	16	Believ	12362

Los resultados encontrados en la Tabla 6.7 muestran que el stemmer de Snowball presenta un rendimiento mayor en la frecuencia de los terminos, esto se puede atribuir a que el stemmer de Snowball es más agresivo en la eliminación de sufijos y prefijos, lo cual puede llevar a una mayor cantidad de terminos que son relevantes para la recuperación de información. Sin embargo la pobre calidad en el procesado entregado por el stemmer de porter justifico su reemplazo por el de Snowball. Sin embargo, este cambio tuvo como consecuencia un impacto directo a la correlación del metodo IDF en ndcg@10, con una disminución de 0.146 a 0.05. La causa principal de este efecto no ha sido investigada profundamente, pero puede deberse a que el *Stemmer* original procesaba una mayor gamma de tokens comunes en el dataset pero que no se correspondian con ninguna palabra, sino con números o caracteres especiales, que podrian ser abundantes en el corpus. Un estudio mas profundo sobre la calidad de los conjuntos de datos podria ayudar a entender este efecto.




Figura 6.12: Correlación de los métodos QPP - tau de Kendall




Figura 6.13: Boxplot de las correlaciones de los métodos QPP - tau de Kendall




Figura 6.14: Grafico de dispersión de nDCG@10 vs IDF-avg




Figura 6.15: Grafico de dispersión de nDCG@10 vs IDF-max - tau de Kendall




Figura 6.16: Grafico de dispersión de nDCG@10 vs NQC




Figura 6.17: Grafico de dispersión de nDCG@10 vs UEF-NQC - tau de Kendall

6.3 Discusión de los resultados

CAPÍTULO VII: CONCLUSIONES Y TRABAJO FUTURO

7.1 Principales conclusiones

Resumen de los hallazgos más importantes...

7.2 Recomendaciones para investigaciones futuras

Descripción de las contribuciones realizadas...

7.3 Trabajo Futuro

Identificación de líneas de investigación futuras...

REFERENCIAS BIBLIOGRÁFICAS

- [1] ZHAO, Ying, Falk SCHOLER y Yohannes TSEGAY. Effective Pre-retrieval Query Performance Prediction Using Similarity and Variability Evidence. En: Craig MACDONALD, Iadh OUNIS, Vassilis PLACHOURAS, Ian RUTHVEN y Ryen W. WHITE, eds. *Advances in Information Retrieval*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008, p. 52-64. ISBN 978-3-540-78646-7.
- [2] ROBERTSON, Stephen. Understanding inverse document frequency: on theoretical arguments for IDF. *Journal of Documentation* [en línea]. 2004, **60**(5), 503-520. ISSN 0022-0418. Disponible en: doi:10.1108/00220410410560582
- [3] CRONEN-TOWNSEND, Steve, Yun ZHOU y W. Bruce CROFT. Predicting query performance. En: *Proceedings of the 25th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Tampere, Finland: Association for Computing Machinery, 2002, p. 299-306. SIGIR '02. ISBN 1581135610. Disponible en: doi:10.1145/564376.564429
- [4] SHTOK, Anna, Oren KURLAND, David CARMEL, Fiana RAIBER y Gad MARKOVITS. Predicting Query Performance by Query-Drift Estimation. *ACM Trans. Inf. Syst.* [en línea]. 2012, **30**(2). ISSN 1046-8188. Disponible en: doi:10.1145/2180868.2180873
- [5] ZHOU, Yun y W. Bruce CROFT. Query performance prediction in web search environments. En: *Proceedings of the 30th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Amsterdam, The Netherlands: Association for Computing Machinery, 2007, p. 543-550. SIGIR '07. ISBN 9781595935977. Disponible en: doi:10.1145/1277741.1277835
- [6] SHTOK, Anna, Oren KURLAND y David CARMEL. Using statistical decision theory and relevance models for query-performance prediction. En: *Proceedings of the 33rd International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Geneva, Switzerland: Association for Computing Machinery, 2010, p. 259-266. SIGIR '10. ISBN 9781450301534. Disponible en: doi:10.1145/1835449.1835494
- [7] ZENDEL, Oleg, Maik FRÖBE y Guglielmo FAGGIOLI. QPPTK@ TIREx: Simplified Query Performance Prediction for Ad-Hoc Retrieval Experiments. *WOWS 2024*. 2024, 50.
- [8] FAGGIOLI, Guglielmo, Oleg ZENDEL, J. Shane CULPEPPER, Nicola FERRO y Falk SCHOLER. An Enhanced Evaluation Framework for Query Performance Prediction. En: Djoerd HIEMSTRA, Marie-Francine MOENS, Josiane MOTHE, Raffaele PEREGO, Martin POTTHAST y Fabrizio SEBASTIANI, eds. *Advances in Information Retrieval*. Cham: Springer International Publishing, 2021, p. 115-129. ISBN 978-3-030-72113-8.
- [9] TAO, Yongquan y Shengli WU. Query Performance Prediction By Considering Score Magnitude and Variance Together. En: *Proceedings of the 23rd ACM International Conference on Conference on Information and Knowled-*

- ge Management* [en línea]. Shanghai, China: Association for Computing Machinery, 2014, p. 1891-1894. CIKM '14. ISBN 9781450325981. Disponible en: doi:10.1145/2661829.2661906
- [10] HAUFF, Claudia, Leif AZZOPARDI y Djoerd HIEMSTRA. The Combination and Evaluation of Query Performance Prediction Methods. En: Mohand BOUGHANEM, Catherine BERRUT, Josiane MOTHE y Chantal SOULE-DUPUY, eds. *Advances in Information Retrieval*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2009, p. 301-312. ISBN 978-3-642-00958-7.
- [11] VOORHEES, E.M. The Sixth Text REtrieval Conference (TREC-6). *Information Processing & Management* [en línea]. 2000, **36**(1), 1-2. ISSN 0306-4573. Disponible en: doi:[https://doi.org/10.1016/S0306-4573\(99\)00042-4](https://doi.org/10.1016/S0306-4573(99)00042-4)