



FACULTAD DE INGENIERÍA Y ARQUITECTURA

**EVALUACIÓN COMPARATIVA DE MÉTODOS QUERY
PERFORMANCE PREDICTION (QPP) PARA BÚSQUEDAS AD-HOC
UTILIZANDO MÉTRICAS DE CORRELACIÓN.**

Trabajo de memoria para obtener el título de:

INGENIERO CIVIL EN COMPUTACIÓN E INFORMÁTICA

**Alumno: José Emmanuel Raúl Sandoval Vega.
Luis Emersson Brain Fredes.**

Profesor Patrocinante: Dr. Mauricio Andrés Oyarzún Silva.

IQUIQUE - CHILE

2025

[Dedicatoria...]

AGRADECIMIENTOS

[Agradezco...]

ÍNDICE DE MATERIAS

CAPÍTULO I: INTRODUCCIÓN	1
1.1 Contexto del proyecto	1
1.2 Objetivo General	2
1.3 Objetivos Específicos	2
1.4 Estructura del trabajo de título	2
CAPÍTULO II: ANTECEDENTES	4
2.1 Marco teórico	4
2.1.1 Sistemas de Information Retrieval (IR)	4
2.1.2 Predicción de Rendimiento de Consultas (QPP)	4
2.1.3 Métricas Clásicas de Evaluación en IR	4
2.1.4 Métricas de Correlación para Evaluar Métodos QPP	4
2.2 Herramientas utilizadas	4
2.2.1 Pyterrier	4
2.2.2 ir_datasets	4
2.2.3 ir_measures	4
2.2.4 Docker	4
CAPÍTULO III: TRABAJOS RELACIONADOS	5
3.1 Métodos de Predicción de Rendimiento de Consultas (QPP)	5
3.1.1 IDF (Frecuencia Inversa de Documentos)	5
3.1.2 SCQ (Similitud entre consulta y colección)	7
3.1.3 NQC (Normalized Query Commitment)	8
3.1.4 Clarity Score (CS)	9
3.1.5 WIG (Weighted Information Gain)	10
3.1.6 UEF (Utility Estimation Framework)	11
3.2 Estudios comparativos similares	12
3.2.1 QPPTK en TIREx	12
3.2.2 An Enhanced Evaluation Framework for Query Performance Prediction (2021)	13
CAPÍTULO IV: DISEÑO DE LA EVALUACIÓN COMPARATIVA	16
4.1 Selección de métodos de QPP	16
4.1.1 Criterios de selección	17
4.1.2 Métodos seleccionados	19
4.2 Selección de conjuntos de datos	22
4.2.1 Criterios de inclusión	22
4.2.2 Justificación de los conjuntos de datos seleccionados	24

4.3	Entorno experimental	26
4.3.1	Flujo del sistema	27
4.3.2	Configuración técnica	29
4.4	Relación entre diseño experimental y objetivos	33
4.4.1	Relación con el objetivo general	33
4.4.2	Alineación con los Objetivos Específicos	34
CAPÍTULO V: IMPLEMENTACIÓN		37
5.1	Configuración del entorno experimental	38
5.1.1	Docker y dependencias	39
5.1.2	Integración de conjuntos de datos	40
5.1.3	Indexación y consultas	42
5.2	Implementación de métodos QPP	42
5.2.1	Métodos pre-retrieval	43
5.2.2	Métodos post-retrieval	44
5.3	Implementación de la evaluación	44
5.3.1	Cálculo de correlaciones	45
5.3.2	Visualización de resultados	45
5.4	Pruebas de validación	45
5.4.1	Estructura de las pruebas	46
5.4.2	Metodología de validación	46
5.4.3	Resultados de la validación	47
CAPÍTULO VI: ANÁLISIS DE RESULTADOS		48
6.1	Resultados obtenidos en conjuntos de datos	49
6.2	Comparación de métodos QPP	52
6.3	Discusión de los resultados	60
6.3.1	Importancia de las correlaciones observadas	60
6.3.2	Rendimiento de métodos pre-retrieval	60
6.3.3	Rendimiento de métodos post-retrieval	61
6.3.4	Complejidad Inherente de la Tarea	61
6.3.5	Implicaciones sobre una línea base experimental	61
CAPÍTULO VII: CONCLUSIONES Y TRABAJO FUTURO		63
7.1	Principales conclusiones	63
7.2	Recomendaciones para investigaciones futuras	63
7.3	Trabajo Futuro	63

ÍNDICE DE TABLAS

Tabla 4.1: Criterios de selección de métodos de QPP 17

Tabla 4.2: Métodos de QPP seleccionados 20

Tabla 4.3: Criterios de inclusión de datasets 22

Tabla 4.4: Tabla de datasets y sus criterios de inclusión 24

Tabla 4.5: Parámetros principales de BM25 29

Tabla 4.6: Parámetros principales de configuración 30

Tabla 4.7: Configuración de métricas por dataset 32

Tabla 4.8: Relación entre diseño experimental y objetivos 34

Tabla 4.9: Relación entre diseño experimental y objetivos 36

Tabla 5.1: Componentes principales del sistema implementado 37

Tabla 5.2: Stack tecnológico principal 38

Tabla 5.3: Configuración del entorno experimental 38

Tabla 5.4: Componentes principales del Dockerfile 40

Tabla 5.5: Tipos de visualizaciones implementadas 45

Tabla 5.6: Módulos principales de pruebas unitarias 46

Tabla 5.7: Resultados de ejecución por componente 47

Tabla 6.1: Muestra de terminos Porter vs Snowball Stemmers 53

Tabla 6.2: Niveles de significancia de las correlaciones en tau de Kendall 56

ÍNDICE DE FIGURAS

Figura 4.1: Diagrama de componentes del entorno de evaluación 27

Figura 5.1: Dockerfile para la configuración del entorno experimental 39

Figura 5.2: Configuración de formato de dataset 41

Figura 5.3: Código de implementación del factory de métodos QPP 42

Figura 5.4: Diagrama de la capa de métodos QPP 43

Figura 5.5: Implementación del método WIG 44

Figura 6.1: Diagrama de flujo del análisis de resultados 48

Figura 6.2: Diagrama de caja para las métricas nDCG y AP 49

Figura 6.3: Media de las métricas nDCG y AP 50

Figura 6.4: Histogramas de las métricas nDCG y AP 51

Figura 6.5: Gráfico de dispersión de nDCG@10 vs AP 52

Figura 6.6: Correlación de los métodos QPP - tau de Kendall 53

Figura 6.7: Correlación de los métodos QPP - tau de Kendall 54

Figura 6.8: Diagrama de caja de correlaciones métodos QPP vs nDCG@10 en tau de Kendall 55

Figura 6.9: Gráfico de dispersión de nDCG@10 vs NQC 57

Figura 6.10: Gráfico de dispersión de nDCG@10 vs UEF-NQC - tau de Kendall 58

Figura 6.11: Gráficos de dispersión de nDCG@10 vs IDF 59

NOMENCLATURA

IR (Information Retrieval): Campo de estudio que se enfoca en la recuperación de información relevante a partir de grandes colecciones de datos.

QPP (Query Performance Prediction): Técnicas y métodos utilizados para predecir el rendimiento de una consulta en sistemas de recuperación de información.

BM25: Modelo de recuperación de información basado en la frecuencia de términos, ampliamente utilizado en sistemas de búsqueda.

AP (Average Precision): Métrica de evaluación que mide la precisión promedio de los resultados recuperados, considerando la posición de los documentos relevantes.

nDCG (Normalized Discounted Cumulative Gain): Métrica de evaluación que mide la calidad del ranking de documentos recuperados, considerando la relevancia y la posición de los documentos.

Qrels (Query Relevance Judgments): Juicios de relevancia que indican la pertinencia de los documentos recuperados para una consulta específica.

Stemming: Proceso de reducir palabras a su raíz o forma base, utilizado en el preprocesamiento de texto para mejorar la recuperación de información.

Stopwords: Palabras comunes que se eliminan durante el preprocesamiento de texto para mejorar la eficiencia de la recuperación de información.

Pre-retrieval QPP: Métodos de predicción de rendimiento de consultas basados en estadísticas del corpus antes de la recuperación de documentos.

Post-retrieval QPP: Métodos de predicción de rendimiento de consultas basados en la información obtenida después de recuperar documentos.

RESUMEN

En la actualidad, los sistemas de recuperación de información (IR) enfrentan el desafío de predecir la calidad de los resultados de búsquedas, especialmente en consultas ad-hoc, donde la eficacia de los métodos de Query Performance Prediction (QPP) varía significativamente según el dominio y el tipo de consulta. Esta variabilidad puede derivar en respuestas subóptimas y un uso ineficiente de recursos, lo que subraya la necesidad de una evaluación robusta y reproducible de los métodos QPP más utilizados. Es así como, este proyecto, se enfoca en implementar y evaluar métodos QPP no basados en inteligencia artificial (IA) para búsquedas ad-hoc, utilizando métricas de correlación estandarizadas como tau de Kendall, con el objetivo de establecer una línea base para futuras investigaciones y facilitar el desarrollo de nuevos enfoques.

De esta forma, el objetivo principal del proyecto es evaluar comparativamente métodos de QPP para búsquedas ad-hoc, identificando sus fortalezas y debilidades en diferentes contextos. Para ello, fueron seleccionados seis métodos QPP ampliamente reconocidos en la literatura: IDF (Inverse Document Frequency), SCQ (Similarity Between a Query and a Collection), NQC (Normalized Query Commitment), Clarity Score (CS), WIG (Weighted Information Gain) y UEF (Utility Estimation Framework), los cuales fueron implementados y evaluados en cinco datasets representativos (Cranfield, MS MARCO Passage, Antique/test, BEIR-TREC-COVID y CAR Fold 0), que abarcan una amplia gama de dominios y tipos de consultas, asegurando la generalización de los resultados.

Es así como el análisis de los resultados fue centrado en la comparación de las correlaciones entre los puntajes de los métodos QPP y las métricas de rendimiento del sistema de recuperación, en donde se revela que los métodos post-retrieval presentan las correlaciones más altas, superando significativamente a los métodos pre-retrieval como IDF, que presenta correlaciones cercanas a cero, adicional a esto, se observa que la implementación de UEF mejora considerablemente el rendimiento de los métodos post-retrieval.

Finalmente, los resultados del proyecto establecen una línea base sólida para la evaluación de métodos QPP en búsquedas ad-hoc, sin embargo, la complejidad propia de la tarea de predicción del rendimiento de consultas sigue siendo un desafío, lo que sugiere la necesidad de desarrollar métodos híbridos que combinen las fortalezas de diferentes enfoques.

CAPÍTULO I: INTRODUCCIÓN

1.1 Contexto del proyecto

La predicción del rendimiento de consultas (QPP) ha emergido como una herramienta prometedora en los sistemas de recuperación de información (IR). La capacidad de predecir la calidad de los resultados de búsqueda antes de la ejecución de la consulta permite tanto optimizar los recursos como al mismo tiempo mejorar la experiencia de los usuarios. Sin embargo, la eficacia de los métodos QPP varía significativamente según el dominio, el tipo de consulta, e incluso los modelos de recuperación utilizados, algo que se evidencia especialmente en búsquedas ad-hoc. Esta variabilidad subraya la necesidad de evaluaciones robustas y reproducibles, que permitan comparar y contrastar diferentes enfoques de tal forma que se pueda establecer una línea base clara para futuras investigaciones.

La complejidad del problema de QPP se magnifica por la diversidad de escenarios de aplicación y la heterogeneidad de los datos en diferentes dominios. Los sistemas de recuperación de información modernos deben manejar consultas que varían desde preguntas simples hasta construcciones complejas en lenguaje natural, cada una con sus propios desafíos de predicción de rendimiento. Además, la calidad de los resultados puede verse afectada por factores como la ambigüedad del lenguaje, la especificidad de la consulta, y la cobertura del tema en la colección de documentos.

La motivación sobre el campo de Query Performance Prediction (QPP) ha aumentado en los últimos años debido a los avances en el campo de la inteligencia artificial, específicamente en el área del procesamiento de lenguaje natural (NLP), donde nuevos modelos de lenguaje como BERT, GPT entre otros han demostrado ser muy efectivos en tareas de recuperación de información mediante el uso de técnicas especializadas como RAG (Retrieval augmented generation). Bajo esta premisa se abre un nuevo paradigma de métodos QPP basados en consultas conversacionales, donde la interacción entre el usuario y el sistema de recuperación de información se da de forma más natural.

Este trabajo busca establecer una línea base sobre los enfoques tradicionales para asegurar un avance en las futuras investigaciones de métodos QPP, mediante la implementación de un benchmark abierto y reproducible, disponible en GitHub.¹

¹<https://github.com/emerssn/QPP-Benchmark>

1.2 Objetivo General

Evaluar comparativamente métodos de Query Performance Prediction (QPP) para búsquedas Ad-hoc utilizando métricas de correlación.

1.3 Objetivos Específicos

1. Revisar la literatura sobre métodos de QPP en búsquedas ad-hoc sin el uso de inteligencia artificial.
2. Identificar y describir los principales métodos QPP utilizados en la actualidad.
3. Implementar y evaluar métodos QPP no basados en inteligencia artificial utilizando un conjunto de datos estandarizados y un marco de evaluación común.
4. Analizar y documentar el rendimiento de los métodos QPP implementados para establecer una línea base para futuras comparaciones.
5. Identificar fortalezas y debilidades de diferentes enfoques, proporcionando ideas para futuras investigaciones en métodos QPP.

1.4 Estructura del trabajo de título

El presente trabajo está organizado en siete capítulos, además de incluir las referencias bibliográficas que detallan todos los documentos citados y utilizados en su elaboración. Los capítulos son los siguientes:

Capítulo I: Introducción. Presenta el contexto y motivación del proyecto, junto con los objetivos general y específicos planteados para su realización. Se describe la importancia de la predicción del rendimiento de consultas (QPP) en sistemas de recuperación de información y la necesidad de una evaluación comparativa robusta.

Capítulo II: Antecedentes. Proporciona el marco teórico necesario para comprender el trabajo, incluyendo conceptos fundamentales sobre sistemas de recuperación de información, predicción del rendimiento de consultas, métricas de evaluación y las herramientas utilizadas en el proyecto.

Capítulo III: Trabajos Relacionados. Revisa y analiza los principales métodos QPP desarrollados en la literatura, enfocándose en aquellos no basados en inteligencia artificial. Se examinan sus características, fortalezas y limitaciones, estableciendo el estado del arte en el campo.

Capítulo IV: Diseño de la Evaluación Comparativa. Define la metodología experimental, incluyendo la selección de métodos QPP, datasets, métricas de evaluación

y el entorno experimental. Se detalla la configuración técnica y los procedimientos para garantizar la reproducibilidad de los experimentos.

Capítulo V: Implementación. Describe en detalle la implementación del sistema, la configuración del entorno experimental y los procesos de validación. Se incluyen aspectos técnicos sobre la integración de herramientas y la ejecución de experimentos.

Capítulo VI: Análisis de Resultados. Presenta y analiza los resultados obtenidos en la evaluación comparativa, examinando el rendimiento de cada método QPP en diferentes escenarios y datasets. Se discuten las implicaciones de los hallazgos y se comparan con resultados previos de la literatura.

Capítulo VII: Conclusiones y Trabajo Futuro. Resume los principales hallazgos y contribuciones del proyecto, estableciendo la línea base para futuras investigaciones en QPP. Se identifican limitaciones del estudio y se proponen direcciones para investigaciones futuras.

Finalmente, se incluyen las referencias bibliográficas que sustentan el trabajo realizado, asegurando la trazabilidad y reproducibilidad de la investigación.

CAPÍTULO II: ANTECEDENTES

2.1 Marco teórico

Conceptos básicos y principios fundamentales...

2.1.1 Sistemas de Information Retrieval (IR)

2.1.2 Predicción de Rendimiento de Consultas (QPP)

2.1.3 Métricas Clásicas de Evaluación en IR

2.1.4 Métricas de Correlación para Evaluar Métodos QPP

2.2 Herramientas utilizadas

2.2.1 Pyterrier

2.2.2 ir_datasets

2.2.3 ir_measures

2.2.4 Docker

CAPÍTULO III: TRABAJOS RELACIONADOS

La predicción del rendimiento de consultas (QPP) es un área de investigación importante dentro de los sistemas de recuperación de información, puesto que permite anticipar la calidad de los resultados de una consulta sin necesariamente ejecutarla de forma completa. Es así, que a lo largo de los años se han desarrollado numerosos métodos QPP con diferentes características y aptos para distintas situaciones, los que han sido evaluados exhaustivamente en una larga cantidad de estudios. Estos estudios no solo han definido métricas y herramientas para medir la efectividad de los métodos QPP, sino que también han desarrollado análisis comparativos (benchmarks) que sirven como referencia en el estado del arte dentro del área.

A continuación, se revisan estudios relevantes relacionados con la predicción del rendimiento de consultas, presentando los principales métodos utilizados en la literatura, para posteriormente, analizar el uso de datasets y entornos de experimentación para la comparación de métodos, destacando investigaciones previas que han servido como base para el diseño experimental de este proyecto.

3.1 Métodos de Predicción de Rendimiento de Consultas (QPP)

En el contexto de este proyecto, se priorizó la revisión de métodos de Query Performance Prediction que no dependen de enfoques basados en inteligencia artificial (IA), los cuales, clasificados como pre-retrieval y post-retrieval, son altamente valorados por su simplicidad y robustez en la predicción del rendimiento de consulta sirviendo como base para métodos QPP más complejos.

Es así como, durante la revisión de la literatura, se identificaron trabajos claves que evaluaron y desarrollaron diferentes métodos QPP en diferentes contextos, como búsquedas ad-hoc y benchmarks de recuperación de información, proporcionando métricas importantes para evaluar la calidad de las consultas, los cuales se presentan a continuación.

3.1.1 IDF (Frecuencia Inversa de Documentos)

El predictor Inverse Document Frequency (IDF), ampliamente utilizado en el área, puede de igual manera funcionar como predictor pre-retrieval en sistemas de recuperación de información, este mide que tan específicos son los términos de una

consulta dentro de un corpus. En el documento [1], se profundiza su relevancia como un componente clave en la predicción del rendimiento de consultas (QPP), específicamente su capacidad para identificar términos altamente selectivos, es decir, aquellos que aparecen en pocos documentos (menos comunes) y, por ende, aportan mayor discriminación en la búsqueda. El IDF también puede ser utilizado en su variante IDF-Max, donde el término con la mayor frecuencia inversa dentro de una consulta sirve como indicador principal de su efectividad. Este indicador, que se basa en estadística, se adoptó rápidamente como una herramienta esencial en la predicción del rendimiento de consultas (QPP) pre-retrieval, siendo incorporada en otros esquemas y modelos probabilísticos de búsqueda.

La fórmula comúnmente utilizada del IDF en sistemas modernos, debido a su suavizado y estabilidad matemática, se define como:

$$IDF(t) = \ln \left(1 + \frac{N}{f_t} \right) \quad (3.1)$$

Donde N es el número total de documentos en el corpus y f_t es el número de documentos que contienen el término t , y se añade 1 para evitar divisiones por cero o valores indefinidos.

En el artículo [2], el autor señala que el IDF asigna pesos más bajos a los términos frecuentes debido a su limitado poder discriminatorio, mientras que otorga pesos más altos a los términos menos comunes, los cuales poseen mayor capacidad para distinguir documentos relevantes, asegurando que los términos poco frecuentes, pero informativos, tengan un mayor impacto en el cálculo de relevancia. Además, se destaca que, aunque la formulación exacta del algoritmo puede variar según los autores, su utilidad general permanece sólida en una amplia gama de aplicaciones prácticas, incluyendo la recuperación de información y otros contextos relacionados con el análisis de datos.

De esta forma, el IDF ha sido ampliamente utilizado debido a su robustez y simplicidad. En el artículo [2], el autor argumenta que el IDF equilibra de forma eficaz la especificidad y la relevancia, permitiendo su aplicación en diferentes contextos, tales como recuperación de textos, análisis de lenguaje natural e incluso en recuperación de medios no textuales.

En cuanto a su relevancia para el presente proyecto de evaluación de métodos de QPP, el IDF resulta relevante, ya que su capacidad para capturar la especificidad

de los términos yace de manera tácita en otros predictores QPP, además, como se menciona en el artículo [3], su integración en distintas métricas proporciona una línea base confiable para la comparación con métodos más avanzados, validando su referencia tanto de forma heurística como de herramienta teórica sólida y bien fundamentada.

3.1.2 SCQ (Similitud entre consulta y colección)

El método SCQ (Similarity Between a Query and a Collection), es un predictor pre-retrieval propuesto por Ying Zhao, Falk Scholer y Yohannes Tsegay. En el artículo [1] los autores explican que el SCQ calcula un puntaje de similitud entre una consulta y la colección de documentos, utilizando la frecuencia de términos en la colección y la frecuencia inversa de documentos (IDF) como evidencias para determinar la relevancia. Siendo una de sus principales ventajas que se basa en estadísticas disponibles durante el proceso de indexado, eliminando la necesidad de realizar búsquedas previas.

La fórmula matemática que define al SCQ es la siguiente:

$$SCQ = \sum_{t \in Q} \left((1 + \ln(f_{c,t})) \cdot \ln \left(1 + \frac{N}{f_t} \right) \right) \quad (3.2)$$

Donde Q es el conjunto de términos de la consulta, $f_{c,t}$ corresponde a la frecuencia del término t en la colección, f_t es el número de documentos en los que aparece el término t , y finalmente N es el número total de documentos de la colección.

Como se menciona, el SCQ mide la similitud mediante una representación vectorial, donde tanto las consultas como los documentos son tratados como vectores. La proximidad entre estos vectores se interpreta como un indicador de relevancia que permite identificar consultas que potencialmente obtendrán un mejor rendimiento en la recuperación de información. Además, este predictor puede ajustarse mediante la normalización por longitud de la consulta o evaluarse en función del valor máximo de SCQ alcanzado por los términos individuales.

Es así como, gracias a su balance entre la simplicidad y precisión, el SCQ promete ser una herramienta útil para sistemas de recuperación de información que manejan grandes volúmenes de datos en tiempo real, en donde su capacidad para establecer relaciones entre las características de las consultas y su rendimiento lo convierte en

una contribución importante para tareas que involucran una alta variabilidad en las consultas, posicionándose como un estándar en evaluaciones pre-retrieval.

Por lo tanto, para el presente proyecto, el SCQ es particularmente relevante porque permite analizar consultas en dominios complejos y heterogéneos, estableciendo una relación clara entre las características de las consultas y su rendimiento esperado, lo que facilita una evaluación comparativa de métodos.

3.1.3 NQC (Normalized Query Commitment)

El método NQC (“Normalized Query Commitment”) fue propuesto por Anna Shtok, Oren Kurland y David Carmel como un predictor post-retrieval que evalúa la efectividad de una consulta midiendo la dispersión de los puntajes de recuperación entre los documentos más relevantes. En el artículo [4], los autores destacan que una menor dispersión temática en los documentos recuperados está asociada con una mayor efectividad de las consultas, lo cual se refleja en la distribución de los puntajes de recuperación.

Por lo tanto, el enfoque de NQC se centra en medir la desviación estándar de los puntajes de recuperación normalizados por el promedio del corpus, lo que permite identificar consultas cuyos documentos recuperados son consistentes en términos de relevancia, sugiriendo un buen desempeño de la consulta. Además, los autores explican que los documentos con puntajes significativamente superiores al promedio son menos propensos a exhibir desviaciones temáticas, lo que se traduce en un menor grado de “query drift” y un mejor rendimiento de recuperación.

El método NQC se define matemáticamente como:

$$NQC(q, M) = \frac{\sqrt{\frac{1}{k} \sum_{d \in D[k]_q} (Score(d) - \mu)^2}}{Score(D)} \quad (3.3)$$

En donde q corresponde a la consulta, M al modelo de recuperación, $D[k]_q$ a la lista de los k documentos mejor rankeados, μ al promedio de los puntajes de recuperación en $D[k]_q$ y $Score[D]$ al puntaje de recuperación del corpus considerado como un único documento concatenado.

NQC resulta especialmente útil en el ámbito de la recuperación de información debido a su capacidad para capturar la consistencia en documentos relevantes y su adaptabilidad a diferentes modelos de recuperación, siendo su diseño simple lo que

permite aplicarlo de manera eficiente, incluso en escenarios complejos donde se requiere alta precisión en los resultados.

Para el presente proyecto, NQC es relevante al proporcionar una métrica que permite evaluar la calidad de las consultas al correlacionar la dispersión de los puntajes con la efectividad esperada, lo que es fundamental para analizar consultas en dominios con alta variabilidad y establecer comparaciones confiables entre los diferentes métodos de predicción.

3.1.4 Clarity Score (CS)

El método Clarity Score (CS) fue desarrollado por Steve Cronen-Townsend, Yun Zhou y W. Bruce Croft como un predictor post-retrieval que analiza la claridad o coherencia de las consultas en sistemas de recuperación de información. En el artículo [3], los autores explican que el CS se basa en la comparación entre un modelo de lenguaje generado a partir de una consulta y el modelo de lenguaje global del corpus, utilizando la divergencia de Kullback-Leibler como herramienta matemática que permite calcular la distancia entre ambos modelos.

La lógica detrás de CS implica que consultas con términos más claros y específicos generarán modelos de lenguaje que se diferencian significativamente del modelo del corpus, obteniendo puntajes más altos. Estos términos, al estar menos expuestos a interpretaciones ambiguas, tienden a recuperar documentos más relevantes y precisos. Por otro lado, las consultas con puntajes más bajos suelen reflejar una mayor ambigüedad o dispersión temática, lo que puede afectar negativamente la precisión de los resultados recuperados.

Como se menciona, el CS se calcula como la divergencia de Kullback-Leibler entre el modelo de lenguaje de la consulta y el modelo de lenguaje de la colección:

$$CS(Q) = \sum_{w \in V} \left(P(w | Q) \log 2 \frac{P(w | Q)}{P_{coll}(w)} \right) \quad (3.4)$$

En donde w es un término en el vocabulario V , $P(w | Q)$ es la probabilidad del término w en el modelo de lenguaje de la consulta y $P_{coll}(w)$ es la probabilidad del término w en el modelo de lenguaje de la colección.

En términos prácticos, el CS demuestra ser una herramienta valiosa en el campo de la Recuperación de Información por varias razones fundamentales. En primer lugar, su capacidad para cuantificar la claridad de una consulta a través de la divergencia KL

proporciona una medida objetiva de la especificidad de los términos de búsqueda. Además, al basarse en la comparación con el modelo de lenguaje de la colección completa, el método captura efectivamente las peculiaridades y la distribución del vocabulario en el dominio específico. Sin embargo, es importante señalar que su efectividad puede variar según las características del corpus y la naturaleza de las consultas, siendo particularmente útil en colecciones donde la ambigüedad terminológica representa un desafío significativo para la recuperación de información.

Finalmente, en el contexto del presente proyecto, el Clarity Score es relevante por su capacidad para proporcionar un indicador temprano sobre la calidad de las consultas, permitiendo evaluar cómo estas interactúan con el corpus y qué tan bien pueden desempeñarse en términos de recuperación efectiva, resultando crucial en escenarios donde la variabilidad y complejidad de las consultas pueden influir significativamente en los resultados esperados.

3.1.5 WIG (Weighted Information Gain)

El método Weighted Information Gain (WIG) fue desarrollado por Yun Zhou y W. Bruce Croft como un predictor post-retrieval diseñado para abordar los desafíos de la predicción del rendimiento de consultas en entornos de búsqueda web. En el artículo [5], los autores destacan que WIG mide la contribución promedio de los documentos mejor clasificados a la calidad del rendimiento de la consulta, basándose en el análisis de las características individuales de los términos y su proximidad, lo que permite evaluar la efectividad de las consultas en colecciones grandes y heterogéneas.

El cálculo de WIG se realiza comparando el cambio en la información entre un estado inicial, representado por un documento promedio del corpus, y el estado posterior, que corresponde a los resultados obtenidos tras la recuperación de los documentos relevantes. Este enfoque utiliza conceptos como la ganancia de información ponderada y distribuciones de probabilidad para estimar la calidad de la consulta, lo que lo convierte en una herramienta robusta para analizar el desempeño en escenarios complejos.

En cuanto a su fórmula, WIG se define como la diferencia entre la entropía ponderada de los documentos mejor clasificados y la entropía del modelo de lenguaje de la colección, lo que es igual a:

$$WIG(Q) = \frac{1}{k} \sum_{d \in D_k} \left(P(Q | d) \log \frac{P(Q | d)}{P(Q | C)} \right) \quad (3.5)$$

En donde Q es la consulta, D_k es el conjunto de los k documentos mejor clasificados, $P(Q | d)$ es la probabilidad de la consulta Q dado el documento d , y $P(Q | C)$ es la probabilidad de la consulta Q dado el modelo de lenguaje de la colección.

Es así que, WIG es especialmente relevante debido a su capacidad para adaptarse a distintos tipos de consultas y colecciones, incluyendo aquellas con gran diversidad en calidad y estilo de los documentos, resultando crucial para evaluar la efectividad de las consultas, proporcionando una métrica sólida para comparar métodos avanzados de predicción del rendimiento y asegurando un análisis confiable en dominios variados.

3.1.6 UEF (Utility Estimation Framework)

El Utility Estimation Framework (UEF) fue desarrollado por Anna Shtok, Oren Kurland y David Carmel como un enfoque post-retrieval que utiliza principios de la teoría estadística de decisiones para predecir el rendimiento de consultas. En el artículo [6] los autores explican que este método evalúa la calidad de un ranking de documentos basándose en su utilidad estimada con respecto a la necesidad de información representada en la consulta, proceso que se realiza al medir la similitud esperada entre el ranking generado y los rankings inducidos por modelos de relevancia.

El marco UEF permite una gran flexibilidad al emplear diferentes métricas de similitud, como el coeficiente de correlación de Pearson, y al estimar modelos de relevancia utilizando pseudo-relevance feedback. Esta combinación proporciona una base teórica sólida para predecir el rendimiento de consultas, ya que integra la precisión de los modelos de relevancia con un enfoque estructurado que captura las características del ranking generado por la consulta.

A continuación se observa la fórmula general del UEF:

$$U(\pi_M(q; D)) = \int_{R_q} Sim(\pi_M(R_q; D))p(R_q | I_q)dR_q \quad (3.6)$$

En donde, $\pi_M(q; D)$ corresponde al ranking generado por el modelo M , R_q al modelo de relevancia estimado basado en la consulta q , Sim es la medida de similitud entre rankings y $p(R_q | I_q)$ a la probabilidad de que R_q represente la necesidad de información subyacente I_q .

El UEF destaca por su fundamentación teórica en la teoría estadística de decisiones, lo que le permite estimar de manera robusta la utilidad esperada de un ranking. Su diseño matemático incorpora explícitamente la incertidumbre inherente en la estimación de relevancia a través de la distribución de probabilidad $p(R_q | Iq)$, mientras que la función de similitud *Sim* cuantifica la concordancia entre el ranking original y los rankings generados por los modelos de relevancia estimados.

Es así que el UEF representa un avance significativo en la predicción del rendimiento de consultas al proporcionar un marco teórico sólido que unifica diferentes aspectos de la recuperación de información. Su formulación matemática rigurosa, basada en principios estadísticos, permite una evaluación sistemática de la calidad de los rankings, considerando tanto la estructura de los resultados como la incertidumbre en la estimación de relevancia.

3.2 Estudios comparativos similares

En cuanto a la investigación de trabajos relacionados, también se identificaron estudios comparativos que evaluaron diferentes métodos QPP en escenarios diversos, los cuales son claves para establecer un marco comparativo que permita validar los resultados finales de este proyecto, además estos trabajos no solo permiten identificar fortalezas y debilidades de cada enfoque, sino que también establecen líneas base estandarizadas para validar nuevos métodos y enfoques más experimentales.

A continuación, se presentan los estudios relevantes que evaluaron métodos QPP como IDF, SCQ, Clarity Score, entre otros, destacando sus aportes al estado del arte del área y su influencia en el diseño de este proyecto.

3.2.1 QPPTK en TIREx

Un reciente estudio relevante para el presente proyecto es el desarrollado por Zendel, Fröbe y Faggioli en 2024, que proporciona una referencia fundamental al implementar y evaluar un marco de predicción del rendimiento de consultas (QPP) utilizando el Query Performance Prediction Toolkit (QPPTK) dentro de la plataforma TIREx. En este trabajo [7], los autores analizaron el desempeño de 12 métodos de predicción en combinación con diversos modelos de recuperación de información y 23 conjuntos de datos, incluyendo benchmarks reconocidos como TREC Robust04 y MS MARCO, por lo que, la amplitud de la evaluación y su enfoque en la reproducibilidad de los experimentos lo convierten en un recurso valioso para este proyecto.

Como se menciona, el estudio incluye una evaluación exhaustiva de métodos pre-retrieval, como IDF y SCQ, y post-retrieval, como NQC y Clarity Score, además, se demuestra cómo la evaluación cruzada en múltiples benchmarks permite identificar patrones de rendimiento y validar la generalización de los métodos seleccionados, enfoque que se destaca por la importancia de utilizar plataformas estandarizadas, como TIREx, que no solo permiten configurar entornos experimentales reproducibles, sino que también minimizan los sesgos potenciales en los resultados al estandarizar la configuración y los parámetros de los experimentos.

Una de las contribuciones clave del trabajo es la integración de QPPTK en TIREx, lo que facilita la realización de experimentos reproducibles, lo que se logra mediante la utilización de índices preconstruidos y configuraciones consistentes que garantizan estabilidad en las pruebas. Así mismo, los resultados generados son compartidos abiertamente, promoviendo su reutilización en futuros estudios, enfoque que resulta relevante para este proyecto, donde la reproducibilidad y la estandarización son fundamentales para garantizar la validez de las comparaciones entre métodos.

Es así que, los hallazgos de los autores, proporcionan métricas clave, como correlaciones entre predictores y métricas clásicas de recuperación, esenciales para validar los métodos implementados en este proyecto, además, su metodología y diseño experimental sirven como referencia directa para configurar los experimentos, asegurando que las evaluaciones sigan estándares establecidos en la literatura.

En resumen, este estudio no solo se destaca por la profundidad de su análisis, sino también por su contribución al establecimiento de prácticas experimentales reproducibles, que es en donde radica su relevancia para el proyecto presentado, ya que propone un diseño experimental y proporciona un marco sólido para evaluar métodos de predicción del rendimiento de consultas en entornos complejos.

3.2.2 An Enhanced Evaluation Framework for Query Performance Prediction (2021)

Otro estudio destacado y relevante para el presente proyecto es el realizado por Guglielmo Faggioli et al. en 2021, quienes desarrollaron un marco de evaluación mejorado para la predicción del rendimiento de consultas (QPP), el cual aborda limitaciones clave de los enfoques tradicionales mediante la integración de análisis

estadísticos avanzados y métricas diseñadas para evaluar, no solo la precisión, sino también la variabilidad y robustez de los métodos QPP en diferentes escenarios. Este marco supera las limitaciones de las evaluaciones basadas únicamente en correlaciones, como la dificultad para interpretar valores agregados únicos y la incapacidad para identificar consultas específicas donde los métodos fallan.

Es así que, en el artículo [8], los autores proponen un enfoque innovador que incluye métricas basadas en errores, como el Scaled Absolute Rank Error (SARE) y el Scaled Mean Absolute Rank Error (sMARE), las cuales permiten medir el error de predicción de manera distribuida por consulta. Además, incorporan técnicas estadísticas avanzadas, como el análisis de varianza (ANOVA) y pruebas post hoc para evaluar las diferencias entre métodos con mayor detalle. Estas herramientas permiten no solo comparar la precisión de los predictores, sino también analizar la influencia de factores como el tema de la consulta, el método de recuperación y la configuración de stemming en el rendimiento del QPP.

Como se menciona, el artículo se destaca por su enfoque en la medición de errores distribuidos por consulta, lo que permite un análisis más granular del desempeño de los métodos, en donde se realizaron experimentos en conjuntos de datos estándar como TREC Robust-04, utilizando métodos pre-retrieval, como MaxIDF y SCQ, y post-retrieval, como NQC y Clarity Score, cuyos resultados revelaron que factores como el modelo de recuperación, la configuración de stemming y “stoplists”, y la naturaleza de las consultas influyen significativamente en el rendimiento del QPP. Por ejemplo, se observó que los métodos post-retrieval, como NQC y Clarity, tienden a tener una correlación más alta con la precisión promedio (AP), mientras que los métodos pre-retrieval, como MaxIDF, pueden ser más robustos en ciertos escenarios. Estos hallazgos proporcionan información valiosa para optimizar estos sistemas y seleccionar el método más adecuado según la situación.

En el contexto del presente proyecto, el marco propuesto por los autores es importante, ya que introduce prácticas de evaluación reproducibles y detalladas, alineadas con estándares modernos, además de que, sus hallazgos sobre la interacción de factores experimentales y el rendimiento del QPP sirven como guía directa para configurar experimentos que sean estadísticamente sólidos y representativos en escenarios reales. Por ejemplo, el uso de ANOVA y pruebas post hoc permite identificar no solo qué métodos son superiores en general, sino también en qué condiciones específicas (como ciertos tipos de consultas o configuraciones) un método puede ser mejor que otro, lo que es particularmente útil en aplicaciones prácticas donde la variabilidad de las consultas y los documentos es alta, como en motores de búsqueda web y sistemas de recomendación.

En resumen, el trabajo de los autores, no solo proporciona un marco metodológico avanzado para la evaluación de QPP, sino que también ofrece insights prácticos sobre cómo optimizar estos sistemas en función de factores contextuales, lo que lo convierte en una referencia clave para el presente proyecto, especialmente en la fase de diseño experimental y evaluación de métodos de predicción de rendimiento de consultas.

CAPÍTULO IV: DISEÑO DE LA EVALUACIÓN COMPARATIVA

En este capítulo se presenta el diseño experimental desarrollado para llevar a cabo la evaluación comparativa de métodos de Query Performance Prediction (QPP).

El diseño no solo tiene como propósito validar la implementación técnica de los métodos QPP seleccionados, sino también establecer líneas base que permitan analizar sus fortalezas y limitaciones en contextos variados propios de los sistemas de recuperación de información. Para ello, se consideraron criterios sólidos y alineados con las mejores prácticas del estado del arte, garantizando la representatividad y el rigor del análisis comparativo.

La necesidad de un diseño comparativo sólido radica en la creciente complejidad de los sistemas de recuperación de información y la diversidad de escenarios en los que estos se aplican, y es en este contexto que es importante métodos QPP adecuados para poder optimizar recursos y mejorar la precisión de los resultados, por lo que adoptar criterios cuidadosamente definidos basados en las mejores prácticas del estado del arte es crucial para garantizar que cada componente del diseño cumpla con los estándares de calidad y reproducibilidad.

Además, en el presente proyecto, el diseño de la evaluación comparativa no solo busca responder preguntas específicas sobre el rendimiento de los métodos seleccionados, sino también contribuir al avance del estado del arte en QPP, estableciendo un marco que promueva prácticas experimentales reproducibles, transparentes y aplicables a diversos contextos, garantizando que los hallazgos obtenidos sean relevantes tanto para la comunidad científica como para la práctica en sistemas de recuperación de información.

4.1 Selección de métodos de QPP

La selección de métodos QPP resulta crucial en el diseño de este proyecto, ya que determina la relevancia y la validez del análisis comparativo.

Para garantizar que los enfoques evaluados sean representativos y estén alineados con los objetivos del estudio, se establecieron criterios rigurosos basados en la literatura científica revisada, los cuales priorizan la inclusión de métodos reconocidos en el estado del arte, con fundamentos estadísticos sólidos y un alto grado de reproducibilidad.

A continuación, se describen los criterios aplicados en el proceso de selección, así como los métodos QPP finalmente escogidos para la posterior evaluación comparativa.

4.1.1 Criterios de selección

Como se ha mencionado, la selección de métodos de Query Performance Prediction (QPP) es un proceso fundamental para garantizar que los métodos evaluados sean representativos, robustos y relevantes en el contexto de los sistemas de recuperación de información. Con este propósito, se definieron criterios específicos que permiten abordar el problema desde una perspectiva teórica sólida y práctica aplicable, los que aseguran la validez de la evaluación comparativa y su alineación con los objetivos del proyecto.

Tabla 4.1: Criterios de selección de métodos de QPP

Criterio	Descripción	Importancia para el proyecto
Base estadística y simplicidad	Métodos con fundamentos sólidos y fácilmente comprensibles.	Facilita la reproducibilidad y asegura resultados confiables.
Uso en estudios previos	Métodos comúnmente implementados en investigaciones recientes.	Garantiza relevancia científica y comparabilidad con investigaciones previas
Diversidad de enfoques	Cobertura de métodos pre-retrieval y post-retrieval, cada uno enfocado en aspectos distintos del rendimiento.	Permite una evaluación integral que abarca múltiples aspectos del rendimiento de consultas.
Relevancia en el estado del arte	Métodos no basados en inteligencia artificial y ampliamente reconocidos por su efectividad teórica y práctica.	Asegura un marco comparativo que no depende de tecnologías supervisadas y promueve análisis no sesgados.

La Tabla 4.1 resume los criterios definidos para la selección de los métodos de QPP, en donde cada criterio cumple un rol específico para garantizar que los métodos seleccionados no solo sean estadísticamente sólidos, sino también relevantes y diversificados en su enfoque, asegurando que el análisis comparativo resultante sea exhaustivo y útil para evaluar las fortalezas y limitaciones de los métodos elegidos.

- **Base estadística y simplicidad:** Se seleccionan métodos que se basan en conceptos matemáticos fundamentales, como la frecuencia de términos en el corpus y su relación con la consulta, ya que estos métodos son ampliamente reconocidos por su sencillez y su capacidad para ser implementados y replicados sin necesidad de recursos computacionales avanzados. Este criterio asegura que los métodos elegidos puedan ser utilizados como referencia en investigaciones futuras, promoviendo la reproducibilidad de los experimentos y el entendimiento teórico de los predictores.
- **Uso en estudios previos:** Se buscan métodos que han sido recurrentemente evaluados en trabajos recientes que analizan sistemas de recuperación de información, ya que no solo garantiza que los resultados del proyecto sean comparables con investigaciones previas, sino que también asegura que los métodos seleccionados representan soluciones probadas y bien documentadas.
- **Diversidad de enfoques:** Se seleccionan métodos tanto pre-retrieval como post-retrieval para capturar diferentes aspectos del problema, mientras que unos se enfocan en estimar la calidad de una consulta basándose únicamente en estadísticas del corpus, los otros evalúan la calidad considerando los documentos recuperados. Este enfoque integral permite analizar el rendimiento de consultas desde múltiples perspectivas, proporcionando una visión más completa de sus fortalezas y debilidades.
- **Relevancia en el estado del arte:** Se priorizan métodos no basados en inteligencia artificial, ya que estos garantizan un análisis más transparente y menos sesgado en comparación con tecnologías supervisadas, además, de esta forma, los métodos seleccionados han sido ampliamente reconocidos en la literatura por su aplicabilidad en sistemas de recuperación de información y su capacidad para ser implementados sin depender de datasets de entrenamiento o modelos complejos.

Por otra parte, la decisión de priorizar métodos no basados en inteligencia artificial tiene varias razones claves:

- **Transparencia y simplicidad:** Los métodos no basados en inteligencia artificial, ofrecen interpretaciones claras de cómo se calculan y qué factores influyen en su desempeño, esto contrasta con los métodos supervisados, cuya complejidad en ocasiones dificulta la comprensión de su funcionamiento interno.
- **Reproducibilidad:** Al no depender de datasets de entrenamiento o modelos complejos, los métodos no basados en IA pueden ser implementados en cualquier entorno sin necesidad de recursos adicionales, lo que asegura que los experimentos realizados sean replicables por otros investigadores.
- **Independencia del contexto:** Los métodos seleccionados son independientes de los dominios específicos y los cambios en las colecciones de datos, mientras que los métodos supervisados tienden a ser altamente sensibles a las características del dataset de entrenamiento.
- **Contribución al estado del arte:** Este enfoque se alinea con el objetivo de establecer líneas base sólidas para evaluar nuevos métodos, permitiendo que futuros desarrollos en QPP se comparen con estándares bien establecidos.

4.1.2 Métodos seleccionados

Siguiendo los criterios establecidos en la sección anterior y tras un análisis exhaustivo de la literatura, se seleccionaron seis métodos de Query Performance Prediction (QPP) para la evaluación comparativa, los cuales representan enfoques diversos e incluyen estrategias pre-retrieval y post-retrieval, lo que asegura una cobertura de los aspectos clave del rendimiento de consultas en sistemas de recuperación de información. Además, como se ha mencionado, cada método fue elegido por su relevancia en el estado del arte, su fundamento teórico y su impacto demostrado en investigaciones previas, ofreciendo un marco robusto para analizar su efectividad y aplicabilidad en contextos variados.

Tabla 4.2: Métodos de QPP seleccionados

Método QPP	Clasificación	Descripción
1. IDF (Inverse Document Frequency)	Pre-retrieval	Mide la rareza de los términos en un corpus mediante la frecuencia inversa de documentos.
2. SCQ (Similarity between a Query and a Collection)	Pre-retrieval	Calcula la similitud entre los términos de la consulta y la colección basándose en frecuencias y pesos.
3. NQC (Normalized Query Commitment)	Post-retrieval	Evalúa la dispersión de los puntajes de relevancia en los documentos recuperados para predecir la calidad de la consulta.
4. Clarity Score (SC)	Post-retrieval	Mide la divergencia entre el modelo de lenguaje de los documentos recuperados y el modelo de la colección.
5. WIG (Weighted Information Gain)	Post-retrieval	Estima la calidad de la consulta mediante la ganancia de información ponderada basada en los documentos recuperados.
6. UEF (Utility Estimation Framework)	Post-retrieval	Utiliza modelos de relevancia y teoría de decisión estadística para estimar la utilidad de los rankings generados.

En cuanto al análisis de las fortalezas y debilidades de cada método seleccionado en la Tabla 4.2:

- IDF (Inverse Document Frequency): Es un método simple, eficiente y ampliamente utilizado, su capacidad para medir la especificidad de los términos lo

convierte en una herramienta básica para estimar la calidad de las consultas. Por otra parte, depende exclusivamente de estadísticas del corpus, lo que limita su precisión en escenarios donde la calidad de los documentos recuperados influye de forma significativa.

- SCQ (Similarity between a Query and a Collection): Proporciona una evaluación más detallada al considerar la similitud entre la consulta y la colección en su conjunto, lo que resulta útil en contextos con consultas de longitud variada. Por otra lado, puede ser menos efectivo en colecciones con alta heterogeneidad temática debido a su dependencia de estadísticas globales.
- NQC (Normalized Query Commitment): Evalúa la consistencia de los puntajes de relevancia en los documentos recuperados, lo que lo hace efectivo para identificar consultas problemáticas, pero requiere ejecutar consultas y recuperar documentos, lo que implica un costo computacional más alto en comparación con métodos pre-retrieval.
- Clarity Score (CS): Mide la coherencia del lenguaje de los documentos recuperados, lo que lo hace efectivo en consultas específicas con temas bien definidos, pero es sensible a consultas cortas o ambiguas, donde la divergencia entre el modelo de lenguaje y el corpus puede ser menos clara.
- WIG (Weighted Information Gain): Integra múltiples características de los documentos recuperados, como términos y proximidad, proporcionando una evaluación integral, aunque puede ser afectado por colecciones con sesgos en los documentos más relevantes, disminuyendo su precisión en escenarios específicos.
- UEF (Utility Estimation Framework): Ofrece un marco flexible y adaptable, utilizando modelos de relevancia para capturar tanto la utilidad como la precisión de los rankings generados, pero su complejidad estadística puede dificultar su implementación en sistemas con recursos limitados o en contextos donde se prioriza la simplicidad.

Los métodos seleccionados abarcan una gama de enfoques y fundamentos teóricos, lo que garantiza una evaluación comparativa exhaustiva y representativa, en donde la inclusión de métodos tanto pre-retrieval como post-retrieval asegura que se cubran múltiples facetas del problema, proporcionando una base sólida para analizar su desempeño en diferentes contextos, resultando en un diseño experimental robusto que refuerza la validez del estudio y su contribución al avance del estado del arte en predicción de rendimiento de consultas.

4.2 Selección de conjuntos de datos

La selección de datasets es parte fundamental para garantizar una evaluación comparativa robusta y representativa de los métodos de Query Performance Prediction (QPP), es por ello, que se seleccionaron datasets reconocidos en la literatura, priorizando los que ofrecen juicios de relevancia (Qrels) y métricas estandarizadas, permitiendo así validar el desempeño de los métodos seleccionados en escenarios variados.

Estos datasets fueron cuidadosamente seleccionados para abarcar una amplia diversidad de tipos de consultas y dominios, asegurando que los resultados obtenidos sean aplicables y relevantes para diferentes contextos de recuperación de información. Este enfoque garantiza no solo la robustez de los resultados, sino también su generalización a futuros trabajos relacionados con QPP.

4.2.1 Criterios de inclusión

En la Tabla 4.3 se presentan los criterios aplicados en la selección de datasets, detallando su importancia en el contexto del proyecto.

Tabla 4.3: Criterios de inclusión de datasets

Criterio	Descripción	Importancia para el proyecto
Disponibilidad pública	Datasets de acceso abierto y bien documentados, sin restricciones para su uso.	Garantiza la reproducibilidad y facilita la implementación en diversos contextos.
Diversidad de escenarios	Representación de diferentes tipos de consultas (informacionales, navegacionales y transaccionales) y dominios.	Asegura la evaluación integral de los métodos en múltiples contextos.
Uso en el estado del arte	Amplio uso en investigaciones previas de recuperación de información y QPP.	Respalda la validez y comparabilidad de los resultados obtenidos.

Criterio	Descripción	Importancia para el proyecto
Tamaño adecuado	Incluye tanto datasets pequeños como grandes.	Permite evaluar el comportamiento de los métodos en diferentes escalas de datos.
Relevancias conocidas (Qrels)	Incluyen juicios de relevancia establecidos previamente.	Facilitan la evaluación precisa y objetiva del desempeño de los métodos QPP.

- Disponibilidad pública: Es fundamental seleccionar datasets de acceso abierto que estén bien documentados, ya que esto garantiza la transparencia y la reproducibilidad de los experimentos, la disponibilidad pública también asegura que los resultados puedan ser validados por otros investigadores, fomentando la colaboración y el avance en el campo del QPP.
- Diversidad de escenarios: Incluir datasets con diferentes tipos de consultas es crucial para evaluar cómo se desempeñan los métodos QPP en escenarios reales, por ejemplo de consultas informacionales: preguntas abiertas donde el usuario busca adquirir conocimiento general; consultas navegacionales: consultas donde el objetivo es encontrar una página específica; y consultas transaccionales: consultas orientadas a completar una acción. Esta diversidad asegura que los métodos sean efectivos en una variedad de tareas de recuperación, desde búsquedas generales hasta necesidades específicas.
- Uso en el estado del arte: Seleccionar datasets ampliamente utilizados en investigaciones previas permite que los resultados del proyecto sean comparables con estudios existentes, lo que refuerza la validez del análisis comparativo y asegura que las metodologías empleadas cumplan con estándares científicos.
- Tamaño adecuado: La inclusión de datasets de diferentes tamaños permite evaluar el comportamiento de los métodos en escenarios con distintos volúmenes de datos, en donde los datasets pequeños son ideales para pruebas controladas y rápidas, mientras que los grandes, son útiles para analizar la escalabilidad y robustez de los métodos. Este enfoque asegura que los métodos QPP seleccionados sean evaluados en condiciones que reflejen tanto la simplicidad como la complejidad de los sistemas de recuperación de información modernos.

- Relevancias conocidas (qrels): Los juicios de relevancia son esenciales para evaluar el desempeño de los métodos de manera objetiva, al incluir datasets con qrels bien establecidos, se garantiza que los resultados estén basados en un marco estandarizado, facilitando su interpretación y comparación

Es así como la aplicación de estos criterios garantiza que los datasets seleccionados sean adecuados para el análisis comparativo de los métodos QPP, de igual forma, al priorizar la diversidad, relevancia y representatividad, este proyecto establece una base sólida para evaluar el desempeño de los métodos en diferentes contextos y escalas, contribuyendo al avance del estado del arte en predicción del rendimiento de consultas.

4.2.2 Justificación de los conjuntos de datos seleccionados

Como se ha mencionado, los datasets seleccionados para el proyecto fueron escogidos cuidadosamente para garantizar que cubran una amplia gama de escenarios y dominios representativos, por lo que se alinean con los criterios de inclusión previamente establecidos, aportando características únicas que permiten evaluar el rendimiento de QPP en contextos diversos, asegurando resultados generalizables y relevantes para investigaciones futuras, además de contribuir al avance del estado del arte.

A continuación, se presenta la Tabla 4.4 con los datasets seleccionados, seguida de un análisis más detallado de su contribución al presente proyecto.

Tabla 4.4: Tabla de datasets y sus criterios de inclusión

Dataset	Descripción	Contribución al proyecto	Razón de inclusión
Cranfield	Dataset clásico con resúmenes científicos y consultas predefinidas de tamaño reducido.	Facilita pruebas rápidas y controladas para la comparación directa de métodos QPP.	Simplicidad y diseño compacto lo hacen ideal para experimentos iniciales y controlados.
MS MARCO (Passage)	Contiene pasajes derivados de	Proporciona un entorno realista	Refleja el contexto de búsqueda

Dataset	Descripción	Contribución al proyecto	Razón de inclusión
	consultas reales con relevancias asignadas por evaluadores humanos.	y variado para probar la aplicabilidad práctica de los métodos.	quedra cotidiana, crucial para evaluar escenarios reales de recuperación
Antique/Test	Dataset centrado en la recuperación de preguntas y respuestas subjetivas basadas en opiniones.	Evalúa el desempeño de los métodos frente a consultas subjetivas y no factuales.	Introduce complejidad adicional al incorporar preguntas subjetivas difíciles de modelar.
BEIR-TREC-COVID	Parte del benchmark BEIR, centrado en la recuperación de información médica sobre COVID-19.	Permite evaluar los métodos QPP en un dominio altamente especializado y relevante.	Su enfoque en consultas científicas lo hace adecuado para escenarios de alta especificidad.
CAR (Complex Answer Retrieval, Fold 0)	Subconjunto del TREC CAR enfocado en consultas complejas derivadas de la estructura de Wikipedia.	Permite probar los métodos en escenarios con alta complejidad semántica sin sobrecargar el análisis.	Representa consultas avanzadas que requieren modelado detallado, ampliando la diversidad de pruebas.

- **Cranfield:** Este dataset es ideal para experimentos iniciales debido a su tamaño reducido y estructura sencilla, al contener resúmenes científicos y consultas predeterminadas, facilita una evaluación controlada de los métodos QPP, permitiendo identificar rápidamente patrones de comportamiento y limitaciones. Su simplicidad permite analizar la precisión básica de los métodos y sirve como línea base para experimentos más complejos.

- **MS MARCO (Passage):** Proporciona un entorno realista donde las consultas derivan de necesidades cotidianas de usuarios reales, sus relevancias asignadas por evaluadores humanos lo convierten en un recurso clave para probar la aplicabilidad práctica de los métodos QPP. Evalúa la capacidad de los métodos para manejar consultas informacionales y transaccionales en contextos cotidianos. [9].
- **Antique/Test:** Este dataset introduce complejidad al centrarse en preguntas y respuestas subjetivas basadas en opiniones, lo que plantea un desafío adicional para los métodos QPP al modelar consultas no factuales. Analiza cómo los métodos manejan preguntas subjetivas y abiertas, evaluando su capacidad para predecir el rendimiento en dominios con alta variabilidad semántica [10].
- **BEIR-TREC-COVID:** Su enfoque en consultas científicas relacionadas con COVID-19 lo hace altamente relevante para escenarios especializados donde la precisión y la especificidad son esenciales. Evalúa el rendimiento de los métodos en un dominio crítico donde la información relevante es escasa y de alta relevancia. [11].
- **CAR (Complex Answer Retrieval):** Al estar enfocado en consultas complejas derivadas de la estructura de Wikipedia, este dataset permite analizar cómo los métodos QPP manejan escenarios con alta complejidad semántica. Mide la capacidad de los métodos para predecir el rendimiento en consultas que requieren una interpretación profunda y modelado avanzado. [12].

Además, todos los datasets utilizados son de acceso abierto en repositorios públicos y están bien documentados debido a que son ampliamente reconocidos en la comunidad de recuperación de información, lo que asegura que cualquier investigador pueda acceder a ellos sin restricciones para replicar los experimentos. Es así que, la utilización de datasets de acceso abierto garantiza que los resultados del proyecto sean reproducibles y accesibles para futuras investigaciones, fomentando el entorno colaborativo y transparente, evitando problemas legales o éticos relacionados con el uso de datos restringidos o privados.

De esta forma, la selección de datasets con características bien definidas asegura una evaluación diversa y representativa de los métodos QPP seleccionados, ya que este enfoque cubre dominios especializados, tareas cotidianas y casos complejos, estableciendo una base sólida para validar la efectividad y aplicabilidad de los métodos en diferentes contextos de recuperación de información.

4.3 Entorno experimental

En esta sección se describe la configuración del entorno experimental desarrollado

para llevar a cabo la evaluación comparativa de los métodos de Query Performance Prediction (QPP), incluyendo el flujo de los experimentos, las configuraciones técnicas específicas, y las métricas empleadas para la evaluación.

El entorno experimental está diseñado para garantizar la reproducibilidad, flexibilidad y transparencia. Para lograrlo, se ha implementado un entorno basado en capas, y reproducible en Docker, que permite ejecutar los experimentos de manera consistente y controlada, sin depender de configuraciones específicas de hardware o software.

4.3.1 Flujo del sistema




Figura 4.1: Diagrama de componentes del entorno de evaluación

Como se puede apreciar en la Figura 4.1, el diseño experimental sigue un flujo bien definido para garantizar la reproducibilidad y el análisis riguroso de los resultados. El flujo incluye los siguientes pasos principales:

- **Preparación de Datasets:** Los datasets seleccionados, como Cranfield o Antique, se descargan utilizando la librería `ir_datasets` y se preprocesan en el entorno Docker, este proceso incluye la extracción de consultas, preparación

de los juicios de relevancia (qrels) y el formateo adecuado para su uso con PyTerrier.

- **Indexado de Datasets:** Los datasets se indexan utilizando PyTerrier, creando estructuras de datos eficientes para la recuperación de información. Es también en este paso donde se guardan metadatos de los datasets, como la frecuencia de los términos en los documentos como la frecuencia de estos en la colección. Además, se hace uso del “Stemmer» de Snowball sobre los documentos y consultas, para conseguir resultados más precisos en la evaluación.
- **Configuración de Modelos de Recuperación:** Configuración de modelos de recuperación como estándar como BM25 en PyTerrier con parámetros predefinidos, asegurando una base consistente para la evaluación de los métodos QPP.
- **Implementación de los métodos QPP:** Los métodos seleccionados, como, por ejemplo, IDF, SCQ o NQC, se implementan mediante scripts en Python dentro del contenedor Docker, todos estos utilizan una interfaz similar dentro del sistema, permitiendo una ejecución estandarizada de los métodos.
- **Ejecución de los métodos de predicción:** Los experimentos se realizan mediante un script principal que realiza múltiples iteraciones por método y dataset, asegurando estabilidad y fiabilidad de los resultados.
- **Evaluación utilizando juicios de relevancia (qrels):** Se realiza una evaluación del rendimiento de las consultas utilizando la librería de `ir_measures` sobre el sistema de recuperación implementado, esto es el “ground truth» o «verdadero valor» del rendimiento de la consulta en el sistema de recuperación implementado. Posteriormente los resultados se almacenan en formato estructurado para su posterior análisis.
- **Evaluación utilizando métricas de correlación:** Se realiza una evaluación de la correlación entre los puntajes de los predictores y las métricas IR, utilizando la librería de Scipy, para obtener una medida de la efectividad de los predictores QPP con relación al “ground truth».
- **Documentación y Almacenamiento:** Los resultados, configuraciones y scripts de ejecución se almacenan en directorios organizados dentro del contenedor Docker, garantizando su fácil acceso y análisis.

Entre los componentes de la Figura 4.1, se puede discernir la capa de datos, de indexación y recuperación. Estos componentes funcionan completamente dentro de la librería Pyterrier, el cual funciona como un «wrapper» para la librería Terrier, la cual es ampliamente utilizada en la literatura de recuperación de información para la realización de experimentos similares. [13]

4.3.2 Configuración técnica

- **Entorno Docker:** Al permitir encapsular todas las dependencias necesarias en un entorno reproducible, se evitan problemas de compatibilidad y configuración entre máquinas, asegurando que los experimentos puedan ser ejecutados de manera uniforme y reproducible.

El sistema utiliza una imagen base de Python 3.9 con Java 11 instalado para soportar PyTerrier.

- **Parámetros del Modelo de Recuperación:**

El sistema utiliza el modelo de recuperación BM25 (Best Match 25) como método principal de recuperación. Los parámetros han sido mantenidos en su configuración por defecto . Su definición se puede observar en la Tabla 4.5

Tabla 4.5: Parámetros principales de BM25

Parámetro	Descripción	Justificación de Aplicación	Valor
k1	Factor de saturación de término. Controla cómo el score de un documento aumenta con cada ocurrencia adicional de un término de la consulta. Un valor más alto significa que se da más importancia a la frecuencia del término.	Crucial para colecciones con documentos que contienen repeticiones significativas de términos. Afecta directamente el cálculo de scores en métodos QPP post-recuperación como WIG.	1.2
b	Factor de normalización de longitud del documento. Determina cuánto se penalizan los documentos más largos. Un valor más alto significa una normalización más agresiva de la longitud.	Especialmente importante en colecciones heterogéneas como ANTIQUE donde la longitud de los documentos varía significativamente. Impacta el cálculo de NQC al normalizar los scores.	0.75

Otros estudios han propuesto la utilización de otros parámetros para BM25, como el parámetro k_1 , el cual controla la saturación de términos en los documentos, sobretodo al utilizar métodos de clustering, tales experimentos han demostrado que un valor de k_1 mayor a 1.2 puede mejorar el rendimiento de la recuperación. Sin embargo, en este estudio se mantendrán los parámetros por defecto de PyTerrier, ya que se ha demostrado que estos proporcionan un rendimiento adecuado para la mayoría de las tareas de recuperación de información, pero se puede realizar un estudio futuro sobre la utilización de estos parámetros en la evaluación de métodos QPP. [14]

- **Ejecución de los métodos y scripts de evaluación:**

La Tabla 4.6 sistema permite una configuración flexible de la ejecución de la evaluación a través de diversos parámetros que controlan tanto el proceso de recuperación como la evaluación QPP. La configuración se realiza principalmente mediante argumentos de línea de comandos y variables de entorno.

Tabla 4.6: Parámetros principales de configuración

Parámetro	Descripción	Valor por defecto
<code>-datasets</code>	Datasets a evaluar (e.g., <code>antique_test</code> , <code>iquique_small</code>)	Todos los datasets
<code>-max-queries</code>	Límite de consultas a procesar	None (todas)
<code>-list-size</code>	Tamaño de lista para métricas de ranking	10
<code>-wig-list-size</code>	Tamaño de lista para el predictor WIG	5
<code>-nqc-list-size</code>	Tamaño de lista para el predictor NQC	200
<code>-num-results</code>	Número máximo de resultados por consulta	1000
<code>-metrics</code>	Métricas de evaluación (e.g., <code>ndcg@10</code> , <code>ap</code>)	<code>nDCG@10</code> , <code>AP</code>
<code>-correlations</code>	Coeficientes de correlación a calcular (Kendall, Spearman, Pearson)	<code>kendall</code>

-use-uef	Habilita las variantes utilizando el marco UEF (Utility Estimation Framework)	False
-skip-plots	Omite la generación de visualizaciones	False
-output-dir	Directorio de salida para los resultados	None

La ejecución se puede realizar tanto directamente a través de Python como mediante contenedores Docker, donde los parámetros se configuran a través de variables de entorno. El sistema utiliza valores por defecto seleccionados para garantizar una evaluación robusta incluso con configuración mínima.

• **Almacenamiento de Resultados:**

Los resultados de la evaluación se almacenan en una estructura organizada dentro del directorio del proyecto. Las métricas de IR (nDCG, AP) se guardan por consulta en archivos de texto plano, mientras que las correlaciones entre predictores QPP y métricas se almacenan en formato tabular, acompañadas de visualizaciones (diagramas de caja y de dispersión) generadas automáticamente.

La evaluación final integra estos resultados mediante un análisis bidimensional: (1), midiendo la efectividad del sistema de recuperación base, medida a través de las métricas IR por consulta, y (2), midiendo la capacidad predictiva de los métodos QPP, cuantificada mediante coeficientes de correlación por rangos entre los puntajes de los predictores y las métricas IR. Una mayor correlación significa que los puntajes de los predictores son confiables para predecir el rendimiento del sistema de recuperación.

• **Métricas Utilizadas:**

Para el desarrollo de esta evaluación se decanto por el uso de métricas de evaluación que cuentan con una presencia amplia en la literatura, por un lado se decantó por el uso nDCG y AP, las cuales son ampliamente utilizadas en tareas de ranking y precisión proporcionan una medida del rendimiento del sistema de recuperación. Por otro lado, se decantó por el uso de métricas de correlación para la predicción de rendimiento de consultas, como el coeficiente de correlación de Kendall y Spearman, las cuales son ampliamente utilizadas en la literatura y proporcionan una medida de la efectividad de los predictores QPP. [15]

En el contexto de la evaluación de sistemas de recuperación de información, las métricas binarias como Average Precision (**AP**) requieren una distinción clara entre

documentos relevantes y no relevantes. Para lograr esto, se establece un umbral binario sobre los niveles de relevancia originales del dataset, donde los documentos con un nivel de relevancia igual o superior al umbral se consideran relevantes, mientras que aquellos por debajo se consideran no relevantes. Este enfoque permite evaluar el rendimiento del sistema en términos de su capacidad para distinguir entre documentos relevantes y no relevantes.

Por otro lado, las métricas graduadas como el Normalized Discounted Cumulative Gain (nDCG) aprovechan la naturaleza multi-nivel de los juicios de relevancia mediante valores de ganancia. Estos valores representan la utilidad o importancia relativa de cada nivel de relevancia, donde un valor más alto indica una mayor relevancia del documento. La asignación de valores de ganancia es crucial ya que influye directamente en cómo la métrica evalúa la calidad del ranking, penalizando más severamente cuando documentos altamente relevantes (con mayor valor de ganancia) aparecen en posiciones más bajas del ranking. En la Tabla 4.7 se detalla la configuración específica de relevancia y valores de ganancia para cada dataset:

Tabla 4.7: Configuración de métricas por dataset

Dataset	Configuración	Justificación
ANTIQUE	• Relevancia: 4 niveles (1-4) • Umbral binario: ≥ 3 • Valores de ganancia: ▸ Nivel 1: 0.0 ▸ Nivel 2: 0.0 ▸ Nivel 3: 0.5 ▸ Nivel 4: 1.0	Escala más granular que permite distinguir entre documentos marginalmente relevantes (3) y altamente relevantes (4). Los niveles 1-2 se consideran no relevantes para métricas binarias.
Iquique Dataset	• Relevancia: 3 niveles (0-2) • Umbral binario: ≥ 1 • Valores de ganancia: ▸ Nivel 0: 0.0 ▸ Nivel 1: 1.0 ▸ Nivel 2: 2.0	Escala más simple que diferencia entre no relevante (0), relevante (1) y altamente relevante (2). Utiliza una escala lineal para el cálculo de nDCG.

Para el análisis de correlación, el sistema implementa tres coeficientes (τ -Kendall, ρ -Spearman, r -Pearson), pero prioriza τ -Kendall por:

- **Interpretabilidad:** Mide directamente la proporción de pares concordantes vs discordantes
- **Robustez:** Menos sensible a valores atípicos y transformaciones monótonas
- **Normalización:** Rango consistente $[-1,1]$ independiente de la distribución
- **Significancia:** Mejor comportamiento con muestras pequeñas

Además dentro de la literatura se ha discutido sobre el rendimiento e interpretabilidad de otros coeficientes, como el coeficiente de correlación de Pearson, el cual es menos robusto que τ -Kendall y Spearman, y su uso ha sido desestimado en favor de las anteriormente mencionadas. [16]

La implementación utilizara la librería `ir_measures` para garantizar cálculos estandarizados de las métricas IR, mientras que Scipy proporciona implementaciones eficientes de los coeficientes de correlación. El sistema maneja automáticamente casos especiales como queries sin resultados o scores QPP indefinidos, asegurando una evaluación robusta incluso en condiciones no ideales.

4.4 Relación entre diseño experimental y objetivos

El diseño experimental anteriormente expuesto está directamente alineado con los objetivos planteados, garantizando que cada etapa contribuya de forma directa al cumplimiento de las metas establecidas. Es por ello que, en esta sección, se describe la relación entre los elementos del diseño experimental y los objetivos general y específicos, resaltando cómo estos interactúan entre sí para alcanzar los resultados de análisis buscados.

4.4.1 Relación con el objetivo general

Como se ha mencionado en capítulos anteriores, el objetivo general del proyecto consiste en evaluar comparativamente métodos de Query Performance Prediction (QPP) para búsquedas Ad-hoc utilizando métricas de correlación. En alineación con este objetivo, el diseño se ha organizado en las siguientes etapas:

- **Selección de Métodos QPP:** Se han seleccionado seis métodos QPP no basados en inteligencia artificial (IDF, SCQ, NQC, Clarity Score, WIG y UEF) que son ampliamente reconocidos en la literatura y representan enfoques tanto pre-retrieval como post-retrieval.
- **Selección de Datasets:** Se han elegido cinco datasets (Cranfield, MS MARCO Passage, Antique/Test, BEIR-TREC-COVID y CAR Fold 0) que cubren una amplia gama de dominios y tipos de consultas, asegurando que los resultados sean generalizables.

- **Implementación y Evaluación:** Los métodos QPP se implementan en un entorno controlado utilizando herramientas como PyTerrier, Docker e `ir_datasets`, por lo que la evaluación se realiza mediante métricas de correlación y juicios de relevancia.
- **Análisis de Resultados:** Los resultados obtenidos se comparan con estudios previos para determinar la efectividad de los métodos y establecer una línea base para futuras investigaciones.

La Tabla 4.8 resume la relación entre el diseño experimental y cómo contribuye al objetivo general.

Tabla 4.8: Relación entre diseño experimental y objetivos

Etapa del diseño experimental	Contribución al objetivo general
Selección de Métodos QPP	Garantiza que los métodos evaluados sean representativos y relevantes para búsquedas Ad-hoc.
Selección de Datasets	Permite evaluar los métodos en diferentes contextos y dominios, asegurando la generalización de los resultados.
Implementación y Evaluación	Proporciona una evaluación comparativa robusta utilizando métricas de correlación estandarizadas.
Análisis de Resultados	Establece una línea base para futuras comparaciones con nuevos enfoques.

4.4.2 Alineación con los Objetivos Específicos

A continuación, se describe cómo cada objetivo específico se relaciona con el diseño experimental.

El primer objetivo específico del proyecto corresponde a:

a) **Revisar la literatura sobre métodos de QPP en búsquedas Ad-hoc sin el uso de inteligencia artificial.**

Este objetivo se aborda mediante una revisión exhaustiva de trabajos y artículos académicos y experimentales relevantes, priorizando métodos no basados en IA que han sido ampliamente estudiados y documentados, lo que asegura que los métodos

seleccionados sean representativos y relevantes para el contexto de búsquedas Ad-hoc.

El segundo objetivo específico del proyecto corresponde a:

b) Comparar los resultados de los métodos QPP con estudios previos.

Se utilizan métricas de correlación estandarizadas y juicios de relevancia para evaluar el rendimiento de los métodos QPP. Estas métricas son ampliamente aceptadas en la literatura y permiten una comparación directa con estudios previos.

El tercer objetivo específico del proyecto corresponde a:

c) Implementar métodos QPP en búsquedas Ad-hoc sin inteligencia artificial para su evaluación utilizando métricas estandarizadas

La implementación de los métodos se realiza en un entorno experimental controlado utilizando contenedores Docker, que aseguran la replicabilidad y la consistencia en la ejecución de los experimentos con ayuda de scripts en Python, lo que permite una evaluación precisa y reproducible.

El cuarto objetivo específico del proyecto corresponde a:

d) Evaluar los resultados obtenidos de los métodos QPP implementados, determinando su efectividad en función de los resultados descritos en el estado del arte.

La evaluación se realiza comparando las predicciones generadas por los métodos seleccionados con los juicios de relevancia (qrels) asociados a cada dataset, utilizando métricas de correlación como Kendall's Tau. Este análisis permite determinar las fortalezas y limitaciones de cada método en contextos específicos.

El quinto y último objetivo corresponde a:

e) Analizar y documentar el rendimiento de los métodos QPP implementados para establecer una línea base para futuras comparaciones con nuevos enfoques

Los resultados obtenidos se documentan detalladamente, incluyendo las métricas de correlación obtenidas para cada método QPP en cada dataset. Esta documentación sirve como una línea base para futuras investigaciones, permitiendo que otros investigadores comparen nuevos métodos con los resultados obtenidos en este proyecto.

Tabla 4.9: Relación entre diseño experimental y objetivos

Objetivo específico	Elemento del diseño experimental
a)	Revisión de literatura y selección de métodos representativos
b)	Selección de datasets reconocidos y herramientas de evaluación estandarizadas.
c)	Implementación de métodos QPP en entornos replicables.
d)	Evaluación de predicciones mediante métricas de correlación y juicios de relevancia.
e)	Documentación y análisis de resultados en función de los objetivos del proyecto.

Como se observa en la Tabla 4.9, el diseño experimental del proyecto está cuidadosamente alineado con los objetivos del proyecto, en donde la selección de métodos QPP, la elección de datasets, la implementación en un entorno controlado y el uso de métricas de correlación estandarizadas garantizan que los resultados sean robustos, reproducibles y relevantes para el campo de la predicción del rendimiento de consultas, resultando en un enfoque que no solo cumple con los objetivos del proyecto, sino que también establece una base sólida para futuras investigaciones en QPP.

CAPÍTULO V: IMPLEMENTACIÓN

La implementación del entorno de evaluación representa la materialización del diseño experimental previamente descrito. Este capítulo detalla los aspectos técnicos y prácticos del desarrollo, abordando desde la configuración del entorno hasta la implementación específica de cada componente del sistema.

El desarrollo se fundamenta en tres pilares principales: el sistema de recuperación de información, la implementación de los métodos QPP, y el framework de evaluación. Como se puede observar en la Tabla 5.1, cada uno de estos componentes requiere consideraciones técnicas específicas y se integran para formar un sistema cohesivo y reproducible.

Tabla 5.1: Componentes principales del sistema implementado

Componente	Consideraciones principales
Sistema de recuperación	• Implementación de BM25 como algoritmo base • Indexación eficiente de documentos • Procesamiento de consultas
Métodos QPP	• Implementación de predictores pre y post-retrieval • Manejo de dependencias entre componentes • Cálculo eficiente de estadísticas
Framework de evaluación	• Procesamiento de juicios de relevancia • Cálculo de métricas de evaluación • Análisis de correlaciones • Generación de visualizaciones

La implementación se realizó priorizando la modularidad y la reproducibilidad, utilizando herramientas y bibliotecas ampliamente reconocidas en el campo de la recuperación de información. El sistema se desarrolló completamente en Python, aprovechando un conjunto de bibliotecas especializadas cuyas funciones principales se detallan en la Tabla 5.2. Estas herramientas fueron seleccionadas por su madurez, documentación y amplia adopción en la comunidad de recuperación de información.

Tabla 5.2: Stack tecnológico principal

Aspecto	Herramienta/Biblioteca	Propósito
Recuperación	PyTerrier	Indexación y búsqueda de documentos
Datasets	ir_datasets	Acceso a colecciones estándar
Evaluación	ir_measures	Cálculo de métricas IR
Estadísticas	scipy, numpy	Análisis de correlaciones
Visualización	matplotlib, seaborn	Generación de gráficos

A continuación, se detallan los aspectos específicos de la implementación, comenzando con la configuración del entorno experimental y continuando con la implementación de cada componente del sistema.

5.1 Configuración del entorno experimental

El entorno experimental se encuentra configurado para ser ejecutado en un variedad de entornos debido a la utilización de Docker, el cual permite la ejecución de entornos virtuales en diferentes sistemas operativos. De manera general y para preservar la reproducibilidad de los resultados, se ha configurado el entorno experimental para ser ejecutado en un sistema operativo Linux, utilizando Python 3.9.21 y PyTerrier 0.13.0.

Tabla 5.3: Configuración del entorno experimental

Componente	Descripción	Versión
Docker	Contenedor de entornos virtuales	25.0.5
Python	Lenguaje de programación	3.9.21
PyTerrier	Librería de recuperación de información	0.13.0 más snapshot para el soporte de modelos de relevancia
IR-datasets	Librería de conjuntos de datos	0.5.9

Como se puede apreciar en la Tabla 5.3, se ha optado por implementar el entorno experimental en componentes de software con versiones específicas y estables,

esperando lograr la mayor reproducibilidad posible de los resultados. La ejecución también es posible en sistemas operativos Windows y MacOS, pero estas cuentan con procesos de instalación y configuración mas complejos.

5.1.1 Docker y dependencias

Docker es la principal herramienta que permite la ejecución del entorno experimental, esta cuenta con una amplia gama de herramientas que permiten la ejecución de entornos virtuales en diferentes sistemas operativos. Para los propósitos de este trabajo, se ha optado por imágenes de docker basados en la versión Slim Buster de Debian, la cual destaca en su ligereza y velocidad de ejecución.

Dockerfile

```
1  # Imagen Debian optimizada para Python
2  FROM python:3.9-slim-buster
3
4  # Configuraciones de entorno
5  ENV LANG=C.UTF-8
6  ENV LC_ALL=C.UTF-8
7  ENV JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
8  ENV PATH="$JAVA_HOME/bin:$PATH"
9
10 # Instalación de Java y otras dependencias
11 RUN apt-get update && \
12     apt-get install -y openjdk-11-jdk && \
13     apt-get install -y --no-install-recommends \
14     build-essential \
15     && apt-get clean && \
16     rm -rf /var/lib/apt/lists/*
17 ...
```

Figura 5.1: Dockerfile para la configuración del entorno experimental

La Figura 5.1 muestra el archivo Docker utilizado para la configuración del entorno experimental, este Dockerfile se encuentra disponible en el repositorio de GitHub del proyecto. En este se especifican las principales dependencias y configuraciones de entorno necesarias para la ejecución del entorno experimental.

Tabla 5.4: Componentes principales del Dockerfile

Componente	Descripción
Imagen base	Python 3.9 slim-buster - Versión ligera de Debian optimizada para Python
Configuración UTF-8	Establece codificación UTF-8 para el manejo correcto de caracteres especiales y términos en diferentes idiomas presentes en los datasets, esto en la practica es necesario para evitar errores de procesamiento de tokens.
JDK 11	Java Development Kit necesario para PyTerrier, ya que este utiliza componentes Java para el procesamiento e indexación de documentos
Build essentials	Herramientas básicas de compilación necesarias para algunas dependencias de Python

La Tabla 5.4 muestra los componentes esenciales para la configuración y ejecución del entorno experimental. Diversos errores fueron enfrentados debido a la codificación de caracteres durante las primeras pruebas del entorno, especialmente al procesar términos con caracteres especiales o diacríticos presentes en los datasets. La configuración explícita de UTF-8 en el contenedor Docker resultó fundamental para asegurar el correcto procesamiento de los documentos y consultas, evitando problemas de codificación que podrían afectar la calidad de la indexación y, por ende, los resultados de la evaluación.

5.1.2 Integración de conjuntos de datos

Como se explico anteriormente, los conjuntos de datos utilizados en este trabajo se encuentran disponibles en la librería IR-datasets, la cual cuenta con una amplia gama de conjuntos de datos tanto clásicos como modernos de recuperación de información junto a sus consultas y respectivos juicios de relevancia.

Cada dataset cuenta con una cantidad de documentos y consultas disponibles para realizar la evaluación, por otro lado los juicios de relevancia o “Qrels” suponen un desafío extra para la implementación de la evaluación, puesto que cada dataset cuenta con distintos niveles de relevancia para las consultas, lo cual si no se maneja adecuadamente puede alterar drásticamente los resultados de la correlación.

Esto es así puesto a que la evaluación clásica de métodos IR se basa en el cálculo de métricas como nDCG, AP, MAP, etc, las cuales dependen de los juicios de relevancia actuando como *ground truth* para su cálculo.

```
1 DATASET_FORMATS = {
2     "antique_test": {
3         "relevance_levels": {
4             1: "Out of context/nonsensical",
5             2: "Not relevant but on topic",
6             3: "Marginally relevant",
7             4: "Highly relevant"
8         },
9         "binary_threshold": 3, # Puntajes >= 3 son
                                # considerados relevantes para las métricas binarias
10        "gain_values": { # Valores de ganancia para nDCG
11            1: 0,
12            2: 1,
13            3: 2,
14            4: 3
15        }
16    }
```

Figura 5.2: Configuración de formato de dataset

La Figura 5.2 muestra la configuración específica para el dataset antique_test, donde se definen cuatro niveles de relevancia (1-4) con sus respectivas descripciones semánticas. Esta configuración es importante por dos razones principales: primero, establece un umbral binario en 3 para las métricas que requieren juicios binarios (como Precision y Recall), considerando como relevantes solo los documentos con puntuaciones de 3 o 4. Segundo, define valores de ganancia específicos para el cálculo de nDCG, donde se asigna diferentes valores de ganancia en cada nivel. Esta diferenciación en el manejo de los niveles de relevancia es fundamental para obtener evaluaciones precisas, ya que un manejo inadecuado de estos valores podría llevar a distorsiones significativas en el cálculo de las métricas de evaluación y, consecuentemente, afectar la correlación con los predictores QPP. Por ejemplo, si no se estableciera el umbral binario adecuadamente o se asignaran valores de ganancia incorrectos, documentos marginalmente relevantes podrían tener el mismo peso que documentos altamente relevantes en el cálculo de las métricas, lo que no reflejaría fielmente la calidad real de los resultados de búsqueda.

5.1.3 Indexación y consultas

El proceso de indexación utilizado para la evaluación es el estándar de PyTerrier mediante la construcción de un índice invertido a partir de un corpus de documentos. Este índice invertido es utilizado para la recuperación de documentos relevantes para una consulta, utilizando el algoritmo BM25. Durante el tiempo de indexado, se realiza la tokenización de los documentos y consultas, aplicando un algoritmo de stemming y eliminación de “stopwords” para la normalización de los datos.

5.2 Implementación de métodos QPP

La implementación de los métodos QPP difiere en las dos categorías en la que se dividen los “métodos”, pre-retrieval y post-retrieval, el primer caso solo cuenta con una dependencia para su implementación, la cual es el índice invertido generado a partir de un corpus de documentos. Mientras que en el segundo caso, cuenta con dos, el índice invertido generado a partir de un corpus de documentos y los resultados de un sistema de recuperación de información en respuesta a una consulta.

```
1  # Creación del factory de métodos QPP
2  qpp_factory = QPPMethodFactory(
3      index_builder=index_builder,
4      retrieval_results=retrieval_results,
5      rm_results=rm_results_df,
6      dataset_name=dataset_path
7  )
8
9  # Computo de los puntajes de los métodos QPP
10 qpp_scores = qpp_factory.compute_all_scores(
11     queries=queries,
12     list_size_param=args.list_size
13 )
```

Figura 5.3: Código de implementación del factory de métodos QPP




Figura 5.4: Diagrama de la capa de métodos QPP

Para cumplir con los requisitos de los métodos QPP, se ha implementado un factory, el cual se encarga de la creación y computo de los puntajes de los métodos QPP. Este factory se encarga de tomar las dependencias necesarias y entregarlas a los métodos QPP, para que estos puedan ser computados.

Para la implementación de los métodos QPP, se ha utilizado un enfoque mixto, tanto utilizando código abierto como propio, para la satisfacer las necesidades de la evaluación a realizar. Todo el código utilizado se encuentra disponible en el repositorio de GitHub de este trabajo, el cual se puede encontrar en el repositorio² de el usuario **Zendelo** en GitHub.

5.2.1 Métodos pre-retrieval

En esta categoría se implementaron dos de los métodos más utilizados en las evaluaciones de la literatura, por un lado se encuentra el método IDF, el cual se basa en la frecuencia de los términos en los documentos, y por otro lado se encuentra el método SCQ, el cual se basa en la similitud de la consulta a los documentos de la colección.

Ambos métodos cuentan con variaciones, ya sea el valor promedio de los términos de la consulta, o alternativamente el valor máximo de los términos de la consulta. Estas variaciones son utilizadas en diferentes evaluaciones y se ha optado por implementar ambas en el entorno experimental.

²<https://github.com/Zendelo/QPP-EnhancedEval/tree/qpptk-dev>

5.2.2 Métodos post-retrieval

En esta categoría se considero una mayor gama de predictores, desde métodos semi-nales del campo como Clarity, hasta frameworks mas recientes como UEF. Estos métodos requieren de una dependencia extra, la cual es el resultado de un sistema de recuperación de información en respuesta a una consulta.

```
1 def calc_wig(self, list_size_param):
2     """
3     Calculates the WIG score following Zhou and Croft's method.
4     Y. Zhou and W. B. Croft. Query performance prediction in
5     web search environments
6     """
7     scores_vec = self.scores_vec[:list_size_param]
8     if self.corpus_score == 0:
9         print("Corpus score is zero; returning WIG score as 0.0
10              to avoid division by zero.")
11         return 0.0
12     wig_score = (scores_vec.mean() - self.ql_corpus_score) /
13                 np.sqrt(len(self.query_terms))
14     return wig_score
```

Figura 5.5: Implementación del método WIG

La Figura 5.5 muestra la implementación del método post-retrieval WIG, en este podemos identificar tanto el uso del índice invertido como el resultado de el puntaje del modelo de recuperación de información frente a toda la colección como se puede apreciar en la Ecuación (3.5). Adicionalmente se puede observar parámetros como el tamaño de la lista de documentos a considerar, el cual fue definido como 5 para WIG y en 200 para NQC bajo la recomendación de la literatura y nuestros propios experimentos. [4, 5, 17] Para finalizar, también cabe mencionar que todas los puntajes fueron considerando el puntaje promedio de los 1000 primeros documentos de la lista de resultados.

5.3 Implementación de la evaluación

La implementación de la evaluación de los métodos QPP se realiza mediante un analizador de correlaciones que permite calcular y visualizar las relaciones entre los puntajes de predicción y las métricas de rendimiento real del sistema. Este analizador está diseñado para procesar los resultados de múltiples métodos QPP y métricas de recuperación, generando análisis estadísticos y visualizaciones que facilitan la interpretación de los resultados.

5.3.1 Cálculo de correlaciones

El análisis se basa principalmente en el cálculo de coeficientes de correlación entre los puntajes QPP y las métricas de recuperación (nDCG y AP). Se implementaron tres tipos de correlaciones:

- Correlación de Pearson: Mide la relación lineal entre las variables
- Correlación de Spearman: Evalúa la relación monótona entre variables usando rangos
- Correlación de Kendall (τ): Mide la ordinalidad entre pares de observaciones

La significancia estadística de las correlaciones se verifica mediante pruebas de hipótesis, considerando un nivel de significancia de $\alpha \leq 0.05$. Las correlaciones no significativas son registradas pero marcadas apropiadamente en los reportes.

5.3.2 Visualización de resultados

Para facilitar la interpretación de los resultados, se implementaron tres tipos principales de visualizaciones como se puede observar en la Tabla 5.5, siguiendo la línea de otras evaluaciones. [7, 8, 16]

Tabla 5.5: Tipos de visualizaciones implementadas

Tipo de gráfico	Descripción
Mapas de calor	Muestran la matriz de correlaciones entre todos los métodos QPP y las métricas de evaluación, utilizando una escala de colores para representar la fuerza y dirección de las correlaciones
Diagramas de dispersión	Visualizan la relación entre cada método QPP y una métrica específica, incluyendo líneas de regresión para mejor interpretación
Diagramas de caja	Presentan la distribución de las correlaciones para cada método QPP, permitiendo comparar su estabilidad y rendimiento general

5.4 Pruebas de validación

La validación exhaustiva del sistema implementado se realizó mediante una suite completa de pruebas unitarias, diseñada para verificar el correcto funcionamiento de cada componente del entorno de evaluación. Se desarrolló un framework de

pruebas automatizado que permite la ejecución sistemática de casos de prueba y la generación de informes detallados.

5.4.1 Estructura de las pruebas

Las pruebas unitarias se organizaron en siete módulos principales, cada uno enfocado en un componente específico del sistema:

Tabla 5.6: Módulos principales de pruebas unitarias

Módulo de prueba	Aspectos evaluados
QPPCorrelationAnalyzer	Análisis de correlaciones, generación de visualizaciones y reportes estadísticos
Evaluator	Cálculo de métricas de evaluación (nDCG, AP)
Clarity	Implementación del predictor Clarity, incluyendo cálculos de KL-divergence
NQC	Funcionalidad del predictor NQC y cálculos de scores normalizados
WIG	Implementación del predictor WIG y procesamiento de scores
IDF	Cálculos de IDF y variantes de agregación
SCQ	Implementación del predictor SCQ y manejo de términos

5.4.2 Metodología de validación

La validación se realizó mediante un enfoque sistemático que incluye:

- **Pruebas de casos límite:** Verificación del comportamiento del sistema ante consultas vacías, términos desconocidos y valores extremos.
- **Validación de consistencia:** Comprobación de la coherencia en el procesamiento de términos y el stemming.
- **Pruebas de integración:** Verificación de la correcta interacción entre componentes, especialmente en el análisis de correlaciones.

- **Validación de métricas:** Comprobación de cálculos de nDCG y AP contra valores conocidos.

5.4.3 Resultados de la validación

La ejecución completa de la suite de pruebas, que comprende 50 casos de prueba distribuidos entre los diferentes módulos, demostró la robustez del sistema implementado. Como se evidencia en los resultados:

- Tasa de éxito del 100% en todos los módulos de prueba
- Tiempo total de ejecución de 11.27 segundos
- Cobertura completa de todos los componentes críticos del sistema

Tabla 5.7: Resultados de ejecución por componente

Componente	Pruebas ejecutadas	Tiempo de ejecución (s)
QPPCorrelationAnalyzer	10	8.25
Evaluator	6	0.05
Clarity	8	0.03
NQC	6	0.01
WIG	7	0.01
IDF	7	0.01
SCQ	6	0.01

La validación exhaustiva realizada confirma la fiabilidad y precisión del entorno de evaluación implementado, proporcionando una base sólida para los experimentos subsiguientes. El sistema demostró ser robusto ante diversos escenarios de prueba, manteniendo la consistencia en el procesamiento de consultas y el cálculo de métricas de evaluación.

CAPÍTULO VI: ANÁLISIS DE RESULTADOS

A traves de la literatura se ha establecido de manera casi unánime el análisis del rendimiento de los métodos QPP mediante el uso de métricas de correlación. Entre los primeros trabajos se puede encontrar el de E.M Voorhees en la conferencia TREC-6, donde se presenta el primer análisis de la capacidad de expertos en predecir el rendimiento de las consultas, donde se pudo observar que la mayor correlación lineal entre los resultados de los expertos fue de solo 0.26. [18].

El campo de la predicción del rendimiento de consultas se ha desarrollado a lo largo de los años, y se ha establecido el uso de juicios de relevancia y métricas como el tau de Kendall para la evaluación de los predictores. En este sentido, se encuentran dos puntos de interés, por un lado la evaluación del sistema de recuperación subyacente, y por otro la evaluación de los predictores utilizando como pre-requisito la evaluación del sistema de recuperación.

La configuración general utilizada para el experimento se presenta en la Figura 6.1:




Figura 6.1: Diagrama de flujo del análisis de resultados

Donde se puede observar que el proceso de evaluación involucra métricas de evaluación de recuperación clásicas como nDCG o AP, y más adelante, métricas de correlación de predictores como el tau de Kendall, el cual debido a su naturaleza no lineal, se presenta como una métrica más fuerte frente a otras métricas como el coeficiente de Pearson.

6.1 Resultados obtenidos en conjuntos de datos

Como se menciona anteriormente, previo a la evaluación de los métodos QPP, es necesario evaluar el sistema de recuperación subyacente, en este caso BM25 utilizando el conjunto de datos *antique test* y sus 4 niveles de relevancia para sus cerca de 200 consultas proporcionadas.




Figura 6.2: Diagrama de caja para las métricas nDCG y AP

En un primer vistazo a los resultados del experimento tenemos que la Figura 6.2 muestra que el sistema de recuperación BM-25 presenta un rendimiento mayor en la métrica nDCG@10 frente a las métrica AP. Ambos experimentos presentan un rango de resultados similar, desde el 0 y sin sobrepasar el 0.8 en ninguno de los casos.

Es posible observar la existencia de *outliers* en los resultados de la métrica AP, los cuales sobresalen muy por encima en comparación del ultimo cuartil de los resultados. Esto se puede interpretar a que ciertas consultas consiguen resultados muy altos en comparación a las demás, debido a ser frecuentemente representadas en los juicios de relevancia y en la colección de documentos.

La media de las métricas nDCG y AP se puede observar en la Figura 6.3, donde se puede observar que el sistema de recuperación BM-25 presenta un rendimiento

mucho mayor en la métrica $nDCG@10$ frente a los resultados de AP. Específicamente tenemos una media de 0.36 para $nDCG@10$ y 0.18 para AP, lo que evidencia la capacidad del sistema para rankear documentos en las 10 primeras posiciones sobre la precisión de la completitud de los documentos recuperados.




Figura 6.3: Media de las métricas $nDCG$ y AP

La Figura 6.4 sirve para complementar la información anterior dando una perspectiva más detallada de los resultados obtenidos. Se puede observar que para $nDCG@10$ tenemos una distribución ligeramente bimodal, una en 0.2-0.3 y otra en 0.5-0.7, esto se puede interpretar como dos grupos intrínsecamente distintos de consultas, el primero de ellos muestra un rendimiento de nuestro sistema de recuperación más bajo, mientras que el segundo es satisfactoriamente rankeado. Estos hallazgos pueden llevar evaluar que características de las consultas en estos grupos las hacen más fácil o difícil de rankear.




Figura 6.4: Histogramas de las métricas nDCG y AP

La Figura 6.5 muestra el gráfico de dispersión de los valores de nDCG@10 y AP, donde principalmente se puede apreciar la fuerte correlación ($r=0.84$) que existe entre ambas métricas, lo cual sugiere una calidad de recuperación similar entre ambos experimentos. Sin embargo algo interesante a tener en cuenta es el patrón «palo de hockey» que se forma entre las dos métricas. Esto apunta a que:

- En el rango inferior($nDCG@10 < 0.4$) tenemos rendimientos mas dispersos, donde una valor de nDCG@10 alto no necesariamente implica un valor de AP alto.
- En el rango superior($nDCG@10 > 0.6$) la relación se vuelve mas predecible. Cuando nuestro sistema de recuperación presenta un rendimiento alto en nDCG@10, el rendimiento en AP tiende a ser alto igualmente.

Finalmente el rango intermedio tenemos la ocurrencia de algunos *outliers*, como se menciono anteriormente, nDCG@10 presenta resultados mayores a AP, y en algunos casos estos pueden llegar a contar una diferencia significativa (0.6 vs 0.1).




Figura 6.5: Gráfico de dispersión de nDCG@10 vs AP

6.2 Comparación de métodos QPP

Los métodos QPP evaluados en esta sección fueron contrastados directamente con los resultados de la evaluación de la sección anterior realizada en el dataset *antique test* utilizando el coeficiente de correlación tau de Kendall.

La Figura 6.6 muestra el resultado general de la correlación en el tau de Kendall para los métodos QPP a través de las dos métricas nDCG@10 y AP. Empezando por el lado izquierdo del mapa de correlación tenemos los dos métodos pre-retrieval IDF y SCQ en sus variantes promedio y máximo, a posteriori, el resto de los métodos son de tipo post-retrieval, terminando por las variantes UEF de estos.




Figura 6.6: Correlación de los métodos QPP - tau de Kendall

También fueron computadas las correlaciones con el coeficiente de Pearson y Spearman, pero no se presentan en esta sección debido a que no presentan resultados significativamente distintos a los obtenidos en el tau de Kendall. Estos resultados se encuentran en el Anexo.

Se observa que la menor de las correlaciones la presenta el método IDF, el cual presenta una correlación no mayor de 0.05 en todas sus variantes. Este resultado viene fuertemente ligado al preprocesado tanto de los documentos como de las consultas, puesto que anteriormente el pipeline de procesado utilizaba el *stemmer* incorporado por pyterrier, el cual es el clásico *Porter Stemmer*. Los resultados de este fueron puestos bajo la lupa para corroborar su buen funcionamiento dando los siguientes resultados:

Tabla 6.1: Muestra de terminos Porter vs Snowball Stemmers

Porter (pyterrier)	Frecuencia	Snowball(nltk)	Frecuencia
0	753	small	5891
00	45	group	3578
000	50	politician	625
0001	16	believ	12362

Los resultados encontrados en la Tabla 6.1 muestran que el stemmer de Snowball presenta un rendimiento mayor en la frecuencia de los términos, esto se puede atribuir a que el stemmer de Snowball es más agresivo en la eliminación de sufijos y prefijos, lo cual puede llevar a una mayor cantidad de términos que son relevantes para la recuperación de información. Sin embargo la pobre calidad en el procesado

entregado por el stemmer de porter justifico su reemplazo por el de Snowball. Sin embargo, este cambio tuvo como consecuencia un impacto directo a la correlación del método IDF en $nDCG@10$, con una disminución de 0.146 a 0.05. La causa principal de este efecto no ha sido investigada profundamente, pero puede deberse a que el *Stemmer* original procesaba una mayor gamma de tokens comunes en el dataset pero que no se correspondían con ninguna palabra, sino con números o caracteres especiales, que podrían ser abundantes en el corpus. Un estudio mas profundo sobre la calidad de los conjuntos de datos podría ayudar a comprender este efecto de mejor forma.




Figura 6.7: Correlación de los métodos QPP - tau de Kendall

Por otro lado, el método SCQ muestra un rendimiento significativamente superior al IDF, presentando correlaciones moderadas positivas en el rango de 0.18-0.26 para ambas métricas de evaluación. Este contraste en el rendimiento entre ambos métodos pre-retrieval resulta particularmente interesante, ya que SCQ incorpora tanto la frecuencia de documentos (df) como la frecuencia en la colección (cf) en su cálculo, mientras que IDF se limita únicamente a la frecuencia de documentos.

La superioridad de SCQ se hace más evidente en su variante máxima, alcanzando correlaciones de 0.2596 con $nDCG@10$ y 0.2663 con AP. Estos resultados sugieren que la incorporación de estadísticas adicionales de la colección proporciona una visión más matizada de la importancia de los términos y, por ende, una mejor capacidad predictiva del rendimiento de las consultas. Es notable cómo estos patrones de

correlación se mantienen consistentes tanto para $nDCG@10$ como para AP, lo que indica que la efectividad de estos predictores no está sesgada hacia una métrica de evaluación particular.

Si bien una correlación de aproximadamente 0.26 no podría considerarse extremadamente fuerte, representa una mejora significativa sobre el método IDF y sugiere que SCQ captura señales más significativas sobre el potencial rendimiento de las consultas. Este hallazgo tiene implicaciones relevantes para el diseño de sistemas de predicción de rendimiento de consultas, indicando que la incorporación de estadísticas más completas de la colección puede conducir a predicciones más confiables.

La Figura 6.8 muestra el diagrama de caja asociado a cada correlación, como se menciono anteriormente, el método IDF es el que presenta una menor correlación, mientras que el método UEF-NQC es el que presenta la mayor correlación del grupo con un valor de 0.42 con respecto a $nDCG@10$. Se puede apreciar que pese a que la mayoría de los métodos presentan cajas relativamente planas, lo que indica una estabilidad en sus correlaciones, algunos métodos como WIG y UEF-NQC muestran una mayor variabilidad en sus resultados. Particularmente, UEF-NQC exhibe un rango más amplio de correlaciones, con un valor promedio de 0.4 y un mínimo cercano a 0.39, lo que sugiere que su rendimiento, aunque superior, puede ser menos consistente que otros métodos. Esta variabilidad podría atribuirse a la naturaleza más compleja del método, que al incorporar más factores en su cálculo, puede ser más sensible a las características específicas de las consultas.




Figura 6.8: Diagrama de caja de correlaciones métodos QPP vs $nDCG@10$ en tau de Kendall

Los niveles de significancia presentados en la Tabla 6.2 muestran un patrón interesante en cuanto a la confiabilidad estadística de las correlaciones obtenidas. El método IDF, tanto en su variante promedio como máxima, presenta un nivel de significancia $p \geq 0.05$, lo que indica que no podemos rechazar la hipótesis nula de que no existe correlación entre las predicciones de IDF y las métricas de rendimiento. Este resultado es consistente con las bajas correlaciones observadas anteriormente y refuerza la conclusión de que IDF, en su implementación actual, no es un predictor confiable del rendimiento de las consultas en nuestro sistema.

Tabla 6.2: Niveles de significancia de las correlaciones en tau de Kendall

	nDCG@10	AP
IDF AVG	≥ 0.05	≥ 0.05
IDF-Max	≥ 0.05	≥ 0.05
SCQ-AVG	< 0.001	< 0.001
SCQ-Max	> 0.001	> 0.001
NQC	> 0.001	> 0.001
UEF-NQC	> 0.001	> 0.001
WIG	< 0.001	< 0.001
UEF-WIG	< 0.001	< 0.001
Clarity	< 0.001	< 0.001
UEF-Clarity	< 0.001	< 0.001

Por otro lado, todos los demás métodos evaluados muestran niveles de significancia $p < 0.001$, lo que indica una muy alta confianza estadística en las correlaciones observadas. Este contraste marcado entre IDF y el resto de los métodos sugiere que la falta de rendimiento de IDF no es un resultado del azar, sino una limitación inherente al método en el contexto específico de nuestro experimento.

Es particularmente notable que incluso SCQ, que también es un método pre-retrieval y comparte algunas características con IDF, logra correlaciones estadísticamente significativas. Esto refuerza la hipótesis de que la incorporación de estadísticas adicionales de la colección (como lo hace SCQ) proporciona una base más sólida para la predicción del rendimiento de las consultas.

Los métodos post-retrieval y sus variantes UEF mantienen niveles de significancia consistentemente altos ($p < 0.001$), lo que valida su superior capacidad predictiva observada en las correlaciones. Este patrón sugiere que el acceso a la información

post-recuperación proporciona señales más confiables para la predicción del rendimiento de las consultas.




Figura 6.9: Gráfico de dispersión de nDCG@10 vs NQC

La Figura 6.9 muestra la relación entre las puntuaciones del predictor NQC y los valores reales de nDCG@10. El gráfico revela una correlación positiva moderada ($\tau = 0.4007$) entre las predicciones y el rendimiento real, lo que indica que NQC posee una capacidad predictiva considerable. Esta correlación se visualiza mediante la línea de tendencia naranja, que muestra una pendiente positiva consistente a lo largo del rango de predicción.

Un aspecto notable es la dispersión de los puntos alrededor de la línea de tendencia, particularmente en el rango medio de puntuaciones QPP (0.2-0.4). Esta variabilidad sugiere que la precisión del predictor no es uniforme para todas las consultas, lo cual es un comportamiento esperado en la predicción del rendimiento de consultas debido a la complejidad inherente de la tarea.

Los valores de nDCG@10 se concentran principalmente entre 0.2 y 0.6, con algunos casos excepcionales que alcanzan hasta 0.8. Esta distribución refleja la diversidad en la dificultad de las consultas en nuestra colección de prueba. Es importante notar la presencia de puntos con nDCG@10 = 0, que corresponden a consultas donde no

se recuperaron documentos relevantes en las primeras 10 posiciones, casos que el método NQC maneja adecuadamente en su implementación.




Figura 6.10: Gráfico de dispersión de nDCG@10 vs UEF-NQC - tau de Kendall

La Figura 6.10 presenta la versión mejorada del predictor NQC mediante el marco UEF, mostrando un incremento en la correlación ($\tau = 0.4245$) respecto a su versión base ($\tau = 0.4007$). Esta mejora es particularmente significativa ya que refleja un patrón consistente observado en casi todos los predictores post-retrieval al aplicar el marco UEF, con la notable excepción del método WIG, el cual mostró ser más sensible a la cantidad de documentos recuperados.

La mejora en el rendimiento se puede atribuir a la capacidad del marco UEF para incorporar información de la expansión de consultas en el modelo de predicción. Esto se evidencia en la línea de tendencia ligeramente más pronunciada y en bandas de confianza más ajustadas en ciertas regiones del gráfico. El mecanismo subyacente se basa en la correlación entre las puntuaciones de recuperación originales y las de la consulta expandida, donde una alta correlación sugiere una consulta bien formulada y probablemente efectiva.

Es notable cómo UEF-NQC maneja mejor los casos extremos, particularmente en el rango superior de puntuaciones QPP (0.5-0.7), y muestra una predicción más consistente en el rango medio (0.2-0.4). Esta mejora en la capacidad predictiva sugiere que la incorporación del comportamiento de reformulación de consultas

en QPP puede conducir a predicciones más confiables, especialmente en consultas desafiantes donde los predictores tradicionales podrían tener dificultades.




Figura 6.11: Gráficos de dispersión de nDCG@10 vs IDF

La Figura 6.11 presenta los gráficos de dispersión para las dos variantes del predictor IDF: promedio y máximo, los cuales presentan la mayor anomalía dentro de los resultados. Ambos gráficos revelan correlaciones extremadamente débiles con los valores de nDCG@10, con $\tau = 0.0451$ para IDF promedio y $\tau = -0.0100$ para IDF máximo. Estos resultados son consistentes con los niveles de significancia previamente discutidos ($p \geq 0.05$) y refuerzan visualmente la limitada capacidad predictiva del método IDF en nuestro experimento.

Un aspecto notable en ambas variantes es la presencia de heterocedasticidad, es decir, una variación no constante en la dispersión de los valores nDCG@10 a lo largo del rango de puntuaciones IDF. En el caso de IDF máximo, esta heterogeneidad es particularmente pronunciada en el rango medio (6-8), donde se observa una dispersión en forma de abanico que sugiere una mayor incertidumbre en las predicciones. La variante de IDF promedio muestra un patrón de varianza más estable en el rango medio (4.5-6.5), pero exhibe un incremento notable en la variabilidad alrededor de las puntuaciones 6-7.

Esta variabilidad no uniforme tiene implicaciones importantes para la fiabilidad de las predicciones: sugiere que la capacidad predictiva de IDF no es consistente a través de diferentes tipos de consultas y que la confianza en las predicciones debería ajustarse según el rango de puntuación IDF en que se encuentre la consulta. La presencia de estas regiones de alta incertidumbre, junto con las correlaciones cercanas a cero, indica que el uso directo de IDF como predictor de rendimiento podría no ser apropiado sin modificaciones sustanciales o la incorporación de características adicionales.

Estos resultados apuntan que, a pesar de ser un concepto fundamental en recuperación de información, el uso directo de IDF para la predicción del rendimiento de consultas podría requerir ser complementado con características adicionales o transformado de manera que capture mejor los aspectos cualitativos de las consultas. Esta observación se alinea con el mejor rendimiento observado en SCQ, que extiende el concepto de IDF incorporando estadísticas adicionales de la colección.

6.3 Discusión de los resultados

Los resultados obtenidos en este estudio revelan patrones significativos en el rendimiento de los diferentes métodos de predicción de consultas (QPP), proporcionando insights valiosos sobre su efectividad y limitaciones en el contexto de la recuperación de información.

6.3.1 Importancia de las correlaciones observadas

La evaluación de los métodos QPP mostró un rango de correlaciones que van desde valores cercanos a 0 (IDF) hasta aproximadamente 0.42 (UEF-NQC). Aunque estas correlaciones podrían parecer modestas a primera vista, es importante contextualizarlas dentro del campo de la predicción del rendimiento de consultas. Como se señala en [19], correlaciones incluso tan bajas como 0.1 pueden tener valor práctico en ciertos contextos, siendo particularmente útiles cuando superan el umbral de 0.5. En este sentido, los resultados obtenidos por métodos como UEF-NQC ($\tau = 0.4245$) y NQC ($\tau = 0.4007$) se acercan a niveles de correlación que pueden considerarse prácticamente significativos.

6.3.2 Rendimiento de métodos pre-retrieval

Un hallazgo particularmente interesante emerge al analizar el comportamiento de los métodos pre-retrieval. Como señala [20], estos métodos son especialmente atractivos debido a su eficiencia computacional, ya que no requieren ejecutar el proceso de recuperación. Sin embargo, nuestros resultados muestran una marcada diferencia entre los dos métodos pre-retrieval evaluados: mientras que IDF mostró correlaciones prácticamente nulas ($\tau \approx 0.05$), SCQ alcanzó correlaciones moderadas ($\tau \approx 0.26$).

Esta disparidad sugiere que, si bien los métodos pre-retrieval pueden ser prometedores por su eficiencia, su efectividad depende crucialmente de la sofisticación de sus métricas. El mejor rendimiento de SCQ puede atribuirse a su capacidad para

incorporar tanto la frecuencia de documentos como la frecuencia en la colección, proporcionando una vista más completa de la importancia de los términos.

Por ultimo cabe mencionar que el método SCQ presenta mejores resultados en su variante máxima y promedio frente a los benchmarks disponibles en la literatura en el mismo conjunto de datos. [7] Poniendo en evidencia la importancia del preprocesado de consultas y documentos en la predicción del rendimiento de las consultas.

6.3.3 Rendimiento de métodos post-retrieval

Los resultados demuestran consistentemente que los métodos post-retrieval, particularmente en sus variantes UEF, superan a los métodos pre-retrieval. El método UEF-NQC, con una correlación de $\tau = 0.4245$, representa una mejora significativa sobre los métodos pre-retrieval más efectivos. Esta superioridad sugiere que la información adicional disponible después de la recuperación proporciona señales más confiables para la predicción del rendimiento.

En cuanto a la comparación con otras evaluaciones en la literatura, los métodos se encuentran generalmente en línea o un poco por encima de los resultados de Zendel et al. [7], con la única excepción de Clarity, el cual presenta un rendimiento inferior probablemente debido a su enfoque de lenguaje natural y el preprocesado utilizado.

6.3.4 Complejidad Inherente de la Tarea

La dificultad fundamental de predecir el rendimiento de las consultas se evidencia en estudios previos con expertos humanos [21, 22], donde incluso profesionales con conocimiento profundo de la terminología y sus ambigüedades mostraron una capacidad limitada para predecir el rendimiento de las consultas. Este contexto hace que los resultados obtenidos por los métodos automáticos, particularmente UEF-NQC, sean más apreciables, ya que logran correlaciones moderadas en una tarea inherentemente compleja.

6.3.5 Implicaciones sobre una línea base experimental

Los resultados sugieren varias implicaciones importantes. Primero, la elección entre métodos pre y post-retrieval debe considerar el balance entre eficiencia y efectividad. Mientras que SCQ ofrece un compromiso razonable, logrando correlaciones moderadas sin el costo computacional de la recuperación, los métodos post-retrie-

val como UEF-NQC proporcionan predicciones significativamente más confiables cuando el tiempo de procesamiento no es una limitación crítica.

Segundo, la variabilidad en el rendimiento observada en el análisis de dispersión sugiere que podría ser beneficioso desarrollar métodos híbridos que combinen las fortalezas de diferentes predictores, potencialmente adaptando la estrategia de predicción según las características específicas de la consulta.

En tercer lugar, aun con los resultados prometedores obtenidos en ciertos casos como NQC y UEF-NQC, cabe recalcar que las correlaciones siguen siendo aun bajas para la mayoría de los métodos, lo cual sugiere que la tarea de predecir el rendimiento de las consultas sigue siendo una tarea compleja y que el desarrollo de métodos más sofisticados que puedan capturar mejor los matices que afectan el rendimiento de la recuperación de información sigue siendo una tarea pendiente.

CAPÍTULO VII: CONCLUSIONES Y TRABAJO FUTURO

7.1 Principales conclusiones

Resumen de los hallazgos más importantes...

7.2 Recomendaciones para investigaciones futuras

Descripción de las contribuciones realizadas...

7.3 Trabajo Futuro

Identificación de líneas de investigación futuras...

REFERENCIAS BIBLIOGRÁFICAS

- [1] ZHAO, Ying, Falk SCHOLER y Yohannes TSEGAY. Effective Pre-retrieval Query Performance Prediction Using Similarity and Variability Evidence. En: Craig MACDONALD, Iadh OUNIS, Vassilis PLACHOURAS, Ian RUTHVEN y Ryen W. WHITE, eds. *Advances in Information Retrieval*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008, p. 52-64. ISBN 978-3-540-78646-7.
- [2] ROBERTSON, Stephen. Understanding inverse document frequency: on theoretical arguments for IDF. *Journal of Documentation* [en línea]. 2004, **60**(5), 503-520. ISSN 0022-0418. Disponible en: doi:10.1108/00220410410560582
- [3] CRONEN-TOWNSEND, Steve, Yun ZHOU y W. Bruce CROFT. Predicting query performance. En: *Proceedings of the 25th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Tampere, Finland: Association for Computing Machinery, 2002, p. 299-306. SIGIR '02. ISBN 1581135610. Disponible en: doi:10.1145/564376.564429
- [4] SHTOK, Anna, Oren KURLAND, David CARMEL, Fiana RAIBER y Gad MARKOVITS. Predicting Query Performance by Query-Drift Estimation. *ACM Trans. Inf. Syst.* [en línea]. 2012, **30**(2). ISSN 1046-8188. Disponible en: doi:10.1145/2180868.2180873
- [5] ZHOU, Yun y W. Bruce CROFT. Query performance prediction in web search environments. En: *Proceedings of the 30th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Amsterdam, The Netherlands: Association for Computing Machinery, 2007, p. 543-550. SIGIR '07. ISBN 9781595935977. Disponible en: doi:10.1145/1277741.1277835
- [6] SHTOK, Anna, Oren KURLAND y David CARMEL. Using statistical decision theory and relevance models for query-performance prediction. En: *Proceedings of the 33rd International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Geneva, Switzerland: Association for Computing Machinery, 2010, p. 259-266. SIGIR '10. ISBN 9781450301534. Disponible en: doi:10.1145/1835449.1835494
- [7] ZENDEL, Oleg, Maik FRÖBE y Guglielmo FAGGIOLI. QPPTK@ TIREx: Simplified Query Performance Prediction for Ad-Hoc Retrieval Experiments. *WOWS 2024*. 2024, 50.
- [8] FAGGIOLI, Guglielmo, Oleg ZENDEL, J. Shane CULPEPPER, Nicola FERRO y Falk SCHOLER. An Enhanced Evaluation Framework for Query Performance Prediction. En: Djoerd HIEMSTRA, Marie-Francine MOENS, Josiane MOTHE, Raffaele PEREGO, Martin POTTHAST y Fabrizio SEBASTIANI, eds. *Advances in Information Retrieval*. Cham: Springer International Publishing, 2021, p. 115-129. ISBN 978-3-030-72113-8.
- [9] NGUYEN, Tri, Mir ROSENBERG, Xia SONG, Jianfeng GAO, Saurabh TIWARY, Rangan MAJUMDER y Li DENG. MS MARCO: A Human Generated MACHINE Reading COMprehension Dataset [en línea]. 2016. Dispo-

nible en: <https://www.microsoft.com/en-us/research/publication/ms-marco-human-generated-machine-reading-comprehension-dataset/>

- [10] HASHEMI, Helia, Mohammad ALIANNEJADI, Hamed ZAMANI y W. Bruce CROFT. ANTIQUE: A Non-factoid Question Answering Benchmark. En: *Advances in Information Retrieval: 42nd European Conference on IR Research, ECIR 2020, Lisbon, Portugal, April 14–17, 2020, Proceedings, Part II* [en línea]. Lisbon, Portugal: Springer-Verlag, 2020, p. 166-173. ISBN 978-3-030-45441-8. Disponible en: doi:10.1007/978-3-030-45442-5_21
- [11] VOORHEES, Ellen, Tasmeer ALAM, Steven BEDRICK, Dina DEMNER-FUSHMAN, William R. HERSH, Kyle LO, Kirk ROBERTS, Ian SOBOROFF y Lucy Lu WANG. TREC-COVID: constructing a pandemic information retrieval test collection. *SIGIR Forum* [en línea]. 2021, **54**(1). ISSN 0163-5840. Disponible en: doi:10.1145/3451964.3451965
- [12] NANNI, Federico, Bhaskar MITRA, Matt MAGNUSSON y Laura DIETZ. Benchmark for Complex Answer Retrieval. En: *Proceedings of the ACM SIGIR International Conference on Theory of Information Retrieval* [en línea]. Amsterdam, The Netherlands: Association for Computing Machinery, 2017, p. 293-296. ICTIR '17. ISBN 9781450344906. Disponible en: doi:10.1145/3121050.3121099
- [13] MACDONALD, Craig, Nicola TONELLOTO, Sean MACAVANEY y Iadh OUNIS. PyTerrier: Declarative Experimentation in Python from BM25 to Dense Retrieval. En: *Proceedings of the 30th ACM International Conference on Information & Knowledge Management* [en línea]. Virtual Event, Queensland, Australia: Association for Computing Machinery, 2021, p. 4526-4533. CIKM '21. ISBN 9781450384469. Disponible en: doi:10.1145/3459637.3482013
- [14] WHISSELL, John S. y Charles L. A. CLARKE. Improving document clustering using Okapi BM25 feature weighting. *Inf. Retr.* [en línea]. 2011, **14**(5), 466-487. ISSN 1386-4564. Disponible en: doi:10.1007/s10791-011-9163-y
- [15] FORTHOFER, Ron N. y Robert G. LEHNEN. Rank Correlation Methods. En: *Public Program Analysis: A New Categorical Data Approach* [en línea]. Boston, MA: Springer US, 1981, p. 146-163. ISBN 978-1-4684-6683-6. Disponible en: doi:10.1007/978-1-4684-6683-6_9
- [16] HAUFF, Claudia, Leif AZZOPARDI y Djoerd HIEMSTRA. The Combination and Evaluation of Query Performance Prediction Methods. En: Mohand BOUGHANEM, Catherine BERRUT, Josiane MOTHE y Chantal SOULE-DUPUY, eds. *Advances in Information Retrieval*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2009, p. 301-312. ISBN 978-3-642-00958-7.
- [17] TAO, Yongquan y Shengli WU. Query Performance Prediction By Considering Score Magnitude and Variance Together. En: *Proceedings of the 23rd ACM International Conference on Conference on Information and Knowledge Management* [en línea]. Shanghai, China: Association for Computing Machinery, 2014, p. 1891-1894. CIKM '14. ISBN 9781450325981. Disponible en: doi:10.1145/2661829.2661906

- [18] VOORHEES, E.M. The Sixth Text REtrieval Conference (TREC-6). *Information Processing & Management* [en línea]. 2000, **36**(1), 1-2. ISSN 0306-4573. Disponible en: doi:[https://doi.org/10.1016/S0306-4573\(99\)00042-4](https://doi.org/10.1016/S0306-4573(99)00042-4)
- [19] HAUFF, Claudia, Leif AZZOPARDI, Djoerd HIEMSTRA y Franciska de JONG. Query Performance Prediction: Evaluation Contrasted with Effectiveness. En: Cathal GURRIN, Yulan HE, Gabriella KAZAI, Udo KRUSCHWITZ, Suzanne LITTLE, Thomas ROELLEKE, Stefan RÜGER y Keith van RIJSBERGEN, eds. *Advances in Information Retrieval*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2010, p. 204-216. ISBN 978-3-642-12275-0.
- [20] THOMAS, Paul, Falk SCHOLER, Peter BAILEY y Alistair MOFFAT. Tasks, Queries, and Rankers in Pre-Retrieval Performance Prediction. En: *Proceedings of the 22nd Australasian Document Computing Symposium* [en línea]. Brisbane, QLD, Australia: Association for Computing Machinery, 2017. ADCS '17. ISBN 9781450363914. Disponible en: doi:10.1145/3166072.3166079
- [21] CHIFU, Adrian-Gabriel, Sébastien DÉJEAN, Stefano MIZZARO y Josiane MOTHE. Human-based query difficulty prediction. En: *Advances in Information Retrieval: 39th European Conference on IR Research, ECIR 2017, Aberdeen, UK, April 8-13, 2017, Proceedings 39*. 2017, p. 343-356.
- [22] HAUFF, Claudia, Diane KELLY y Leif AZZOPARDI. A comparison of user and system query performance predictions. En: *Proceedings of the 19th ACM International Conference on Information and Knowledge Management* [en línea]. Toronto, ON, Canada: Association for Computing Machinery, 2010, p. 979-988. CIKM '10. ISBN 9781450300995. Disponible en: doi:10.1145/1871437.1871562