



FACULTAD DE INGENIERÍA Y ARQUITECTURA

**EVALUACIÓN COMPARATIVA DE MÉTODOS QUERY
PERFORMANCE PREDICTION (QPP) PARA BÚSQUEDAS AD-HOC
UTILIZANDO MÉTRICAS DE CORRELACIÓN.**

Trabajo de memoria para obtener el título de:

INGENIERO CIVIL EN COMPUTACIÓN E INFORMÁTICA

**Alumno: José Emmanuel Raúl Sandoval Vega.
Luis Emersson Brain Fredes.**

Profesor Patrocinante: Dr. Mauricio Andrés Oyarzún Silva.

IQUIQUE - CHILE

2025

[Dedicatoria...]

AGRADECIMIENTOS

[Agradezco...]

ÍNDICE DE MATERIAS

CAPÍTULO I: INTRODUCCIÓN	1
1.1 Contexto del proyecto	1
1.2 Objetivo General	1
1.3 Objetivos Específicos	2
1.4 Estructura del trabajo de título	2
CAPÍTULO II: MARCO TEÓRICO	4
2.1 Sistemas de Recuperación de Información (IR)	4
2.1.1 Modelos de recuperación de información.	5
2.1.2 Componentes de un sistema de recuperación de información.	8
2.1.3 Consultas, tópicos y búsquedas Ad-hoc	11
2.2 Predicción de Rendimiento de Consultas (QPP)	13
2.2.1 Dificultad y rendimiento de las consultas	13
2.2.2 Soluciones al Problema de la Dificultad de las Consultas	17
2.2.3 Taxonomías en QPP	19
2.2.3.1 Predictores <i>pre-retrieval</i>	20
2.2.3.2 Predictores <i>post-retrieval</i>	20
2.2.4 Aplicaciones de QPP en IR	21
2.2.5 Supuestos, limitaciones y amenazas a la validez	23
2.3 Métricas de Evaluación de Rendimiento y Correlación	24
2.3.1 Juicios de relevancia (<i>Qrels</i>)	24
2.3.2 Métricas de evaluación clásicas en IR	25
2.3.3 Protocolos de evaluación de QPP y diseño experimental	27
2.3.4 Métricas de correlación para evaluar métodos QPP	28
CAPÍTULO III: TRABAJOS RELACIONADOS	31
3.1 Métodos de Predicción de Rendimiento de Consultas (QPP)	31
3.1.1 IDF (Frecuencia Inversa de Documentos)	31
3.1.2 SCQ (Similitud entre consulta y colección)	32
3.1.3 NQC (Normalized Query Commitment)	33
3.1.4 Clarity Score (CS)	34
3.1.5 WIG (Weighted Information Gain)	35
3.1.6 UEF (Utility Estimation Framework)	36
3.2 Estudios comparativos similares	37
3.2.1 QPPTK en TIREx	37
3.2.2 <i>An Enhanced Evaluation Framework for Query Performance Prediction</i> (2021)	38
CAPÍTULO IV: DISEÑO DE LA EVALUACIÓN COMPARATIVA	40
4.1 Protocolo de evaluación experimental	40
4.1.1 Paradigma de evaluación de métodos QPP	40

4.1.2	Flujo del sistema	42
4.1.3	Configuración técnica	44
4.2	Selección de conjuntos de datos	48
4.2.1	Criterios de inclusión	48
4.2.2	Justificación de los conjuntos de datos seleccionados	50
4.3	Selección de métodos de QPP	57
4.3.1	Criterios de selección	58
4.3.2	Métodos seleccionados	60
CAPÍTULO V: IMPLEMENTACIÓN		63
5.1	Configuración del entorno experimental	64
5.1.1	Docker y dependencias	65
5.1.2	Integración de conjuntos de datos	66
5.1.3	Preprocesamiento, indexación y consultas	67
5.2	Implementación de métodos QPP	69
5.2.1	Métodos pre-retrieval	71
5.2.2	Métodos post-retrieval	72
5.3	Implementación de la evaluación	74
5.3.1	Cálculo de correlaciones	74
5.3.2	Visualización de resultados	75
5.4	Pruebas de validación	76
5.4.1	Datos para las prueba	76
5.4.2	Componentes del módulo de pruebas	78
5.4.3	Casos de prueba representativos	79
5.4.4	Resultados de la validación	83
CAPÍTULO VI: ANÁLISIS DE RESULTADOS		85
6.1	Caracterización de los conjuntos de datos	86
6.1.1	Distribución de niveles de relevancia	86
6.1.2	Dificultad de consultas basada en rendimiento	88
6.2	Comparación de métodos QPP	91
6.2.1	Visión general de las correlaciones	91
6.2.2	Análisis por familia de métodos	101
6.2.3	Significancia estadística de las correlaciones	102
6.3	Análisis comparativo de los resultados	104
6.4	Discusión de los resultados	107
6.4.1	Contextualización y validación de la línea base	108
6.4.2	La complejidad inherente y el límite estadístico	108
6.4.3	Análisis de la sensibilidad de Clarity	110
CAPÍTULO VII: CONCLUSIONES Y TRABAJO FUTURO		113
7.1	Principales conclusiones	113

7.2 Cumplimiento de los objetivos específicos 114

7.3 Síntesis de hallazgos 115

7.4 Alcance del trabajo de título 115

7.5 Trabajo futuro 116

ÍNDICE DE TABLAS

Tabla 2.1: Modelos de recuperación de información y su propósito dentro de un sistema IR. 7

Tabla 2.2: Recursos y métricas comunes para la evaluación de sistemas IR y de métodos de predicción de rendimiento. 10

Tabla 2.3: Formas de definir la dificultad de una consulta. 16

Tabla 2.4: Factores y señales típicas en predictores post-retrieval. 20

Tabla 4.1: Parámetros principales de BM25. 45

Tabla 4.2: Parámetros principales de configuración. 46

Tabla 4.3: Criterios de inclusión de datasets. 48

Tabla 4.4: Tabla de datasets y sus criterios de inclusión. 51

Tabla 4.5: Estadísticos de los datasets seleccionados. 52

Tabla 4.6: Configuración de métricas por dataset. 56

Tabla 4.7: Criterios de selección de métodos de QPP. 58

Tabla 4.8: Métodos de QPP seleccionados. 60

Tabla 5.1: Componentes principales del sistema implementado. 63

Tabla 5.2: Stack tecnológico principal. 63

Tabla 5.3: Configuración del entorno experimental. 64

Tabla 5.4: Componentes principales del Dockerfile. 65

Tabla 5.5: Comparación de vocabularios entre tokenizadores. 68

Tabla 5.6: Impacto en la cobertura de consultas. 69

Tabla 5.7: Características del dataset de prueba IquiqueDataset. 76

Tabla 5.8: Muestra de documentos del corpus IquiqueDataset (5 de 8). 77

Tabla 5.9: Consultas del dataset IquiqueDataset y su cobertura de relevancia. 77

Tabla 5.10: Componentes evaluados mediante pruebas unitarias. 78

Tabla 5.11: Resultados de ejecución de pruebas unitarias por componente. 83

Tabla 6.1: Distribución de juicios de relevancia por dataset. 87

Tabla 6.2: Distribución de dificultad de consultas según nDCG@10. 89

Tabla 6.3: Correlaciones (P-ρ, S-ρ y K-τ) entre métodos QPP y nDCG@10 en los distintos datasets evaluados. 105

Tabla 6.4: Distribución del efecto suelo por dataset. CAR presenta la mayor concentración de consultas con rendimiento nulo. 109

Tabla 6.5: Ejemplos de consultas CAR con brecha semántica. Los encabezados jerárquicos de Wikipedia no comparten vocabulario léxico con los párrafos relevantes. 109

Tabla 6.6: Comparación de estadísticas de colección y Clarity entre Cranfield y TREC-COVID. 111

Tabla 6.7: Contribución de términos en Cranfield 112

Tabla 6.8: Contribución de términos en TREC-COVID 112

ÍNDICE DE FIGURAS

Figura 2.1: Diagrama de Venn del Modelo Booleano. 5

Figura 2.2: Representación geométrica del Modelo Vectorial. 6

Figura 2.3: Componentes estructurales del modelo BM25. 7

Figura 2.4: Componentes fundamentales de un sistema de Recuperación de Información. 9

Figura 2.5: Flujo de un sistema de recuperación basado en Modelos de Relevancia. 18

Figura 4.1: Diagrama de componentes del entorno de evaluación. 42

Figura 5.1: Dockerfile para la configuración del entorno experimental. 65

Figura 5.2: Configuración de formato de dataset. 66

Figura 5.3: Código de implementación del factory de métodos QPP. 69

Figura 5.4: Diagrama de la capa de métodos QPP. 70

Figura 5.5: Implementación del suavizado de Dirichlet en Clarity. 72

Figura 5.6: Implementación del método WIG. 74

Figura 5.7: Prueba de validación del cálculo de IDF para términos individuales. 80

Figura 5.8: Prueba de suavizado de Dirichlet y consistencia de stemming en Clarity. ... 80

Figura 5.9: Prueba de evaluación de métricas con rankings perfecto e invertido. 81

Figura 5.10: Prueba de cálculo de correlaciones y alineamiento de identificadores. 82

Figura 6.1: Diagrama de flujo del análisis de resultados. 86

Figura 6.2: Distribución de niveles de relevancia en Cranfield. 87

Figura 6.3: Distribución de niveles de relevancia en CAR. 88

Figura 6.4: Distribución de dificultad de consultas en Antique/Test. 89

Figura 6.5: Distribución de dificultad de consultas en CAR. 90

Figura 6.6: Distribución de dificultad de consultas en Cranfield. 90

Figura 6.7: Diagramas de dispersión QPP vs nDCG@10 en Antique/Test. 93

Figura 6.8: Diagramas de dispersión QPP vs nDCG@10 en CAR. 95

Figura 6.9: Diagramas de dispersión QPP vs nDCG@10 en TREC-COVID. 97

Figura 6.10: Diagramas de dispersión en Cranfield. 99

Figura 6.11: Diagramas de dispersión en MS MARCO (Passage). 100

Figura 6.12: Significancia estadística (p-values) en Antique/Test. 102

Figura 6.13: Significancia estadística (p-values) en TREC-COVID. 103

NOMENCLATURA

IR (Information Retrieval): Campo de estudio que se enfoca en la recuperación de información relevante a partir de grandes colecciones de datos.

QPP (Query Performance Prediction): Técnicas y métodos utilizados para predecir el rendimiento de una consulta en sistemas de recuperación de información.

BM25: Modelo de recuperación de información basado en la frecuencia de términos, ampliamente utilizado en sistemas de búsqueda.

AP (Average Precision): Métrica de evaluación que mide la precisión promedio de los resultados recuperados, considerando la posición de los documentos relevantes.

nDCG (Normalized Discounted Cumulative Gain): Métrica de evaluación que mide la calidad del ranking de documentos recuperados, considerando la relevancia y la posición de los documentos.

Qrels (Query Relevance Judgments): Juicios de relevancia que indican la pertinencia de los documentos recuperados para una consulta específica.

Stemming: Proceso de reducir palabras a su raíz o forma base, utilizado en el preprocesamiento de texto para mejorar la recuperación de información.

Stopwords: Palabras comunes que se eliminan durante el preprocesamiento de texto para mejorar la eficiencia de la recuperación de información.

Pre-retrieval QPP: Métodos de predicción de rendimiento de consultas basados en estadísticas del corpus antes de la recuperación de documentos.

Post-retrieval QPP: Métodos de predicción de rendimiento de consultas basados en la información obtenida después de recuperar documentos.

RESUMEN

En la actualidad, los sistemas de recuperación de información (IR) enfrentan el desafío de predecir la calidad de los resultados de búsquedas, especialmente en consultas ad-hoc, donde la eficacia de los métodos de Query Performance Prediction (QPP) varía significativamente según el dominio y el tipo de consulta. Esta variabilidad puede derivar en respuestas subóptimas y un uso ineficiente de recursos, lo que subraya la necesidad de una evaluación robusta y reproducible de los métodos QPP más utilizados. Es así como, este proyecto, se enfoca en implementar y evaluar métodos QPP no basados en inteligencia artificial (IA) para búsquedas ad-hoc, utilizando métricas de correlación estandarizadas como Tau de Kendall, Spearman y Pearson, con el objetivo de establecer una línea base para futuras investigaciones y facilitar el desarrollo de nuevos enfoques.

De esta forma, el objetivo principal del proyecto es evaluar comparativamente métodos de QPP para búsquedas ad-hoc, identificando sus fortalezas y debilidades en diferentes contextos. Para ello, fueron seleccionados seis métodos QPP ampliamente reconocidos en la literatura: IDF (Inverse Document Frequency), SCQ (Similarity Between a Query and a Collection), NQC (Normalized Query Commitment), Clarity Score (CS), WIG (Weighted Information Gain) y UEF (Utility Estimation Framework), los cuales fueron implementados y evaluados en cinco datasets representativos (Cranfield, MS MARCO Passage, Antique/test, BEIR-TREC-COVID y CAR Judged), que abarcan una amplia gama de dominios y tipos de consultas, asegurando la generalización de los resultados.

Es así como el análisis de los resultados fue centrado en la comparación de las correlaciones entre los puntajes de los métodos QPP y las métricas de rendimiento del sistema de recuperación, en donde se revela que los métodos post-retrieval presentan las correlaciones más altas, superando significativamente a los métodos pre-retrieval como IDF, que presenta correlaciones cercanas a cero, adicional a esto, se observa que la implementación de UEF mejora considerablemente el rendimiento de los métodos post-retrieval.

Finalmente, los resultados del proyecto establecen una línea base sólida para la evaluación de métodos QPP en búsquedas ad-hoc, sin embargo, la complejidad propia de la tarea de predicción del rendimiento de consultas sigue siendo un desafío, lo que sugiere la necesidad de desarrollar métodos híbridos que combinen las fortalezas de diferentes enfoques.

CAPÍTULO I: INTRODUCCIÓN

1.1 Contexto del proyecto

La predicción del rendimiento de consultas (QPP) ha emergido como una herramienta prometedora en los sistemas de recuperación de información (IR). La capacidad de predecir la calidad de los resultados de búsqueda antes de la ejecución de la consulta permite tanto optimizar los recursos como al mismo tiempo mejorar la experiencia de los usuarios. No obstante, la eficacia de los métodos QPP varía significativamente según el dominio, el tipo de consulta, e incluso los modelos de recuperación utilizados, algo que se evidencia especialmente en búsquedas ad-hoc. Esta variabilidad subraya la necesidad de evaluaciones robustas y reproducibles, que permitan comparar y contrastar diferentes enfoques de tal forma que se pueda establecer una línea base clara para futuras investigaciones.

La complejidad del problema de QPP se magnifica por la diversidad de escenarios de aplicación y la heterogeneidad de los datos en diferentes dominios. Los sistemas de recuperación de información modernos deben manejar consultas que varían desde preguntas simples hasta construcciones complejas en lenguaje natural, cada una con sus propios desafíos de predicción de rendimiento. Además, la calidad de los resultados puede verse afectada por factores como la ambigüedad del lenguaje, la especificidad de la consulta, y la cobertura del tema en la colección de documentos.

La motivación sobre el campo de Query Performance Prediction (QPP) ha aumentado en los últimos años debido a los avances en el campo de la inteligencia artificial, específicamente en el área del procesamiento de lenguaje natural (NLP), donde nuevos modelos de lenguaje como BERT, GPT entre otros han demostrado ser muy efectivos en tareas de recuperación de información mediante el uso de técnicas especializadas como RAG (Retrieval augmented generation). Bajo esta premisa se abre un nuevo paradigma de métodos QPP basados en consultas conversacionales, donde la interacción entre el usuario y el sistema de recuperación de información se da de forma más natural.

Este trabajo busca establecer una línea base sobre los enfoques tradicionales para asegurar un avance en las futuras investigaciones de métodos QPP, mediante la implementación de un benchmark abierto y reproducible, disponible en GitHub.¹

1.2 Objetivo General

Evaluar comparativamente métodos de Query Performance Prediction (QPP) para búsquedas Ad-hoc utilizando métricas de correlación.

¹<https://github.com/emerssn/QPP-Benchmark>

1.3 Objetivos Específicos

1. Revisar la literatura sobre métodos de QPP en búsquedas ad-hoc sin el uso de inteligencia artificial.
2. Identificar y describir los principales métodos QPP utilizados en la actualidad.
3. Implementar y evaluar métodos QPP no basados en inteligencia artificial utilizando un conjunto de datos estandarizados y un marco de evaluación común.
4. Analizar y documentar el rendimiento de los métodos QPP implementados para establecer una línea base para futuras comparaciones.
5. Identificar fortalezas y debilidades de diferentes enfoques, proporcionando ideas para futuras investigaciones en métodos QPP.

1.4 Estructura del trabajo de título

El presente trabajo de título se compone de los siguientes siete capítulos:

Capítulo I: Introducción. Presenta el contexto y motivación del proyecto, junto con los objetivos general y específicos planteados para su realización. Se describe la importancia de la predicción del rendimiento de consultas (QPP) en sistemas de recuperación de información y la necesidad de una evaluación comparativa robusta.

Capítulo II: Marco Teórico. Proporciona el marco teórico necesario para comprender el trabajo, incluyendo conceptos fundamentales sobre sistemas de recuperación de información, predicción del rendimiento de consultas, métricas de evaluación y las herramientas utilizadas en el proyecto.

Capítulo III: Trabajos Relacionados. Revisa y analiza los principales métodos QPP desarrollados en la literatura, enfocándose en aquellos no basados en inteligencia artificial. Se examinan sus características, fortalezas y limitaciones, estableciendo el estado del arte en el campo.

Capítulo IV: Diseño de la Evaluación Comparativa. Define la metodología experimental, incluyendo la selección de métodos QPP, datasets, métricas de evaluación y el entorno experimental. Se detalla la configuración técnica y los procedimientos para garantizar la reproducibilidad de los experimentos.

Capítulo V: Implementación. Describe en detalle la implementación del sistema, la configuración del entorno experimental y los procesos de validación. Se incluyen aspectos técnicos sobre la integración de herramientas y la ejecución de experimentos.

Capítulo VI: Análisis de Resultados. Presenta y analiza los resultados obtenidos en la evaluación comparativa, examinando el rendimiento de cada método QPP en diferentes escenarios y datasets. Se discuten las implicaciones de los hallazgos y se comparan con resultados previos de la literatura.

Capítulo VII: Conclusiones y Trabajo Futuro. Resume los principales hallazgos y contribuciones del proyecto, estableciendo la línea base para futuras investigaciones en QPP. Se identifican limitaciones del estudio y se proponen direcciones para investigaciones futuras.

CAPÍTULO II: MARCO TEÓRICO

2.1 Sistemas de Recuperación de Información (IR)

El campo de la Recuperación de Información (IR) se centra en el estudio de métodos y sistemas que permiten localizar, dentro de grandes colecciones de documentos, aquellos que respondan de mejor forma a una necesidad informativa expresada por el usuario a través de una consulta o *query*. Este proceso implica identificar, clasificar y ordenar documentos según su grado de relevancia, apoyándose en modelos matemáticos y estadísticos que describen la relación entre las palabras de la consulta y el contenido del corpus. En la práctica, los sistemas de recuperación de información sustentan desde buscadores web hasta repositorios científicos y bases de datos digitales [1].

Cabe mencionar que, en el contexto de IR se entiende por documento cualquier unidad de información almacenada en el sistema, como puede ser un artículo científico, una página web o un informe técnico.

El conjunto completo de documentos disponibles para ser buscados se denomina corpus o colección. Por otra parte, la consulta o *query* corresponde a la expresión, generalmente breve, con la que el usuario comunica su necesidad de información, esta puede estar compuesta por palabras clave, frases o descripciones más amplias.

En los sistemas de evaluación, estas consultas se agrupan junto con sus documentos y juicios de relevancia en lo que se conoce como colecciones de referencia o *query logs*, las cuales permiten medir objetivamente el rendimiento de distintos modelos de recuperación.

Así mismo, en este trabajo la relevancia se entenderá como el grado en que un documento satisface la necesidad informativa planteada en la consulta. De forma complementaria, se denomina ruido a los documentos que, aun siendo recuperados, no aportan información útil respecto al tema consultado. Por lo tanto, un sistema de recuperación efectivo es aquel que maximiza los documentos relevantes y minimiza el ruido, priorizando la calidad de los resultados.

El propósito fundamental de un sistema IR consiste en maximizar la relevancia de los resultados y minimizar el ruido, es decir, la cantidad de documentos menos pertinentes dentro del conjunto de datos recuperado. Esta función se ha vuelto crítica frente al crecimiento exponencial de la información que disponemos en formato digital, donde la eficiencia en las búsquedas y la organización del conocimiento determinan la calidad de la experiencia informativa. Además, como se menciona en [2], la efectividad de un sistema IR no depende únicamente del modelo de recuperación utilizado, sino también de la formulación de la consulta y de la naturaleza del corpus.

El desarrollo de la Recuperación de Información se remonta a mediados del siglo XX, con los primeros sistemas booleanos aplicados en bibliotecas digitales. Con el avance de la informática y el Internet, el volumen de datos textuales creció de forma exponencial,

impulsando el surgimiento de modelos estadísticos y probabilísticos capaces de manejar grandes colecciones de documentos.

Actualmente, el campo ha evolucionado hacia el uso de modelos híbridos, que integran principios clásicos de IR con técnicas de aprendizaje automático y modelos de lenguaje, permitiendo una comprensión más profunda de la intención del usuario [3].

En la actualidad, estos modelos se utilizan en motores de búsqueda, asistentes conversacionales y sistemas de recomendación, demostrando que la IR se ha convertido en un componente transversal dentro del procesamiento de la información digital.

En este sentido, la Recuperación de Información no solo constituye la base de los sistemas de búsqueda automatizada, sino también establece un punto de partida para la comprensión del comportamiento de las consultas, el análisis de su dificultad y la estimación del rendimiento, siendo estos los aspectos centrales para la presente investigación, cuyo objetivo se orienta en evaluar distintos métodos de predicción sobre el desempeño de consultas en modelos clásicos de recuperación de información.

2.1.1 Modelos de recuperación de información.

Los modelos de recuperación de información constituyen el núcleo de un sistema IR, ya que estos definen cómo se mide la relevancia entre una consulta y los documentos del corpus. Estos modelos, además de definir formalmente la manera en que los términos de una consulta se comparan con las representaciones internas de los documentos, permiten calcular una puntuación o ranking de relevancia. Es así que, a lo largo de los años, se han desarrollado tres enfoques principales: el modelo booleano, el modelo vectorial y el modelo probabilístico, cada uno con sus propias ventajas y limitaciones [2, 4].

El modelo booleano fue el primero en ser implementado y se basa en la lógica clásica de operadores como AND, OR y NOT. En este enfoque, un documento es recuperado únicamente si cumple con las condiciones lógicas impuestas por la consulta realizada, sin establecer grados intermedios de relevancia. Si bien, este modelo es eficiente en contextos cerrados debido a su simplicidad, carece de una capacidad para ordenar los resultados, lo que limita su utilidad en escenarios de búsquedas más complejos [1].




Figura 2.1: Diagrama de Venn del Modelo Booleano.

Por otra parte, el modelo vectorial introdujo una representación algebraica tanto para los documentos como para las consultas, tratándolos como vectores en un espacio multidimensional, en el que cada dimensión corresponde a un término y los pesos asignados reflejan su importancia relativa. La similitud entre consulta y documento se mide, por lo general, mediante el coseno entre los vectores. Este particular enfoque permitió establecer rankings de relevancia y representó un avance significativo en la precisión de los sistemas IR [4].




Figura 2.2: Representación geométrica del Modelo Vectorial.

Por último, el modelo probabilístico se basa en estimar la probabilidad de relevancia de un documento a través de una consulta, en donde su versión más consolidada, el BM25 (abreviatura de “Best Match 25”, refiriéndose a la iteración número 25 de la función de ranking), calcula dicha probabilidad a partir de la frecuencia de los términos en el documento y su frecuencia inversa en el corpus, normalizando además por la longitud del texto, como se puede ver en la Figura 2.3. En este aspecto, BM25 ofrece equilibrio entre simplicidad, interpretabilidad y desempeño, razón por la cual es el modelo base en la mayoría de los experimentos y benchmarks actuales de IR [4].




Figura 2.3: Componentes estructurales del modelo BM25.

Además de los modelos clásicos, se han desarrollado extensiones que buscan optimizar la precisión y la capacidad de generalización. Entre ellas, el BM25F incorpora información estructural de los documentos, el RM3 introduce retroalimentación mediante expansión de consultas, y los modelos neuronales de recuperación (Neural IR) utilizan representaciones distribuidas del texto para capturar relaciones semánticas más complejas [3]. Estas variantes reflejan la evolución del campo hacia un paradigma híbrido, en el que los modelos tradicionales siguen siendo la base para experimentos controlados y reproducibles.

Tabla 2.1: Modelos de recuperación de información y su propósito dentro de un sistema IR.

Modelo	Principio de funcionamiento	Ventajas	Limitaciones o uso típico
Booleano	Recupera documentos que cumplen exactamente la condición lógica (AND, OR, NOT).	Simple, interpretable, útil en colecciones controladas.	No entrega ranking ni grados de relevancia; poca flexibilidad en consultas reales.
Vectorial	Representa documentos y consultas como vectores	Permite ranking, ponderación de térmi-	Sensible al vocabulario y sinónimos; re-

Modelo	Principio de funcionamiento	Ventajas	Limitaciones o uso típico
	ponderados y mide similitud.	nos (TF-IDF) y mejora de precisión.	quiere buen preprocesamiento.
Probabilístico / BM25	Estima probabilidad de relevancia según frecuencia de término, rareza en el corpus y longitud del documento.	Equilibrio entre desempeño y simplicidad; estándar en benchmarks.	Requiere calibración de parámetros; asume independencia de términos.
Extensiones (BM25F, RM3, Neural IR)	Incorporan la estructura del documento, retroalimentación o las representaciones distribuidas.	Mejoran recuperación en dominios complejos o semánticos.	Mayor costo computacional; suelen usarse como capa superior o en escenarios específicos.

El resultado final que entrega un sistema IR se presenta como un ranking de documentos, es decir, una lista ordenada de mayor a menor relevancia estimada. Este refleja la manera en que los usuarios perciben la utilidad del sistema, ya que la mayoría solo revisa los primeros resultados, lo que convierte la posición del documento en un factor crítico de evaluación. En este trabajo se adopta principalmente el escenario de recuperación clásica, basado en BM25 y colecciones estándar, dado que la mayoría de los métodos de predicción de rendimiento han sido propuestos y validados en este contexto, y porque permite la comparación directa con estudios previos como los reportados en QPP-TK y benchmarks recientes de QPP [4].

2.1.2 Componentes de un sistema de recuperación de información.

Para que la búsqueda sea eficiente en colecciones grandes, los sistemas IR no recorren todos los documentos cada vez que se hace una consulta, sino que utilizan estructuras de datos especializadas, siendo la más común el índice invertido, que almacena, para cada término,

la lista de documentos en los que aparece. De esta forma, el sistema puede ir directamente a los documentos candidatos sin revisar toda la colección.

Es así que un sistema de recuperación de información se compone de diversas etapas que trabajan de forma conjunta para transformar documentos sin estructura en resultados relevantes para el usuario. En términos generales, estas etapas son la indexación, la representación de los documentos y consultas, el modelo de recuperación y la evaluación del sistema [5, 6].

La indexación constituye el proceso inicial, encargado de convertir los documentos en representación internas que se puedan manipular. Para ello, se aplican distintas técnicas de preprocesamiento, como la *tokenización*, que consiste en dividir el texto en unidades mínimas llamadas *tokens*; la eliminación de palabras vacías o *stopwords*, es decir, términos muy frecuentes que aportan poca información; y el *stemming* o lematización, que reduce las palabras a su forma canónica con el objetivo de unificar variantes morfológicas. El resultado es una estructura conocida como índice invertido, que permite localizar rápidamente qué documentos contienen un término específico y con qué frecuencia. Este componente es esencial para la eficiencia del sistema, ya que permite búsquedas rápidas en grandes volúmenes de información.

La eficiencia de estas estructuras es fundamental para la escalabilidad del sistema, especialmente cuando el corpus crece hasta millones de documentos como ocurre en los benchmarks modernos.




Figura 2.4: Componentes fundamentales de un sistema de Recuperación de Información.

Por otra parte, la representación de documentos y consultas determina cómo se describen los textos dentro del sistema, asignando un peso a cada término para indicar su importancia relativa. En los sistemas clásicos, la representación más extendida es el modelo de espacio

vectorial, en el cual tanto los documentos como las consultas se representan mediante vectores cuyas dimensiones corresponden a los términos del vocabulario.

El cálculo de estos pesos sigue criterios estadísticos, en donde la técnica estándar es el *esquema TF-IDF*, que combina dos componentes: *la frecuencia del término (TF)* que mide cuántas veces aparece un término dentro de un documento y *la frecuencia inversa de documento (IDF)* que indica cuán raro o discriminativo es el término dentro del corpus completo. De esta forma, se otorga mayor importancia a palabras que son relevantes dentro de un documento pero poco frecuentes en la colección, mejorando la capacidad del sistema para distinguir documentos pertinentes [5].

Posteriormente, el modelo de recuperación se encarga de comparar las representaciones de las consultas con las de los documentos, generando así una puntuación de similitud o probabilidad de relevancia. Es a partir de estas puntuaciones que el sistema construye un ranking de resultados, donde los documentos se ordenan de mayor a menor relevancia, siendo este ranking la salida final que recibe el usuario [4].

Por último, la evaluación del sistema mide el desempeño del proceso de recuperación. En esta etapa, se utilizan juicios de relevancia (*qrels*) para determinar si los documentos recuperados son pertinentes o no. Los *qrels* son listas que asocian cada consulta con los identificadores de los documentos que fueron marcados como relevantes por evaluadores humanos, funcionando como estándar de comparación para medir la efectividad de un modelo.

Tabla 2.2: Recursos y métricas comunes para la evaluación de sistemas IR y de métodos de predicción de rendimiento.

Recurso / métrica	Qué mide	Cuándo se usa	Notas
Qrels (juicios de relevancia)	Listado de documentos marcados como relevantes para cada consulta.	Base de toda evaluación offline (TREC, Cranfield, Antique).	Pueden ser binarios o graduados; dependen de evaluador humano.
Precision / Recall	Exactitud y cobertura de los documentos recuperados.	Tareas simples o colecciones pequeñas.	No consideran orden del ranking.

Recurso / métrica	Qué mide	Cuándo se usa	Notas
MAP (Mean Average Precision)	Precisión promedio sobre todas las posiciones relevantes.	Comparar sistemas en búsquedas Ad-hoc.	Promedia sobre consultas; sensible a consultas difíciles.
nDCG	Relevancia graduada ponderada por la posición en el ranking.	Cuando hay distintos niveles de relevancia o se valora el orden.	Muy usada en benchmarks modernos.
Kendall's τ / Pearson r	Asociación entre valores predichos y rendimiento real.	Evaluar métodos de QPP.	Necesitan pares (predicho, observado) por consulta.

En la evaluación de sistemas IR suele asumirse que los juicios de relevancia son correctos y completos, sin embargo, distintos estudios demuestran que la calidad de estos juicios depende en gran medida de la experticia del evaluador y del dominio temático de la colección. Cuando los evaluadores no son especialistas en el área o cuando la tarea es muy abierta, pueden aparecer discrepancias entre jueces, lo que introduce ruido en las métricas obtenidas y, por extensión, en la evaluación de los métodos de predicción de rendimiento [7, 8].

Esta situación es particularmente relevante para trabajos como el presente, donde el objetivo es correlacionar el valor entregado por un predictor con la efectividad real de la consulta, por ende, si los juicios de relevancia son incompletos o poco consistentes, la correlación observada puede reflejar las limitaciones de la colección más que las del método evaluado. De esta forma, los componentes de un sistema de recuperación de información funcionan como partes de un ciclo continuo, la indexación estructura, la representación abstrae, el modelo de recuperación calcula y la evaluación retroalimenta el proceso.

2.1.3 Consultas, tópicos y búsquedas Ad-hoc

Es importante distinguir entre consulta y tópico, la primera es la expresión que el usuario introduce en el sistema, mientras que el tópico representa la necesidad informativa

completa, que puede incluir una descripción y una narrativa que detalla qué se considera relevante.

Las consultas son la forma en la cual los usuarios expresan su necesidad de información dentro de un sistema IR. Por lo general, estas son breves, ambiguas o incompletas, lo que genera variabilidad en el rendimiento de los sistemas [9].

A cada consulta se le asocia un tópico, entendido como el contexto o tema subyacente que representa la intención informativa del usuario. En los benchmarks tradicionales, cada tópico incluye una descripción breve de la necesidad informativa y una lista de documentos considerados relevantes. Esta estructura permite establecer condiciones experimentales controladas para evaluar el rendimiento de distintos sistemas y analizar la variabilidad entre consultas.

Este esquema responde al denominado *paradigma Cranfield*, en el cual se define un conjunto fijo de consultas, se construye un conjunto de documentos candidatos y se recolectan juicios de relevancia humanos para cada consulta. A partir de esta configuración es posible comparar distintos modelos de recuperación bajo las mismas condiciones y, sobre todo, repetir los experimentos en el tiempo, lo que explica por qué colecciones como *TREC*, *Cranfield* o *Antique* se utilizan de forma recurrente en trabajos de evaluación y en investigaciones sobre QPP [9, 10].

Dentro del campo de IR, el término búsqueda Ad-hoc hace referencia a una tarea en la que se intenta recuperar los documentos más relevantes de un corpus dado una consulta única y sin contexto previo. A diferencia de otras búsquedas, como la interactiva o conversacional, la búsqueda Ad-hoc no cuenta con realimentación del usuario ni refinamiento iterativo. Por ello, el desempeño del sistema depende en gran medida de qué tan bien logra interpretar los términos de la consulta y relacionarlos con los documentos del corpus [6].

Los estudios sobre rendimiento en sistemas IR han demostrado que la dificultad de una consulta está estrechamente vinculada con su capacidad de discriminar documentos relevantes, por ejemplo, las consultas cortas o con términos frecuentes en el corpus tienden a recuperar documentos menos específicos, reduciendo la efectividad. En contraste, las consultas con términos raros o especializados suelen dar resultados más concentrados y relevantes [5]. Este comportamiento explica la necesidad de métricas y métodos de predicción de la dificultad, que permitan estimar la calidad esperada de la recuperación antes de disponer de juicios humanos.

En los últimos años, el concepto de búsqueda Ad-hoc se ha extendido hacia escenarios más complejos, como la búsqueda conversacional o multiturno, en los que la consulta forma parte de un diálogo progresivo con el sistema. Estas nuevas modalidades introducen desafíos adicionales, como el seguimiento de contexto o la reformulación dinámica de la intención informativa [9].

No obstante, el paradigma Ad-hoc sigue siendo el marco experimental más utilizado para la evaluación de métodos QPP, ya que permite controlar las variables de consulta y corpus, proporcionando resultados comparables entre diferentes modelos de recuperación.

2.2 Predicción de Rendimiento de Consultas (QPP)

La predicción del rendimiento de consultas (QPP, Query Performance Prediction), también conocida como estimación de la dificultad de la consulta (QDE, Query Difficulty Estimation), representa una rama de investigación en el campo de la Recuperación de Información (IR) que se enfoca en predecir la calidad de los resultados de búsqueda para una consulta dada, recuperados por un sistema de recuperación específico, **sin necesidad** de información de relevancia proporcionada por un operador humano. Este desafío surge de la observación de que los sistemas de búsqueda a menudo fallan en responder eficazmente a ciertas consultas, lo que se asocia directamente con la noción de **dificultad de la consulta** [5].

La diversidad en el rendimiento de las consultas y entre diferentes sistemas ha impulsado esta área, buscando mitigar la variabilidad en la efectividad de la recuperación. En este sentido, QPP cumple un rol netamente preventivo: anticipar la dificultad para activar ajustes selectivos (expansión, elección de parámetros o flujos alternativos) antes de observar fallos, reduciendo la variabilidad y mejorando la experiencia del usuario.

2.2.1 Dificultad y rendimiento de las consultas

La **dificultad de una consulta**, en el ámbito de la Recuperación de Información (IR), se asocia principalmente con la incapacidad de un sistema para responder de manera efectiva a una necesidad de información específica. Una consulta se considera **difícil** cuando el sistema de búsqueda obtiene un rendimiento deficiente en términos de sus medidas de efectividad. Este concepto es fundamental, ya que los fallos del sistema suelen estar directamente relacionados con la complejidad inherente o contextual de la consulta, lo que subraya la importancia de su predicción en la mejora continua de los sistemas de IR. La noción de dificultad de la consulta no es universal, y su interpretación puede variar dependiendo del contexto, el corpus, la ambigüedad de la consulta y el sistema de recuperación utilizado.

En contraste, el **rendimiento de una consulta** se define como una forma de estimar la dificultad inherente de la misma, mediante diversos experimentos de recuperación que generan a la vez múltiples métricas relacionadas con la calidad de los resultados obtenidos por el sistema. Estas métricas, obtenidas a través de experimentos que evalúan el resultado de la recuperación contra juicios de relevancia humana (*Qrels*), incluyen nDCG, Recall, AP y MAP, entre otras. Cada experimento de recuperación produce estas métricas simultáneamente sobre la misma lista ordenada de documentos, permitiendo una evaluación multidimensional de la efectividad del sistema. Un alto rendimiento en estas métricas indica

una consulta **fácil** con baja dificultad inherente, mientras que valores bajos sugieren una consulta **difícil** que desafía la capacidad del sistema para satisfacer la necesidad informativa del usuario. La predicción de este rendimiento, es por tanto, el núcleo de la predicción de rendimiento de consultas (*QPP*), buscando estimar estas métricas sin requerir juicios humanos de relevancia.

La interdependencia entre la dificultad y el rendimiento de las consultas es fundamental. Una **consulta** inherentemente **difícil**, ya sea por su **ambigüedad**, **la escasez de documentos relevantes en el corpus**, o **la formulación ineficaz**, tenderá a producir un bajo rendimiento en la mayoría de los sistemas de IR. Por lo tanto, estimar la dificultad de la consulta es, en esencia, **un intento de predecir el rendimiento que un sistema específico logrará para esa consulta en el contexto de un corpus específico**. Esta predicción permite a los sistemas anticipar posibles fallos y aplicar estrategias correctivas de manera proactiva, mejorando la experiencia del usuario y la eficiencia general del sistema.

Los **factores** que contribuyen a la dificultad de una consulta son variados y complejos. Pueden estar relacionados con la expresión misma de la consulta, como la ambigüedad léxica o semántica, o con su longitud y especificidad. Otro conjunto de factores se deriva del conjunto de datos o corpus, incluyendo su heterogeneidad, la distribución de términos y la cantidad de documentos relevantes disponibles. Finalmente, el método de recuperación empleado también influye en la dificultad percibida, ya que diferentes algoritmos pueden manejar la misma consulta con distintos niveles de éxito. Esta fuerte dependencia en múltiples factores hace que la predicción de la dificultad sea un desafío significativo incluso cuando se trata de predicciones realizadas por jueces expertos en el área [1, 11].

La **generalidad** de la dificultad de una consulta es un aspecto clave a considerar. Una consulta puede ser difícil para un sistema de recuperación particular, pero no para otros, o puede ser consistentemente difícil a través de una variedad de sistemas y colecciones. Esta generalidad se mide a menudo promediando el rendimiento predicho de la consulta a través de múltiples métodos de recuperación y diversas colecciones de documentos. Comprender esta variabilidad es esencial para desarrollar y evaluar predictores de dificultad que sean robustos y aplicables en diferentes escenarios de búsqueda, más allá de un único contexto sistema-colección [8].

Recientemente la literatura ha propuesto varias estrategias formales para definir la **dificultad** de una consulta q en particular. Todas parten del valor $m_{S_i}(q)$; la puntuación que entrega una métrica de efectividad M (p. ej., $nDCG$, AP) cuando se evalúa la lista recuperada para q por un sistema de recuperación S_i . Este valor sintetiza el rendimiento del sistema en esa consulta (cuanto menor es $m_{S_i}(q)$, más difícil resultó q para S_i). y es la variable base con la que se etiquetan las clases de dificultad. Estas estrategias se resumen en la Tabla 2.3:

1. **Percentiles:** Particiona la distribución de la métrica M por consulta mediante percentiles. En el caso binario, como se muestra en la Ecuación (2.1), una consulta q se

considera **difícil** para un sistema S_i si su valor $m_{S_i}(q)$ es menor o igual que un percentil p_x , es decir, si aproximadamente $x\%$ de las consultas tienen un valor inferior. En el caso de desear una **dificultad graduada**, se utilizan $N - 1$ percentiles para definir N clases ordenadas de dificultad, donde la primera clase agrupa las consultas más difíciles y la última las más fáciles.

$$p_x : \text{dificultad}(q) = 1_{\{m_{S_i}(q) \leq p_x\}} \quad (2.1)$$

En estas expresiones, $\text{dificultad}(q)$ es una función **indicadora** que toma el valor 1 cuando la consulta q se etiqueta como **difícil** y 0 en caso contrario. El parámetro p_x corresponde al percentil x -ésimo de la distribución de M sobre todas las consultas, de modo que $1_{\{m_{S_i}(q) \leq p_x\}}$ marca como **difíciles** aquellas cuyo rendimiento cae en el $x\%$ inferior de la distribución.

$$q \in \begin{cases} D_1 & \text{si } m_{S_i}(q) \leq p_1 \\ D_i, \forall_i = 2, \dots, N-2 & \text{si } P_{i-1} < m_{S_i}(q) \leq P_i \\ D_N & \text{si } m_{S_i}(q) > P_{N-1} \end{cases} \quad (2.2)$$

En el caso graduado Ecuación (2.2), los símbolos $D_1, \dots, D_N$ representa **clases ordenadas de dificultad** (por ejemplo, **muy difícil**, **difícil**, **fácil**, **muy fácil**), mientras que $P_1, \dots, P_{N-1}$ son percentiles crecientes que dividen la distribución de M en N segmentos. Cada consulta q se asigna a una clase D_k en función del intervalo en el que cae su valor $m_{S_i}(q)$ con respecto a estos cortes percentilares.

2. **Umbrales:** Fija cortes absolutos sobre la métrica para definir clases de dificultad. En el caso binario, como se expresa en la Ecuación (2.3), una consulta q es **difícil** para S_i si $m_{S_i}(q)$ es menor o igual que un umbral T (por ejemplo, consultas con $P@10 \leq 0.1$). Para el caso graduado, se emplea un conjunto de umbrales $T_1, \dots, T_{N-1}$ que inducen N clases de dificultad ordenadas.

$$T : \text{dificultad}(q) = 1_{\{m_{S_i}(q) \leq T\}} \quad (2.3)$$

Generalmente existen dos configuraciones típicas:

En la definición por umbrales, T es un **corte absoluto** fijado directamente sobre la escala de la métrica M . De nuevo, $\text{dificultad}(q)$ es una función indicadora que vale 1 si el rendimiento $m_{S_i}(q)$ de la consulta cae por debajo o en el propio umbral T (es

decir, si la consulta no alcanza un mínimo de efectividad considerado aceptable) y 0 en caso contrario.

- **Umbral único:** Se define un solo punto de corte. Por ejemplo, las consultas con $P@10 \leq 0.1$ se consideran **difíciles** y el resto **no difíciles**, creando una clasificación binaria.
- **Pares de umbrales:** Se usan dos umbrales para aislar los extremos. Por ejemplo, con el par $(0.1, 0.9)$, las consultas con $AP \leq 0.1$ son **muy difíciles** y aquellas con $AP \geq 0.9$ son **muy fáciles**. Las consultas intermedias se ignoran o se les asigna una clase intermedia, creando un margen que facilita la predicción al enfocarse solo en los casos más claros [1].

En la versión graduada, una secuencia ordenada de umbrales $T_1 < \dots < T_{\{N-1\}}$ permite definir varias clases de dificultad a partir de rangos absolutos de M : por ejemplo, **muy difícil** para $m_{\{S_i\}}(q) \leq T_1$, **difícil** para $T_1 < m_{\{S_i\}}(q) \leq T_2$, y así sucesivamente, hasta una última clase que agrupa las consultas con mejores valores de la métrica.

3. **Combinada:** Combina ambos criterios: percentiles y por umbral. En el caso binario, presentado en la Ecuación (2.4), una consulta se considera **difícil** si es clasificada como difícil tanto por la definición basada en percentiles como por la basada en umbrales (es decir, si $m_{S_i}(q) \leq T$ y $m_{S_i}(q) \leq p_x$). Para dificultad graduada, la clase asignada a una consulta corresponde a la intersección de las clases obtenidas con cada una de las dos estrategias anteriores.

$$\text{dificultad}(q) = 1_{\{m_{s_i}(q) \leq T \ \& \ m_{s_i}(q) \leq p_x\}} \quad (2.4)$$

En la definición combinada, la función $\text{dificultad}(q)$ solo toma el valor 1 cuando **simultáneamente** se cumplen las dos condiciones anteriores: el rendimiento de la consulta está por debajo del percentil p_x y, al mismo tiempo, por debajo del umbral absoluto T . La notación $1_{\{A \wedge B\}}$ indica la función indicadora del evento intersección entre A y B : vale 1 únicamente cuando ambas desigualdades se satisfacen, y 0 en cualquier otro caso.

Estas estrategias pueden plantearse en un enfoque **centrado en un único sistema**, donde la dificultad se define respecto de un sistema S_i específico, o bien respecto de un **conjunto de sistemas** $S = \{S_1, \dots, S_K\}$, reemplazando el conjunto de valores $\{m_{S_1}(q), \dots, m_{S_K}(q)\}$ por su promedio $\frac{1}{K} \sum_{i=1}^K m_{S_i}(q)$ sobre todos los sistemas considerados. La evidencia empírica muestra que las definiciones por umbrales con una separación marcada entre clases (p. ej., **muy difíciles** vs. **muy fáciles**) suelen producir sets de entrenamiento más contrastados y por ende, predicciones más estables y con mayores verdaderos positivos que las definiciones puramente percentilares o combinadas [1].

Tabla 2.3: Formas de definir la dificultad de una consulta.

Definición	Descripción	Notas/Configuración típica
Percentiles	Particiona la distribución de la métrica M por consulta mediante percentiles para inducir clases de dificultad (por ejemplo, de muy difícil a muy fácil).	Caso binario: difícil si $m_{S_i}(q) \leq p_x$. Caso graduado: $N - 1$ percentiles definen N clases ordenadas; sensibilidad fuerte al dataset.
Umbrales	Fija cortes absolutos sobre la métrica para definir clases de dificultad, típicamente enfocadas en consultas muy difíciles o muy fáciles.	Caso binario: difícil si $m_{S_i}(q) \leq T$ (ej: $P@10 \leq 0.1$). Caso graduado: umbrales $T_1, \dots, T_{N-1}$ inducen N clases; configuraciones habituales con umbral único o pares de umbrales para aislar extremos.
Combinada	Combina criterios percentilares y de umbrales, asignando dificultad sólo cuando ambas definiciones coinciden.	Menos estable empíricamente que los esquemas basados sólo en umbrales con brechas marcadas entre clases.
Ámbito	Definición respecto de un sistema específico o de un conjunto de sistemas de recuperación.	Centrada en un sistema S_i o sobre un conjunto S , promediando la métrica entre sistemas.

2.2.2 Soluciones al Problema de la Dificultad de las Consultas

La dificultad inherente de ciertas consultas ha impulsado el desarrollo de técnicas robustas para mejorar la efectividad de los sistemas de recuperación de información. A lo largo del tiempo, las soluciones han evolucionado desde métodos estadísticos clásicos hasta arquitecturas neuronales avanzadas, buscando siempre mitigar los fallos de recuperación asociados a consultas ambiguas, complejas o con desajuste de vocabulario.

Una de las primeras y más influyentes soluciones fue el desarrollo de **modelos de relevancia**. En lugar de depender exclusivamente de los términos de la consulta original, esta técnica utiliza un proceso de dos etapas para refinar la búsqueda.

Primero, se realiza una recuperación inicial y se asume que los documentos mejor clasificados son relevantes (un concepto conocido como *pseudo-relevance feedback*). A partir de este conjunto de documentos, se construye un modelo probabilístico que estima la distribución de términos que probablemente aparecerían en documentos verdaderamente relevantes. Los términos con alta probabilidad en este modelo, que pueden no haber estado en la consulta original, se utilizan para expandir o reestructurar la consulta.

Finalmente, esta nueva “consulta expandida” se utiliza para realizar una segunda recuperación, que a menudo produce un ranking de resultados mucho más preciso, resolviendo problemas comunes como la sinonimia y la polisemia [12].




Figura 2.5: Flujo de un sistema de recuperación basado en Modelos de Relevancia.

En la Figura 5 se ilustra el flujo típico de expansión mediante modelos de relevancia: una consulta inicial se ejecuta con un ranker léxico (BM25) para obtener los *top-K* documentos; a partir de ese conjunto pseudo-relevante se estima un modelo que induce nuevos términos y pesos; con la consulta expandida resultante se realiza una segunda recuperación, cuyo objetivo es reordenar con mayor precisión y producir un ranking final de documentos más alineado con la intención de la consulta.

Más recientemente, la llegada de los **Modelos extensos del lenguaje** (LLMs) ha supuesto un avance significativo en el panorama de la recuperación de información. Sin embargo, uno de sus mayores problemas es que su conocimiento se “**congela**” en el momento del entrenamiento, lo que **limita su acceso a información reciente** y los hace propensos a “**alucinar**” o generar contenido incorrecto.

Para superar estas limitaciones, ha surgido el paradigma de la **Generación Aumentada por Recuperación (RAG)**. Los modelos RAG combinan un recuperador de información con un LLM generativo en un proceso de dos fases:

1. **Recuperación:** Un sistema de recuperación busca en una base de conocimiento (por ejemplo, una colección de documentos) para encontrar fragmentos de texto relevantes para la consulta.
2. **Generación:** Estos fragmentos recuperados se proporcionan como contexto a un LLM junto con la consulta original. El LLM sintetiza una respuesta coherente y factual, fundamentada en la evidencia extraída.

Este enfoque ancla las respuestas del LLM en información verificable, reduciendo las alucinaciones y permitiendo que el conocimiento del sistema se actualice simplemente actualizando la base de conocimiento documental. Es una técnica especialmente poderosa para consultas de conocimiento intensivo que demandan respuestas precisas y actualizadas [3].

A pesar de su efectividad, estas soluciones avanzadas (desde la expansión de consultas hasta *pipelines LLM + RAG*) suelen tener un costo computacional elevado. No es eficiente ni necesario aplicarlas a todas las consultas, especialmente a aquellas que son simples y pueden ser respondidas adecuadamente por un sistema de recuperación estándar.

Por otro lado la **Predicción del Rendimiento de Consultas (QPP)** busca destacar especialmente en este área. Los predictores funcionan como una herramienta de diagnóstico que estima de antemano la efectividad esperada de un sistema para una consulta dada, sin necesidad de utilizar juicios de relevancia humanos. Al predecir si una consulta será “fácil” o “difícil”, un sistema de IR puede tomar decisiones proactivas y selectivas. Para una consulta predicha como “fácil”, se puede utilizar un método de recuperación rápido y eficiente. En cambio, si una consulta se predice como “difícil”, el sistema puede activar mecanismos más eficaces y costosos, como la expansión de consultas, el uso de modelos de relevancia o la activación de un *pipeline* de *RAG* para garantizar una respuesta de alta calidad. Por ende, QPP permite a los sistemas de recuperación gestionar estratégicamente sus recursos, mejorando la robustez y la eficiencia general al tiempo que se mitigan los fallos en las consultas más desafiantes [5].

2.2.3 Taxonomías en QPP

La literatura distingue dos categorías principales de predictores de rendimiento de consulta según el momento en que extraen información: métodos *pre-retrieval* y *post-retrieval*. Los primeros formalmente se caracterizan por actuar antes de ejecutar la búsqueda utilizando únicamente la consulta y estadísticas del índice; los segundos explotan señales observadas en la lista recuperada a partir de un modelo de recuperación de información (p. ej., patrones en las puntuaciones y funciones de ranking) [13].

En paralelo, al adentrarnos en el campo de la inteligencia artificial, podemos encontrar otras categorías de clasificación por ejemplo, **régimen de aprendizaje (no supervisados frente a supervisados)** y por **entorno (búsqueda ad-hoc y conversacional utilizando modelos extensos del lenguaje)**, cuyas elecciones suponen compromisos entre costo computacional, latencia y capacidad para modelar fenómenos como ambigüedad, variación temática y distribuciones de consultas [9, 14].

2.2.3.1 Predictores *pre-retrieval*

Los predictores *pre-retrieval* estiman la dificultad de una consulta a priori, sin ejecutar recuperación. Se apoyan en propiedades intrínsecas de la consulta y en estadísticas globales de la colección disponibles en tiempo de indexación. De forma general, caracterizan la especificidad y ambigüedad de la consulta, así como su potencial discriminativo en la colección, a partir de medidas o estadísticas resumidas que capturan propiedades léxicas de la consulta (longitud, diversidad o concentración de términos) y el patrón con que dichos términos aparecen en la colección (frecuencia y variabilidad entre documentos). Su atractivo radica en el bajo costo computacional y en que permiten decisiones de control (expansión, selección de sistema o ajuste de parámetros) antes de observar una lista recuperada [15, 16].

2.2.3.2 Predictores *post-retrieval*

Los predictores *post-retrieval* se estiman una vez disponible la lista recuperada para la consulta determinada y se apoyan en señales observables en dicha lista. En términos generales, se agrupan en cuatro familias:

- 1. El comportamiento de las puntuaciones devueltas por el ranker
- 2. La coherencia y consistencia semántica de los documentos en la cima del ranking
- 3. La estabilidad del ranking ante perturbaciones controladas (robustez)
- 4. El consenso con variantes del sistema o de la consulta.

Estas familias de señales buscan captar indicios de dificultad a partir de la respuesta del sistema para la consulta concreta.

Tabla 2.4: Factores y señales típicas en predictores post-retrieval.

Factor	Descripción	Ejemplos de señales
Puntuaciones del ranker	Patrones en las puntuaciones devueltas (magnitud, dispersión)	Varianza y distribución de puntajes, diferencias en el top-1 vs top-10

Factor	Descripción	Ejemplos de señales
	sión, forma y separabilidad entre tope y cola).	
Coherencia del tope	Consistencia semántica entre los documentos top-K y con la consulta.	Similaridad promedio entre top-K, comparación de modelos de lenguaje de los resultados y el dataset (clarity score)
Robustez del ranking	Estabilidad del ranking ante perturbaciones controladas del sistema, de los datos y de la consulta.	Sensibilidad a ruido/perturbación, estabilidad al remover/alterar top-K
Consenso entre variantes	Acuerdo con variantes del sistema o de la consulta.	Correlación de rangos entre el ranking original y variantes (por ejemplo, con stemming, con expansión de consulta).

Los enfoques *post-retrieval* pueden ser no supervisados (agregan señales derivadas de la propia lista devuelta) o supervisados (aprenden a mapear representaciones de consulta-lista a una estimación de rendimiento). Su efectividad depende del tipo de recuperador (léxico o denso), de la profundidad considerada (top-k frente a listas profundas) y de las propiedades de la colección, dado que distintas distribuciones de puntuaciones y estructuras de ranking favorecen señales diferentes. Aunque su costo es mayor que el de los métodos pre-retrieval, suelen proporcionar estimaciones más informadas al incorporar evidencia del resultado concreto de recuperación [13, 17, 18].

2.2.4 Aplicaciones de QPP en IR

La capacidad de predecir el rendimiento de una consulta abre un amplio abanico de aplicaciones prácticas que permiten a los sistemas de recuperación de información (IR) operar de manera más inteligente, robusta y eficiente. En lugar de tratar todas las consultas de la misma manera, los sistemas pueden utilizar los predictores de QPP para adaptar dinámicamente su comportamiento. Sin embargo, la utilidad de estas aplicaciones depende críticamente de la calidad del predictor: **se requiere una correlación moderadamente**

alta entre el rendimiento predicho y el real para que estas estrategias mejoren de manera fiable la efectividad del sistema [10].

- **Activación selectiva de mecanismos avanzados:** Como se mencionó anteriormente, técnicas como la expansión de consultas mediante modelos de relevancia o el uso de arquitecturas complejas como RAG son computacionalmente costosas. Sobre este punto, QPP funciona como una herramienta de diagnóstico que estima de antemano la efectividad esperada. Si una consulta se predice como **difícil**, el sistema puede activar estos mecanismos más potentes para garantizar una respuesta de alta calidad. En cambio, para una consulta predicha como **fácil**, se puede utilizar un método de recuperación estándar, optimizando así el uso de recursos sin sacrificar la calidad en los casos necesarios [5].
- **Expansión selectiva de consultas:** La retroalimentación de pseudo-relevancia (*pseudo-relevance feedback*, PRF) es una técnica común para expandir consultas, pero su aplicación indiscriminada tiene consecuencias negativas. Si los documentos mejor clasificados iniciales no son relevantes, los términos añadidos pueden desviar el enfoque de la consulta original, un fenómeno conocido como *query drift*. Este desvío a menudo degrada el rendimiento en lugar de mejorarlo. Los predictores QPP permiten una aplicación más segura de esta técnica. Si se predice que una consulta tendrá un bajo rendimiento, se considera como una buena candidata para la expansión, ya que el potencial de mejora es elevado y el riesgo de empeorar un resultado ya pobre es negligible. Por el contrario, si se predice que una consulta ya es efectiva, aplicar la expansión podría ser innecesario o incluso perjudicial. De este modo, la predicción actúa como un guardián, aplicando la expansión solo cuando es probable que sea beneficiosa [17].
- **Búsqueda federada y metabúsqueda:** En entornos donde los resultados provienen de múltiples colecciones o motores de búsqueda, la QPP es fundamental para la fusión inteligente de resultados. En la **metabúsqueda**, se consultan varios motores de búsqueda, mientras que en la **búsqueda federada**, se busca en múltiples colecciones con un solo motor. En ambos casos, en lugar de combinar los rankings basándose únicamente en los puntajes de cada fuente, se puede predecir el rendimiento de la consulta en cada una de ellas de forma independiente. Los resultados de las fuentes donde se predice un alto rendimiento pueden recibir una mayor ponderación en el ranking final. Esta estrategia ha demostrado mejorar significativamente la calidad de los resultados combinados, aunque su éxito también depende de la fiabilidad del predictor utilizado [5, 10].
- **Retroalimentación al usuario y al sistema:** La QPP también se utiliza para proporcionar retroalimentación directa. Un sistema puede informar al usuario que su consulta es probablemente “difícil” y que los resultados pueden ser de baja calidad, sugiriendo reformulaciones o términos alternativos. A nivel de administración del

sistema, el análisis de las consultas predichas como difíciles en los registros de búsqueda (*query logs*) puede ayudar a identificar **contenido faltante** en la colección, guiando así los esfuerzos para enriquecer la base de conocimiento y cubrir las brechas de información detectadas [5].

2.2.5 Supuestos, limitaciones y amenazas a la validez

A pesar de su potencial, la efectividad y la evaluación de los métodos de QPP se basan en un conjunto de supuestos y están sujetas a limitaciones importantes que deben ser consideradas para interpretar correctamente sus resultados.

La evaluación y la aplicación de los métodos de QPP descansan sobre varios supuestos centrales. Un supuesto extendido sostiene que una alta correlación (Pearson, Kendall, Spearman) entre las predicciones y una métrica de efectividad (AP, nDCG) se traduce en utilidad práctica; sin embargo, la evidencia empírica muestra que la correlación, **aun siendo estadísticamente significativa**, no garantiza por sí sola una mejora operativa, pues la utilidad real depende de cómo la predicción informa decisiones concretas dentro del sistema [10].

A ello se suma una fuerte dependencia de los juicios de relevancia (*Qrels*) como “suelo de verdad”. Este supuesto es particularmente frágil, ya que la calidad de los *Qrels* está sujeta a la variabilidad inherente al juicio humano. La evaluación de la relevancia no es un proceso mecánico; está influenciada por **la experiencia y el conocimiento del dominio del evaluador**. Se ha demostrado que los evaluadores no expertos (“generalistas”) tienden a producir juicios menos precisos y más superficiales en comparación con los expertos del dominio, recurriendo con frecuencia a la simple coincidencia de palabras clave en lugar de a una comprensión profunda de la **intención** de la consulta. Esta discrepancia introduce una fuente potencialmente significativa de sesgo en los resultados de evaluación, lo que significa que un predictor de QPP puede estar siendo interpretado incorrectamente para replicar los juicios de un tipo particular de evaluador, en lugar de una noción objetiva de relevancia [7].

La validez de las evaluaciones también está modulada por las características de los conjuntos de datos y de las muestras de consulta empleados. El rendimiento observado de un predictor depende en gran medida del **tipo de colección**: resultados alentadores en corpus limpios y homogéneos (p. ej., noticias) no necesariamente se sostienen en colecciones provenientes de la web más **ruidosas y heterogéneas**; por ello, las conclusiones de benchmarks deben interpretarse con cautela y no extrapolarse sin verificación a contextos productivos [8]. A ello se añade la sensibilidad a tamaños muestrales reducidos de consultas, frecuentes en campañas de evaluación: con pocas consultas, las estimaciones son más inestables y los intervalos de confianza se amplían, dificultando discernir si las diferencias entre predictores reflejan efectos genuinos o artefactos de muestreo. La composición de

la muestra (por ejemplo, una sobre-representación de consultas fáciles o difíciles) puede, además, sesgar las métricas y favorecer ciertas familias de predictores.

2.3 Métricas de Evaluación de Rendimiento y Correlación

Las **métricas de evaluación** cuantifican la calidad de un ranking y permiten contrastar, de forma objetiva, lo que un sistema recupera con lo que se espera encontrar. En el contexto de *QPP*, operan como punto de comparación para juzgar si las predicciones se alinean con el rendimiento observado a nivel de consulta y de colección. La base de todo cualquier métrica de evaluación son los **juicios de relevancia**, que fijan qué documentos del corpus se consideran relevantes para una consulta dada.

Sobre esa referencia se calculan medidas ampliamente utilizadas como ***Precision***, ***AP***, ***MAP*** y ***nDCG***. Estas métricas capturan distintos aspectos del rendimiento: exactitud en los tope del ranking, cobertura de documentos relevantes, calidad promedio a lo largo de la lista y sensibilidad a las relevancias graduadas. Su valor depende del orden de los resultados y de parámetros como la profundidad de corte (k), por lo que deben interpretarse en función del escenario de uso.

Para la evaluación de *QPP* se utiliza un protocolo experimental que utiliza las métricas de efectividad calculadas por consulta (por ejemplo, *AP*, *MAP*, *nDCG*) correlacionandolas directamente con el valor del predictor para la misma consulta. La comparación emplea **coeficientes de correlación de rangos** y se acompaña de **pruebas de significancia e intervalos de confianza** para estimar la robustez. De este modo, la utilidad del predictor se juzga por la magnitud y la estabilidad de las correlaciones y por su capacidad para guiar decisiones.

2.3.1 Juicios de relevancia (*Qrels*)

Los juicios de relevancia (*Qrels*) son las etiquetas que, para cada consulta, indican qué elementos del corpus son relevantes y con qué grado (binario o multigrado). Operan como referencia objetiva para calcular métricas de efectividad a nivel de consulta y de colección y, por tanto, constituyen el “suelo de verdad” o “*ground truth*” frente al cual se contrastan sistemas de recuperación y estimadores de rendimiento. Su definición y disponibilidad condicionan de forma directa la interpretación de resultados y la comparabilidad entre trabajos.

La obtención humana de *Qrels* suele realizarse mediante campañas de evaluación con anotadores expertos o capacitados, frecuentemente apoyadas en la técnica de *pooling*: es decir se agregan los resultados *top-k* resultantes de múltiples sistemas y se juzga ese subconjunto. Este procedimiento permite cubrir un espacio de resultados amplio con costos controlados, pero introduce incompletitud (no todos los elementos relevantes son juzgados) y sesgos de cobertura ligados a los sistemas incluidos y a la profundidad del *pool*. La **calidad** de

los juicios depende de guías de anotación, formación y control de calidad (p. ej., acuerdo entre anotadores medido con coeficientes como el K de Cohen) y de la escala de relevancia empleada; estos factores por ende tienen un impacto directo en la estabilidad de las métricas [7, 11, 19].

2.3.2 Métricas de evaluación clásicas en IR

En términos formales, una métrica de evaluación asigna a cada consulta un valor escalar que resume el rendimiento de un sistema a partir del ranking devuelto y de los juicios de relevancia (*Qrels*) asociados a sus documentos. A partir de estas puntuaciones por consulta se definen luego versiones agregadas a nivel de sistema, promediando sobre un conjunto de consultas: por ejemplo, *Precision@n(R)* corresponde a la media de las precisiones por consulta al corte n para el sistema R .

Entre las métricas más utilizadas se encuentran la **Precision** y la **Exhaustividad (Recall)**, sobre las cuales se construyen medidas más complejas como la **Precisión Media (AP)**, su promedio sobre consultas (*MAP*) y la **Ganancia Acumulada Descontada Normalizada (nDCG)**, que difieren en si asumen relevancia binaria o graduada y en la forma en que penalizan posiciones más profundas en el ranking [20].

La **Precisión (Precision)**, definida en la Ecuación (2.5), mide la fracción de documentos recuperados que son relevantes. Responde a la pregunta: “¿Qué proporción de los resultados que mostré son realmente útiles?”. Es un indicador de la exactitud de la búsqueda y requiere que los juicios de relevancia sean binarizados (es decir, un documento es relevante o no lo es, sin grados intermedios).

$$\text{Precision@n(R)} = \frac{1}{Q} \sum_{i=1}^Q \left[\frac{1}{n} \sum_{j=1}^n \text{rel}^b(d_j^i) \right] \quad (2.5)$$

Donde Q es el número de consultas del conjunto de evaluación, R denota el sistema o algoritmo de recuperación evaluado, n es la profundidad de corte (el número de primeras posiciones consideradas en el ranking) y d_j^i es el documento en la posición j de la lista devuelta por R para la consulta q_i ; finalmente, $\text{rel}^b(d_j^i)$ es la relevancia **binarizada** del documento d_j^i , devolviendo 1 si es relevante y 0 en caso contrario.

Una variante común es la **Precisión en K (Precision@K)**, que calcula la precisión considerando únicamente los primeros K resultados del ranking. Es especialmente útil porque refleja la experiencia del usuario, quien raramente explora más allá de la primera página de resultados [20].

La **Precisión Media (Average Precision, AP)** es una métrica que evalúa la calidad de un ranking para una única consulta combinando estas dos ideas. Se calcula promediando la

precisión en cada posición donde se encuentra un documento relevante. *AP* favorece a los sistemas que no solo recuperan muchos documentos relevantes (alta exhaustividad), sino que también los clasifican en las primeras posiciones (alta precisión). Para evaluar un sistema en un conjunto de consultas, se utiliza la **Precisión Media Promedio** (*Mean Average Precision, MAP*), que es simplemente el promedio de los valores de *AP* de todas las consultas [5].

$$\text{MAP@n(R)} = \frac{1}{Q} \sum_{i=1}^Q \left[\frac{1}{n_i} \sum_{j=1}^n \text{rel}^b(d_j^i) * \text{AP@j(R, } q_i) \right] \quad (2.6)$$

En la Ecuación (2.6), n_i corresponde al número de documentos relevantes para la consulta q_i según los *Qrels* y $\text{AP@j(R, } q_i)$ denota el valor de *AP* calculado hasta la posición j del ranking para la consulta q_i , manteniendo la misma convención de índices i (consulta) y j (posición) y la misma función de relevancia binarizada $\text{rel}^b(d_j^i)$ empleadas en la fórmula de Precisión.

La **Ganancia Acumulada Descontada Normalizada (Normalized Discounted Cumulative Gain, nDCG)** definida en la Ecuación (2.7), es una métrica más sofisticada que, a diferencia de la Precisión, sí tiene en cuenta los diferentes niveles de relevancia (por ejemplo, “relevante”, “muy relevante”). A nivel de consulta, puede verse como la razón entre la DCG obtenida por el sistema y la mejor DCG posible para esa misma consulta (IDCG).

$$\text{nDCG}_i = \frac{\text{DCG}_i}{\text{IDCG}_i} \quad (2.7)$$

La idea central es que los documentos altamente relevantes son más valiosos que los marginalmente relevantes, y la relevancia de un documento disminuye cuanto más abajo aparece en la lista de resultados.

Para ello, se asigna una ganancia a cada documento que crece exponencialmente con su nivel de relevancia (*rel*) derivado de los juicios de relevancia. Luego, esta ganancia se descuenta logarítmicamente según la posición del documento (j). Finalmente, el valor se normaliza dividiéndolo por un factor N_i , que representa la ganancia ideal para esa consulta (IDCG), para obtener una puntuación entre 0 y 1.

La fórmula general para calcular nDCG con un corte en n (nDCG@n), promediado sobre un conjunto de Q consultas, se define en la Ecuación (2.8) como:

$$\text{nDCG}@n = \frac{1}{Q} \sum_{i=1}^Q \left[\frac{1}{N_i} \sum_{j=1}^n \frac{2^{\text{rel}(d_j^i)} - 1}{\log_2(j+1)} \right] \quad (2.8)$$

Donde $\text{rel}(d_j^i)$ es ahora la relevancia **graduada** asignada al documento d_j^i (por ejemplo, 0, 1, 2, ... según el nivel de relevancia) y $\log_2(j+1)$ es el factor de descuento logarítmico que penaliza posiciones más profundas en el ranking, manteniendo la misma notación anterior para Q , n , i y j . En esta formulación, N_i cumple exactamente el papel de la **DCG ideal** para la consulta q_i : se corresponde con la **máxima DCG posible** dada la información disponible en los *Qrels*, obtenida ordenando idealmente los documentos conocidos como relevantes antes de calcular la suma interna; por tanto, N_i coincide con la **IDCG** clásica y permite escribir $\text{nDCG}_i = \frac{\text{DCG}_i}{\text{IDCG}_i}$ en el rango $[0, 1]$. El nDCG es una de las métricas más comunes en la evaluación de IR y QPP debido a su capacidad para manejar juicios de relevancia graduados y su sensibilidad al orden de los resultados [20].

2.3.3 Protocolos de evaluación de QPP y diseño experimental

La evaluación de los predictores de QPP sigue por lo general un protocolo experimental específico para garantizar que los resultados sean fiables, comparables e interpretables. El objetivo principal de este protocolo es medir qué tan bien las puntuaciones predichas por un método de QPP se correlacionan con el rendimiento real de un sistema de IR, medido por métricas como AP o nDCG.

Un diseño experimental típico implica varios componentes clave. Primero, se utiliza un conjunto de **colecciones de documentos** y **conjuntos de consultas** estandarizados, como los proporcionados por campañas de evaluación como TREC. Como se discutió anteriormente, el rendimiento de un predictor depende fuertemente del **tipo de colección** y de su nivel de “ruido” [8].

Las consultas se ejecutan utilizando uno o más **sistemas de recuperación de información** (o rankers), como BM25 o modelos neuronales. La efectividad real de cada consulta se calcula utilizando los juicios de relevancia (*Qrels*) disponibles y, en paralelo, se obtiene la puntuación predicha por el método de *QPP*. Sin embargo, como señala [2], el rendimiento observado para una consulta no se debe a una única causa, sino a la interacción de varios efectos. Por una parte, influye la **tarea o necesidad informativa** asociada al tópico: hay temas que, por la abundancia y claridad de los documentos relevantes, resultan intrínsecamente más fáciles que otros. También interviene la **formulación concreta de la consulta**, ya que dos variantes que expresan la misma necesidad pueden producir listas de resultados muy distintas según la elección de términos, su longitud o su ambigüedad. Finalmente, el propio **sistema de recuperación** introduce su efecto, puesto que distintos rankers responden de forma diferente ante la misma combinación de tarea y consulta. Si no

se tienen en cuenta estos componentes, un predictor de *QPP* puede aparentar funcionar bien simplemente porque discrimina tareas fáciles y difíciles, sin capturar realmente la dificultad específica de una formulación de consulta para un sistema dado.

Finalmente, se comparan las dos listas de puntuaciones (la real y la predicha) utilizando métricas de correlación. Un marco de evaluación robusto no se basa en estimaciones puntuales, sino que a menudo utiliza técnicas como los análisis de significancia también como el análisis de varianza (*ANOVA*) para modelar el rendimiento del predictor como una distribución, lo que permite un análisis estadístico más detallado y conclusiones más fiables [21].

2.3.4 Métricas de correlación para evaluar métodos QPP

El método estándar para cuantificar la efectividad de un predictor de QPP es medir la correlación entre la lista de puntuaciones de rendimiento predichas y la lista de puntuaciones de rendimiento reales (por ejemplo, AP o nDCG) para un conjunto de consultas. Dado que no se puede asumir que estas puntuaciones sigan una relación lineal o una distribución de probabilidad específica, se prefieren los **coeficientes de correlación de rangos**. Estos miden el grado de acuerdo entre dos ordenamientos, respondiendo a la pregunta: “¿si el predictor A es mejor que el predictor B, ¿se corresponde esto con un mejor rendimiento real?”.

Los tres coeficientes más comunes en la literatura de QPP son:

1. **Coeficiente de correlación de Pearson (r):** Es el único coeficiente paramétrico de los tres. Mide la **fuerza de la relación lineal** entre dos variables cuantitativas. Aunque es muy conocido, su uso en *QPP* debe ser cuidadoso. Es sensible a la magnitud de las diferencias y a los valores atípicos (*outliers*), y asume que los datos siguen una distribución normal bivariada. Como las métricas de rendimiento raramente cumplen con este supuesto, su aplicación requiere tests de normalidad previos para validar su aplicación. En términos formales, para un conjunto de n pares (x_i, y_i) con $i = 1, \dots, n$, se define en la Ecuación (2.9) como:

$$r = \frac{\sum_{i=1}^n (x_i - m_x)(y_i - m_y)}{\sqrt{\sum_{i=1}^n (x_i - m_x)^2 \sum_{i=1}^n (y_i - m_y)^2}} \quad (2.9)$$

Aquí, x_i y y_i representan las observaciones emparejadas de dos variables aleatorias (por ejemplo, altura y peso de una misma persona), mientras que m_x y m_y corresponden a sus medias muestrales.

2. **Coeficiente de correlación de rangos de Spearman (ρ):** Es una alternativa no paramétrica a Pearson. En lugar de usar los valores brutos, primero los convierte en rangos

y luego calcula el coeficiente de Pearson sobre esos rangos. Por ello, mide la **fuerza de una relación monotónica** (es decir, si una variable tiende a aumentar cuando la otra lo hace, sin que la relación tenga que ser lineal). Es menos sensible a los *outliers* que Pearson, pero puede ser afectado por la presencia de muchos rangos empatados. En la práctica, ρ se obtiene aplicando la misma fórmula de Pearson sobre los rangos ($R(x_i), R(y_i)$); cuando no hay empates, admite además la forma cerrada clásica presentada en la Ecuación (2.10):

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (2.10)$$

donde d_i representa, para cada observación i , la diferencia entre los rangos asignados a x_i e y_i , es decir, cuánto se desplaza la posición relativa del elemento i entre ambos ordenamientos. Cuando las dos listas coinciden perfectamente en su orden (máxima concordancia), todas las diferencias de rango valen cero y la suma de d_i^2 es nula, lo que produce $\rho = 1$; a medida que las posiciones relativas divergen, las diferencias de rango crecen, aumenta la suma de d_i^2 y el valor de ρ disminuye, reflejando menor acuerdo entre los rankings.

3. **Coeficiente de correlación de rangos de Kendall (τ)**: Es una medida no paramétrica que se considera la más robusta de las tres para la evaluación de *QPP*. En lugar de considerar la magnitud o el rango, τ se basa en el número de **pares concordantes** y **discordantes** entre los dos rankings. Un par de observaciones (x_i, y_i) y (x_j, y_j) es concordante si el orden relativo de x_i y x_j coincide con el de y_i y y_j , y discordante si dicho orden se invierte. Debido a que se basa en conteos, no asume ninguna distribución de los datos, es robusta frente a valores atípicos y maneja bien los empates en los rankings. Su interpretación también es más directa: representa la diferencia entre la probabilidad de que dos elementos estén en el mismo orden y la probabilidad de que estén en órdenes diferentes. La variante τ_b de Kendall, que corrige por empates en ambas listas y es la que se utiliza habitualmente en *QPP*, se define en la Ecuación (2.11) como:

$$\tau_b = \frac{P - Q}{\sqrt{(P + Q + T)(P + Q + U)}} \quad (2.11)$$

Aquí, P y Q denotan el número de pares concordantes y discordantes entre los dos rankings, mientras que T y U cuentan los pares empatados solo en la primera o solo en la segunda lista, respectivamente. De este modo, τ_b mide el balance neto entre concor-

dancias y discordancias, normalizado para corregir el efecto de los empates y mantener el coeficiente en el intervalo $[-1, 1]$.

En la práctica, Spearman y Kendall son generalmente preferidos sobre Pearson en la investigación de *QPP* por su naturaleza no paramétrica. Kendall's τ es a menudo el preferido por su robustez y su interpretación probabilística, aunque Spearman's ρ también se reporta comúnmente [22].

Finalmente, es crucial entender que una correlación estadísticamente significativa no siempre implica una mejora práctica. La investigación ha demostrado que una correlación, aunque sea alta (p. ej., > 0.5), puede no ser suficiente para que una aplicación como la expansión selectiva de consultas mejore de manera fiable el rendimiento del sistema. La utilidad real depende de la magnitud de esa correlación y del contexto de la aplicación, y muchos predictores existentes no alcanzan el umbral de fiabilidad necesario en escenarios reales [10, 22].

CAPÍTULO III: TRABAJOS RELACIONADOS

La predicción del rendimiento de consultas (QPP) es un área de investigación importante dentro de los sistemas de recuperación de información, puesto que permite anticipar la calidad de los resultados de una consulta sin necesariamente ejecutarla de forma completa. Es así, que a lo largo de los años se han desarrollado numerosos métodos QPP con diferentes características y aptos para distintas situaciones, los que han sido evaluados exhaustivamente en una larga cantidad de estudios. Estos estudios no solo han definido métricas y herramientas para medir la efectividad de los métodos QPP, sino que también han desarrollado análisis comparativos (*benchmarks*) que sirven como referencia en el estado del arte dentro del área.

A continuación, se revisan estudios relevantes relacionados con la predicción del rendimiento de consultas, presentando los principales métodos utilizados en la literatura, para posteriormente, analizar el uso de *datasets* y entornos de experimentación para la comparación de métodos, destacando investigaciones previas que han servido como base para el diseño experimental de este proyecto.

3.1 Métodos de Predicción de Rendimiento de Consultas (QPP)

En el contexto de este proyecto, se priorizó la revisión de métodos de *Query Performance Prediction* que no dependen de enfoques basados en inteligencia artificial (IA), los cuales, clasificados como *pre-retrieval* y *post-retrieval*, son altamente valorados por su simplicidad y robustez en la predicción del rendimiento de consulta sirviendo como base para métodos QPP más complejos.

Es así como, durante la revisión de la literatura, se identificaron trabajos claves que evaluaron y desarrollaron diferentes métodos QPP en diferentes contextos, como búsquedas *ad-hoc* y *benchmarks* de recuperación de información, proporcionando métricas importantes para evaluar la calidad de las consultas, los cuales se presentan a continuación.

3.1.1 IDF (Frecuencia Inversa de Documentos)

El predictor *Inverse Document Frequency* (IDF), ampliamente utilizado en el área, puede de igual manera funcionar como predictor *pre-retrieval* en sistemas de recuperación de información, este mide que tan específicos son los términos de una consulta dentro de un corpus. En el documento [15], se profundiza su relevancia como un componente clave en la predicción del rendimiento de consultas (QPP), específicamente su capacidad para identificar términos altamente selectivos, es decir, aquellos que aparecen en pocos documentos (menos comunes) y, por ende, aportan mayor discriminación en la búsqueda. El IDF también puede ser utilizado en su variante IDF-Max, donde el término con la mayor frecuencia inversa dentro de una consulta sirve como indicador principal de su efectividad.

Este indicador, que se basa en estadística, se adoptó rápidamente como una herramienta esencial en la predicción del rendimiento de consultas (QPP) *pre-retrieval*, siendo incorporada en otros esquemas y modelos probabilísticos de búsqueda.

$$IDF(t) = \ln\left(1 + \frac{N}{f_t}\right) \quad (3.1)$$

Como se ve en la Ecuación (3.1), N es el número total de documentos en el *corpus* y f_t es el número de documentos que contienen el término t , y se añade 1 para evitar divisiones por cero o valores indefinidos.

En el artículo [16], el autor señala que el IDF asigna pesos más bajos a los términos frecuentes debido a su limitado poder discriminatorio, mientras que otorga pesos más altos a los términos menos comunes, los cuales poseen mayor capacidad para distinguir documentos relevantes, asegurando que los términos poco frecuentes, pero informativos, tengan un mayor impacto en el cálculo de relevancia. Además, se destaca que, aunque la formulación exacta del algoritmo puede variar según los autores, su utilidad general permanece sólida en una amplia gama de aplicaciones prácticas, incluyendo la recuperación de información y otros contextos relacionados con el análisis de datos.

De esta forma, el IDF ha sido ampliamente utilizado debido a su robustez y simplicidad. En el artículo [16], el autor argumenta que el IDF equilibra de forma eficaz la especificidad y la relevancia, permitiendo su aplicación en diferentes contextos, tales como recuperación de textos, análisis de lenguaje natural e incluso en recuperación de medios no textuales.

En cuanto a su relevancia para el presente proyecto de evaluación de métodos de QPP, el IDF resulta relevante, ya que su capacidad para capturar la especificidad de los términos yace de manera tacita en otros predictores QPP, además, como se menciona en el artículo [6], su integración en distintas métricas proporciona una línea base confiable para la comparación con métodos más avanzados, validando su referencia tanto de forma heurística como de herramienta teórica sólida y bien fundamentada.

3.1.2 SCQ (Similitud entre consulta y colección)

El método *Similarity Between a Query and a Collection* (SCQ) , es un predictor *pre-retrieval* propuesto por Ying Zhao, Falk Scholer y Yohannes Tsegay. En el artículo [15] los autores explican que el SCQ calcula un puntaje de similitud entre una consulta y la colección de documentos, utilizando la frecuencia de términos en la colección y la frecuencia inversa de documentos (IDF) como evidencias para determinar la relevancia. Siendo una de sus principales ventajas que se basa en estadísticas disponibles durante el proceso de indexado, eliminando la necesidad de realizar búsquedas previas.

$$SCQ = \sum_{t \in Q} \left((1 + \ln(f_{c,t})) \cdot \ln \left(1 + \frac{N}{f_t} \right) \right) \quad (3.2)$$

En la Ecuación (3.2), podemos ver que Q es el conjunto de términos de la consulta, $f_{c,t}$ corresponde a la frecuencia del término t en la colección, f_t es el número de documentos en los que aparece el término t , y finalmente N es el número total de documentos de la colección.

Como se menciona, el SCQ mide la similitud mediante una representación vectorial, donde tanto las consultas como los documentos son tratados como vectores. La proximidad entre estos vectores se interpreta como un indicador de relevancia que permite identificar consultas que potencialmente obtendrán un mejor rendimiento en la recuperación de información. Además, este predictor puede ajustarse mediante la normalización por longitud de la consulta o evaluarse en función del valor máximo de SCQ alcanzado por los términos individuales.

Es así como, gracias a su balance entre la simplicidad y precisión, el SCQ promete ser una herramienta útil para sistemas de recuperación de información que manejan grandes volúmenes de datos en tiempo real, en donde su capacidad para establecer relaciones entre las características de las consultas y su rendimiento lo convierte en una contribución importante para tareas que involucran una alta variabilidad en las consultas, posicionándose como un estándar en evaluaciones pre-retrieval.

Por lo tanto, para el presente trabajo de título, el SCQ es particularmente relevante porque permite analizar consultas en dominios complejos y heterogéneos, estableciendo una relación clara entre las características de las consultas y su rendimiento esperado, lo que facilita una evaluación comparativa de métodos.

3.1.3 NQC (Normalized Query Commitment)

El método *Normalized Query Commitment* (NQC) fue propuesto por Anna Shtok, Oren Kurland y David Carmel como un predictor post-retrieval que evalúa la efectividad de una consulta midiendo la dispersión de los puntajes de recuperación entre los documentos más relevantes. En el artículo [17], los autores destacan que una menor dispersión temática en los documentos recuperados está directamente asociada con una mayor efectividad de las consultas, lo cual se refleja en la distribución de los puntajes de recuperación.

Por lo tanto, el enfoque de NQC se centra en medir la desviación estándar de los puntajes de recuperación normalizados por el promedio del corpus, lo que permite identificar consultas cuyos documentos recuperados son consistentes en términos de relevancia, sugiriendo un buen desempeño de la consulta. Además, los documentos con puntajes significativamente

superiores al promedio son menos propensos a exhibir desviaciones temáticas, lo que se traduce en un menor grado de *query drift* y un mejor rendimiento de recuperación.

$$NQC(q, M) = \frac{\sqrt{\frac{1}{k} \sum_{d \in D[k]_q} (Score(d) - \mu)^2}}{Score(D)} \quad (3.3)$$

En la Ecuación (3.3), q corresponde a la consulta, M al modelo de recuperación, $D[k]_q$ a la lista de los k documentos mejor rankeados, μ al promedio de los puntajes de recuperación en $D[k]_q$ y $Score[D]$ al puntaje de recuperación del corpus considerado como un único documento concatenado.

NQC resulta especialmente útil en el ámbito de la recuperación de información debido a su capacidad para capturar la consistencia en documentos relevantes y su adaptabilidad a diferentes modelos de recuperación, siendo su diseño simple lo que permite aplicarlo de manera eficiente, incluso en escenarios complejos donde se requiere alta precisión en los resultados.

Para el presente trabajo de título, NQC es relevante al proporcionar una métrica que permite evaluar la calidad de las consultas al correlacionar la dispersión de los puntajes con la efectividad esperada, lo que es fundamental para analizar consultas en dominios con alta variabilidad y establecer comparaciones confiables entre los diferentes métodos de predicción.

3.1.4 Clarity Score (CS)

El método *Clarity Score* (CS) fue desarrollado por Steve Cronen-Townsend, Yun Zhou y W. Bruce Croft como un predictor *post-retrieval* que analiza la claridad o coherencia de las consultas en sistemas de recuperación de información. En el artículo [6], los autores explican que el CS se basa en la comparación entre un modelo de lenguaje generado a partir de una consulta y el modelo de lenguaje global del *corpus*, utilizando la divergencia de Kullback-Leibler como herramienta matemática que permite calcular la distancia entre ambos modelos.

La lógica detrás de CS implica que consultas con términos más claros y específicos generarán modelos de lenguaje que se diferencian significativamente del modelo del corpus, obteniendo puntajes más altos. Estos términos, al estar menos expuestos a interpretaciones ambiguas, tienden a recuperar documentos más relevantes y precisos. Por otro lado, las consultas con puntajes más bajos suelen reflejar una mayor ambigüedad o dispersión temática, lo que puede afectar negativamente la precisión de los resultados recuperados.

El CS se calcula como la divergencia de Kullback-Leibler entre el modelo de lenguaje de la consulta y el modelo de lenguaje de la colección lo que se puede ver en la Ecuación (3.4).

$$CS(Q) = \sum_{w \in V} \left(P(w | Q) \log 2 \frac{P(w | Q)}{P_{coll}(w)} \right) \quad (3.4)$$

En donde w es un término en el vocabulario V , $P(w | Q)$ es la probabilidad del término w en el modelo de lenguaje de la consulta y $P_{coll}(w)$ es la probabilidad del término w en el modelo de lenguaje de la colección.

En términos prácticos, el CS demuestra ser una herramienta valiosa en el campo de la Recuperación de Información por varias razones fundamentales. En primer lugar, su capacidad para cuantificar la claridad de una consulta a través de la divergencia KL proporciona una medida objetiva de la especificidad de los términos de búsqueda. Además, al basarse en la comparación con el modelo de lenguaje de la colección completa, el método captura efectivamente las peculiaridades y la distribución del vocabulario en el dominio específico. Sin embargo, es importante señalar que su efectividad puede variar según las características del corpus y la naturaleza de las consultas, siendo particularmente útil en colecciones donde la ambigüedad terminológica representa un desafío significativo para la recuperación de información.

Finalmente, en el contexto del presente trabajo de título, el *Clarity Score* es relevante por su capacidad para proporcionar un indicador temprano sobre la calidad de las consultas, permitiendo evaluar cómo estas interactúan con el corpus y qué tan bien pueden desempeñarse en términos de recuperación efectiva, resultando crucial en escenarios donde la variabilidad y complejidad de las consultas pueden influir significativamente en los resultados esperados.

3.1.5 WIG (Weighted Information Gain)

El método *Weighted Information Gain* (WIG) fue desarrollado por Yun Zhou y W. Bruce Croft como un predictor post-retrieval diseñado para abordar los desafíos de la predicción del rendimiento de consultas en entornos de búsqueda web. En el artículo [14], los autores destacan que WIG mide la contribución promedio de los documentos mejor clasificados a la calidad del rendimiento de la consulta, basándose en el análisis de las características individuales de los términos y su proximidad, lo que permite evaluar la efectividad de las consultas en colecciones grandes y heterogéneas.

El cálculo de WIG se realiza comparando el cambio en la información entre un estado inicial, representado por un documento promedio del *corpus*, y el estado posterior, que corresponde a los resultados obtenidos tras la recuperación de los documentos relevantes. Este enfoque utiliza conceptos como la ganancia de información ponderada y distribuciones de probabilidad para estimar la calidad de la consulta, lo que lo convierte en una herramienta robusta para analizar el desempeño en escenarios complejos.

En la Ecuación (3.5), podemos ver que WIG se define como la diferencia entre la entropía ponderada de los documentos mejor clasificados y la entropía del modelo de lenguaje de la colección.

$$WIG(Q) = \frac{1}{k} \sum_{d \in Dk} \left(P(Q | d) \log \frac{P(Q | d)}{P(Q | C)} \right) \quad (3.5)$$

En donde Q es la consulta, Dk es el conjunto de los k documentos mejor clasificados, $P(Q | d)$ es la probabilidad de la consulta Q dado el documento d , y $P(Q | C)$ es la probabilidad de la consulta Q dado el modelo de lenguaje de la colección.

Es así que, WIG es especialmente relevante debido a su capacidad para adaptarse a distintos tipos de consultas y colecciones, incluyendo aquellas con gran diversidad en calidad y estilo de los documentos, resultando crucial para evaluar la efectividad de las consultas, proporcionando una métrica sólida para comparar métodos avanzados de predicción del rendimiento y asegurando un análisis confiable en dominios variados.

3.1.6 UEF (Utility Estimation Framework)

El *Utility Estimation Framework* (UEF) fue desarrollado por Anna Shtok, Oren Kurland y David Carmel como un enfoque post-retrieval que utiliza principios de la teoría estadística de decisiones para predecir el rendimiento de consultas. En el artículo [18] los autores explican que este método evalúa la calidad de un ranking de documentos basándose en su utilidad estimada con respecto a la necesidad de información representada en la consulta, proceso que se realiza al medir la similitud esperada entre el ranking generado y los rankings inducidos por modelos de relevancia.

El marco UEF permite una gran flexibilidad al emplear diferentes métricas de similitud, como el coeficiente de correlación de Pearson, y al estimar modelos de relevancia utilizando *pseudo-relevance feedback*. Esta combinación proporciona una base teórica sólida para predecir el rendimiento de consultas, ya que integra la precisión de los modelos de relevancia con un enfoque estructurado que captura las características del ranking generado por la consulta.

$$U(\pi_M(q; D)) = \int_{R_q} Sim(\pi_M(R_q; D)) p(R_q | I_q) dR_q \quad (3.6)$$

En la Ecuación (3.6), $\pi_M(q; D)$ corresponde al ranking generado por el modelo M , R_q al modelo de relevancia estimado basado en la consulta q , Sim es la medida de similitud entre

rankings y $p(R_q | Iq)$ a la probabilidad de que R_q represente la necesidad de información subyacente Iq .

El UEF destaca por su fundamentación teórica en la teoría estadística de decisiones, lo que le permite estimar de manera robusta la utilidad esperada de un ranking. Su diseño matemático incorpora explícitamente la incertidumbre inherente en la estimación de relevancia a través de la distribución de probabilidad $p(R_q | Iq)$, mientras que la función de similitud Sim cuantifica la concordancia entre el ranking original y los rankings generados por los modelos de relevancia estimados.

Es así que el UEF representa un avance significativo en la predicción del rendimiento de consultas al proporcionar un marco teórico sólido que unifica diferentes aspectos de la recuperación de información. Su formulación matemática rigurosa, basada en principios estadísticos, permite una evaluación sistemática de la calidad de los rankings, considerando tanto la estructura de los resultados como la incertidumbre en la estimación de relevancia.

3.2 Estudios comparativos similares

En cuanto a la investigación de trabajos relacionados, también se identificaron estudios comparativos que evaluaron diferentes métodos QPP en escenarios diversos, los cuales son claves para establecer un marco comparativo que permita validar los resultados finales de este proyecto, además estos trabajos no solo permiten identificar fortalezas y debilidades de cada enfoque, sino que también establecen líneas base estandarizadas para validar nuevos métodos y enfoques más experimentales.

A continuación, se presentan los estudios relevantes que evaluaron métodos QPP como IDF, SCQ, Clarity Score, entre otros, destacando sus aportes al estado del arte del área y su influencia en el diseño de este proyecto.

3.2.1 QPPTK en TIREx

Un reciente estudio relevante para el presente trabajo de título es el desarrollado por Zendel, Fröbe y Faggioli [4] en 2024, que proporciona una referencia fundamental al implementar y evaluar un marco de predicción del rendimiento de consultas (QPP) utilizando el *Query Performance Prediction Toolkit* (QPPTK) dentro de la plataforma TIREx. En este trabajo [4], los autores analizaron el desempeño de 12 métodos de predicción en combinación con diversos modelos de recuperación de información y 23 conjuntos de datos, incluyendo *benchmarks* reconocidos como TREC Robust04 y MS MARCO, por lo que, la amplitud de la evaluación y su enfoque en la reproducibilidad de los experimentos lo convierten en un recurso valioso para este proyecto.

Como se menciona, el estudio incluye una evaluación exhaustiva de métodos *pre-retrieval*, como IDF y SCQ, y *post-retrieval*, como NQC y Clarity Score, además, se demuestra cómo

la evaluación cruzada en múltiples *benchmarks* permite identificar patrones de rendimiento y validar la generalización de los métodos seleccionados, enfoque que se destaca por la importancia de utilizar plataformas estandarizadas, como TIREx (*The Information Retrieval Experiment Platform*). Esta plataforma se define como una infraestructura diseñada para fomentar experimentos de recuperación de información que sean reproducibles, escalables y estandarizados mediante la integración de herramientas como *ir_datasets* y *PyTerrier*, lo que no solo permite configurar entornos experimentales reproducibles, sino que también minimiza los sesgos potenciales en los resultados al estandarizar la configuración y los parámetros de los experimentos.

Una de las contribuciones clave del trabajo es la integración de una biblioteca que agrupa y estandariza las implementaciones de los distintos algoritmos de predicción (QPPTK) en TIREx, lo que facilita la realización de experimentos reproducibles, lo que se logra mediante la utilización de índices preconstruidos y configuraciones consistentes que garantizan estabilidad en las pruebas. Así mismo, los resultados generados son compartidos abiertamente, promoviendo su reutilización en futuros estudios, enfoque que resulta relevante para este proyecto, donde la reproducibilidad y la estandarización son fundamentales para garantizar la validez de las comparaciones entre métodos.

Es así que, los hallazgos de los autores, proporcionan métricas clave, como correlaciones entre predictores y métricas clásicas de recuperación, esenciales para validar los métodos implementados en este proyecto, además, su metodología y diseño experimental sirven como referencia directa para configurar los experimentos, asegurando que las evaluaciones sigan estándares establecidos en la literatura.

En resumen, este estudio no solo se destaca por la profundidad de su análisis, sino también por su contribución al establecimiento de prácticas experimentales reproducibles, que es en donde radica su relevancia para el proyecto presentado, ya que propone un diseño experimental y proporciona un marco sólido para evaluar métodos de predicción del rendimiento de consultas en entornos complejos.

3.2.2 *An Enhanced Evaluation Framework for Query Performance Prediction (2021)*

Otro estudio destacado y relevante para el presente trabajo de título es el realizado por Guglielmo Faggioli et al. [21] en 2021, quienes desarrollaron un marco de evaluación mejorado para la predicción del rendimiento de consultas (QPP), el cual aborda limitaciones clave de los enfoques tradicionales mediante la integración de análisis estadísticos avanzados y métricas diseñadas para evaluar, no solo la precisión, sino también la variabilidad y robustez de los métodos QPP en diferentes escenarios. Este marco supera las limitaciones de las evaluaciones basadas únicamente en correlaciones, como la dificultad para interpretar valores agregados únicos y la incapacidad para identificar consultas específicas donde los métodos fallan.

Es así que, en el artículo [21], los autores proponen un enfoque innovador que incluye métricas basadas en errores, como el *Scaled Absolute Rank Error* (SARE) y el *Scaled Mean Absolute Rank Error* (sMARE), las cuales permiten medir el error de predicción de manera distribuida por consulta. Además, incorporan técnicas estadísticas avanzadas, como el análisis de varianza (ANOVA) y pruebas *post hoc* para evaluar las diferencias entre métodos con mayor detalle. Estas herramientas permiten no solo comparar la precisión de los predictores, sino también analizar la influencia de factores como el tema de la consulta, el método de recuperación y la configuración de *stemming* en el rendimiento del QPP.

Como se menciona, el artículo se destaca por su enfoque en la medición de errores distribuidos por consulta, lo que permite un análisis más granular del desempeño de los métodos, en donde se realizaron experimentos en conjuntos de datos estándar como TREC Robust-04, utilizando métodos *pre-retrieval*, como MaxIDF y SCQ, y *post-retrieval*, como NQC y Clarity Score, cuyos resultados revelaron que factores como el modelo de recuperación, la configuración de *stemming* y *stoplists*, y la naturaleza de las consultas influyen significativamente en el rendimiento del QPP. Por ejemplo, se observó que los métodos *post-retrieval*, como NQC y Clarity, tienden a tener una correlación más alta con la precisión promedio (AP), mientras que los métodos *pre-retrieval*, como MaxIDF, pueden ser más robustos en ciertos escenarios. Estos hallazgos proporcionan información valiosa para optimizar estos sistemas y seleccionar el método más adecuado según la situación.

En el contexto del presente trabajo de título, el marco propuesto por los autores es importante, ya que introduce prácticas de evaluación reproducibles y detalladas, alineadas con estándares modernos, además de que, sus hallazgos sobre la interacción de factores experimentales y el rendimiento del QPP sirven como guía directa para configurar experimentos que sean estadísticamente sólidos y representativos en escenarios reales. Por ejemplo, el uso de ANOVA y pruebas *post hoc* permite identificar no solo qué métodos son superiores en general, sino también en qué condiciones específicas (como ciertos tipos de consultas o configuraciones) un método puede ser mejor que otro, lo que es particularmente útil en aplicaciones prácticas donde la variabilidad de las consultas y los documentos es alta, como en motores de búsqueda web y sistemas de recomendación.

En resumen, el trabajo de los autores, no solo proporciona un marco metodológico avanzado para la evaluación de QPP, sino que también ofrece *insights* prácticos sobre cómo optimizar estos sistemas en función de factores contextuales, lo que lo convierte en una referencia clave para el presente trabajo de título, especialmente en la fase de diseño experimental y evaluación de métodos de predicción de rendimiento de consultas.

CAPÍTULO IV: DISEÑO DE LA EVALUACIÓN COMPARATIVA

El diseño de esta evaluación comparativa no solo tiene como propósito validar la implementación técnica de los métodos QPP seleccionados, sino también establecer líneas base que permitan analizar sus fortalezas y limitaciones en contextos variados propios de los sistemas de recuperación de información. Para ello, se consideraron criterios sólidos y alineados con las mejores prácticas del estado del arte, garantizando la representatividad y el rigor del análisis comparativo.

La necesidad de un diseño comparativo sólido radica en la creciente complejidad de los sistemas de recuperación de información y la diversidad de escenarios en los que estos se aplican. Como señala [4], uno de los desafíos fundamentales en la investigación de QPP radica en la falta de reproducibilidad y estabilidad de los resultados experimentales, debido en parte a la variabilidad en las configuraciones de los sistemas de recuperación y en los conjuntos de datos utilizados. Esta variabilidad justifica la adopción de un marco experimental que utilice múltiples *datasets* representativos de diferentes dominios y tipos de consultas, emplee herramientas estandarizadas que garanticen la reproducibilidad, y aplique métricas de evaluación ampliamente aceptadas en la literatura. El diseño experimental propuesto sigue las recomendaciones de estudios recientes que enfatizan la importancia de establecer líneas base estables y reproducibles para futuras comparaciones [4, 21].

En el presente trabajo de título, el diseño de la evaluación comparativa no solo busca responder preguntas específicas sobre el rendimiento de los métodos seleccionados, sino también contribuir al avance del estado del arte en QPP, estableciendo un marco que promueva prácticas experimentales reproducibles, transparentes y aplicables a diversos contextos, garantizando que los hallazgos obtenidos sean relevantes tanto para la comunidad científica como para la práctica en sistemas de recuperación de información.

4.1 Protocolo de evaluación experimental

En esta sección se describe el protocolo de evaluación desarrollado para llevar a cabo la evaluación comparativa de los métodos de *Query Performance Prediction* (QPP). A continuación se presenta el flujo general de los experimentos, las métricas empleadas para la evaluación, y las configuraciones técnicas específicas del entorno experimental.

Respecto a este último, está diseñado para garantizar la reproducibilidad, flexibilidad y transparencia. Para lograrlo, se ha implementado un entorno basado en capas, y reproducible en Docker, que permite ejecutar los experimentos de manera consistente y controlada, sin depender de configuraciones específicas de hardware o software.

4.1.1 Paradigma de evaluación de métodos QPP

Antes de describir el flujo del sistema, es fundamental formalizar el paradigma de evalua-

ción estándar utilizado en la literatura para cuantificar la calidad de los métodos de *Query Performance Prediction* (QPP). Este marco conceptual constituye la base teórica del diseño experimental.

El paradigma de evaluación se modela a partir de los siguientes componentes fundamentales:

1. **Contexto de Recuperación:** En la Ecuación (4.1), $\mathcal{C}$ es una colección de documentos y $\mathcal{Q} = \{q_1, \dots, q_n\}$ un conjunto de n consultas de evaluación. Dado un sistema de recuperación S (*ranker*), la ejecución de una consulta $q_i \in \mathcal{Q}$ sobre el corpus genera una lista ordenada de documentos L_i :

$$L_i = S(q_i, \mathcal{C}) \quad (4.1)$$

2. **Ground Truth (Efectividad Real):** Para cada consulta q_i , existe un conjunto de juicios de relevancia R_i (*qrels*). Como se define en la Ecuación (4.2), la efectividad real del sistema para dicha consulta, denotada como $m_S(q_i)$, se obtiene aplicando una métrica de evaluación $\mathcal{M}$ (como AP o nDCG) sobre la lista recuperada:

$$m_S(q_i) = \mathcal{M}(L_i, R_i) \quad (4.2)$$

El conjunto de valores de efectividad para todas las consultas conforma el vector de desempeño real $\vec{m}_S \in \mathbb{R}^n$:

$$\vec{m}_S = [m_S(q_1), m_S(q_2), \dots, m_S(q_n)]^\top \quad (4.3)$$

3. **Predicción de Rendimiento:** Un método QPP se define como una función estimadora φ que asigna un puntaje a cada consulta, intentando aproximar su dificultad. Según la Ecuación (4.4), el vector de predicciones $\vec{\varphi} \in \mathbb{R}^n$ se construye calculando:

$$\vec{\varphi} = [\varphi(q_1), \varphi(q_2), \dots, \varphi(q_n)]^\top \quad (4.4)$$

Dependiendo del tipo de predictor, la función $\varphi(q_i)$ puede depender solo de la consulta y el *corpus* (*pre-retrieval*) o también de la lista recuperada L_i (*post-retrieval*).

4. **Evaluación de la Calidad:** Finalmente, la calidad del predictor P se cuantifica midiendo la asociación estadística entre el desempeño real y el predicho. Esto se formaliza en

la Ecuación (4.5) mediante una función de correlación (típicamente Pearson ρ o Kendall τ):

$$\text{Calidad}(P) = \text{Corr}(\vec{m}_S, \vec{\varphi}) \tag{4.5}$$

El objetivo experimental es, por tanto, encontrar un predictor φ^* tal que maximice esta correlación, tal como se expresa en la Ecuación (4.6):

$$\varphi^* = \arg \max_{\varphi} \text{Corr}(\vec{m}_S, \vec{\varphi}) \tag{4.6}$$

Una alta correlación positiva indica que el predictor es capaz de ordenar las consultas de manera similar a su rendimiento real, permitiendo distinguir fiablemente entre consultas “difíciles” y “fáciles” par el sistema S [17].

4.1.2 Flujo del sistema

El diseño experimental sigue un flujo bien definido en el contexto de la recuperación de información, garantizando su entendimiento, reproducibilidad y el análisis riguroso de los resultados, como se puede apreciar en la Figura 4.1.




Figura 4.1: Diagrama de componentes del entorno de evaluación.

El flujo incluye los siguientes pasos principales:

- **Preparación de *Datasets*:** Los *datasets* seleccionados, más adelante descritos, se descargan de manera completa utilizando la librería *ir_datasets* y se preprocesan en

- el entorno *Docker*, este proceso incluye la extracción de consultas, preparación de los juicios de relevancia (*Qrels*) y el formateo adecuado para su uso con *PyTerrier*.
- **Indexado de *Datasets*:** Los *datasets* se indexan utilizando *PyTerrier*, creando estructuras de datos eficientes para la recuperación de información. Es también en este paso donde se guardan metadatos de los *datasets*, como la frecuencia de los términos en los documentos como la frecuencia de estos en la colección. Además, se hace uso del “*Stemmer*” de *Snowball* sobre los documentos y consultas, para conseguir resultados más precisos en la evaluación.
 - **Configuración de Modelos de Recuperación:** Configuración de modelos de recuperación como estándar como *BM25* en *PyTerrier* con parámetros predefinidos, asegurando una base consistente para la evaluación de los métodos *QPP*.
 - **Implementación de los métodos *QPP*:** Los métodos seleccionados, como, por ejemplo, *IDF*, *SCQ* o *NQC*, se implementan mediante scripts en *Python* dentro del contenedor *Docker*, todos estos utilizan una interfaz similar dentro del sistema, permitiendo una ejecución estandarizada de los métodos.
 - **Ejecución de los métodos de predicción:** Los experimentos se realizan mediante un script principal que realiza múltiples iteraciones por método y dataset, asegurando estabilidad y fiabilidad de los resultados.
 - **Evaluación utilizando juicios de relevancia (*Qrels*):** Se realiza una evaluación del rendimiento de las consultas utilizando la librería de *ir_measures* sobre el sistema de recuperación implementado, esto es el “*ground truth*” del rendimiento de la consulta en el sistema de recuperación implementado. Posteriormente los resultados se almacenan en formato estructurado para su posterior análisis.
 - **Evaluación utilizando métricas de correlación:** Se realiza una evaluación de la correlación entre los puntajes de los predictores y las métricas IR, utilizando la biblioteca de código abierto en *Python*, *Scipy*, especializada en computación científica y análisis estadístico, para obtener una medida de la efectividad de los predictores *QPP* con relación al “*ground truth*”.
 - **Documentación y Almacenamiento:** Los resultados, configuraciones y scripts de ejecución se almacenan en directorios organizados dentro del contenedor *Docker*, garantizando su fácil acceso y análisis.

Entre los componentes de la Figura 4.1, se puede discernir la capa de datos, de indexación y recuperación. Estos componentes funcionan completamente dentro de la librería *Pyterrier*, el cual funciona como un *wrapper* para la librería *Terrier*, la cual es ampliamente utilizada en la literatura de recuperación de información para la realización de experimentos similares [23].

4.1.3 Configuración técnica

Para garantizar la fiabilidad, reproducibilidad y comparabilidad de los experimentos, se ha establecido un marco técnico estandarizado que regula desde el entorno de ejecución hasta los parámetros específicos de los algoritmos.

A continuación se detallan los componentes fundamentales de la configuración técnica:

- **Entorno *Docker*:** Al permitir encapsular todas las dependencias necesarias en un entorno reproducible, se evitan problemas de compatibilidad y configuración entre máquinas, asegurando que los experimentos puedan ser ejecutados de manera uniforme y reproducible. Esta decisión de diseño se alinea con las recomendaciones del QPPTK, cuya arquitectura permite delegar aspectos secundarios como la configuración del sistema de recuperación o el procesamiento del *corpus* a salidas cacheadas, permitiendo que los investigadores se enfoquen exclusivamente en el desarrollo y evaluación de métodos QPP [4].

El sistema utiliza una imagen base de *Python 3.9* con *Java 11* instalado para soportar PyTerrier.

- **Parámetros del Modelo de Recuperación:** El sistema utiliza el modelo de recuperación *BM25* (*Best Match 25*) como método principal de recuperación. La elección de *BM25* como modelo base sigue la práctica estándar en la literatura de QPP, donde los análisis experimentales comúnmente emplean *BM25* para garantizar la comparabilidad con estudios previos [4, 17]. Esta decisión permite que los resultados obtenidos puedan ser directamente contrastados con trabajos anteriores y establece una línea base estable para la evaluación de los predictores. Los parámetros han sido mantenidos en su configuración por defecto, como se observa en la Tabla 4.1.

Tabla 4.1: Parámetros principales de BM25.

Parámetro	Descripción	Justificación de Aplicación	Valor
k1	Factor de saturación de término. Controla cómo el score de un documento aumenta con cada ocurrencia adicional de un término de la consulta. Un valor más alto significa que se da más importancia a la frecuencia del término.	Crucial para colecciones con documentos que contienen repeticiones significativas de términos. Afecta directamente el cálculo de scores en métodos QPP post-recuperación como WIG.	1.2
b	Factor de normalización de longitud del documento. Determina cuánto se penalizan los documentos más largos. Un valor más alto significa una normalización más agresiva de la longitud.	Especialmente importante en colecciones heterogéneas como <i>ANTIQUE</i> donde la longitud de los documentos varía significativamente. Impacta el cálculo de NQC al normalizar los scores.	0.75

Otros estudios han propuesto la utilización de otros parámetros para BM25, como el parámetro k1, el cual controla la saturación de términos en los documentos, sobretudo al utilizar métodos de *clustering*, tales experimentos han demostrado que un valor de k1 mayor a 1.2 puede mejorar el rendimiento de la recuperación. Sin embargo, en este estudio se mantendrán los parámetros por defecto de PyTerrier, ya que se ha demostrado que estos proporcionan un rendimiento adecuado para la mayoría de las tareas de recuperación de información, pero se puede realizar un estudio futuro sobre la utilización de estos parámetros en la evaluación de métodos QPP [24].

- **Ejecución de los métodos y scripts de evaluación:** La Tabla 4.2 muestra una configuración flexible de la ejecución de la evaluación a través de diversos parámetros que controlan tanto el proceso de recuperación como la evaluación QPP. La configuración se realiza principalmente mediante argumentos de línea de comandos y variables de entorno.

Tabla 4.2: Parámetros principales de configuración.

Parámetro	Descripción	Valor por defecto
-datasets	Datasets a evaluar (e.g., antique_test, trec_covid, msmarco_dl20_judged)	Todos los datasets
-max-queries	Límite de consultas a procesar	None (todas)
-list-size	Tamaño de lista para métricas de ranking	10
-wig-list-size	Tamaño de lista para el predictor WIG	5
-nqc-list-size	Tamaño de lista para el predictor NQC	200
-num-results	Número máximo de resultados por consulta	1000
-metrics	Métricas de evaluación (e.g., ndcg@10, ap)	nDCG@10, AP
-correlations	Coefficientes de correlación a calcular (Kendall, Spearman, Pearson)	kendall
-use-uef	Habilita las variantes utilizando el marco UEF (Utility Estimation Framework)	True
-skip-plots	Omite la generación de visualizaciones	False
-output-dir	Directorio de salida para los resultados	None

La ejecución se puede realizar tanto directamente a través de Python como mediante contenedores *Docker*, donde los parámetros se configuran a través de variables de entorno. El sistema utiliza valores por defecto seleccionados para garantizar una evaluación robusta incluso con configuración mínima.

- **Almacenamiento de Resultados:** Los resultados de la evaluación se almacenan en una estructura organizada dentro del directorio del proyecto. Las métricas de IR (nDCG, AP) se guardan por consulta en archivos de texto plano, mientras que las correlaciones entre predictores QPP y métricas se almacenan en formato tabular, acompañadas de visualizaciones (diagramas de caja y de dispersión) generadas automáticamente.

La evaluación final integra estos resultados mediante un análisis bidimensional: Primero midiendo la efectividad del sistema de recuperación base, medida a través de las métricas IR por consulta, y luego midiendo la capacidad predictiva de los métodos QPP, cuantificada mediante coeficientes de correlación por rangos entre los puntajes de los predictores y las métricas IR. Una mayor correlación significa que los puntajes de los predictores son confiables para predecir el rendimiento del sistema de recuperación.

- **Métricas Utilizadas:** Para el desarrollo de esta evaluación se optó por el uso de métricas de evaluación que cuentan con una presencia amplia en la literatura, por un lado se decantó por el uso nDCG y MAP, las cuales son ampliamente utilizadas en tareas de ranking y precisión proporcionan una medida del rendimiento del sistema de recuperación. Por otro lado, se decantó por el uso de métricas de correlación para la predicción de rendimiento de consultas, como el coeficiente de correlación de Kendall y Spearman, las cuales son ampliamente utilizadas en la literatura y proporcionan una medida de la efectividad de los predictores QPP [22].

En el contexto de la evaluación de sistemas de recuperación de información, las métricas binarias como *Average Precision* (AP) requieren una distinción clara entre documentos relevantes y no relevantes. Para lograr esto, se establece un umbral binario sobre los niveles de relevancia originales del *dataset*, donde los documentos con un nivel de relevancia igual o superior al umbral se consideran relevantes, mientras que aquellos por debajo se consideran no relevantes. Este enfoque permite evaluar el rendimiento del sistema en términos de su capacidad para distinguir entre documentos relevantes y no relevantes.

Por otro lado, las métricas graduadas como el *Normalized Discounted Cumulative Gain* (nDCG) aprovechan la naturaleza multi-nivel de los juicios de relevancia mediante valores de ganancia. Estos valores representan la utilidad o importancia relativa de cada nivel de relevancia, donde un valor más alto indica una mayor relevancia del documento. La asignación de valores de ganancia es crucial ya que influye directamente en cómo la métrica evalúa la calidad del ranking, penalizando más severamente cuando documentos altamente relevantes (con mayor valor de ganancia) aparecen en posiciones más bajas del ranking.

Para el análisis de correlación, el sistema implementa tres coeficientes (τ -Kendall, ρ -Spearman, r -Pearson), pero prioriza τ -Kendall por interpretabilidad, ya que mide directamente la proporción de pares concordantes vs discordantes, por robustez al ser menos sensible a valores atípicos y transformaciones monótonas, por normalización, ya que su rango consistente $[-1,1]$ es independiente de la distribución y por su significancia al tener mejor comportamiento con muestras pequeñas.

La elección de estas métricas de correlación está fundamentada en las prácticas estándar del campo de QPP. Como documentan [17], existen dos medidas de evaluación comúnmente utilizadas en el marco de predicción de rendimiento de consultas: el coeficiente de correlación de Pearson (ρ), que se calcula entre los valores de Average Precision reales y los valores asignados por el método de predicción, y el coeficiente de correlación τ de Kendall, que se calcula entre un ranking de consultas ordenadas por su AP real y un ranking inducido por los valores del predictor. Para ambas métricas, valores de correlación más altos indican una mayor calidad de predicción [17].

De igual forma en [13] validan este enfoque metodológico al evaluar la calidad de predicción mediante ambos coeficientes: la correlación de Pearson mide la correlación lineal entre dos variables en un rango de $[-1,1]$, mientras que τ de Kendall mide la asociación entre dos cantidades medidas, donde 1 denota que los dos rankings son idénticos y -1 indica que uno es el inverso del otro.

Además, dentro de la literatura se ha discutido sobre el rendimiento e interpretabilidad de otros coeficientes, como el coeficiente de correlación de Pearson, el cual es menos robusto que τ -Kendall y Spearman, y su uso ha sido desestimado en favor de las anteriormente mencionadas [8]. El marco de evaluación mejorado propuesto por [21] sugiere además modelar el rendimiento de *QPP* como una distribución en lugar de depender de estimaciones puntuales, lo que proporciona implicaciones estadísticas importantes y supera limitaciones del enfoque tradicional basado únicamente en correlaciones.

La implementación utilizará la librería *ir_measures* para garantizar cálculos estandarizados de las métricas de recuperación de información, mientras que *Scipy* proporciona implementaciones eficientes de los coeficientes de correlación. El sistema maneja automáticamente casos especiales como queries sin resultados o scores *QPP* indefinidos, asegurando una evaluación robusta incluso en condiciones no ideales.

4.2 Selección de conjuntos de datos

La selección de *datasets* es parte fundamental para garantizar una evaluación comparativa robusta y representativa de los métodos *QPP*, es por ello, que se seleccionaron *datasets* reconocidos en la literatura, priorizando los que ofrecen juicios de relevancia *Qrels* y métricas estandarizadas, permitiendo así validar el desempeño de los métodos seleccionados en escenarios variados.

Además, investigaciones como [17] han validado sus metodologías utilizando colecciones *TREC* ampliamente reconocidas incluidas en esta evaluación, las cuales han sido empleadas en numerosos estudios de predicción de rendimiento de consultas, permitiendo un análisis profundo de la calidad de predicción y el estudio de diversos factores que afectan a los predictores. Este enfoque garantiza no solo la robustez de los resultados, sino también su generalización a futuros trabajos relacionados con *QPP*.

4.2.1 Criterios de inclusión

La Tabla 4.3 presentan los criterios aplicados en la selección de *datasets*, detallando su importancia en el contexto del proyecto.

Tabla 4.3: Criterios de inclusión de datasets.

Criterio	Descripción	Importancia para el proyecto
Disponibilidad pública	Datasets de acceso abierto y bien documentados, sin restricciones para su uso.	Garantiza la reproducibilidad y facilita la implementación en diversos contextos.
Diversidad de escenarios	Representación de diferentes tipos de consultas (informacionales, navegacionales y transaccionales) y dominios.	Asegura la evaluación integral de los métodos en múltiples contextos.
Uso en el estado del arte	Amplio uso en investigaciones previas de recuperación de información y QPP.	Respalda la validez y comparabilidad de los resultados obtenidos.
Tamaño adecuado	Incluye tanto datasets pequeños como grandes.	Permite evaluar el comportamiento de los métodos en diferentes escalas de datos.
Relevancias conocidas (Qrels)	Incluyen juicios de relevancia establecidos previamente.	Facilitan la evaluación precisa y objetiva del desempeño de los métodos QPP.

- **Disponibilidad pública** : Es fundamental seleccionar *datasets* de acceso abierto que estén bien documentados, ya que esto garantiza la transparencia y la reproducibilidad de los experimentos, la disponibilidad pública también asegura que los resultados puedan ser validados por otros investigadores, fomentando la colaboración y el avance en el campo del QPP.
- **Diversidad de escenarios**: Incluir *datasets* con diferentes tipos de consultas es crucial para evaluar cómo se desempeñan los métodos QPP en escenarios reales, por ejemplo de consultas informacionales: preguntas abiertas donde el usuario busca adquirir conocimiento general; consultas navegacionales: consultas donde el objetivo es encontrar una página específica; y consultas transaccionales: consultas orientadas a completar una acción. Esta diversidad asegura que los métodos sean

efectivos en una variedad de tareas de recuperación, desde búsquedas generales hasta necesidades específicas.

- **Uso en el estado del arte:** Seleccionar *datasets* ampliamente utilizados en investigaciones previas permite que los resultados del proyecto sean comparables con estudios existentes, lo que refuerza la validez del análisis comparativo y asegura que las metodologías empleadas cumplan con estándares científicos.
- **Tamaño adecuado:** La inclusión de *datasets* de diferentes tamaños permite evaluar el comportamiento de los métodos en escenarios con distintos volúmenes de datos, en donde los *datasets* pequeños son ideales para pruebas controladas y rápidas, mientras que los grandes, son útiles para analizar la escalabilidad y robustez de los métodos. Este enfoque asegura que los métodos QPP seleccionados sean evaluados en condiciones que reflejen tanto la simplicidad como la complejidad de los sistemas de recuperación de información modernos.
- **Relevancias conocidas (*qrels*):** Los juicios de relevancia son esenciales para evaluar el desempeño de los métodos de manera objetiva, al incluir *datasets* con *qrels* bien establecidos, se garantiza que los resultados estén basados en un marco estandarizado, facilitando su interpretación y comparación

Es así como la aplicación de estos criterios garantiza que los *datasets* seleccionados sean adecuados para el análisis comparativo de los métodos QPP, de igual forma, al priorizar la diversidad, relevancia y representatividad, este proyecto establece una base sólida para evaluar el desempeño de los métodos en diferentes contextos y escalas, contribuyendo al avance del estado del arte en predicción del rendimiento de consultas.

4.2.2 Justificación de los conjuntos de datos seleccionados

Como se ha mencionado, los *datasets* seleccionados para el proyecto fueron escogidos cuidadosamente para garantizar que cubran una amplia gama de escenarios y dominios representativos, por lo que se alinean con los criterios de inclusión previamente establecidos, aportando características únicas que permiten evaluar el rendimiento de QPP en contextos diversos, asegurando resultados generalizables y relevantes para investigaciones futuras, además de contribuir al avance del estado del arte.

Un criterio fundamental en la selección fue la preferencia por *datasets* con juicios de relevancia multi-nivel (*graded relevance judgments*). Esta decisión se fundamenta en las siguientes ventajas:

- **Anotaciones manuales de alta calidad:** Los *qrels* de múltiples niveles son típicamente anotados por evaluadores expertos o jueces especializados, lo que garantiza una mayor precisión y consistencia en los juicios de relevancia.

- **Significado semántico por nivel:** Cada nivel de relevancia tiene un significado específico y definido (por ejemplo, “no relevante”, “parcialmente relevante”, “altamente relevante”), lo que permite una evaluación más matizada del rendimiento.
- **Compatibilidad con métricas graduadas:** Los juicios multi-nivel permiten el uso de métricas con factores de ganancia como nDCG que aprovechan la granularidad de las anotaciones, proporcionando una evaluación más completa del sistema de recuperación.

La Tabla 4.4 especifica los datasets seleccionados, seguida de la Tabla 4.5 que detalla los estadísticos de cada colección, incluyendo el origen de sus consultas y juicios de relevancia.

Tabla 4.4: Tabla de datasets y sus criterios de inclusión.

Dataset	Descripción	Contribución al proyecto	Razón de inclusión
Cranfield Collection	Dataset clásico con resúmenes científicos y consultas pre-determinadas de tamaño reducido.	Facilita pruebas rápidas y controladas para la comparación directa de métodos QPP.	Simplicidad y diseño compacto lo hacen ideal para experimentos iniciales y controlados.
ANTIQUE	Dataset centrado en la recuperación de preguntas y respuestas subjetivas basadas en opiniones.	Evalúa el desempeño de los métodos frente a consultas subjetivas y no factuales.	Introduce complejidad adicional al incorporar preguntas subjetivas difíciles de modelar.
TREC-COVID	Parte del benchmark BEIR, centrado en la recuperación de información médica sobre COVID-19.	Permite evaluar los métodos QPP en un dominio altamente especializado y relevante.	Su enfoque en consultas científicas lo hace adecuado para escenarios de alta especificidad.
MS MARCO Passage (TREC DL 2020)	Subconjunto del MS MARCO Passage utilizado en TREC Deep Learning 2020 con juicios oficiales.	Proporciona un entorno realista para evaluar la aplicabilidad práctica de los métodos.	Refleja el contexto de búsqueda cotidiana con anotaciones de relevancia detalladas.
TREC CAR	Dataset del TREC CAR v1.5 Year 1	Proporciona evaluación con juicios humanos	Incluye juicios negativos explícitos que permiten un

Dataset	Descripción	Contribución al proyecto	Razón de inclusión
	con juicios de relevancia manuales.	manos detallados en escala graduada.	análisis más profundo.

Tabla 4.5: Estadísticos de los datasets seleccionados.

Dataset	Variante ir_datasets	Documen- tos	Consultas	Qrels	Origen de Anotaciones
Cranfield	cranfield	1.400	225	1.837	Expertos en aerodinámica (1960s)
ANTIQUE	antique/ test	403.666	200	6.589	Crowdworkers (Amazon MTurk)
TREC-COVID	beir/trec-covid	171.332	50	66.336	Asesores NIST (expertos médicos)
MS MARCO DL 2020	msmarco-passage/ trec-dl-2020/ judged	8.841.823	54	11.386	Asesores NIST (TREC DL 2020)
TREC CAR	car/v1.5/ trec-y1/ manual	29.678.367	2.287	29.571	Asesores NIST (juicios manuales)

Cranfield Collection: La colección Cranfield representa uno de los hitos fundacionales en la historia de la recuperación de información. Desarrollada entre 1958 y 1966 en el *Cranfield Institute of Technology* (actualmente Cranfield University) en el Reino Unido, bajo la dirección de Cyril Cleverdon, constituye el primer intento sistemático de evaluar sistemas de recuperación de información bajo condiciones controladas.

- **Documentos:** La colección consta de 1.400 resúmenes científicos en el dominio de la aerodinámica. Cada documento incluye campos de identificador, título, texto del abstract, autor y referencia bibliográfica.
- **Consultas:** Las 225 consultas fueron formuladas en lenguaje natural por investigadores del área, representando necesidades de información reales del dominio científico.
- **Origen de Qrels:** Los juicios de relevancia fueron anotados manualmente por expertos en aerodinámica, estableciendo una escala de 5 niveles (-1 a 4). Estos juicios introdujeron el concepto de “*relevance judgments*” que se convertiría en estándar para la evaluación de IR. La distribución incluye: 225 juicios de nivel -1, 128 de nivel 1, 387 de nivel 2, 734 de nivel 3, y 363 de nivel 4.
- **Importancia histórica:** Los experimentos de Cranfield establecieron el “paradigma Cranfield” que incluye una colección de documentos, un conjunto de consultas con juicios de relevancia asociados, y evaluación basada en *precisión* y *recall*, metodología que posteriormente adoptaría TREC.

ANTIQUE (*A Non-factoid Question Answering Benchmark*): ANTIQUE es un benchmark diseñado específicamente para la recuperación de respuestas no factuales, desarrollado por investigadores de la Universidad de Massachusetts Amherst y publicado en 2019 [25].

- **Documentos:** La colección contiene 403.666 pasajes cortos de respuestas extraídos de Yahoo! Answers (Webscope L6), un servicio de preguntas y respuestas comunitario donde usuarios formulaban preguntas de diversa índole.
- **Consultas:** El conjunto de test incluye 200 preguntas no factuales de dominio abierto, caracterizadas por ser subjetivas y basadas en opiniones, donde no existe una única respuesta “correcta”. Las preguntas provienen de categorías diversas como consejos, recomendaciones y experiencias personales.
- **Origen de Qrels:** Los 6,589 juicios de relevancia del conjunto de test fueron recolectados mediante crowdsourcing en Amazon Mechanical Turk. Los anotadores evaluaron todas las respuestas disponibles para cada pregunta utilizando una escala de 4 niveles: nivel 1 (fuera de contexto), nivel 2 (no relevante), nivel 3 (marginamente relevante), y nivel 4 (altamente relevante). La distribución incluye: 1.642 juicios de nivel 1, 2.417 de nivel 2, 1.196 de nivel 3, y 1.334 de nivel 4.
- **Objetivo:** Este dataset introduce complejidad adicional para los sistemas de recuperación debido a la naturaleza subjetiva de las consultas, donde la relevancia depende de factores contextuales y de opinión difíciles de modelar estadísticamente.

TREC-COVID: TREC-COVID fue una iniciativa colaborativa entre el *Allen Institute for Artificial Intelligence* (AI2), el *National Institute of Standards and Technology* (NIST), la

National Library of Medicine (NLM), Oregon Health & Science University (OHSU), y la University of Texas Health Science Center at Houston (UTHealth) [26].

- **Documentos:** La colección utiliza el corpus CORD-19 (*COVID-19 Open Research Dataset*) mantenido por Semantic Scholar. La versión BEIR contiene 171.332 artículos científicos representados por sus títulos y abstracts, incluyendo campos como identificador, texto, título, URL y PubMed ID.
- **Consultas:** Las 50 consultas representan necesidades de información reales de científicos, clínicos, responsables de políticas públicas y otros profesionales que necesitaban navegar la creciente literatura científica sobre COVID-19 durante la pandemia. Cada consulta incluye un título conciso, una descripción expandida y una narrativa que especifica qué documentos serían considerados relevantes.
- **Origen de Qrels:** Los 66.336 juicios de relevancia fueron creados por asesores de NIST con experiencia biomédica, provenientes de NLM, OHSU y UTHealth. La evaluación se realizó en cinco rondas consecutivas durante 2020, acumulando juicios de relevancia profundos (*“deep relevance judgments”*). La escala incluye: nivel -1 (no evaluado o documento eliminado, 2 juicios), nivel 0 (no relevante, 41.661 juicios), nivel 1 (relevante, 10.456 juicios), y nivel 2 (altamente relevante, 14.217 juicios).
- **Objetivos:** El track buscó evaluar algoritmos de búsqueda para ayudar a gestionar el corpus de literatura científica sobre COVID-19 y descubrir métodos aplicables a futuras crisis biomédicas globales.

MS MARCO Passage (*TREC Deep Learning 2020*): MS MARCO (*Microsoft Machine Reading COmprehension*) es una colección a gran escala desarrollada por Microsoft Research, utilizada como base para el *TREC Deep Learning Track* desde 2019 [27].

- **Documentos:** El *corpus* completo contiene 8.841.823 pasajes extraídos de documentos web reales indexados por Bing. Cada pasaje consiste en un identificador y el texto del pasaje.
- **Consultas:** Las consultas del TREC DL 2020 fueron muestreadas del conjunto de evaluación de MS MARCO. Originalmente, estas consultas provienen de preguntas reales y anónimas formuladas por usuarios del motor de búsqueda Bing, lo que garantiza que representan necesidades de información auténticas y cotidianas. El subconjunto *“judged”* contiene 54 consultas que fueron evaluadas por asesores de NIST.
- **Origen de Qrels:** A diferencia de los juicios de relevancia escasos de MS MARCO original (donde típicamente solo un documento es marcado como relevante por consulta), el TREC DL 2020 proporciona 11.386 juicios de relevancia detallados creados por asesores de NIST. La escala de 4 niveles incluye: nivel 0 (irrelevante, 7.780 juicios), nivel 1 (relacionado, 1,940 juicios), nivel 2 (altamente relevante,

1.020 juicios), y nivel 3 (perfectamente relevante, 646 juicios). El umbral binario oficial de TREC es ≥ 2 .

TREC CAR (*Complex Answer Retrieval*): TREC CAR es una colección de recuperación de pasajes *ad-hoc* construida a partir de Wikipedia, diseñada para abordar necesidades de información complejas que requieren respuestas extensas y estructuradas [28].

- **Documentos:** El corpus v1.5 contiene 29.678.367 pasajes extraídos de Wikipedia (*dump* de diciembre 2016). Cada documento incluye un identificador único y el texto del pasaje.
- **Consultas:** Las 2.287 consultas del *Year 1* (2017) fueron derivadas de la estructura jerárquica de artículos de Wikipedia. Cada consulta incluye un identificador, texto completo, título del artículo y la jerarquía de encabezados que representa la sección específica. Las consultas fueron seleccionadas manualmente de temas de ciencia popular y medio ambiente, inspiradas en noticias de actualidad y temas de interés general.
- **Origen de Qrels:** La versión “manual” (*car/v1.5/trec-y1/manual*) contiene 29.571 juicios de relevancia creados por seis asesores de NIST utilizando *pools* de documentos contruidos a partir de las entregas de los participantes. La escala graduada de 6 niveles es la más detallada entre los datasets seleccionados:
 - Nivel -2: Basura/spam (42 juicios)
 - Nivel -1: No relevante (12.785 juicios)
 - Nivel 0: No relevante pero tema cercano (9.219 juicios)
 - Nivel 1: Podría mencionarse (3.094 juicios)
 - Nivel 2: Debería mencionarse (1.970 juicios)
 - Nivel 3: Debe mencionarse (2.461 juicios)
- **Diferencia con qrels automáticos:** TREC CAR también ofrece qrels automáticos derivados de la estructura de Wikipedia, pero para este proyecto se utiliza exclusivamente la versión con juicios manuales por su mayor fiabilidad y la inclusión de juicios negativos explícitos.

Además, todos los datasets utilizados son de acceso abierto en repositorios públicos y están bien documentados debido a que son ampliamente reconocidos en la comunidad de recuperación de información, lo que asegura que cualquier investigador pueda acceder a ellos sin restricciones para replicar los experimentos. Todos los datasets son accesibles a través de la librería *ir_datasets*, garantizando un proceso estandarizado de carga y preprocesamiento. Es así que, la utilización de datasets de acceso abierto garantiza que los resultados del proyecto sean reproducibles y accesibles para futuras investigaciones, fomentando el entorno colaborativo y transparente, evitando problemas legales o éticos relacionados con el uso de datos restringidos o privados.

De esta forma, la selección de datasets con características bien definidas asegura una evaluación diversa y representativa de los métodos QPP seleccionados, ya que este enfoque cubre dominios especializados, tareas cotidianas y casos complejos, estableciendo una base sólida para validar la efectividad y aplicabilidad de los métodos en diferentes contextos de recuperación de información.

Una vez definidos los conjuntos de datos, es necesario operacionalizar las métricas de evaluación descritas en la *Sección 4.1* ajustándolas a las escalas de relevancia particulares de cada colección seleccionada, dado que cada *dataset* posee criterios de juicio distintos, se ha establecido una configuración estandarizada para los umbrales de relevancia y los valores de ganancia.

En la Tabla 4.6 se detalla la configuración específica de relevancia, umbrales binarios y valores de ganancia para cada *dataset* seleccionado.

Tabla 4.6: Configuración de métricas por dataset.

Dataset	Configuración	Justificación
Cranfield Collection	- Relevancia: 5 niveles (-1 a 4) - Umbral binario: ≥ 1 - Valores de ganancia: - Nivel -1: 0 (Sin interés) - Nivel 1: 1 (Interés mínimo) - Nivel 2: 2 (Referencia útil) - Nivel 3: 3 (Alta relevancia) - Nivel 4: 4 (Respuesta completa)	Escala graduada clásica que permite distinguir desde documentos sin interés hasta respuestas completas. Ideal para experimentos controlados.
ANTI-QUE	- Relevancia: 4 niveles (1-4) - Umbral binario: ≥ 3 - Valores de ganancia: - Nivel 1: 0 (Fuera de contexto) - Nivel 2: 1 (No relevante) - Nivel 3: 2 (Marginal) - Nivel 4: 3 (Altamente relevante)	Escala granular para preguntas subjetivas. Los niveles 1-2 se consideran no relevantes para métricas binarias.
TREC-COVID	- Relevancia: 4 niveles (-1 a 2) - Umbral binario: ≥ 1 - Valores de ganancia:	Incluye nivel -1 para documentos no evaluados. Permite distinguir infor-

	▸ Nivel -1: 0 (No evaluado/negativo) ▸ Nivel 0: 0 (No relevante) ▸ Nivel 1: 1 (Relevante) ▸ Nivel 2: 2 (Altamente relevante)	mación COVID-19 de alta relevancia.
MS MARCO Passage (TREC DL 2020)	• Relevancia: 4 niveles (0-3) • Umbral binario: ≥ 2 • Valores de ganancia: ▸ Nivel 0: 0 (Irrelevante) ▸ Nivel 1: 1 (Relacionado) ▸ Nivel 2: 2 (Altamente relevante) ▸ Nivel 3: 3 (Perfectamente relevante)	Umbral binario en ≥ 2 siguiendo la práctica oficial de TREC. Escala graduada para nDCG.
TREC CAR	• Relevancia: 6 niveles (-2 a 3) • Umbral binario: ≥ 1 • Valores de ganancia: ▸ Nivel -2: 0 (Basura) ▸ Nivel -1: 0 (No relevante) ▸ Nivel 0: 0 (No relevante, tema cercano) ▸ Nivel 1: 1 (Puede mencionarse) ▸ Nivel 2: 2 (Debería mencionarse) ▸ Nivel 3: 3 (Debe mencionarse)	Escala detallada con juicios manuales. Incluye niveles negativos para contenido basura o irrelevante.

4.3 Selección de métodos de QPP

La selección de métodos QPP resulta crucial en el diseño de este proyecto, ya que determina la relevancia y la validez del análisis comparativo.

Para garantizar que los enfoques evaluados sean representativos y estén alineados con los objetivos del estudio, se establecieron criterios rigurosos basados en la literatura científica revisada, los cuales priorizan la inclusión de métodos reconocidos en el estado del arte, con fundamentos estadísticos sólidos y un alto grado de reproducibilidad.

A continuación, se describen los criterios aplicados en el proceso de selección, así como los métodos QPP finalmente escogidos para la posterior evaluación comparativa.

4.3.1 Criterios de selección

Como se ha mencionado, la selección de métodos de *Query Performance Prediction* (QPP) es un proceso fundamental para garantizar que los métodos evaluados sean representativos, robustos y relevantes en el contexto de los sistemas de recuperación de información. Con este propósito, se definieron criterios específicos que permiten abordar el problema desde una perspectiva teórica sólida y práctica aplicable, los que aseguran la validez de la evaluación comparativa y su alineación con los objetivos del proyecto.

Tabla 4.7: Criterios de selección de métodos de QPP.

Criterio	Descripción	Importancia para el proyecto
Base estadística y simplicidad	Métodos con fundamentos sólidos y fácilmente comprensibles.	Facilita la reproducibilidad y asegura resultados confiables.
Uso en estudios previos	Métodos comúnmente implementados en investigaciones recientes.	Garantiza relevancia científica y comparabilidad con investigaciones previas
Diversidad de enfoques	Cobertura de métodos pre-retrieval y post-retrieval, cada uno enfocado en aspectos distintos del rendimiento.	Permite una evaluación integral que abarca múltiples aspectos del rendimiento de consultas.
Relevancia en el estado del arte	Métodos no basados en inteligencia artificial y ampliamente reconocidos por su efectividad teórica y práctica.	Asegura un marco comparativo que no depende de tecnologías supervisadas y promueve análisis no sesgados.

La Tabla 4.7 resume los criterios definidos para la selección de los métodos de QPP, en donde cada criterio cumple un rol específico para garantizar que los métodos seleccionados no solo sean estadísticamente sólidos, sino también relevantes y diversificados en su enfoque, asegurando que el análisis comparativo resultante sea exhaustivo y útil para evaluar las fortalezas y limitaciones de los métodos elegidos.

- **Base estadística y simplicidad:** Se seleccionan métodos que se basan en conceptos matemáticos fundamentales, como la frecuencia de términos en el *corpus* y su relación con la consulta, ya que estos métodos son ampliamente reconocidos por su sencillez y su capacidad para ser implementados y replicados sin necesidad de recursos computacionales avanzados. Este criterio asegura que los métodos elegidos puedan ser utilizados como referencia en investigaciones futuras, promoviendo la reproducibilidad de los experimentos y el entendimiento teórico de los predictores.
- **Uso en estudios previos:** Se buscan métodos que han sido recurrentemente evaluados en trabajos recientes que analizan sistemas de recuperación de información, ya que no solo garantiza que los resultados del proyecto sean comparables con investigaciones previas, sino que también asegura que los métodos seleccionados representan soluciones probadas y bien documentadas.
- **Diversidad de enfoques:** Se seleccionan métodos tanto *pre-retrieval* como *post-retrieval* para capturar diferentes aspectos del problema, mientras que unos se enfocan en estimar la calidad de una consulta basándose únicamente en estadísticas del corpus, los otros evalúan la calidad considerando los documentos recuperados. Este enfoque integral permite analizar el rendimiento de consultas desde múltiples perspectivas, proporcionando una visión más completa de sus fortalezas y debilidades.
- **Relevancia en el estado del arte:** Se priorizan métodos no basados en inteligencia artificial, ya que estos garantizan un análisis más transparente y menos sesgado en comparación con tecnologías supervisadas, además, de esta forma, los métodos seleccionados han sido ampliamente reconocidos en la literatura por su aplicabilidad en sistemas de recuperación de información y su capacidad para ser implementados sin depender de datasets de entrenamiento o modelos complejos.

Por otra parte, la decisión de priorizar métodos no basados en inteligencia artificial tiene varias razones claves:

- **Transparencia y simplicidad:** Los métodos no basados en inteligencia artificial, ofrecen interpretaciones claras de cómo se calculan y qué factores influyen en su desempeño, esto contrasta con los métodos supervisados, cuya complejidad en ocasiones dificulta la comprensión de su funcionamiento interno.
- **Reproducibilidad:** Al no depender de datasets de entrenamiento o modelos complejos, los métodos no basados en IA pueden ser implementados en cualquier entorno sin necesidad de recursos adicionales, lo que asegura que los experimentos realizados sean replicables por otros investigadores.
- **Independencia del contexto:** Los métodos seleccionados son independientes de los dominios específicos y los cambios en las colecciones de datos, mientras que los métodos supervisados tienden a ser altamente sensibles a las características del dataset de entrenamiento.

- **Contribución al estado del arte:** Este enfoque se alinea con el objetivo de establecer líneas base sólidas para evaluar nuevos métodos, permitiendo que futuros desarrollos en QPP se comparen con estándares bien establecidos.

4.3.2 Métodos seleccionados

Siguiendo los criterios establecidos en la sección anterior y tras un análisis exhaustivo de la literatura, se seleccionaron seis métodos de *Query Performance Prediction* (QPP) para la evaluación comparativa, los cuales representan enfoques diversos e incluyen estrategias *pre-retrieval* y *post-retrieval*, lo que asegura una cobertura de los aspectos clave del rendimiento de consultas en sistemas de recuperación de información. Además, como se ha mencionado, cada método fue elegido por su relevancia en el estado del arte, su fundamento teórico y su impacto demostrado en investigaciones previas, ofreciendo un marco robusto para analizar su efectividad y aplicabilidad en contextos variados.

Tabla 4.8: Métodos de QPP seleccionados.

Método QPP	Clasificación	Descripción
1. IDF (<i>Inverse Document Frequency</i>)	<i>Pre-retrieval</i>	Mide la rareza de los términos en un <i>corpus</i> mediante la frecuencia inversa de documentos.
2. SCQ (<i>Similarity between a Query and a Collection</i>)	<i>Pre-retrieval</i>	Calcula la similitud entre los términos de la consulta y la colección basándose en frecuencias y pesos.
3. NQC (<i>Normalized Query Commitment</i>)	<i>Post-retrieval</i>	Evalúa la dispersión de los puntajes de relevancia en los documentos recuperados para predecir la calidad de la consulta.
4. <i>Clarity Score</i> (SC)	<i>Post-retrieval</i>	Mide la divergencia entre el modelo de lenguaje de los documentos recuperados y el modelo de la colección.
5. WIG (<i>Weighted Information Gain</i>)	<i>Post-retrieval</i>	Estima la calidad de la consulta mediante la ganancia de información ponderada basada en los documentos recuperados.

Método QPP	Clasificación	Descripción
6. UEF (<i>Utility Estimation Framework</i>)	<i>Post-retrieval</i>	Utiliza modelos de relevancia y teoría de decisión estadística para estimar la utilidad de los rankings generados.

En cuanto al análisis de las fortalezas y debilidades de cada método seleccionado en la Tabla 4.8:

- **IDF (*Inverse Document Frequency*)** : Es un método simple, eficiente y ampliamente utilizado, su capacidad para medir la especificidad de los términos lo convierte en una herramienta básica para estimar la calidad de las consultas. Por otra parte, depende exclusivamente de estadísticas del corpus, lo que limita su precisión en escenarios donde la calidad de los documentos recuperados influye de forma significativa.
- **SCQ (*Similarity between a Query and a Collection*)**: Proporciona una evaluación más detallada al considerar la similitud entre la consulta y la colección en su conjunto, lo que resulta útil en contextos con consultas de longitud variada. Por otra lado, puede ser menos efectivo en colecciones con alta heterogeneidad temática debido a su dependencia de estadísticas globales.
- **NQC (*Normalized Query Commitment*)**: Evalúa la consistencia de los puntajes de relevancia en los documentos recuperados, lo que lo hace efectivo para identificar consultas problemáticas, pero requiere ejecutar consultas y recuperar documentos, lo que implica un costo computacional más alto en comparación con métodos pre-retrieval.
- **Clarity Score (CS)**: Mide la coherencia del lenguaje de los documentos recuperados, lo que lo hace efectivo en consultas específicas con temas bien definidos, pero es sensible a consultas cortas o ambiguas, donde la divergencia entre el modelo de lenguaje y el corpus puede ser menos clara.
- **WIG (*Weighted Information Gain*)**: Integra múltiples características de los documentos recuperados, como términos y proximidad, proporcionando una evaluación integral, aunque puede ser afectado por colecciones con sesgos en los documentos más relevantes, disminuyendo su precisión en escenarios específicos.
- **UEF (*Utility Estimation Framework*)**: Ofrece un marco flexible y adaptable, utilizando modelos de relevancia para capturar tanto la utilidad como la precisión de los rankings generados, pero su complejidad estadística puede dificultar su implementación en sistemas con recursos limitados o en contextos donde se prioriza la simplicidad.

Los métodos seleccionados abarcan una gama de enfoques y fundamentos teóricos, lo que garantiza una evaluación comparativa exhaustiva y representativa, en donde la inclusión de métodos tanto *pre-retrieval* como *post-retrieval* asegura que se cubran múltiples facetas del problema, proporcionando una base sólida para analizar su desempeño en diferentes contextos, resultando en un diseño experimental robusto que refuerza la validez del estudio y su contribución al avance del estado del arte en predicción de rendimiento de consultas.

CAPÍTULO V: IMPLEMENTACIÓN

La implementación del entorno de evaluación representa la materialización del diseño experimental previamente descrito. Este Capítulo detalla los aspectos técnicos y prácticos del desarrollo, abordando desde la configuración del entorno hasta la implementación específica de cada componente del sistema.

El desarrollo se fundamenta en tres pilares principales: el sistema de recuperación de información, la implementación de los métodos QPP, y el framework de evaluación. Como se puede observar en la Tabla 5.1, cada uno de estos componentes requiere consideraciones técnicas específicas, como el manejo consistente del vocabulario y la optimización de cálculos estadísticos, integrándose para formar un sistema cohesivo y reproducible.

Tabla 5.1: Componentes principales del sistema implementado.

Componente	Consideraciones principales
Sistema de recuperación	• Implementación de BM25 como algoritmo base • Indexación eficiente de documentos • Procesamiento de consultas
Métodos QPP	• Implementación de predictores pre y post-retrieval • Manejo de dependencias entre componentes • Cálculo eficiente de estadísticas
Framework de evaluación	• Procesamiento de juicios de relevancia • Cálculo de métricas de evaluación • Análisis de correlaciones • Generación de visualizaciones

La implementación se realizó priorizando la modularidad y la reproducibilidad, utilizando herramientas y bibliotecas ampliamente reconocidas en el campo de la recuperación de información. El sistema se desarrolló completamente en Python, aprovechando un conjunto de bibliotecas especializadas cuyas funciones principales se detallan en la Tabla 5.2. Estas herramientas fueron seleccionadas por su madurez, documentación y amplia adopción en la comunidad de recuperación de información.

Tabla 5.2: Stack tecnológico principal.

Aspecto	Herramienta/Biblioteca	Propósito
---------	------------------------	-----------

Recuperación	PyTerrier	Indexación y búsqueda de documentos
Datasets	ir_datasets	Acceso a colecciones estándar
Evaluación	ir_measures	Cálculo de métricas IR
Estadísticas	scipy, numpy	Análisis de correlaciones
Visualización	matplotlib, seaborn	Generación de gráficos

A continuación, se detallan los aspectos específicos de la implementación, comenzando con la configuración del entorno experimental y continuando con la implementación de cada componente del sistema.

5.1 Configuración del entorno experimental

El entorno experimental se encuentra configurado para ser ejecutado en un variedad de entornos debido a la utilización de Docker, el cual permite la ejecución de entornos virtuales en diferentes sistemas operativos. De manera general y para preservar la reproducibilidad de los resultados, se ha configurado el entorno experimental para ser ejecutado en un sistema operativo Linux, utilizando Python 3.9.21 y PyTerrier 0.13.0.

Tabla 5.3: Configuración del entorno experimental.

Componente	Descripción	Versión
Docker	Contenedor de entornos virtuales	25.0.5
Python	Lenguaje de programación	3.9.21
PyTerrier	Librería de recuperación de información	0.13.0 más snapshot para el soporte de modelos de relevancia
IR-datasets	Librería de conjuntos de datos	0.5.9

Como se puede apreciar en la Tabla 5.3, se ha optado por implementar el entorno experimental en componentes de software con versiones específicas y estables, esperando lograr la mayor reproducibilidad posible de los resultados. La ejecución también es posible en sistemas operativos Windows y MacOS, pero estas cuentan con procesos de instalación y configuración mas complejos.

5.1.1 Docker y dependencias

Docker es la principal herramienta que permite la ejecución del entorno experimental, esta cuenta con una amplia gama de herramientas que permiten la ejecución de entornos virtuales en diferentes sistemas operativos. Para los propósitos de este trabajo, se ha optado por imágenes de docker basados en la versión Slim Buster de Debian, la cual destaca en su ligereza y velocidad de ejecución.

```
1  # Imagen Debian optimizada para Python
2  FROM python:3.9-slim-buster
3
4  # Configuraciones de entorno
5  ENV LANG=C.UTF-8
6  ENV LC_ALL=C.UTF-8
7  ENV JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
8  ENV PATH="$JAVA_HOME/bin:$PATH"
9
10 # Instalación de Java y otras dependencias
11 RUN apt-get update && \
12     apt-get install -y openjdk-11-jdk && \
13     apt-get install -y --no-install-recommends \
14     build-essential \
15     && apt-get clean && \
16     rm -rf /var/lib/apt/lists/*
17 ...
```

Dockerfile

Figura 5.1: Dockerfile para la configuración del entorno experimental.

La Figura 5.1 muestra el archivo Docker utilizado para la configuración del entorno experimental, este Dockerfile se encuentra disponible en el repositorio de GitHub del proyecto. En este se especifican las principales dependencias y configuraciones de entorno necesarias para la ejecución del entorno experimental.

Tabla 5.4: Componentes principales del Dockerfile.

Componente	Descripción
Imagen base	Python 3.9 slim-buster - Versión ligera de Debian optimizada para Python
Configuración UTF-8	Establece codificación UTF-8 para el manejo correcto de caracteres especiales y términos en diferentes idiomas pre-

	sentes en los datasets, esto en la practica es necesario para evitar errores de procesamiento de tokens.
JDK 11	Java Development Kit necesario para PyTerrier, ya que este utiliza componentes Java para el procesamiento e indexación de documentos
Build essentials	Herramientas básicas de compilación necesarias para algunas dependencias de Python

La Tabla 5.4 muestra los componentes esenciales para la configuración y ejecución del entorno experimental. Diversos errores fueron enfrentados debido a la codificación de caracteres durante las primeras pruebas del entorno, especialmente al procesar términos con caracteres especiales o diacríticos presentes en los datasets. La configuración explícita de UTF-8 en el contenedor Docker resultó fundamental para asegurar el correcto procesamiento de los documentos y consultas, evitando problemas de codificación que podrían afectar la calidad de la indexación y, por ende, los resultados de la evaluación.

5.1.2 Integración de conjuntos de datos

Como se explicó anteriormente, los conjuntos de datos utilizados en este trabajo se encuentran disponibles en la librería IR-datasets, la cual cuenta con una amplia gama de conjuntos de datos tanto clásicos como modernos de recuperación de información junto a sus consultas y respectivos juicios de relevancia.

Cada dataset cuenta con una cantidad de documentos y consultas disponibles para realizar la evaluación, por otro lado los juicios de relevancia suponen un desafío extra para la implementación de la evaluación, puesto que cada dataset cuenta con distintos niveles de relevancia para las consultas, si estos no se manejan adecuadamente puede alterar drásticamente los resultados de la correlación.

Esto es así puesto a que la evaluación clásica de métodos IR se basa en el cálculo de métricas como nDCG, AP, etc, las cuales dependen de los juicios de relevancia actuando como *ground truth* para su cálculo.

```
1 DATASET_FORMATS = {
2     "antique_test": {
3         "relevance_levels": {
4             1: "Out of context/nonsensical",
5             2: "Not relevant but on topic",
6             3: "Marginally relevant",
```



```
7         4: "Highly relevant"
8     },
9     "binary_threshold": 3, # Puntajes >= 3 son considerados
    relevantes para las métricas binarias
10    "gain_values": { # Valores de ganancia para nDCG
11        1: 0,
12        2: 1,
13        3: 2,
14        4: 3
15    }
16 }
```

Figura 5.2: Configuración de formato de dataset.

La Figura 5.2 muestra la configuración específica para el dataset `antique_test`, donde se definen cuatro niveles de relevancia (1-4) con sus respectivas descripciones semánticas. Esta configuración es importante por dos razones principales: primero, establece un umbral binario en 3 para las métricas que requieren juicios binarios (como Precision y Recall), considerando como relevantes solo los documentos con puntuaciones de 3 o 4. Segundo, define valores de ganancia específicos para el cálculo de nDCG, donde se asigna diferentes valores de ganancia en cada nivel.

Esta diferenciación en el manejo de los niveles de relevancia es fundamental para obtener evaluaciones precisas, ya que un manejo inadecuado de estos valores podría llevar a distorsiones significativas en el cálculo de las métricas de evaluación y, consecuentemente, afectar la correlación con los predictores QPP. Por ejemplo, si no se estableciera el umbral binario adecuadamente o se asignaran valores de ganancia incorrectos, documentos marginalmente relevantes podrían tener el mismo peso que documentos altamente relevantes en el cálculo de las métricas, lo que no reflejaría fielmente la calidad real de los resultados de búsqueda.

5.1.3 Preprocesamiento, indexación y consultas

El proceso de indexación constituye la base sobre la cual operan tanto el sistema de recuperación como los predictores QPP. En esta implementación, se optó por una estrategia de indexación personalizada en lugar de utilizar el pipeline por defecto de PyTerrier. Específicamente, los documentos son pre-procesados utilizando un pipeline unificado basado en la librería NLTK antes de ser ingestados por el indexador integrado de la librería.

Este pipeline de preprocesamiento aplica tokenización, eliminación de *stopwords* y *stemming* (utilizando el famoso *SnowballStemmer*) de manera consistente tanto para los documentos como para las consultas. La justificación técnica de esta decisión radica en la necesidad de garantizar una correspondencia exacta entre el vocabulario del índice y los

términos generados durante el procesamiento de las consultas lo cual sucede en dos capas distintas dentro del flujo del sistema.

Durante el desarrollo se observó que el tokenizador por defecto de Terrier presentaba inconsistencias significativas en el manejo de ciertos tipos de términos. Este comportamiento se manifestaba especialmente en secuencias numéricas: términos como “0”, “00” y “000” eran indexados como tokens distintos por Terrier, mientras que el pipeline de preprocesamiento basado en NLTK/Snowball los unificaba o eliminaba según su configuración de *stopwords*. Esta discrepancia causaba un desajuste de vocabulario (*vocabulary mismatch*), donde términos presentes en la consulta procesada en Python no encontraban correspondencia en el índice de Terrier, resultando en frecuencias de documento igual a cero. A su vez, esto generaba puntajes nulos o incorrectos en predictores sensibles como IDF y SCQ. Al indexar el texto ya procesado por el mismo pipeline que las consultas, se elimina esta fuente de error y se asegura la coherencia del vocabulario.

Para cuantificar el impacto de esta discrepancia, se realizó un análisis comparativo de los vocabularios generados por ambos pipelines de tokenización sobre el dataset Antique/test, que comprende 403.666 documentos. Los resultados, presentados en la Tabla 5.5, revelan diferencias estadísticamente significativas entre ambos enfoques de tokenización.

Tabla 5.5: Comparación de vocabularios entre tokenizadores.

Métrica	NLTK (Snowball)	PyTerrier
Términos únicos	238.298	218.336
Ocurrencias totales	8.200.515	7.295.979
Distribución del vocabulario combinado (Total de 254.530 términos)		
Términos compartidos	202.104 (79.4%)	
Términos exclusivos	36.194 (14.2%)	16.232 (6.4%)

El análisis revela un overlap de vocabulario del 79.4% entre ambos tokenizadores. El 14.2% de términos exclusivos de NLTK corresponde principalmente a secuencias numéricas largas que el stemmer preserva de forma individual, mientras que el 6.4% exclusivo de PyTerrier se compone de concatenaciones de tokens (como “001html” o “10degr”) que no fueron separadas correctamente durante el preprocesamiento. Esta discrepancia del 20.6% en el vocabulario total impacta directamente en la capacidad del sistema para procesar consultas, como se cuantifica en la Tabla 5.6.

Tabla 5.6: Impacto en la cobertura de consultas.

Métrica de cobertura	NLTK (Snowball)	PyTerrier
Cobertura de términos en consultas	98.98% (873/882)	88.44% (780/882)
Queries con términos OOV	9	102
Tasa OOV en predictores	0.69%	11.56%

La diferencia en cobertura de terminos en las consultas fue determinante para la elección del pipeline: NLTK/Snowball alcanza una cobertura del 98.98% de los términos presentes en las consultas, PyTerrier solo cubre el 88.44%. Esta brecha de 10.54 puntos porcentuales significa que, utilizando el tokenizador por defecto de Terrier, un 11.56% de los términos de las consultas no encontrarían correspondencia en el índice, generando valores OOV (*out of vocabulary*) que distorsionan los cálculos de los predictores. En el caso de IDF y SCQ, se identificaron 6 de las 200 queries afectadas por términos problemáticos, incluyendo errores ortográficos (“inspeciton”), nombres propios (“murrieta”) y concatenaciones accidentales (“june3”). Estos hallazgos fundamentan la decisión de adoptar un pipeline de preprocesamiento unificado basado en Snowball, garantizando así la coherencia del vocabulario entre el índice y las consultas.

Adicionalmente, para optimizar el rendimiento de los predictores *pre-retrieval*, se implementó mecanismos de caché estadísticos, el cual pre-calcula y almacena en un archivo JSON las estadísticas globales más consultadas, como la frecuencia de colección (*Collection Frequency*, CF) y la frecuencia de documentos (*Document Frequency*, DF) para cada término. Esta estrategia evita la sobrecarga computacional que implicaría realizar múltiples consultas JNI (*Java Native Interface*) al índice de Terrier o escaneos completos del índice para obtener estadísticas básicas repetitivas, reduciendo significativamente el tiempo de ejecución de los experimentos, especialmente en *datasets* grandes como MS MARCO.

5.2 Implementación de métodos QPP

La implementación de los métodos QPP difiere en las dos categorías en la que se dividen los “métodos”, pre-retrieval y post-retrieval, el primer caso solo cuenta con una dependencia para su implementación, la cual es el índice invertido generado a partir de un corpus de documentos. Mientras que en el segundo caso, cuenta con dos, el índice invertido generado a partir de un corpus de documentos y los resultados de un sistema de recuperación de información en respuesta a una consulta.

```
1 # Creación del factory de métodos QPP
2 qpp_factory = QPPMethodFactory(
```

Python

```
3     index_builder=index_builder,
4     retrieval_results=retrieval_results,
5     rm_results=rm_results_df,
6     dataset_name=dataset_path
7 )
8
9 # Compueto de los puntajes de los métodos QPP
10 qpp_scores = qpp_factory.compute_all_scores(
11     queries=queries,
12     list_size_param=args.list_size
13 )
```

Figura 5.3: Código de implementación del factory de métodos QPP.




Figura 5.4: Diagrama de la capa de métodos QPP.

Para cumplir con los requisitos de los métodos QPP, se ha implementado un factory, el cual se encarga de la creación y compueto de los puntajes de los métodos QPP. Este factory se encarga de tomar las dependencias necesarias y entregarlas a los métodos QPP, para que estos puedan ser computados.

Para la implementación de los métodos QPP, se ha utilizado como base código abierto pero con mejoras y modificaciones propias para satisfacer las necesidades de la evaluación a realizar. Todo el código externo utilizado se encuentra disponible en el repositorio de *GitHub* de *QPP-EnhancedEval*.²

²<https://github.com/Zendelo/QPP-EnhancedEval/tree/qpptk-dev>

5.2.1 Métodos pre-retrieval

En esta categoría se implementaron dos de los métodos más utilizados en las evaluaciones de la literatura: IDF y SCQ. Si bien conceptualmente son sencillos, su implementación robusta requirió abordar desafíos específicos relacionados con el manejo de términos.

Para el método **IDF (Inverse Document Frequency)**, se implementó un manejo riguroso de términos para asegurar la estabilidad del predictor. Estas modificaciones no son triviales, sino que surgieron tras iteraciones experimentales donde se observó que la implementación estándar producía correlaciones artificialmente bajas (cerca de cero) debido a inestabilidad numérica.

En primer lugar, se implementó una distinción explícita para los términos fuera del vocabulario (OOV). A diferencia de enfoques que simplemente asignan un valor nulo, esta implementación asigna un valor centinela de frecuencia de documento igual a -1 a los términos que no existen en absoluto en el índice. El beneficio crítico de este manejo es prevenir que la presencia de un solo término desconocido (por ejemplo, un error tipográfico) invalide el puntaje de toda una consulta al propagar valores nulos o indefinidos, permitiendo que el sistema degrade suavemente su estimación basándose únicamente en los términos conocidos.

En segundo lugar, se incorporó la técnica de **suavizado Laplaciano** (*add-1 smoothing*) en el cálculo del predictor IDF. Esta técnica consiste en simular que cada término del vocabulario ha sido observado una vez más de lo que realmente aparece en la colección.

$$P_{\text{smooth}}(w) = \frac{\text{count}(w) + 1}{N + V} \quad (5.1)$$

En la Ecuación (5.1) $\text{count}(w)$ es la frecuencia del término w , N es el total de tokens y V el tamaño del vocabulario. La justificación técnica para aplicar este suavizado en QPP es debido a que aporta **estabilidad numérica** al evitar divisiones por cero e indefiniciones logarítmicas (como $\log(0)$) que invalidarían el cálculo para términos extremadamente raros [29].

Por otro lado, la implementación de **SCQ (Collection Query Similarity)** se benefició directamente de la optimización de caché estadística mencionada en la sección de indexación. Dado que SCQ requiere consultar intensivamente las frecuencias CF y DF para cada término de la consulta, el acceso directo a las estadísticas pre-calculadas permite calcular la similitud consulta-colección de manera eficiente. Se implementaron variantes del método que agregan los puntajes de los términos utilizando tanto la suma como el máximo (*max_scq*), permitiendo evaluar qué estrategia de agregación captura mejor la dificultad de la consulta.

5.2.2 Métodos post-retrieval

En esta categoría se consideró una gama más amplia de predictores, abarcando desde métodos basados en divergencia como Clarity, hasta frameworks basados en utilidad como UEF. La implementación de estos métodos implica una complejidad mayor, ya que requieren interactuar tanto con el índice invertido como con la lista de resultados recuperada.

Un aspecto crítico en la implementación del **Clarity Score** fue el suavizado del modelo de lenguaje de la colección. Para estimar la probabilidad $P(w|C)$ de un término en la colección, se utilizó **suavizado de Dirichlet** con un parámetro $\mu = 1000$. Esta decisión no solo responde a una necesidad de estabilidad numérica, sino que es fundamental para la robustez de los modelos de lenguaje en Recuperación de Información, especialmente en función de la naturaleza de la colección procesada.

En el contexto de colecciones pequeñas o constituidas por documentos breves, como pasajes, **snippets** (fragmentos de texto cortos que resumen el contenido de un documento en la lista de resultados) o el propio dataset Cranfield utilizado, la frecuencia de términos (**term frequency**) es intrínsecamente escasa. Sin un mecanismo de suavizado, los modelos de lenguaje derivados resultantes serían extremadamente ruidosos y estarían sesgados hacia los pocos términos observados, provocando que la divergencia KL diverja artificialmente debido a probabilidades nulas o a picos de frecuencia no representativos. En este contexto, la técnica de suavizado de Dirichlet es una herramienta útil que reduce la varianza de la estimación, evita la sobreestimación de términos raros y estabiliza el modelo de la consulta. Esto permitiría que el puntaje de Clarity correlacione efectivamente con la dificultad real de la consulta y no con el ruido estadístico inherente a la escasez de datos.

```
1 def _get_collection_probabilities(self, terms:
2     Iterable[str]) -> Dict[str, float]:
3     """
4     Calcula P(w|C) (modelo de lenguaje) con suavización de
5     Dirichlet.
6     Fórmula: (cf + mu * p0) / (total_terms + mu), con p0 uniforme.
7     """
8     total_terms = max(1, self.index_stats['total_terms'])
9     mu = self.mu_bg
10    p0 = self._uniform_prior
11
12    probs = {}
13    for term in terms:
14        cf = float(self.index_stats['term_cf'].get(term, 0))
15
16        # SIN SUAVIZADO:
17        # prob = cf / total_terms
```

```
16      # En colecciones pequeñas, esta estimación de máxima
      verosimilitudes altamente sensible a eventos raros y a
      términos no observados.
17      # En particular, cf = 0 induce prob = 0, lo que vuelve
      inestable el cálculo de divergencias (p. ej., KL).
18
19      # CON SUAVIZADO:
20      # Se incorporan 'mu' observaciones virtuales distribuidas
      según 'p0',
21      # lo que reduce la varianza de la estimación y mejora la
      estabilidad del modelo de lenguaje.
22      probs[term] = (cf + mu * p0) / (total_terms + mu)
23      return probs
```

Figura 5.5: Implementación del suavizado de Dirichlet en Clarity.

Por otra parte, en colecciones masivas o con documentos extensos (como artículos de noticias o páginas web completas), donde las frecuencias de términos son más altas y estadísticamente fiables, el modelo empírico tiende a converger con la distribución real del lenguaje. Si bien el suavizado sigue aportando estabilidad, su impacto relativo es menor. En estos casos, un parámetro μ excesivamente alto podría resultar contraproducente, ya que diluiría la especificidad del documento al acercar su modelo demasiado a la distribución uniforme de la colección, disminuyendo artificialmente el puntaje de Clarity. Dado que esta investigación opera sobre colecciones de tamaño controlado y características específicas, la elección de un μ entre 500 y 1000 resulta un buen equilibrio para asegurar la validez de las predicciones [30].

Para el método **UEF (Utility Estimation Framework)**, la implementación se centró en la robustez del cálculo de correlación. UEF estima la dificultad correlacionando los puntajes de recuperación originales con los obtenidos tras una expansión de consulta (en este caso, utilizando el modelo **RM3**). Para asegurar la validez de esta correlación, se implementó un alineamiento estricto de las listas de resultados basado en identificadores de documento (docno), asegurando que la comparación se realice sobre la intersección de documentos recuperados en ambas etapas. Además, se normalizan los puntajes antes del cálculo de correlación para mitigar diferencias de escala entre las pasadas de recuperación.

Finalmente, para **NQC (Normalized Query Commitment)** y **WIG**, se incorporaron mecanismos de manejo de excepciones para casos de varianza cero. En situaciones donde todos los documentos recuperados tienen el mismo puntaje (lo cual puede ocurrir con consultas muy cortas o en colecciones con pocos documentos relevantes), la desviación estándar se anula, lo que podría causar errores de división. La implementación detecta estos casos y asigna un puntaje de dificultad predefinido, garantizando la continuidad de la evaluación sin interrupciones.

```
1 def calc_wig(self, list_size_param):
2     """
3     Calcula el WIG score siguiendo el método de Zhou y Croft.
4     Y. Zhou and W. B. Croft. Query performance prediction in web
5     search environments
6     """
7     scores_vec = self.scores_vec[:list_size_param]
8     if self.corpus_score == 0:
9         print("El puntaje del corpus es cero; retornando WIG score
10             como 0.0 para evitar división por cero.")
11         return 0.0
12     wig_score = (scores_vec.mean() - self.corpus_score) /
13     np.sqrt(len(self.query_terms))
14     return wig_score
```

Figura 5.6: Implementación del método WIG.

La Figura 5.6 muestra la implementación del método post-retrieval WIG, en este podemos identificar tanto el uso del índice invertido (*scores_vec*) como el resultado de el puntaje del modelo de recuperación de información frente a toda la colección (*corpus_score*) como se puede apreciar en la Ecuación (3.5). Adicionalmente se puede observar parámetros como el tamaño de la lista de documentos a considerar, el cual fue definido como 5 para WIG y en 200 para NQC bajo la recomendación de la literatura y nuestros propios experimentos [13, 14, 17]. Para finalizar, también cabe mencionar que todas los puntajes fueron considerando el puntaje promedio de los 1.000 primeros documentos de la lista de resultados.

5.3 Implementación de la evaluación

La implementación de la evaluación de los métodos QPP se realiza mediante un analizador de correlaciones que permite calcular y visualizar las relaciones entre los puntajes de predicción y las métricas de rendimiento real del sistema. Este analizador está diseñado para procesar los resultados de múltiples métodos QPP y métricas de recuperación, generando análisis estadísticos y visualizaciones que facilitan la interpretación de los resultados.

5.3.1 Cálculo de correlaciones

El análisis se basa principalmente en el cálculo de coeficientes de correlación entre los puntajes QPP y las métricas de recuperación (nDCG y AP). Se implementaron tres tipos de correlaciones: **Pearson**, que mide la relación lineal entre las variables; **Spearman**, que evalúa la relación monótona entre variables usando rangos; y **Kendall (τ)**, que mide la ordinalidad entre pares de observaciones. Para el cálculo, se utilizan las funciones especia-

lizadas de la librería Scipy, las cuales retornan tanto el coeficiente de correlación como los valores p asociados a la prueba de hipótesis.

Un aspecto crítico de la implementación es el **alineamiento de identificadores de consulta (QIDs)** entre los puntajes QPP y las métricas de recuperación. Dado que no todas las consultas pueden tener resultados válidos en ambos conjuntos (por ejemplo, consultas sin documentos relevantes en los *qrels* o con puntajes QPP indefinidos), el sistema calcula la intersección de QIDs comunes antes de proceder con el análisis. Adicionalmente, se aplica un filtro de **número mínimo de consultas** ($n \geq 5$) para garantizar que las correlaciones calculadas tengan suficiente respaldo estadístico, descartando comparaciones que podrían resultar espurias debido a tamaños de muestra insuficientes.

El manejo de **valores nulos y no numéricos** es otro aspecto relevante: los valores faltantes son detectados y excluidos del cálculo de correlación, evitando que contaminen los resultados. La significancia estadística se verifica mediante pruebas de hipótesis, considerando múltiples umbrales: $\alpha < 0.05$ (significativo), $\alpha < 0.01$ (muy significativo) y $\alpha < 0.001$ (altamente significativo). Las correlaciones que no alcanzan el umbral de significancia son registradas pero marcadas apropiadamente en los reportes generados.

5.3.2 Visualización de resultados

Para facilitar la interpretación de los hallazgos experimentales, se implementó un conjunto de visualizaciones organizadas en dos categorías principales: análisis de correlación y análisis de juicios de relevancia. Esta estrategia de representación gráfica sigue los lineamientos metodológicos de evaluaciones recientes en el área [4, 8, 21].

En primera instancia, para el análisis de correlación QPP, se generaron mapas de calor (*heatmaps*) que despliegan la matriz de correlaciones entre los métodos predictivos y las métricas de evaluación. Para ello, se utilizó una escala de colores divergente (*coolwarm*) centrada en cero, lo que permite identificar rápidamente la fuerza y dirección de las asociaciones, además de una variante específica para visualizar la significancia estadística, categorizando los valores p en cuatro niveles jerárquicos (desde no significativo $\geq 0,05$ hasta altamente significativo $< 0,001$).

De forma complementaria, se construyeron diagramas de dispersión con líneas de regresión para examinar la linealidad de las predicciones y facilitar la comparación del comportamiento distributivo de cada método.

Por otro lado, la segunda categoría de visualizaciones se orientó a la caracterización de los juicios de relevancia y la dificultad de las consultas. Se graficó la distribución de niveles de relevancia presente en los *qrels*, proporcionando contexto sobre la granularidad de cada dataset. Asimismo, se implementaron gráficos para la clasificación de la dificultad, segmentando las consultas en categorías (fáciles, intermedias y difíciles) según percentiles de efectividad establecidos en la literatura.

Finalmente, se generaron histogramas y diagramas de caja para analizar la distribución de las métricas de recuperación (como nDCG y AP), lo que resulta fundamental para detectar patrones de rendimiento del sistema base y la presencia de valores atípicos (*outliers*) que pudiesen influir en la predicción.

5.4 Pruebas de validación

La validación de la evaluación constituye una etapa del desarrollo necesaria para garantizar la fiabilidad del entorno de evaluación implementado. Su propósito es verificar que cada componente funciona correctamente de forma aislada y en conjunto con los demás. En el contexto de la Recuperación de Información, donde los cálculos numéricos y estadísticos son fundamentales, la validación adquiere especial relevancia ya que un error en el cálculo de frecuencias o en la normalización de puntajes puede propagarse y distorsionar los resultados de correlación, invalidando las conclusiones experimentales.

Para garantizar la fiabilidad del entorno de evaluación implementado, se desarrolló un conjunto de pruebas unitarias utilizando el framework *unittest* de *Python*. Las pruebas unitarias constituyen la base de la pirámide de testeo en ingeniería de software, verificando el comportamiento de unidades individuales de código (funciones, métodos o clases) de forma aislada y reproducible. A diferencia de las pruebas de integración o de sistema, las pruebas unitarias permiten identificar con precisión la fuente de un fallo y facilitan la regresión automática ante cambios en el código.

5.4.1 Datos para las prueba

Para ejecutar las pruebas unitarias se requiere un corpus de documentos con sus respectivas consultas y juicios de relevancia. Sin embargo, utilizar *datasets* completos como Antique o MS MARCO para pruebas unitarias presenta inconvenientes prácticos: tiempos de indexación prolongados, mayor consumo de memoria y dificultad para verificar manualmente los resultados esperados.

Por esta razón, se diseñó un *dataset* de prueba sintético denominado *IquiqueDataset*, inspirado en información turística e histórica de la ciudad de Iquique en Chile. Este *dataset* cumple con los requisitos de legibilidad en español del pipeline de preprocesamiento y permite verificar manualmente cada cálculo gracias a su tamaño reducido.

Tabla 5.7: Características del dataset de prueba IquiqueDataset.

Característica	Valor
Número de documentos	8
Idioma	Español

Número de consultas	8
Juicios de relevancia	22
Niveles de relevancia	Multinivel (1: marginal, 2: relevante, 3: altamente relevante)

El *corpus* incluye ocho documentos breves que abarcan temas como la geografía de Iquique, la Zona Franca (ZOFRI), la playa Cavancha, el Museo Regional, el clima desértico costero, la Guerra del Pacífico, la industria del salitre y el patrimonio cultural pampino. Esta diversidad temática permite evaluar el comportamiento de los predictores ante consultas con diferente especificidad y cobertura documental.

Tabla 5.8: Muestra de documentos del corpus IquiqueDataset (5 de 8).

Doc ID	Contenido
doc0	Iquique es una ciudad portuaria y comuna del norte de Chile, capital de la provincia homónima y de la región de Tarapacá
doc1	La Zona Franca de Iquique (ZOFRI) es uno de los centros comerciales más importantes del norte de Chile y Sudamérica
doc2	Playa Cavancha es la playa urbana más popular de Iquique, ideal para el surf y deportes acuáticos
doc3	El Museo Regional de Iquique exhibe la historia de la cultura Chinchorro y la época del salitre
doc4	El clima de Iquique es desértico costero con abundante nubosidad y temperaturas moderadas durante todo el año

Tabla 5.9: Consultas del dataset IquiqueDataset y su cobertura de relevancia.

QID	Consulta	Docs. relevantes
0	playa cavancha iquique	3
1	zona franca zofri	2
2	museo historia iquique	4
3	historia salitre guerra pacifico	4
4	clima temperatura iquique	2

5	patrimonio cultural pampino	3
6	comercio norte chile sudamerica	3
7	combate naval peru chile	2

Como se observa en la Tabla 5.9, las consultas presentan diferentes grados de dificultad inherente. Todas las consultas utilizan juicios de relevancia multinivel, donde el nivel 3 indica alta relevancia, el nivel 2 indica relevancia moderada, y el nivel 1 indica relevancia marginal. Esta gradación permite evaluar métricas como nDCG que consideran la posición y el grado de relevancia de los documentos recuperados.

5.4.2 Componentes del módulo de pruebas

Las pruebas unitarias se organizaron en una estructura jerárquica que refleja la arquitectura del sistema. Se crearon módulos de testing para cada capa importante de la evaluación: un módulo para las pruebas del analizador de correlaciones y el evaluador de métricas, y módulos separados para cada uno de los predictores QPP, distinguiendo entre métodos *pre-retrieval* y *post-retrieval* según la taxonomía establecida en el marco teórico.

Tabla 5.10: Componentes evaluados mediante pruebas unitarias.

Componente	Casos	Aspectos evaluados
Analizador de correlaciones	10	Inicialización, cálculo de correlaciones (Pearson, Spearman, Kendall), generación de mapas de calor, diagramas de dispersión, diagramas de caja, reportes y alineamiento de identificadores
Evaluador de métricas	6	Cálculo de nDCG@10 y AP para rankings perfectos e invertidos, evaluación de múltiples métricas simultáneas y manejo de consultas inválidas
Clarity	8	Cómputo de frecuencias de términos, probabilidades de colección con suavizado Dirichlet, divergencia KL, consistencia de stemming y manejo de documentos vacíos
NQC	6	Inicialización de vectores de puntajes, cálculo de puntaje del corpus, normaliza-

		ción por desviación estándar y manejo de datos vacíos
WIG	7	Vectores de puntajes, puntaje del corpus, cálculo WIG con normalización por longitud de consulta y frecuencias de colección
UEF	8	Correlación entre rankings original y re-rankeado, límites de correlación, manejo de puntajes base cero, procesamiento por lotes y escenarios de correlación perfecta
IDF	7	Cálculo de frecuencia de documento por término, manejo de términos fuera del vocabulario, agregación por promedio y máximo, y procesamiento por lotes
SCQ	6	Estadísticas de frecuencia de colección y documento, cálculo de similitud consulta-colección, métodos de agregación (suma, promedio, máximo) y términos desconocidos

La ejecución de las pruebas se automatizó mediante un sistema de descubrimiento automático que localiza y ejecuta todos los casos de prueba del proyecto. Este sistema genera tres tipos de reportes: un archivo de texto plano con el resumen de ejecución, un archivo estructurado con estadísticas detalladas por componente, y un informe formateado que incluye indicadores visuales de éxito o fallo para cada caso individual.

5.4.3 Casos de prueba representativos

A continuación se describen casos de prueba representativos de cada categoría, ilustrando la metodología de validación empleada y los escenarios cubiertos.

Predictores pre-retrieval (IDF y SCQ): Las pruebas del predictor IDF verifican el correcto cálculo de la frecuencia inversa de documento para términos individuales y múltiples. Un caso crítico es el manejo de términos fuera del vocabulario: cuando un término de la consulta no existe en el índice, el sistema debe manejar esta situación de forma robusta, evitando que el puntaje de toda la consulta se invalide. Las pruebas verifican que el IDF calculado para un término conocido coincide con la fórmula teórica $\log(N/df_t)$ donde

N es el número de documentos del *corpus*, que los términos inexistentes son excluidos del cálculo degradando suavemente la estimación, y que la frecuencia de documento de términos comunes se calcula correctamente.

```
1 # Preprocesar términos de consulta
2 sample_text = "iquique playa"
3 processed_terms = preprocess_text(sample_text)
4 term1, term2 = processed_terms[0], processed_terms[1]
5
6 # Calcular IDF utilizando el predictor
7 score = self.idf.compute_score([term1])
8
9 # Calcular IDF utilizando la fórmula teórica
10 expected_idf = np.log(self.total_docs / self.term_dfs[term1])
11
12 # Verificar que coincide con fórmula teórica con margen de error
13 self.assertAlmostEqual(score, expected_idf)
```

Figura 5.7: Prueba de validación del cálculo de IDF para términos individuales.

La Figura 5.7 ilustra cómo se valida el cálculo del predictor IDF. Primero se preprocesan los términos de una consulta de prueba utilizando la misma función de procesamiento que se emplea durante la indexación, garantizando consistencia en el vocabulario. Luego se calcula el puntaje IDF mediante el predictor implementado y se compara contra el valor esperado según la fórmula teórica. La función `assertAlmostEqual` permite una tolerancia numérica de hasta 7 decimales, acomodando pequeñas diferencias de precisión de punto flotante inherentes a los cálculos logarítmicos.

Predictores post-retrieval (Clarity, NQC, WIG): Las pruebas del predictor Clarity validan el flujo completo de cálculo, desde la construcción del modelo de lenguaje del conjunto pseudo-relevante hasta el cómputo de la divergencia KL. Un aspecto fundamental es la verificación del suavizado de Dirichlet: para distribuciones de probabilidad distintas, la divergencia KL debe ser estrictamente positiva, mientras que para distribuciones idénticas debe aproximarse a cero. Adicionalmente, se verifica que el *stemmer Snowball* produce resultados consistentes entre la indexación y el procesamiento de consultas (por ejemplo, “historia” → “histori”, “iquique” → “iquiqu”).

```
1 # Obtener probabilidades de colección con suavizado de
  Dirichlet
2 stemmed_terms = ['iquiqu', 'playa', 'museo']
3 probs = self.clarity._get_collection_probabilities(stemmed_terms)
```

```

4
5 # Verificar que todas las probabilidades están en rango válido
6 for term, prob in probs.items():
7     self.assertGreaterEqual(prob, 0)
8     self.assertLessEqual(prob, 1)
9
10 # Verificar consistencia de stemming
11 stemmer = SnowballStemmer('spanish')
12 assert stemmer.stem('historia') == 'histori'
13 assert stemmer.stem('iquique') == 'iquiqu'

```

Figura 5.8: Prueba de suavizado de Dirichlet y consistencia de stemming en Clarity.

La Figura 5.8 demuestra la validación del suavizado de Dirichlet implementado en Clarity. El método *get_collection_probabilities* calcula las probabilidades de colección para un conjunto de términos aplicando la fórmula de suavizado mencionada anteriormente. Las verificaciones garantizan que todas las probabilidades resultantes estén en el rango válido $[0, 1]$, condición necesaria para el cálculo posterior de la divergencia KL. La segunda parte de la prueba valida la consistencia del *stemming*: los mismos términos deben transformarse de forma idéntica durante la indexación y durante el procesamiento de consultas, asegurando que el vocabulario del índice coincida con el de las probabilidades de colección.

Evaluador de métricas: Las pruebas del evaluador verifican el cálculo de nDCG y AP contra valores de referencia conocidos. Se construyen dos escenarios extremos: un ranking perfecto donde los documentos relevantes ocupan las primeras posiciones (debiendo producir métricas superiores a 0.8), y un ranking invertido donde los documentos relevantes quedan al final (debiendo producir métricas inferiores a 0.6 para nDCG y 0.5 para AP).

```

1 # Evaluar ranking perfecto (documentos relevantes primero)
2 results = evaluate_results(
3     self.qrels,
4     self.perfect_run,
5     metrics=['ndcg@10'],
6     dataset_name="iquique_dataset",
7     min_results=1
8 )
9
10 # Verificar que nDCG es alto para ranking perfecto
11 ndcg_score = results['ndcg@10']['mean']
12 self.assertGreater(ndcg_score, 0.8)
13
14 # Evaluar ranking invertido (documentos relevantes al final)
15 reversed_results = evaluate_results(

```

```

16     self.qrels,
17     self.reversed_run,
18     metrics=['ndcg@10'],
19     dataset_name="iquique_dataset",
20     min_results=1
21 )
22
23 # Verificar que nDCG es bajo para ranking invertido
24 reversed_score = reversed_results['ndcg@10']['mean']
25 self.assertLess(reversed_score, 0.6)

```

Figura 5.9: Prueba de evaluación de métricas con rankings perfecto e invertido.

La Figura 5.9 valida el evaluador de métricas mediante la construcción de escenarios controlados. En el ranking perfecto, los documentos con mayor relevancia aparecen en las primeras posiciones, lo que debe producir valores de nDCG cercanos a 1.0 (el test verifica > 0.8). Por el contrario, en el ranking invertido los documentos relevantes se posicionan al final de la lista, degradando significativamente la métrica. Esta prueba no solo valida la correcta implementación de nDCG, sino también la sensibilidad de la métrica a la posición de los documentos relevantes. El parámetro `min_results=1` se configura específicamente para el dataset de prueba pequeño, ya que el valor por defecto de 1000 resultados mínimos no es aplicable a colecciones de validación.

Analizador de correlaciones: Las pruebas del analizador de correlaciones validan tanto la lógica de cálculo como la generación de visualizaciones. Se verifica que los coeficientes de Pearson, Spearman y Kendall están siempre en el rango $[-1, 1]$ para cualquier par de variables, que solo los identificadores de consulta presentes simultáneamente en los puntajes QPP y las métricas de recuperación se conservan para el análisis, y que los puntajes vacíos o con valores indefinidos generan excepciones apropiadas o son manejados de forma robusta.

```

1  # Calcular correlaciones entre puntajes QPP y métricas
2  correlations = self.analyzer.calculate_correlations(
3      correlation_types=['pearson', 'spearman', 'kendall']
4  )
5
6  # Verificar que todos los coeficientes están en rango válido
7  for corr_type in ['pearson', 'spearman', 'kendall']:
8      for value in correlations[corr_type].values.flatten():
9          if not np.isnan(value):
10             self.assertTrue(-1 <= value <= 1)
11

```



```

12 # Verificar alineamiento de identificadores de consulta
13 aligned_qids = self.analyzer._align_qids(
14     qpp_scores={'0': 0.5, '1': 0.7},
15     metrics={'0': 0.8, '2': 0.6}
16 )
17 # Solo '0' está presente en ambos conjuntos
18 self.assertEqual(set(aligned_qids), {'0'})

```

Figura 5.10: Prueba de cálculo de correlaciones y alineamiento de identificadores.

La Figura 5.10 muestra dos aspectos fundamentales del análisis de correlaciones. Primero, se valida que todos los coeficientes de correlación calculados (Pearson, Spearman y Kendall) permanezcan dentro de su rango teórico $[-1, 1]$. Los valores fuera de este rango indicarían errores numéricos graves en la implementación. Segundo, se verifica el alineamiento de identificadores de consulta: solo aquellas consultas que poseen tanto puntajes QPP como métricas de recuperación deben incluirse en el análisis. En el ejemplo mostrado, aunque los puntajes QPP contienen las consultas ‘0’ y ‘1’, y las métricas contienen ‘0’ y ‘2’, solo la consulta ‘0’ queda alineada para el cálculo de correlaciones. Este alineamiento correcto es fundamental para evitar correlaciones espurias causadas por datos faltantes.

5.4.4 Resultados de la validación

La ejecución completa del framework de pruebas, que comprende 58 casos distribuidos entre los ocho módulos, demostró la robustez del sistema implementado. Los resultados se resumen en la Tabla 5.11.

Tabla 5.11: Resultados de ejecución de pruebas unitarias por componente.

Componente	Pruebas ejecutadas	Tiempo de ejecución (s)
Analizador de correlaciones	10	8,25
Evaluador de métricas	6	0,05
Clarity	8	0,03
NQC	6	0,01
WIG	7	0,01
UEF	8	0,02
IDF	7	0,01
SCQ	6	0,01

Total	58	8,40
--------------	-----------	-------------

Todos los casos de prueba finalizaron exitosamente, alcanzando una tasa de éxito del 100%. El tiempo total de ejecución de aproximadamente 8,4 segundos resulta adecuado dado el tamaño reducido del dataset de validación, permitiendo obtener resultados rápidos e interpretables.

El analizador de correlaciones concentra la mayor parte del tiempo de ejecución debido a la generación de múltiples visualizaciones en formatos gráficos. Los predictores QPP muestran tiempos de ejecución mínimos gracias a la reutilización del índice y las estadísticas pre-calculadas, lo cual valida las estrategias de optimización mencionadas en secciones anteriores.

La validación exhaustiva realizada confirma la fiabilidad y precisión del entorno de evaluación implementado, proporcionando una base sólida para los experimentos de correlación analizados en el siguiente Capítulo. El sistema demostró ser robusto ante diversos escenarios de prueba, manteniendo la consistencia en el procesamiento de consultas, el cálculo de puntajes QPP y la evaluación de métricas de recuperación.

CAPÍTULO VI: ANÁLISIS DE RESULTADOS

A través de la literatura se ha establecido de manera casi unánime el análisis del rendimiento de los métodos QPP mediante el uso de métricas de correlación. Entre los primeros trabajos se puede encontrar el de E.M Voorhees en la conferencia TREC-6, donde se presenta el primer análisis de la capacidad de expertos en predecir el rendimiento de las consultas, donde se pudo observar que la mayor correlación lineal entre los resultados de los expertos fue de solo 0,26 [11].

El campo de la predicción del rendimiento de consultas se ha desarrollado a lo largo de los años, y se ha establecido el uso de juicios de relevancia y métricas como el Tau de Kendall o el Coeficiente de correlación de Spearman para la evaluación de los predictores. En este sentido, se encuentran dos puntos de interés, por un lado la evaluación del **sistema de recuperación subyacente**, y por otro la **evaluación de los predictores** utilizando como pre-requisito la evaluación del sistema de recuperación.

En esta sección se presentan los resultados obtenidos al evaluar los métodos QPP sobre cinco conjuntos de datos ampliamente utilizados en la comunidad de recuperación de información: **Antique/Test**, **Cranfield**, **BEIR-TREC-COVID**, **MS MARCO (Passage)** y **CAR**. Todos ellos se acceden a través del catálogo *ir_datasets*, lo que garantiza reproducibilidad y un tratamiento consistente de documentos, consultas y juicios de relevancia. En el caso de **MS MARCO (Passage)** y **CAR** se utilizaron específicamente las variantes con juicios multinivel, lo que permite analizar el comportamiento de los predictores en escenarios con información de relevancia más rica.

El rendimiento del sistema de recuperación subyacente (BM25) se midió principalmente con las métricas $nDCG@10$ y MAP. A partir de estas métricas se computaron coeficientes de correlación de Pearson, Spearman y Tau de Kendall entre las puntuaciones de los métodos QPP y los valores de $nDCG@10$ y MAP, lo que permite estudiar tanto relaciones lineales como monótonas entre predictores y rendimiento real.




Figura 6.1: Diagrama de flujo del análisis de resultados.

La configuración general utilizada para el experimento se presenta en la Figura 6.1 donde se puede observar que el proceso de evaluación involucra las métricas de evaluación de recuperación clásicas como nDCG o MAP, y más adelante, métricas de correlación de predictores como el Tau de Kendall, el cual debido a su naturaleza no lineal, se presenta como una métrica más fuerte frente a otras como el coeficiente de Pearson.

6.1 Caracterización de los conjuntos de datos

Previo a la evaluación de los métodos QPP, resulta imprescindible caracterizar los conjuntos de datos utilizados y el rendimiento del sistema de recuperación subyacente. Esta caracterización permite contextualizar los resultados de correlación posteriores y verificar que las diferencias observadas entre predictores se deben a su capacidad predictiva y no a artefactos del corpus o del *ranker*.

El análisis se estructura en dos ejes complementarios: primero, la distribución de los juicios de relevancia (*Qrels*), que describe la composición y balance de cada colección; segundo, la dificultad de las consultas según el rendimiento observado del sistema BM25, clasificada mediante umbrales percentilares.

6.1.1 Distribución de niveles de relevancia

Los juicios de relevancia constituyen el estándar de referencia para evaluar tanto el sistema de recuperación como los predictores QPP. Cada dataset emplea una escala de relevancia propia, que varía desde esquemas binarios simples hasta escalas graduadas con múltiples niveles. La Tabla 6.1 resume la distribución de juicios por nivel para los cinco conjuntos de datos evaluados.

Tabla 6.1: Distribución de juicios de relevancia por dataset.

Dataset	Niveles	Total Qrels	% No Relevantes	Observación
Antique/Test	4	6.589	61,6%	Dominan Out of context y Not relevant
Cranfield	5	1.837	19,2%	80,8% documentos útiles o relevantes
CAR	6	29.571	74,5%	Incluye nivel “Trash” (-2)
MS MARCO	4	11.386	68,3%	Dominado por Irrelevant
TREC-COVID	4	66.336	62,8%	Mayor volumen de juicios

Se observa una considerable heterogeneidad entre colecciones. *Cranfield* destaca por su alta proporción de documentos relevantes (80,8%), lo que sugiere un corpus cuidadosamente curado donde el sistema BM25 tiene mayor probabilidad de éxito. En contraste, *CAR* presenta la escala más compleja (6 niveles, incluyendo “Trash” con valor -2) y el mayor porcentaje de documentos no relevantes (74,5%), características que anticipan dificultades para los predictores.




Figura 6.2: Distribución de niveles de relevancia en Cranfield.




Figura 6.3: Distribución de niveles de relevancia en CAR.

La Figura 6.2 y la Figura 6.3 ilustran visualmente este contraste. En *Cranfield*, los niveles “High relevance” y “Complete answer” dominan la distribución, reflejando un corpus donde la mayoría de los documentos juzgados aportan información útil. En *CAR*, por el contrario, prevalecen los juicios negativos, incluyendo una categoría “Trash” que indica párrafos completamente irrelevantes. Esta diferencia estructural tiene implicaciones directas para la predicción: en *Cranfield*, las consultas tienen mayor probabilidad de obtener resultados satisfactorios, mientras que en *CAR* el sistema enfrenta un escenario inherentemente adverso.

El caso de *TREC-COVID* merece atención especial: con 66.336 juicios, constituye la colección más densamente anotada, lo que proporciona una base estadística robusta para el análisis de correlaciones. Por otra parte, *Antique/Test* y *MS MARCO* presentan distribuciones intermedias con predominio de juicios no relevantes.

6.1.2 Dificultad de consultas basada en rendimiento

La dificultad de una consulta se define operacionalmente a partir del rendimiento observado del sistema de recuperación. Siguiendo la metodología descrita en el marco teórico, se empleó una clasificación basada en percentiles: las consultas cuyo valor de $nDCG@10$ cae en el percentil 20 o inferior se etiquetan como difíciles, aquellas en el percentil 80 o superior como fáciles, y el resto como intermedias.

Tabla 6.2: Distribución de dificultad de consultas según nDCG@10.

Dataset	Consultas	Difíciles	Intermedias	Fáciles
Antique/Test	180	36 (20%)	108 (60%)	36 (20%)
Cranfield	221	45 (20%)	131 (59%)	45 (20%)
CAR	699	198 (28%)	361 (52%)	140 (20%)
MS MARCO	51	11 (22%)	29 (57%)	11 (22%)
TREC-COVID	50	10 (20%)	30 (60%)	10 (20%)

La Tabla 6.2 revela un patrón distintivo en *CAR*: el 28.3% de sus consultas se clasifican como difíciles, la proporción más alta entre todos los datasets. Este hallazgo es consistente con la naturaleza de la tarea *Complex Answer Retrieval*, donde las consultas derivan de encabezados jerárquicos de Wikipedia y requieren recuperar párrafos que no necesariamente comparten vocabulario con la consulta. Dado que BM25 opera mediante coincidencias léxicas (*bag-of-words*), muchas consultas de *CAR* resultan intrínsecamente problemáticas para este ranker, lo que limita el techo de correlación alcanzable por cualquier método de predicción.

En contraste, *Antique/Test* y *TREC-COVID* exhiben distribuciones perfectamente balanceadas (20%-60%-20%), reflejando una variedad equilibrada de consultas que permite evaluar el comportamiento de los predictores a lo largo de todo el espectro de dificultad.




Figura 6.4: Distribución de dificultad de consultas en Antique/Test.




Figura 6.5: Distribución de dificultad de consultas en CAR.

La Figura 6.4 y Figura 6.5 ilustran visualmente el contraste entre *Antique/Test*, con una distribución balanceada, y *CAR*, donde se observa un sesgo hacia consultas difíciles. Esta diferencia estructural anticipa el comportamiento divergente de los predictores QPP en ambos datasets, como se analizará en las secciones siguientes.




Figura 6.6: Distribución de dificultad de consultas en Cranfield.

Por su parte, *Cranfield* (Figura 6.6) exhibe una distribución prácticamente idéntica a *Antique/Test*: 45 consultas difíciles (20%), 131 intermedias (59%) y 45 fáciles (20%). Esta simetría, junto con su alta proporción de documentos relevantes (80,8%), confirma su clasificación como dataset favorable para la tarea de predicción. A pesar de su reducido tamaño de corpus (~1.400 documentos), la variedad equilibrada de consultas proporciona un escenario adecuado para evaluar la capacidad predictiva de los métodos QPP.

6.2 Comparación de métodos QPP

Los métodos QPP evaluados en esta sección fueron contrastados directamente con los resultados de la evaluación del sistema de recuperación utilizando correlaciones de Pearson, Spearman y Kendall entre las puntuaciones de los predictores y las métricas $nDCG@10$ y MAP. La evaluación se realizó sobre cinco conjuntos de datos distintos: *Antique/Test* (180 consultas), *Cranfield* (221 consultas), *BEIR-TREC-COVID* (50 consultas), *MS MARCO (Passage)* (51 consultas) y *CAR* (699 consultas). Esta diversidad de colecciones permite evaluar la robustez y generalización de los métodos QPP en diferentes contextos y tamaños de corpus, desde colecciones pequeñas y especializadas hasta grandes colecciones web.

6.2.1 Visión general de las correlaciones

El análisis visual constituye un complemento indispensable a las métricas numéricas presentadas anteriormente. A continuación, se presentan los diagramas de dispersión generados para cada conjunto de datos, los cuales permiten examinar la relación entre las puntuaciones estimadas por cada método QPP y el rendimiento real del sistema ($nDCG@10$) a nivel de consulta individual.

Estas visualizaciones son críticas para identificar patrones que los coeficientes de correlación agregados (como *Kendall* o *Pearson*) no logran capturar por sí solos, tales como *heterocedasticidad* (varianza no constante), la presencia de valores atípicos (*outliers*) y la identificación de regiones específicas donde un predictor puede ser más o menos confiable. Para garantizar una correcta lectura de los resultados gráficos, se detalla a continuación la metodología de construcción utilizada mediante la biblioteca de visualización estadística *Seaborn* en Python, así como los criterios para su interpretación.

1. **Representación de Datos (Puntos):** Cada punto en el gráfico corresponde a una consulta única (q) del *dataset*.

- El Eje Horizontal (X) representa el valor de predicción (*score*) asignado por el método QPP evaluado.
- El Eje Vertical (Y) representa la métrica de efectividad real obtenida ($nDCG@10$).

2. **Línea de Tendencia (Regresión):** La línea sólida que atraviesa la nube de puntos corresponde a un ajuste de regresión lineal calculado mediante el método de mínimos cuadrados, es decir, la mejor línea recta posible que representa la relación entre las dos variables. Esta línea indica la dirección de la correlación: una pendiente positiva pronunciada sugiere que el método predice correctamente el aumento del rendimiento.
3. **Banda de Confianza (Sombreado):** El área translúcida alrededor de la línea de regresión representa el intervalo de confianza del 95% calculado mediante **bootstrapping**. Este método estima la incertidumbre remuestreando los datos observados con reemplazo, generando múltiples regresiones alternativas y calculando percentiles sobre las predicciones resultantes. A diferencia de métodos paramétricos clásicos (distribución *t* o normal), *bootstrap* no asume ninguna distribución teórica, operando exclusivamente con los datos disponibles.

El procedimiento reutiliza los datos observados mediante iteraciones sucesivas (por defecto 1.000 en *Seaborn*): cada iteración remuestrea consultas con reemplazo, ajusta una regresión sobre la nueva muestra y acumula predicciones; la distribución resultante de predicciones define los límites del intervalo mediante percentiles simétricos.

El ancho de las bandas refleja fielmente la incertidumbre inherente. Bandas amplias surgen cuando el tamaño muestral es reducido (p. ej., 50 consultas en *TREC-COVID*), cuando los puntos exhiben alta dispersión respecto a la línea de tendencia (residuos grandes) o hacia los extremos del eje horizontal, donde pequeños cambios en la pendiente amplifican las diferencias de predicción. Por el contrario, bandas estrechas indican que la tendencia observada es robusta y que diferentes submuestras conducen a conclusiones consistentes sobre la relación entre predicción QPP y rendimiento real.

4. **Coefficiente de Referencia (τ):** Finalmente, cada diagrama incorpora el valor de correlación de *Kendall* (τ) calculado para ese par específico de variables. La inclusión de esta métrica permite contrastar la percepción visual de la dispersión con la medida estadística formal de asociación ordinal, lo que es fundamental para contextualizar la línea de regresión, ya que mientras la línea muestra la tendencia lineal general, el valor τ cuantifica la calidad del ranking.

Bajo estos criterios, un método QPP ideal debería mostrar una nube de puntos compacta y elongada diagonalmente hacia la derecha, acompañada de un τ alto y positivo. Por el contrario, una nube dispersa verticalmente o con una línea de tendencia plana indica una capacidad predictiva pobre, donde el método no logra distinguir eficazmente entre consultas difíciles y fáciles.

A continuación se presentan los diagramas de dispersión organizados por *dataset*, incluyendo los métodos QPP evaluados para su contraste directo.




Figura 6.7: Diagramas de dispersión QPP vs nDCG@10 en Antique/Test.

La Figura 6.7 evidencia el comportamiento diferenciado de los métodos en *Antique/Test*. Los métodos *post-retrieval* basados en divergencia (NQC, WIG y UEF-NQC) dominan visualmente el escenario, presentando las pendientes positivas más pronunciadas y, crucialmente UEF-NQC exhibe la banda de confianza más estrecha y una nube de puntos más compacta que su versión base (NQC), lo que confirma visualmente que la re-estimación de utilidad reduce el ruido de la predicción.

En contraste, los métodos *pre-retrieval* (IDF promedio y máximo) muestran líneas de tendencia horizontales con una dispersión vertical extrema. Es notable cómo consultas con el máximo puntaje IDF pueden tener un nDCG de 0, evidenciando la desconexión entre la rareza de los términos y su relevancia real en este dataset. SCQ muestra un patrón distintivo en su variante *SCQ-Max*: este método selecciona como puntaje el término más discriminativo de la consulta, lo que explica la agrupación observada en el rango $x \in \{45-55\}$. Esto sugiere que la mayoría de las consultas contienen al menos un término medianamente raro que domina el puntaje final, provocando que el método pierda sensibilidad para distinguir entre consultas fáciles y difíciles.

Finalmente, Clarity revela un comportamiento inestable, ya que, aunque su tendencia es positiva, presenta severos *outliers* en valores altos (>150) asociados a un rendimiento mediocre, lo que sugiere que Clarity genera “falsos positivos” de dificultad, asignando puntajes altos a consultas con vocabulario inusual pero que no logran recuperar documentos relevantes.




Figura 6.8: Diagramas de dispersión QPP vs nDCG@10 en CAR.

El caso de *CAR* (Figura 6.8) representa el escenario más crítico de la evaluación y de gran valor experimental. Con 699 consultas, la alta densidad de puntos revela un patrón sistemático distintivo caracterizado por dos fenómenos:

1. **Floor Effect (Efecto Suelo):** Como se define en la literatura estadística [31], la concentración masiva de puntos en el rango de rendimiento nulo ($nDCG@10 \approx 0$) comprime la varianza de la variable dependiente, ya que al no existir una distribución de rendimiento

efectiva, resulta matemáticamente inviable establecer una correlación lineal robusta, independientemente de la calidad del predictor.

1. **Desacople Predictivo:** Se observa una desconexión estructural entre las señales que capturan los métodos QPP (basados en coincidencia léxica y divergencia estática) y la naturaleza de la tarea *Complex Answer Retrieval*. Mientras que los métodos asignan puntuaciones dinámicas a las consultas, sugiriendo que detectan variabilidad en la dificultad, el rendimiento real permanece plano, esto confirma que las heurísticas estadísticas tradicionales son “ciegas” ante la dificultad semántica, validando la necesidad de enfoques neuronales para este tipo de *corpus*.

Este comportamiento confirma la incompatibilidad entre el modelo léxico base (BM25) y la tarea semántica de *Complex Answer Retrieval*. Incluso los métodos de expansión UEF demuestran que la re-estimación de utilidad no es tan útil cuando los documentos iniciales recuperados carecen de relevancia.




Figura 6.9: Diagramas de dispersión QPP vs nDCG@10 en TREC-COVID.

En *TREC-COVID* (Figura 6.9) emerge un patrón distintivo que invierte las jerarquías observadas en los otros conjuntos de datos, ya que visualmente Clarity y su variante UEF-Clarity dominan el espectro, presentando las pendientes positivas más pronunciadas y bandas de confianza estrechas, lo que denota una predicción robusta y bien correlacionada. Por el contrario, los métodos basados en divergencia de puntajes (NQC, WIG), habitualmente dominantes en otros conjuntos de datos, colapsan en líneas de tendencia casi horizontales. Esta inversión se atribuye a la naturaleza técnica y homogénea del *corpus*:

1. **Ventaja de Clarity:** Al basarse en modelos de lenguaje, Clarity explota eficazmente la especificidad del vocabulario médico, por lo que la divergencia entre el modelo de la consulta (términos técnicos precisos) y la colección general es una señal muy limpia en este dominio.
2. **Fallo de NQC/WIG:** La alta densidad de términos relevantes en la colección provoca una “saturación de puntajes” en BM25, ya que al existir muchos documentos con puntuaciones de recuperación similares, la varianza de los *scores* se comprime, privando a NQC y WIG de la señal de dispersión necesaria para discriminar la dificultad de la consulta.




Figura 6.10: Diagramas de dispersión en Cranfield.




Figura 6.11: Diagramas de dispersión en MS MARCO (Passage).

Finalmente, al analizar la Figura 6.10 y la Figura 6.11, es posible contrastar el impacto del tamaño muestral y la naturaleza del dominio.

En *Cranfield* (221 consultas), la densidad de puntos permite identificar tendencias estructurales: WIG, NQC y sus variantes UEF muestran pendientes ascendentes bien definidas. Sin embargo, Clarity exhibe una tendencia descendente anómala (correlación negativa), donde el modelo asigna puntuaciones altas a consultas que obtienen bajo rendimiento real, lo que sugiere que el predictor confunde la coherencia terminológica de los documentos técnicos

recuperados con su relevancia temática real. Por su parte, Los métodos *pre-retrieval* (IDF, SCQ) presentan nubes de puntos amorfas sin direccionalidad, confirmando su ineficacia en colecciones especializadas.

Por otro lado, en *MS MARCO* (51 consultas), la escasez de datos se traduce visualmente en bandas de confianza notablemente más amplias (sombras extensas), lo que alerta sobre la mayor incertidumbre estadística de estas regresiones. A pesar de ello, se observa un patrón interesante: WIG y NQC logran mantener pendientes pronunciadas y paralelas, demostrando capacidad para extraer señal predictiva incluso con una muestra de juicios limitada. Clarity, en cambio, colapsa en una línea horizontal, indicando una ausencia total de señal predictiva en este corpus masivo y heterogéneo.

6.2.2 Análisis por familia de métodos

Los métodos evaluados pueden agruparse en tres familias según su acceso a información del sistema de recuperación:

Métodos pre-retrieval (IDF, SCQ): Estos predictores operan únicamente con estadísticas del índice, sin conocer los documentos recuperados. Los diagramas de dispersión muestran consistentemente líneas de tendencia casi horizontales para IDF, con varianza extrema que invalida cualquier capacidad predictiva. SCQ presenta un comportamiento marginalmente mejor, alcanzando correlaciones moderadas en *Antique/Test* y *Cranfield*, pero su rendimiento se degrada en corpus grandes o especializados como *TREC-COVID*. La ventaja de estos métodos radica exclusivamente en su eficiencia computacional.

Métodos post-retrieval clásicos (WIG, NQC, Clarity): Al acceder a la lista de documentos recuperados y sus puntuaciones, estos métodos capturan señales más informativas. NQC y WIG muestran comportamientos complementarios: mientras NQC se basa en la varianza de puntuaciones del top-k, WIG considera la desviación respecto al promedio del corpus. Clarity, basado en divergencia KL respecto al modelo de lenguaje de la colección, exhibe alta sensibilidad al dominio: domina en *TREC-COVID* pero presenta correlaciones negativas en *Cranfield*.

Variantes UEF: El marco *Utility Estimation Framework* extiende los métodos base incorporando información de pseudo-relevance feedback. Los diagramas revelan que UEF mejora consistentemente a NQC en la mayoría de datasets, con la excepción de *MS MARCO* donde ambos empatan. Para Clarity, UEF amplifica tanto sus contextos favorables (*TREC-COVID*) y aumentando un poco su rendimiento en situaciones difíciles (*Cranfield* con correlación cercana a cero).

6.2.3 Significancia estadística de las correlaciones

La validez de los patrones observados requiere verificar que las correlaciones sean estadísticamente significativas. Un coeficiente de correlación alto carece de utilidad práctica si no supera los umbrales de significancia, especialmente en datasets con pocas consultas donde el azar puede producir correlaciones espurias.

Los mapas de calor de p-values utilizan una escala de cuatro niveles: altamente significativo ($p < 0,001$), muy significativo ($p < 0,01$), significativo ($p < 0,05$) y no significativo ($p \geq 0,05$). Esta gradación permite distinguir entre correlaciones robustas y aquellas que podrían deberse a fluctuaciones aleatorias.




Figura 6.12: Significancia estadística (p-values) en Antique/Test.




Figura 6.13: Significancia estadística (p-values) en TREC-COVID.

Como podemos ver en la Figura 6.12 y la Figura 6.13, ambos datasets contrastan fuertemente. En *Antique/Test* (180 consultas), todos los métodos excepto IDF alcanzan significancia alta ($p < 0,001$), lo que valida la robustez de las correlaciones observadas. En *TREC-COVID* (50 consultas), sin embargo, solo Clarity y UEF-Clarity presentan significancia consistente; métodos como NQC, que tradicionalmente dominan otros datasets, no superan el umbral de $p < 0,05$.

Este fenómeno se explica por la relación matemática entre tamaño muestral y significancia estadística. La prueba de significancia para correlaciones evalúa si el coeficiente observado podría haberse obtenido por azar; con muestras pequeñas, la varianza del estimador es alta y solo correlaciones sustanciales superan el umbral. Concretamente, para τ de Kendall con $n \approx 50$ consultas, solo correlaciones relativamente altas ($\tau \gtrsim 0,18-0,20$) tienden a alcanzar $p < 0,05$, mientras que con $n \approx 180$ consultas correlaciones mucho menores ($\tau \approx 0,10$) pueden resultar significativas. Esto explica por qué métodos como NQC, con correlaciones moderadas en TREC-COVID ($\tau \approx 0,09$), no alcanzan significancia a pesar de mostrar tendencias positivas.

Patrones transversales de significancia

El análisis de los cinco datasets revela consistencias importantes:

- *IDF nunca alcanza significancia estadística* en ningún dataset, confirmando su ineficacia práctica como predictor QPP con el sistema BM25 evaluado.
- *NQC y UEF-NQC* son altamente significativos ($p < 0,001$) en cuatro de cinco datasets, con la única excepción de TREC-COVID.
- *Clarity exhibe significancia polarizada*: altamente significativo en TREC-COVID y Antique, pero no significativo en Cranfield ni MS MARCO.

- *SCQ presenta significancia intermedia*: alcanza $p < 0,001$ en Antique y CAR, pero no supera $p < 0,05$ en MS MARCO ni TREC-COVID.
- *Los datasets pequeños* (MS MARCO con 51 consultas, TREC-COVID con 50) muestran mayor proporción de métodos no significativos, subrayando la importancia del tamaño muestral para conclusiones robustas.

Estos patrones de significancia complementan el análisis de correlaciones y deben considerarse conjuntamente al evaluar la utilidad práctica de cada método. Un predictor con correlación moderada pero altamente significativa puede ser preferible a uno con correlación alta pero estadísticamente dudosa.

Los resultados cuantitativos detallados, incluyendo las correlaciones exactas para cada combinación de método, métrica y dataset, se presentan en la siguiente sección.

6.3 Análisis comparativo de los resultados

Una vez caracterizado el comportamiento visual de los predictores y las propiedades de los conjuntos de datos en las secciones previas, corresponde cuantificar con precisión el rendimiento de los métodos mediante los coeficientes de correlación.

Este análisis cuantitativo resulta indispensable para validar estadísticamente las tendencias observadas y determinar qué métodos ofrecen no solo una relación lineal (*Pearson*) o monótona (*Spearman*), sino un ordenamiento correcto de las consultas según su dificultad (*Kendall*), aspecto crítico para la aplicabilidad real de los sistemas de rendimiento de consultas (QPP).

La Tabla 6.3 presenta la consolidación de los coeficientes obtenidos entre las puntuaciones de cada predictor y la métrica de efectividad $nDCG@10$. Esta tabla constituye la evidencia central de este trabajo, permitiendo contrastar transversalmente el desempeño de los métodos en escenarios de recuperación con características estructural y semánticas muy diversas.

Al respecto, un aspecto técnico relevante que se desprende de la comparación entre los tres coeficientes calculados es la consistencia direccional entre las métricas de correlación, ya que se observa que, en la mayoría casos, los métodos que obtienen un alto τ de *Kendall* también mantienen valores elevados de ρ de *Spearman* y *Pearson*.

Esta alineación sugiere que la relación entre la predicción y el rendimiento real es robusta y no depende exclusivamente de la métrica estadística utilizada. Sin embargo, existen excepciones notables en los métodos pre-retrieval, como *IDF*, donde la discrepancia entre *Pearson* y *Kendall* se acentúa más, lo que indica que, aunque dichos métodos pueden capturar la magnitud general de la dificultad (relación lineal), pueden fallar sistemáticamente en ordenar correctamente las consultas individuales dentro del ranking.

Tabla 6.3: Correlaciones (P-ρ, S-ρ y K-τ) entre métodos QPP y nDCG@10 en los distintos datasets evaluados.

Correlaciones entre métodos QPP y nDCG@10 en múltiples datasets															
Método	Antique/Test			Cranfield			BEIR-TREC-COVID			MS MARCO (Passage)			CAR		
	P-ρ	S-ρ	K-τ	P-ρ	S-ρ	K-τ	P-ρ	S-ρ	K-τ	P-ρ	S-ρ	K-τ	P-ρ	S-ρ	K-τ
IDF Pro-medio	0,164	0,139	0,038	0,249	0,186	0,102	0,123	0,005	-0,006	0,265	0,292	0,209	-0,019	-0,007	-0,005
IDF Má-ximo	0,092	0,076	0,028	0,117	0,087	0,037	0,083	0,030	0,017	0,251	0,253	0,168	0,018	0,009	0,006
SCQ Pro-medio	0,324	0,266	0,180	0,284	0,235	0,104	0,075	0,053	0,032	0,178	0,182	0,127	0,039	0,014	0,010
SCQ Má-ximo	0,379	0,383	0,269	0,310	0,276	0,176	0,062	0,089	0,055	-0,035	0,012	0,030	0,065	0,074	0,051
WIG	0,436	0,450	0,305	0,295	0,324	0,222	0,320	0,278	0,201	0,552	0,560	0,406	0,079	0,099	0,068
NQC	0,524	0,567	0,382	0,297	0,384	0,210	0,192	0,147	0,093	0,553	0,585	0,408	0,125	0,166	0,114
Clarity	0,452	0,430	0,272	-0,025	-0,018	-0,069	0,477	0,461	0,320	0,093	0,068	0,047	0,110	0,146	0,101
UEF-WIG	0,333	0,377	0,252	0,388	0,390	0,233	0,170	0,192	0,134	0,343	0,380	0,253	0,121	0,124	0,086
UEF-NQC	0,553	0,596	0,427	0,359	0,458	0,258	0,182	0,146	0,108	0,552	0,560	0,408	0,131	0,182	0,126
UEF-Clarity	0,463	0,448	0,286	0,161	0,181	0,011	0,496	0,468	0,331	0,190	0,186	0,119	0,113	0,152	0,105

La primera observación que podemos obtener de la Tabla 6.3 es la significativa heterogeneidad en los “techos de rendimiento” alcanzables. Se evidencia que la dificultad de la tarea de predicción no es uniforme:

- En colecciones favorables como *Antique* y *MS MARCO*, los mejores métodos logran correlaciones de *Kendall* robustas ($\tau > 0,40$).
- En escenarios complejos como *CAR*, el rendimiento se desploma drásticamente ($\tau \approx 0,126$).

Este escenario confirma cuantitativamente que la calidad de la predicción está intrínsecamente acotada por las propiedades del conjunto de datos y la capacidad del sistema de recuperación base para satisfacer las necesidades de información planteadas.

Por otra parte, si analizamos el desempeño por familias, se hace evidente la limitación de los métodos *pre-retrieval*:

- **IDF** (Promedio y Máximo) presenta correlaciones consistentemente bajas ($\tau < 0,15$), demostrando una capacidad predictiva cercana al azar.
- **SCQ** revela un comportamiento dual interesante: alcanza correlaciones respetables en colecciones pequeñas como *Antique* ($\tau \approx 0,269$) y *Cranfield* ($\tau \approx 0,176$), pero su rendimiento colapsa en corpus masivos o especializados como *MS MARCO* ($\tau = 0,030$) y *TREC-COVID* ($\tau = 0,055$).

Este hallazgo sugiere que la estadística de coherencia de la consulta, que es útil en contextos simples o reducidos, pierde robustez y se diluye como señal predictiva al escalar a *corpus* que son masivos o con vocabularios técnicos específicos.

Así mismo, esta degradación del rendimiento de *SCQ* en índices masivos puede atribuirse al fenómeno de saturación del espacio semántico. En colecciones pequeñas como *Cranfield*, la ocurrencia de un término es un evento informativo fuerte, sin embargo, en índices del tamaño de *MS MARCO* con millones de pasajes, la probabilidad de que exista co-ocurrencia accidental de términos aumenta exponencialmente, lo que provoca que la métrica de “coherencia” de *SCQ* se vuelva ruidosa, ya que el método no puede distinguir entre una repetición de términos que aporta significado y una que es meramente estadística debido al volumen del *corpus*.

En contraste, los métodos *post-retrieval* dominan el espectro de resultados. *NQC* se consolida como el predictor base más robusto de este trabajo, superando en la mayoría de los escenarios a *WIG* en la mayoría de los escenarios. Esta consistencia de *NQC* a través de los distintos *datasets* valida la hipótesis de que la desviación estándar de las puntuaciones de los documentos recuperados es una señal más fiable de la “certeza” del sistema que la simple acumulación de aportes léxicos utilizada por *WIG*.

Otro caso de estudio excepcional es el del método *Clarity*, en el que los datos numéricos confirman una dependencia extrema del dominio:

- En conjuntos de datos como *Cranfield* fracasa de forma clara ($\tau = -0,069$, correlación nula o inversa).
- En *TREC-COVID* resurge como uno de los métodos líderes ($\tau = 0,320$), y más aún, su variante *UEF-Clarity* alcanza en este *dataset* el valor más alto de la tabla ($\tau = 0,331$).

Esto indica que los modelos de lenguaje, base para *Clarity*, son altamente efectivos cuando el *corpus* posee una homogeneidad temática y terminológica (como son los artículos médicos sobre COVID-19), pero se vuelven inestables e inútiles en colecciones pequeñas o con vocabularios más dispersos.

Respecto a la aplicación del marco *UEF* (*Utility Estimation Framework*), los resultados muestran matices que son importantes, si bien el método logra potenciar el rendimiento en *Antique* y *Cranfield* (elevando la correlación de NQC de 0,382 a 0,427), se observa un fenómeno de “**saturación**” en *MS MARCO*.

En este *dataset*, las correlaciones de NQC y UEF-NQC son idénticas ($\tau = 0,408$), lo que sugiere que en *corpus* de gran escala y diversidad temática, la expansión de consultas, que es el mecanismo central de *UEF*, podría no estar aportando información nueva relevante o, peor aún, podría estar introduciendo ruido que neutraliza las ganancias de la re-estimación.

Finalmente, el análisis del conjunto de datos *CAR* ratifica la dificultad extrema de las tareas de *Complex Answer Retrieval* para los paradigmas actuales, ya que con una correlación máxima de $\tau \approx 0,126$ transversal a todos los métodos probados, se evidencia una barrera estructural, en donde la desconexión semántica entre las consultas (títulos de Wikipedia, en este caso) y los pasajes relevantes, sumada a una escala de relevancia compleja, genera un escenario “ciego” para las señales léxicas y estadísticas tradicionales.

6.4 Discusión de los resultados

El análisis exhaustivo anteriormente evidenciado sobre los cinco conjuntos de datos heterogéneos nos permite no solo evaluar la efectividad puntual de los métodos QPP, sino también establecer principios generales que guíen la investigación futura.

Los resultados confirman que la predicción del rendimiento de consultas es una tarea dependiente de varios factores (multifactorial), cuya dificultad depende tanto de las propiedades estadísticas de la colección como de la naturaleza semántica de la necesidad de información.

En este contexto, si bien los coeficientes de *Pearson* y *Spearman* entregan referencias sobre la linealidad y monotonía general respectivamente, la discusión de los resultados se centra principalmente en el coeficiente τ de *Kendall* respondiendo a la evidencia numérica presentada en la Tabla 6.3, donde se observan ciertas discrepancias, como por ejemplo, para el método *Clarity* en *Antique*, tanto *Pearson* (0,452) como *Spearman* (0,430) sugieren una correlación moderada que se desinfla significativamente al evaluar el ordenamiento estricto mediante *Kendall* (0,272), confirmando que incluso las métricas basadas en rangos como

Spearman pueden ser optimistas, mientras que *Kendall* emerge como un indicador más robusto para interpretar la capacidad real de los predictores en este escenario experimental.

6.4.1 Contextualización y validación de la línea base

Uno de los principales aportes de este trabajo de título es la identificación empírica de una configuración de referencia robusta, en la que los datos demuestran que los métodos *post-retrieval* basados en la dispersión de puntuaciones, específicamente *NQC* y su variante *UEF-NQC*, ofrecen el equilibrio más consistente entre rendimiento y estabilidad.

Aunque los valores de correlación obtenidos (con límites superiores cercanos a $\tau \approx 0,43$) podrían parecer modestos fuera del contexto de la recuperación de información, es crucial interpretarlos bajo los estándares del dominio. Como señala [10], correlaciones incluso tan bajas como $0,1$ poseen valor práctico en escenarios de predicción de dificultad, y valores en el rango obtenido en este trabajo son considerados significativos. De hecho, resultados como los de *Antique* se alinean e incluso superan ligeramente los reportados por [4], validando la calidad de la implementación.

En consecuencia, se establece que métodos como *UEF-NQC* constituyen un *baseline* experimental idóneo para futuras investigaciones, debiendo preferirse sobre métodos más débiles como *IDF*, siempre que el costo computacional de la expansión de consultas sea admisible.

Desde una perspectiva de implementación en sistemas reales, estos hallazgos plantean un compromiso (*trade-off*) crítico entre precisión predictiva y latencia, ya que, si bien *UEF-NQC* se establece como el estándar de calidad, su ejecución implica un costo computacional significativo al requerir una primera recuperación, análisis de puntajes, expansión de consultas y, en ocasiones, una segunda fase de recuperación.

Por lo tanto, en escenarios de alta demanda o tiempo real, este costo podría ser un obstáculo, por ello, la utilidad marginal que ofrecen métodos intermedios como *SCQ* en colecciones acotadas no debe descartarse totalmente, aunque son menos precisos, su ejecución es mucho más rápida al basarse en tablas pre-calculadas, lo que los convierte en candidatos viables para una primera capa de filtrado en arquitecturas de recuperación en cascada.

6.4.2 La complejidad inherente y el límite estadístico

Los resultados consistentemente bajos en el conjunto de datos *CAR* ($\tau < 0,13$) exponen no solo una limitación de los métodos evaluados, sino la complejidad intrínseca de la tarea. Estudios previos con expertos humanos como [32] y [33] han demostrado que incluso profesionales con conocimiento del dominio tienen dificultades para predecir el fracaso de una consulta basándose solo en su formulación.

Esto sugiere que los métodos actuales, que operan bajo supuestos léxicos como *IDF* y *SCQ* o estadísticos como *NQC* y *Clarity* han alcanzado un “techo técnico”, ya que asumen que la dificultad se manifiesta en la rareza de los términos o en la divergencia de distribuciones, pero son “ciegos” a la brecha semántica, por lo que en tareas complejas de recuperación donde la revelancia no es literal sino conceptual como en *CAR*, los métodos estadísticos no logran distinguir claramente entre una respuesta diversa pero relevante y una respuesta ruidosa e irrelevante.

Para cuantificar la magnitud del efecto suelo (*floor effect*), la Tabla 6.4 presenta una comparación transversal del porcentaje de consultas con rendimiento nulo o muy bajo en cada colección evaluada.

Tabla 6.4: Distribución del efecto suelo por dataset. *CAR* presenta la mayor concentración de consultas con rendimiento nulo.

Dataset	Consultas	nDCG@10 = 0	nDCG@10 ≤ 0.1	Media
Antique/Test	180	4,4%	10,0%	0,379
Cranfield	221	18,1%	24,9%	0,320
TREC-COVID	50	14,0%	18,0%	0,473
CAR	699	28,3%	41,9%	0,203

Los datos revelan que *CAR* concentra el 28,3% de sus consultas con nDCG@10 = 0, proporción significativamente mayor que en los demás datasets (Antique: 4,4%, TREC-COVID: 14%). Más aún, el 41,9% de las consultas *CAR* obtienen un rendimiento igual o inferior a 0,1, evidenciando que el problema no es marginal sino estructural.

Para ilustrar concretamente la naturaleza de esta barrera semántica, la Tabla 6.5 presenta ejemplos representativos de consultas con rendimiento nulo:

Tabla 6.5: Ejemplos de consultas *CAR* con brecha semántica. Los encabezados jerárquicos de Wikipedia no comparten vocabulario léxico con los párrafos relevantes.

Consulta (estructura jerárquica)	nDCG@10
Invasive species/Effects/Economic/.../Benefits	0,000
Beach nourishment/Nourishment projects/Hawaii/Waikiki	0,000
Brain damage/Signs and symptoms/Moderate/severe...	0,000
Drinking water/Health aspects/Well contamination...	0,000

Estas consultas ilustran el problema central: las estructuras jerárquicas como “Invasive species/Effects/Economic/Economic opportunities/Benefits” describen un concepto semántico específico (*beneficios económicos de especies invasoras*), pero los párrafos

relevantes en el corpus probablemente discuten el tema sin utilizar exactamente esos términos. El modelo BM25, al operar sobre coincidencias léxicas exactas, no puede recuperar documentos relevantes cuando no existe solapamiento de vocabulario, independientemente de la coherencia conceptual.

Es fundamental también reconocer las limitaciones inherentes al estándar de referencia (*Ground Truth*) utilizado para validar estas predicciones, ya que métricas de recuperación como *nDCG* dependen enteramente de la completitud y calidad de los juicios de relevancia humanos, por lo que, en *datasets* con escada profundidad de juicio (*sparse judgments*) o sesgos de anotación, lo que los métodos QPP intentan predecir no es necesariamente la satisfacción real del usuario, sino la coincidencia con un conjunto de etiquetas estáticas, lo que puede ser particularmente crítico en casos como *CAR*, donde la baja correlación podría estar reflejando no solo la incapacidad de los predictores, sino también la desconexión entre la definición teórica de relevancia del *dataset* y la utilidad real percibida que los métodos estadísticos intentan inferir.

6.4.3 Análisis de la sensibilidad de Clarity

La disparidad observada en el rendimiento del método Clarity entre las colecciones de **Cranfield** y **TREC-COVID** no es accidental, sino que responde a diferencias estructurales profundas en cuanto a escala, riqueza de vocabulario y distribución de frecuencias. Formalmente, Clarity estima la coherencia de los resultados recuperados mediante la divergencia Kullback-Leibler (KL) entre el modelo de lenguaje de la consulta ($P(w|Q)$) y el modelo de lenguaje de la colección ($P(w|C)$), tal como se define en la Ecuación (6.1):

$$\text{Clarity} = \sum_{\{w \in V\}} P(w|Q) \log_2 \left(\frac{P(w|Q)}{P(w|C)} \right) \quad (6.1)$$

Donde $P(w|Q)$ es la probabilidad del término w en el modelo de pseudo-relevancia, y $P(w|C) = \frac{cf_w}{N}$ su probabilidad en la colección (con N el total de tokens). Dado que N es 129 veces mayor en TREC-COVID (15.7M vs 121K), un término con igual frecuencia de colección tendrá $P(w|C) \sim 129$ veces menor, inflando el cociente $\frac{P(w|Q)}{P(w|C)}$ y generando puntajes de Clarity sistemáticamente más altos en colecciones grandes.

Tabla 6.6: Comparación de estadísticas de colección y Clarity entre Cranfield y TREC-COVID.

Métrica	Cranfield	TREC-COVID
Documentos	1,400	171,332
Tokens totales	121,253	15,681,547
Vocabulario	6,054	251,601
Long. promedio doc	86.6	91.5
Términos raros ($cf \leq 5$)	70.6%	78.1%
Terminos unicos ($cf = 1$)	43.1%	46.5%
Consultas evaluadas	225	50
Términos únicos (queries)	612	817
Términos con $P_{coll} \approx 0$	5.7% (contrib. 25.1%)	24.0% (contrib. 52.6%)
Clarity (media $\pm$ std)	2.387 ± 0.249	5.612 ± 0.801

La Tabla 6.6 muestra que ambas colecciones tienen proporciones similares de términos raros (~70-78%). Dado que la divergencia KL es una suma de contribuciones individuales por término ($contrib_w = P(w|Q) \cdot \log_2\left(\frac{P(w|Q)}{P(w|C)}\right)$), podemos analizar qué fracción del puntaje total proviene de términos con $P(w|C)$ muy bajo. La diferencia en rendimiento predictivo radica en la **naturaleza** de estos términos:

- En **Cranfield**, el 25,1% de la divergencia proviene de un 5,7% de términos con $P(w|C) \approx 0$. Estos corresponden principalmente a ruido estadístico propio de colecciones pequeñas, donde cualquier término poco frecuente genera cocientes $\frac{P(w|Q)}{P(w|C)}$ artificialmente altos sin aportar señal semántica útil.
- En **TREC-COVID**, el 52,6% de la divergencia proviene de tecnicismos médicos legítimos (e.g., “sarscov”, “merscov”, “trial”, “drug”). Estos términos son genuinamente discriminativos: indican que la consulta tiene un enfoque temático específico y, por tanto, su alta contribución es informativa.

En resumen, cuando la divergencia está dominada por términos semánticamente relevantes, Clarity predice bien; cuando está dominada por ruido de baja frecuencia, la predicción se degrada. La Tabla 6.8 ejemplifica esta distinción en TREC-COVID: términos específicos como “social” o “drug” generan cocientes altos (>17), mientras que términos genéricos de la literatura científica como “result” o “studi” son correctamente atenuados (~2.2).

Tabla 6.7: Contribución de términos en Cranfield

Término	$P(w Q)$	$P(w C)$	Cociente
flow	0.031	0.016	1.9
number	0.022	0.011	2.0
method	0.015	0.007	2.1
pressur	0.022	0.011	2.1
effect	0.017	0.008	2.1

Tabla 6.8: Contribución de términos en TREC-COVID

Término	$P(w Q)$	$P(w C)$	Cociente
social	0.019	0.0008	23.3
trial	0.019	0.0010	19.9
drug	0.019	0.0011	17.8
sarscov	0.010	0.0006	17.5
peopl	0.012	0.0007	16.4

En conclusión, la evidencia sugiere que Clarity es altamente sensible a la escala del corpus. En colecciones pequeñas, el ruido estadístico domina la divergencia, limitando la utilidad del método; en cambio, en colecciones grandes y temáticamente especializadas, la métrica gana robustez y capacidad predictiva. Para mitigar este sesgo en corpus reducidos, la literatura sugiere normalizaciones sobre el parámetro μ o el filtrado agresivo de términos raros durante el preprocesamiento.

Por otra parte, las limitaciones estructurales observadas, tanto la brecha semántica en *CAR* como la dependencia de dominio de *Clarity*, sugieren que el futuro inmediato de la predicción del rendimiento de consultas no reside en refinar métricas estadísticas, sino en la integración de Inteligencia Artificial y Modelos de Lenguaje Grandes (*LLMs*), debido a que la capacidad de estos modelos para “entender” el contenido abre nuevas vías para superar las limitaciones observadas:

- **Evaluación de Coherencia Semántica:** En lugar de medir la ambigüedad mediante modelos de lenguaje simples, como *Clarity*, un modelo neuronal podría evaluar directamente la coherencia lógica entre la consulta y los documentos recuperados.
- **Predicción Generativa:** Utilizar *LLMs* para reformular la consulta y medir la consistencia de los conjuntos de documentos recuperados para cada variación, proporcionando una señal de robustez mucho más valiosa que la expansión léxica de *UEF*.
- **Decisión Híbrida:** Dado que la eficiencia es clave [2], se propone investigar arquitecturas en cascada donde métodos ligeros como *SCQ* filtren consultas obviamente fáciles, para así reservar el costo computacional de los métodos neuronales solo para aquellas consultas clasificadas como ambiguas o difíciles.

En conclusión, los resultados obtenidos en este trabajo, establecen una línea base sólida con *UEF-NQC*, por ejemplo, pero también evidencia que el objetivo próximo de la investigación QPP exige la evolución de paradigmas que permitan transitar desde la medición estadística hacia la comprensión semántica profunda.

CAPÍTULO VII: CONCLUSIONES Y TRABAJO FUTURO

7.1 Principales conclusiones

El desarrollo de este trabajo de título ha permitido evaluar el desempeño de diversos métodos de Predicción del Rendimiento de Consultas (QPP) en escenarios de recuperación Ad-hoc, abarcando desde enfoques estadísticos básicos hasta estrategias de estimación de utilidad. La evidencia experimental, obtenida a través de cinco conjuntos de datos heterogéneos, permite establecer conclusiones fundamentales sobre la aplicabilidad de estas técnicas.

En primer lugar, se concluye la superioridad de los métodos *post-retrieval* frente a los enfoques *pre-retrieval*, en donde los resultados demuestran que la información contenida en la lista de documentos recuperados, específicamente la dispersión de sus puntuaciones, constituye una señal predictiva más robusta que las estadísticas lingüísticas de la consulta aislada. Mientras métodos *post-retrieval* como *NQC* y *UEF-NQC* lograron correlaciones consistentes, el método *IDF* (*pre-retrieval*) mostró un comportamiento prácticamente aleatorio, confirmando su ineficacia como predictor de rendimiento bajo este contexto.

En segundo lugar, se ha identificado al método *UEF-NQC* como el predictor más estable a nivel transversal. La integración del marco *Utility Estimation Framework* permitió mejorar la capacidad predictiva base de *NQC* en colecciones con vocabularios dispersos, por lo que se establece que *UEF-NQC* constituye la línea base experimental recomendada para futuras investigaciones en el área.

Así mismo, un hallazgo crítico es la dependencia del dominio y la existencia de una “barrera semántica” en los métodos estadísticos. La efectividad de los predictores está condicionada por la homogeneidad del *corpus*: el método *Clarity*, por ejemplo, resultó eficaz en dominios técnicos (*TREC-COVID*), pero ineficaz en colecciones dispersas (*Cranfield*). Más aún, el bajo rendimiento generalizado en el conjunto de datos *CAR* evidencia que los métodos actuales poseen un techo técnico, mostrándose incapaces de modelar relaciones de relevancia semántica compleja que no dependen de la coincidencia léxica.

Adicionalmente, se observó que el preprocesado de datos (mediante algoritmos de *stemming* y eliminación de *stopwords*) juega un rol no trivial en la estabilidad de los predictores, por lo que su correcta implementación resultó fundamental para reducir el ruido en métodos sensibles a la frecuencia de términos como *SCQ*, aunque su impacto fue marginal en métodos basados en divergencia, lo que sugiere que la limpieza de datos debe ajustarse según la naturaleza algorítmica del predictor seleccionado.

Finalmente, la evidencia experimental demuestra que los métodos QPP clásicos presentan una capacidad predictiva significativa pero acotada en el contexto de búsquedas Ad-hoc. Los resultados obtenidos (con techos de $\tau \approx 0,42$) se alinean con los criterios establecidos en [10], quienes postulan que correlaciones medias ($\tau \geq 0,4$) poseen utilidad práctica para

aplicaciones de recuperación, aunque aún distan del umbral ideal de $\tau \geq 0,7$ necesario para una confiabilidad total. Esto valida la calidad de la implementación al replicar exitosamente los resultados de referencia de estudios recientes, confirmando que las herramientas evaluadas ofrecen una capacidad real para estimar la dificultad de las consultas, aunque sujetas a las limitaciones inherentes de los enfoques no neuronales.

7.2 Cumplimiento de los objetivos específicos

Con respecto al objetivo general del trabajo de título, este se considera cumplido satisfactoriamente, ya que se logró evaluar comparativamente seis métodos QPP en un entorno controlado, estableciendo diferencias claras de rendimiento y generando una línea base técnica para la disciplina. A continuación, se detalla el cumplimiento de cada objetivo específico:

- a) Revisar la literatura sobre métodos de QPP en búsquedas Ad-hoc sin el uso de inteligencia artificial:** Este objetivo se cumplió mediante la revisión exhaustiva presentada en los *Capítulos II y III*, donde se documentaron y analizaron los fundamentos teóricos de métodos *pre-retrieval* (*IDF*, *SCQ*) y *post-retrieval* (*NQC*, *Clarity*, *WIG*, *UEF*), priorizando aquellos enfoques clásicos que no dependen de modelos neuronales.
- b) Comparar los resultados de los métodos QPP con estudios previos:** Se logró mediante el análisis cuantitativo del *Capítulo VI*, donde se utilizaron métricas de correlación estandarizadas (*Kendall*, *Pearson*) para contrastar los resultados obtenidos. En particular, los valores alcanzados, por ejemplo, del *dataset Antique*, se alinearon con los benchmarks reportados recientemente en [4], validando la consistencia de la evaluación.
- c) Implementar métodos QPP en búsquedas Ad-hoc sin inteligencia artificial para su evaluación utilizando métricas estandarizadas:** La implementación fue realizada exitosamente utilizando un entorno contenerizado en *Docker* y la biblioteca *PyTerrier*, asegurando la reproducibilidad técnica descrita en el *Capítulo V*, lo que permitió la ejecución controlada de los seis métodos seleccionados sobre los cinco conjuntos de datos definidos.
- d) Evaluar los resultados obtenidos de los métodos QPP implementados, determinando su efectividad en función de los resultados descritos en el estado del arte:** La evaluación se completó mediante el análisis de correlación entre las predicciones de los métodos y las métricas de recuperación, lo que permitió identificar las fortalezas de los métodos *post-retrieval* (basados en dispersión de puntajes) y las limitaciones estructurales de los métodos *pre-retrieval* (basados únicamente en frecuencia de términos).
- e) Analizar y documentar el rendimiento de los métodos QPP implementados para establecer una línea base para futuras comparaciones con nuevos enfoques:** Los resultados fueron documentados detalladamente en el *Capítulo VI*, estableciendo a *UEF-NQC* como la configuración de referencia, por lo que esta documentación

proporciona un punto de comparación robusto para futuras investigaciones que deseen contrastar nuevos enfoques, incluidos aquellos basados en inteligencia artificial.

7.3 Síntesis de hallazgos

Del análisis comparativo se desprenden tres principales hallazgos que sintetizan el comportamiento de los predictores evaluados frente a la variabilidad de los datos:

- **Degradación de métodos pre-retrieval en índices masivos:** Se observó que los predictores basados en estadísticas globales como *SCQ*, aunque eficaces en colecciones acotadas, reducen drásticamente su rendimiento en índices de gran escala como *MS MARCO*. Esto sugiere que las métricas *pre-retrieval* pierden capacidad discriminativa al saturarse el espacio semántico, aumentando la probabilidad de colisiones de términos no informativos.
- **Riesgo de ruido en la expansión post-retrieval (UEF):** Aunque el marco *UEF* potenció el rendimiento en la mayoría de los escenarios, en *MS MARCO* no aportó ganancia sobre su base *NQC*, lo que indica que, en colecciones altamente heterogéneas o cuando la recuperación inicial es imprecisa, la expansión ciega de consultas propia de ciertos métodos *post-retrieval* puede introducir ruido documental (*query drift*), neutralizando los beneficios teóricos de la re-estimación de utilidad.
- **Limitación semántica estructural:** El rendimiento uniformemente bajo en el *dataset CAR* evidencia una “barrera semántica”, en donde los resultados confirman que tanto los métodos *pre-retrieval* como *post-retrieval* clásicos presentan dificultades inherentes para capturar la relevancia conceptual profunda requerida en tareas de respuestas complejas, donde la pertinencia no depende exclusivamente de la recurrencia léxica, sino de relaciones semánticas que estos predictores no logran modelar.

7.4 Alcance del trabajo de título

Es importante delimitar que el presente estudio se centró exclusivamente en métodos de predicción no supervisados y que no utilizan arquitecturas de Inteligencia Artificial moderna. La evaluación se realizó utilizando BM25 como único modelo de recuperación base, por lo que los resultados están condicionados a las características de este modelo léxico.

Asimismo, aunque se utilizaron cinco conjuntos de datos representativos, el análisis se limitó a documentos en idioma inglés y a tareas de recuperación de pasajes, excluyendo otros tipos de tareas como búsqueda de entidades o sistemas de recomendación. Estas delimitaciones fueron necesarias para garantizar la viabilidad computacional, dado que la complejidad inherente a la implementación de métodos *post-retrieval* demandó una profundidad de análisis y recursos de procesamiento que acotaron el alcance experimental.

7.5 Trabajo futuro

A partir de los resultados obtenidos y de las limitaciones identificadas, se proponen las siguientes líneas de investigación para dar continuidad a este trabajo:

- **Integración de Inteligencia Artificial:** Dado el techo de rendimiento observado en tareas semánticas, como en *CAR*, el siguiente paso es incorporar Modelos de Lenguaje Grandes (LLMs) para evaluar la coherencia semántica entre la consulta y los documentos, superando la dependencia léxica de métodos como *Clarity*.
- **Optimización de Parámetros y Configuraciones:** Con el objetivo de mejorar significativamente la correlación con las métricas de rendimiento, se recomienda realizar estudios detallados sobre la influencia de diversos parámetros en los métodos QPP.
- **Estudios de Caso en Dominios Específicos:** Se sugiere aplicar y evaluar los métodos QPP en dominios especializados como medicina, derecho, e-commerce u otros, donde las características particulares de las consultas y documentos podrían influir de manera distinta en el rendimiento de los predictores.
- **Métodos Híbridos en Cascada:** Considerando el compromiso entre costo y efectividad, se sugiere investigar arquitecturas que utilicen métodos ligeros (como SCQ), para filtrar consultas sencillas, reservando el costo computacional de métodos robustos (como UEF-NQC o modelos neuronales) solo para aquellas consultas clasificadas preliminarmente como difíciles.
- **Evaluación sobre Modelos Neuronales:** Sería relevante replicar este protocolo experimental utilizando sistemas de recuperación neuronal como base en lugar de BM25, para determinar si los predictores QPP clásicos mantienen su efectividad cuando la lista de resultados es generada por modelos densos.

De esta forma, este trabajo de título establece una base sólida para la evaluación comparativa de métodos QPP en búsquedas Ad-hoc, al tiempo que abre múltiples avenidas para investigaciones futuras que pueden profundizar y ampliar conocimientos en este campo dinámico y en constante evolución.

REFERENCIAS BIBLIOGRÁFICAS

- [1] MOTHE, Josiane, Léa LAPORTE y Adrian-Gabriel CHIFU. Predicting Query Difficulty in IR: Impact of Difficulty Definition. En: *2019 11th International Conference on Knowledge and Systems Engineering (KSE)* [en línea]. 2019, p. 1–6. ISSN 2164-2508. Disponible en: doi:10.1109/KSE.2019.8919433
- [2] THOMAS, Paul, Falk SCHOLER, Peter BAILEY y Alistair MOFFAT. Tasks, Queries, and Rankers in Pre-Retrieval Performance Prediction. En: *Proceedings of the 22nd Australasian Document Computing Symposium* [en línea]. Brisbane, QLD, Australia: Association for Computing Machinery, 2017. ADCS '17. ISBN 9781450363914. Disponible en: doi:10.1145/3166072.3166079
- [3] LEWIS, Patrick, Ethan PEREZ, Aleksandra PIKTUS, Fabio PETRONI, Vladimir KARPUKHIN, Naman GOYAL, Heinrich KÜTTLER, Mike LEWIS, Wen-tau YIH, Tim ROCKTÄSCHEL y OTHERS. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in neural information processing systems*. 2020, **33**, 9459–9474.
- [4] ZENDEL, Oleg, Maik FRÖBE y Guglielmo FAGGIOLI. QPPTK@ TIREx: Simplified Query Performance Prediction for Ad-Hoc Retrieval Experiments. *WOWS 2024*. 2024, 50.
- [5] CARMEL, David y Elad YOM-TOV. Estimating the query difficulty for information retrieval. En: *Proceedings of the 33rd International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Geneva, Switzerland: Association for Computing Machinery, 2010, p. 911. SIGIR '10. ISBN 9781450301534. Disponible en: doi:10.1145/1835449.1835683
- [6] CRONEN-TOWNSEND, Steve, Yun ZHOU y W. Bruce CROFT. Predicting query performance. En: *Proceedings of the 25th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Tampere, Finland: Association for Computing Machinery, 2002, p. 299–306. SIGIR '02. ISBN 1581135610. Disponible en: doi:10.1145/564376.564429
- [7] KINNEY, Kenneth A., Scott B. HUFFMAN y Juting ZHAI. How evaluator domain expertise affects search result relevance judgments. En: *Proceedings of the 17th ACM Conference on Information and Knowledge Management* [en línea]. Napa Valley, California, USA: Association for Computing Machinery, 2008, p. 591–598. CIKM '08. ISBN 9781595939913. Disponible en: doi:10.1145/1458082.1458160
- [8] HAUFF, Claudia, Leif AZZOPARDI y Djoerd HIEMSTRA. The Combination and Evaluation of Query Performance Prediction Methods. En: Mohand BOUGHANEM, Catherine BERRUT, Josiane MOTHE y Chantal SOULE-DUPUY, eds. *Advances in Information Retrieval*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2009, p. 301–312. ISBN 978-3-642-00958-7.
- [9] MENG, Chuan, Negar ARABZADEH, Mohammad ALIANNEJADI y Maarten de RIJKE. Query Performance Prediction: From Ad-hoc to Conversational Search. En: *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Taipei, Taiwan: Association for Computing Machinery, 2023, p. 2583–2593. SIGIR '23. ISBN 9781450394086. Disponible en: doi:10.1145/3539618.3591919
- [10] HAUFF, Claudia, Leif AZZOPARDI, Djoerd HIEMSTRA y Franciska de JONG. Query Performance Prediction: Evaluation Contrasted with Effectiveness. En: Cathal GURRIN, Yulan HE, Gabriella KAZAI, Udo KRUSCHWITZ, Suzanne LITTLE, Thomas ROELLEKE, Stefan RÜGER y Keith van RIJSBERGEN, eds.

Advances in Information Retrieval. Berlin, Heidelberg: Springer Berlin Heidelberg, 2010, p. 204–216. ISBN 978-3-642-12275-0.


- [11] VOORHEES, E.M. The Sixth Text REtrieval Conference (TREC-6). *Information Processing & Management* [en línea]. 2000, **36**(1), 1–2. ISSN 0306-4573. Disponible en: doi:[https://doi.org/10.1016/S0306-4573\(99\)00042-4](https://doi.org/10.1016/S0306-4573(99)00042-4)
- [12] LAVRENKO, Victor y W. Bruce CROFT. Relevance based language models. En: *Proceedings of the 24th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. New Orleans, Louisiana, USA: Association for Computing Machinery, 2001, p. 120–127. SIGIR '01. ISBN 1581133316. Disponible en: doi:[10.1145/383952.383972](https://doi.org/10.1145/383952.383972)
- [13] TAO, Yongquan y Shengli WU. Query Performance Prediction By Considering Score Magnitude and Variance Together. En: *Proceedings of the 23rd ACM International Conference on Conference on Information and Knowledge Management* [en línea]. Shanghai, China: Association for Computing Machinery, 2014, p. 1891–1894. CIKM '14. ISBN 9781450325981. Disponible en: doi:[10.1145/2661829.2661906](https://doi.org/10.1145/2661829.2661906)
- [14] ZHOU, Yun y W. Bruce CROFT. Query performance prediction in web search environments. En: *Proceedings of the 30th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Amsterdam, The Netherlands: Association for Computing Machinery, 2007, p. 543–550. SIGIR '07. ISBN 9781595935977. Disponible en: doi:[10.1145/1277741.1277835](https://doi.org/10.1145/1277741.1277835)
- [15] ZHAO, Ying, Falk SCHOLER y Yohannes TSEGAY. Effective Pre-retrieval Query Performance Prediction Using Similarity and Variability Evidence. En: Craig MACDONALD, Iadh OUNIS, Vassilis PLACHOURAS, Ian RUTHVEN y Ryen W. WHITE, eds. *Advances in Information Retrieval*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008, p. 52–64. ISBN 978-3-540-78646-7.
- [16] ROBERTSON, Stephen. Understanding inverse document frequency: on theoretical arguments for IDF. *Journal of Documentation* [en línea]. 2004, **60**(5), 503–520. ISSN 0022-0418. Disponible en: doi:[10.1108/00220410410560582](https://doi.org/10.1108/00220410410560582)
- [17] SHTOK, Anna, Oren KURLAND, David CARMEL, Fiana RAIBER y Gad MARKOVITS. Predicting Query Performance by Query-Drift Estimation. *ACM Trans. Inf. Syst.* [en línea]. 2012, **30**(2). ISSN 1046-8188. Disponible en: doi:[10.1145/2180868.2180873](https://doi.org/10.1145/2180868.2180873)
- [18] SHTOK, Anna, Oren KURLAND y David CARMEL. Using statistical decision theory and relevance models for query-performance prediction. En: *Proceedings of the 33rd International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Geneva, Switzerland: Association for Computing Machinery, 2010, p. 259–266. SIGIR '10. ISBN 9781450301534. Disponible en: doi:[10.1145/1835449.1835494](https://doi.org/10.1145/1835449.1835494)
- [19] GANGULY, Debasis y Emine YILMAZ. Query-specific Variable Depth Pooling via Query Performance Prediction. En: *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Taipei, Taiwan: Association for Computing Machinery, 2023, p. 2303–2307. SIGIR '23. ISBN 9781450394086. Disponible en: doi:[10.1145/3539618.3592046](https://doi.org/10.1145/3539618.3592046)
- [20] RADLINSKI, Filip y Nick CRASWELL. Comparing the sensitivity of information retrieval metrics. En: *Proceedings of the 33rd International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Geneva, Switzerland: Association for Computing Machinery, 2010, p. 667–674. SIGIR '10. ISBN 9781450301534. Disponible en: doi:[10.1145/1835449.1835560](https://doi.org/10.1145/1835449.1835560)

- [21] FAGGIOLI, Guglielmo, Oleg ZENDEL, J. Shane CULPEPPER, Nicola FERRO y Falk SCHOLER. An Enhanced Evaluation Framework for Query Performance Prediction. En: Djoerd HIEMSTRA, Marie-Francine MOENS, Josiane MOTHE, Raffaele PEREGO, Martin POTTHAST y Fabrizio SEBASTIANI, eds. *Advances in Information Retrieval*. Cham: Springer International Publishing, 2021, p. 115–129. ISBN 978-3-030-72113-8.
- [22] FORTHOFER, Ron N. y Robert G. LEHNEN. Rank Correlation Methods. En: *Public Program Analysis: A New Categorical Data Approach* [en línea]. Boston, MA: Springer US, 1981, p. 146–163. ISBN 978-1-4684-6683-6. Disponible en: doi:10.1007/978-1-4684-6683-6_9
- [23] MACDONALD, Craig, Nicola TONELLOTO, Sean MACAVANEY y Iadh OUNIS. PyTerrier: Declarative Experimentation in Python from BM25 to Dense Retrieval. En: *Proceedings of the 30th ACM International Conference on Information & Knowledge Management* [en línea]. Virtual Event, Queensland, Australia: Association for Computing Machinery, 2021, p. 4526–4533. CIKM '21. ISBN 9781450384469. Disponible en: doi:10.1145/3459637.3482013
- [24] WHISSELL, John S. y Charles L. A. CLARKE. Improving document clustering using Okapi BM25 feature weighting. *Inf. Retr.* [en línea]. 2011, **14**(5), 466–487. ISSN 1386-4564. Disponible en: doi:10.1007/s10791-011-9163-y
- [25] HASHEMI, Helia, Mohammad ALIANNEJADI, Hamed ZAMANI y W. Bruce CROFT. ANTIQUE: A Non-factoid Question Answering Benchmark. En: *Advances in Information Retrieval: 42nd European Conference on IR Research, ECIR 2020, Lisbon, Portugal, April 14–17, 2020, Proceedings, Part II* [en línea]. Lisbon, Portugal: Springer-Verlag, 2020, p. 166–173. ISBN 978-3-030-45441-8. Disponible en: doi:10.1007/978-3-030-45442-5_21
- [26] VOORHEES, Ellen, Tasmee ALAM, Steven BEDRICK, Dina DEMNER-FUSHMAN, William R. HERSH, Kyle LO, Kirk ROBERTS, Ian SOBOROFF y Lucy Lu WANG. TREC-COVID: constructing a pandemic information retrieval test collection. *SIGIR Forum* [en línea]. 2021, **54**(1). ISSN 0163-5840. Disponible en: doi:10.1145/3451964.3451965
- [27] NGUYEN, Tri, Mir ROSENBERG, Xia SONG, Jianfeng GAO, Saurabh TIWARY, Rangan MAJUMDER y Li DENG. MS MARCO: A Human Generated MACHine Reading COMprehension Dataset [en línea]. 2016. Disponible en: <https://www.microsoft.com/en-us/research/publication/ms-marco-human-generated-machine-reading-comprehension-dataset/>
- [28] NANNI, Federico, Bhaskar MITRA, Matt MAGNUSSON y Laura DIETZ. Benchmark for Complex Answer Retrieval. En: *Proceedings of the ACM SIGIR International Conference on Theory of Information Retrieval* [en línea]. Amsterdam, The Netherlands: Association for Computing Machinery, 2017, p. 293–296. ICTIR '17. ISBN 9781450344906. Disponible en: doi:10.1145/3121050.3121099
- [29] MANNING, Christopher D. *Introduction to information retrieval*. B.m.: Syngress Publishing, 2008.
- [30] LIPANI, Aldo, Thomas ROELLEKE, Mihai LUPU y Allan HANBURY. A systematic approach to normalization in probabilistic models. *Information Retrieval Journal*. 2018, **21**(6), 565–596.
- [31] CRAMER, Duncan y Dennis Laurence HOWITT. *The Sage dictionary of statistics: a practical resource for students in the social sciences*. 2004.
- [32] CHIFU, Adrian-Gabriel, Sébastien DÉJEAN, Stefano MIZZARO y Josiane MOTHE. Human-based query difficulty prediction. En: *Advances in Information*


Retrieval: 39th European Conference on IR Research, ECIR 2017, Aberdeen, UK, April 8-13, 2017, Proceedings 39. 2017, p. 343–356.

- [33] HAUFF, Claudia, Diane KELLY y Leif AZZOPARDI. A comparison of user and system query performance predictions. En: *Proceedings of the 19th ACM International Conference on Information and Knowledge Management* [en línea]. Toronto, ON, Canada: Association for Computing Machinery, 2010, p. 979–988. CIKM '10. ISBN 9781450300995. Disponible en: doi:10.1145/1871437.1871562


ANEXOS




Anexo 7.1: Matriz de correlación horizontal Kendall.




Anexo 7.2: Matriz de correlación horizontal Spearman.




Anexo 7.3: Matriz de correlación horizontal Pearson.




Anexo 7.4: Gráficos de cajas QPP Kendall.




Anexo 7.5: Gráficos de cajas QPP Spearman.



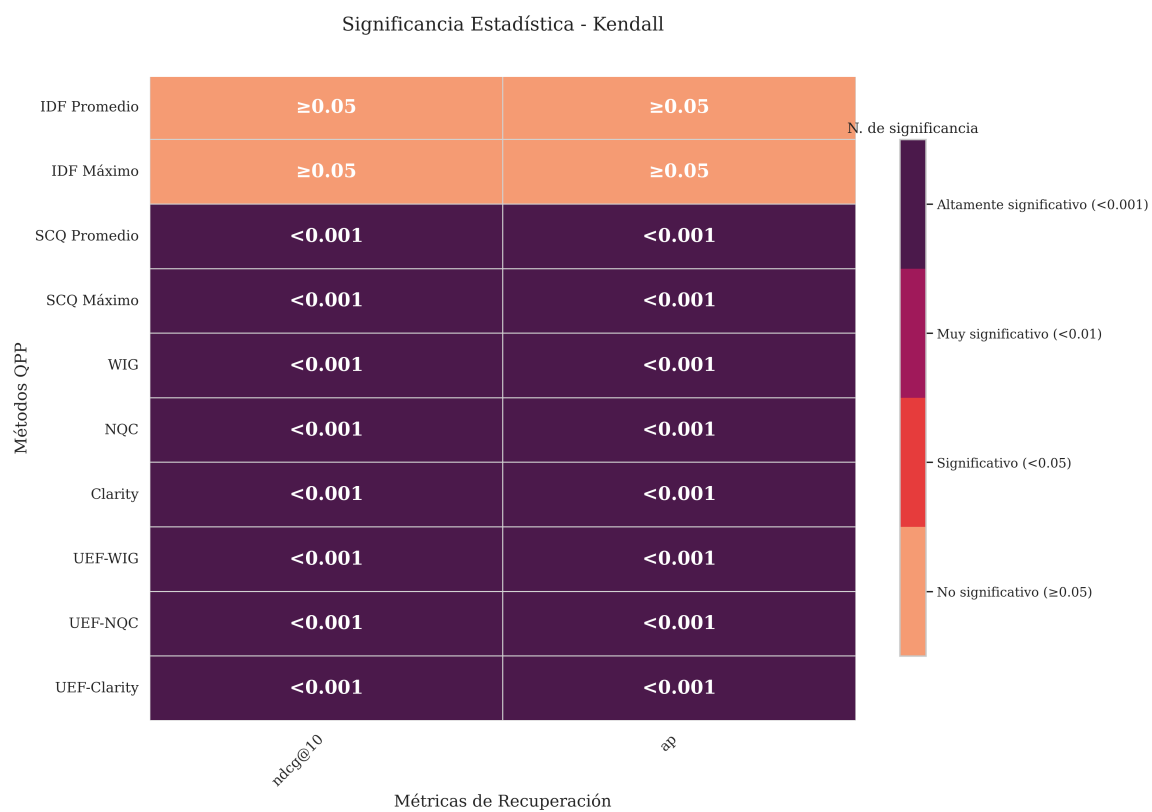
Anexo 7.6: Gráficos de cajas QPP Pearson.




Anexo 7.7: Gráficos de dispersión QPP AP Kendall.




Anexo 7.8: Gráficos de dispersión QPP nDCG@10 Kendall.



Anexo 7.9: Valores p QPP Correlación Kendall.



Anexo 7.10: Valores p QPP Correlación Spearman.



Anexo 7.11: Valores p QPP Correlación Pearson.