



FACULTAD DE INGENIERÍA Y ARQUITECTURA

**EVALUACIÓN COMPARATIVA DE MÉTODOS QUERY
PERFORMANCE PREDICTION (QPP) PARA BÚSQUEDAS AD-HOC
UTILIZANDO MÉTRICAS DE CORRELACIÓN.**

Trabajo de memoria para obtener el título de:

INGENIERO CIVIL EN COMPUTACIÓN E INFORMÁTICA

**Alumno: José Emmanuel Raúl Sandoval Vega.
Luis Emersson Brain Fredes.**

Profesor Patrocinante: Dr. Mauricio Andrés Oyarzún Silva.

IQUIQUE - CHILE

2025

[Dedicatoria...]

AGRADECIMIENTOS

[Agradezco...]

ÍNDICE DE MATERIAS

CAPÍTULO I: INTRODUCCIÓN	1
1.1 Contexto del proyecto	1
1.2 Objetivo General	1
1.3 Objetivos Específicos	2
1.4 Estructura del trabajo de título	2
CAPÍTULO II: MARCO TEÓRICO	4
2.1 Sistemas de Recuperación de Información (IR)	4
2.1.1 Modelos de recuperación de información.	5
2.1.2 Componentes de un sistema de recuperación de información.	8
2.1.3 Consultas, tópicos y búsquedas Ad-hoc	11
2.2 Predicción de Rendimiento de Consultas (QPP)	13
2.2.1 Dificultad y rendimiento de las consultas	13
2.2.2 Soluciones al Problema de la Dificultad de las Consultas	17
2.2.3 Taxonomías en QPP	19
2.2.3.1 Predictores <i>pre-retrieval</i>	20
2.2.3.2 Predictores <i>post-retrieval</i>	20
2.2.4 Aplicaciones de QPP en IR	21
2.2.5 Supuestos, limitaciones y amenazas a la validez	23
2.3 Métricas de Evaluación de Rendimiento y Correlación	24
2.3.1 Juicios de relevancia (<i>Qrels</i>)	24
2.3.2 Métricas de evaluación clásicas en IR	25
2.3.3 Protocolos de evaluación de QPP y diseño experimental	27
2.3.4 Métricas de correlación para evaluar métodos QPP	28
CAPÍTULO III: TRABAJOS RELACIONADOS	31
3.1 Métodos de Predicción de Rendimiento de Consultas (QPP)	31
3.1.1 IDF (Frecuencia Inversa de Documentos)	31
3.1.2 SCQ (Similitud entre consulta y colección)	32
3.1.3 NQC (Normalized Query Commitment)	33
3.1.4 Clarity Score (CS)	34
3.1.5 WIG (Weighted Information Gain)	35
3.1.6 UEF (Utility Estimation Framework)	36
3.2 Estudios comparativos similares	37
3.2.1 QPPTK en TIREx	38
3.2.2 An Enhanced Evaluation Framework for Query Performance Prediction (2021)	39
CAPÍTULO IV: DISEÑO DE LA EVALUACIÓN COMPARATIVA	41
4.1 Protocolo de evaluación experimental	41
4.1.1 Paradigma de evaluación de métodos QPP	42

4.1.2	Flujo del sistema	43
4.1.3	Configuración técnica	44
4.2	Selección de conjuntos de datos	50
4.2.1	Criterios de inclusión	50
4.2.2	Justificación de los conjuntos de datos seleccionados	52
4.3	Selección de métodos de QPP	58
4.3.1	Criterios de selección	58
4.3.2	Métodos seleccionados	60
4.4	Relación entre diseño experimental y objetivos	62
4.4.1	Relación con el objetivo general	63
4.4.2	Alineación con los Objetivos Específicos	64
CAPÍTULO V: IMPLEMENTACIÓN		66
5.1	Configuración del entorno experimental	67
5.1.1	Docker y dependencias	68
5.1.2	Integración de conjuntos de datos	69
5.1.3	Indexación y consultas	70
5.2	Implementación de métodos QPP	71
5.2.1	Métodos pre-retrieval	72
5.2.2	Métodos post-retrieval	72
5.3	Implementación de la evaluación	73
5.3.1	Cálculo de correlaciones	73
5.3.2	Visualización de resultados	73
5.4	Pruebas de validación	74
5.4.1	Estructura de las pruebas	74
5.4.2	Metodología de validación	75
5.4.3	Resultados de la validación	75
CAPÍTULO VI: ANÁLISIS DE RESULTADOS		77
6.1	Resultados obtenidos en conjuntos de datos	77
6.2	Comparación de métodos QPP	80
6.3	Análisis comparativo entre datasets	88
6.4	Discusión de los resultados	89
6.4.1	Importancia de las correlaciones observadas	89
6.4.2	Rendimiento de métodos pre-retrieval	90
6.4.3	Rendimiento de métodos post-retrieval	90
6.4.4	Complejidad Inherente de la Tarea	91
6.4.5	Implicaciones sobre una línea base experimental	91
CAPÍTULO VII: CONCLUSIONES Y TRABAJO FUTURO		94
7.1	Principales conclusiones	94

7.2 Recomendaciones para investigaciones futuras 94

7.3 Trabajo Futuro 95

ÍNDICE DE TABLAS

Tabla 2.1: Modelos de recuperación de información y su propósito dentro de un sistema IR. 7

Tabla 2.2: Recursos y métricas comunes para la evaluación de sistemas IR y de métodos de predicción de rendimiento. 10

Tabla 2.3: Formas de definir la dificultad de una consulta. 16

Tabla 2.4: Factores y señales típicas en predictores post-retrieval 21

Tabla 4.1: Parámetros principales de BM25 45

Tabla 4.2: Parámetros principales de configuración 46

Tabla 4.3: Configuración de métricas por dataset 48

Tabla 4.4: Criterios de inclusión de datasets 51

Tabla 4.5: Tabla de datasets y sus criterios de inclusión 53

Tabla 4.6: Metadatos técnicos de los datasets seleccionados 54

Tabla 4.7: Criterios de selección de métodos de QPP 58

Tabla 4.8: Métodos de QPP seleccionados 61

Tabla 4.9: Relación entre diseño experimental y objetivos 63

Tabla 4.10: Relación entre diseño experimental y objetivos 65

Tabla 5.1: Componentes principales del sistema implementado 66

Tabla 5.2: Stack tecnológico principal 67

Tabla 5.3: Configuración del entorno experimental 67

Tabla 5.4: Componentes principales del Dockerfile 69

Tabla 5.5: Tipos de visualizaciones implementadas 74

Tabla 5.6: Módulos principales de pruebas unitarias 75

Tabla 5.7: Resultados de ejecución por componente 76

Tabla 6.1: Muestra de términos Porter vs Snowball Stemmers 81

Tabla 6.2: Niveles de significancia de las correlaciones en tau de Kendall 84

Tabla 6.3: Resumen de correlaciones de Kendall (τ) para nDCG@10 en cada dataset . . 88

Tabla 6.4: Correlaciones (P- ρ , S- ρ y K- τ) entre métodos QPP y nDCG@10 en los distintos datasets evaluados 93

ÍNDICE DE FIGURAS

Figura 2.1: Diagrama de Venn del Modelo Booleano. 5

Figura 2.2: Representación geométrica del Modelo Vectorial. 6

Figura 2.3: Componentes estructurales del modelo BM25. 7

Figura 2.4: Componentes fundamentales de un sistema de Recuperación de Información. 9

Figura 2.5: Flujo de un sistema de recuperación basado en Modelos de Relevancia. 18

Figura 4.1: Diagrama de componentes del entorno de evaluación 43

Figura 5.1: Dockerfile para la configuración del entorno experimental 68

Figura 5.2: Configuración de formato de dataset 70

Figura 5.3: Código de implementación del factory de métodos QPP 71

Figura 5.4: Diagrama de la capa de métodos QPP 71

Figura 5.5: Implementación del método WIG 72

Figura 6.1: Diagrama de flujo del análisis de resultados 77

Figura 6.2: Diagrama de caja para las métricas nDCG y AP 78

Figura 6.3: Media de las métricas nDCG y AP 79

Figura 6.4: Histogramas de las métricas nDCG y AP 79

Figura 6.5: Gráfico de dispersión de nDCG@10 vs AP 80

Figura 6.6: Correlación de los métodos QPP - tau de Kendall 81

Figura 6.7: Correlación de los métodos QPP - tau de Kendall 82

Figura 6.8: Diagrama de caja de correlaciones métodos QPP vs nDCG@10 en tau de Kendall 83

Figura 6.9: Gráfico de dispersión de nDCG@10 vs NQC 85

Figura 6.10: Gráfico de dispersión de nDCG@10 vs UEF-NQC - tau de Kendall 86

Figura 6.11: Gráficos de dispersión de nDCG@10 vs IDF 87

NOMENCLATURA

IR (Information Retrieval): Campo de estudio que se enfoca en la recuperación de información relevante a partir de grandes colecciones de datos.

QPP (Query Performance Prediction): Técnicas y métodos utilizados para predecir el rendimiento de una consulta en sistemas de recuperación de información.

BM25: Modelo de recuperación de información basado en la frecuencia de términos, ampliamente utilizado en sistemas de búsqueda.

AP (Average Precision): Métrica de evaluación que mide la precisión promedio de los resultados recuperados, considerando la posición de los documentos relevantes.

nDCG (Normalized Discounted Cumulative Gain): Métrica de evaluación que mide la calidad del ranking de documentos recuperados, considerando la relevancia y la posición de los documentos.

Qrels (Query Relevance Judgments): Juicios de relevancia que indican la pertinencia de los documentos recuperados para una consulta específica.

Stemming: Proceso de reducir palabras a su raíz o forma base, utilizado en el preprocesamiento de texto para mejorar la recuperación de información.

Stopwords: Palabras comunes que se eliminan durante el preprocesamiento de texto para mejorar la eficiencia de la recuperación de información.

Pre-retrieval QPP: Métodos de predicción de rendimiento de consultas basados en estadísticas del corpus antes de la recuperación de documentos.

Post-retrieval QPP: Métodos de predicción de rendimiento de consultas basados en la información obtenida después de recuperar documentos.

RESUMEN

En la actualidad, los sistemas de recuperación de información (IR) enfrentan el desafío de predecir la calidad de los resultados de búsquedas, especialmente en consultas ad-hoc, donde la eficacia de los métodos de Query Performance Prediction (QPP) varía significativamente según el dominio y el tipo de consulta. Esta variabilidad puede derivar en respuestas subóptimas y un uso ineficiente de recursos, lo que subraya la necesidad de una evaluación robusta y reproducible de los métodos QPP más utilizados. Es así como, este proyecto, se enfoca en implementar y evaluar métodos QPP no basados en inteligencia artificial (IA) para búsquedas ad-hoc, utilizando métricas de correlación estandarizadas como Tau de Kendall, Spearman y Pearson, con el objetivo de establecer una línea base para futuras investigaciones y facilitar el desarrollo de nuevos enfoques.

De esta forma, el objetivo principal del proyecto es evaluar comparativamente métodos de QPP para búsquedas ad-hoc, identificando sus fortalezas y debilidades en diferentes contextos. Para ello, fueron seleccionados seis métodos QPP ampliamente reconocidos en la literatura: IDF (Inverse Document Frequency), SCQ (Similarity Between a Query and a Collection), NQC (Normalized Query Commitment), Clarity Score (CS), WIG (Weighted Information Gain) y UEF (Utility Estimation Framework), los cuales fueron implementados y evaluados en cinco datasets representativos (Cranfield, MS MARCO Passage, Antique/test, BEIR-TREC-COVID y CAR Judged), que abarcan una amplia gama de dominios y tipos de consultas, asegurando la generalización de los resultados.

Es así como el análisis de los resultados fue centrado en la comparación de las correlaciones entre los puntajes de los métodos QPP y las métricas de rendimiento del sistema de recuperación, en donde se revela que los métodos post-retrieval presentan las correlaciones más altas, superando significativamente a los métodos pre-retrieval como IDF, que presenta correlaciones cercanas a cero, adicional a esto, se observa que la implementación de UEF mejora considerablemente el rendimiento de los métodos post-retrieval.

Finalmente, los resultados del proyecto establecen una línea base sólida para la evaluación de métodos QPP en búsquedas ad-hoc, sin embargo, la complejidad propia de la tarea de predicción del rendimiento de consultas sigue siendo un desafío, lo que sugiere la necesidad de desarrollar métodos híbridos que combinen las fortalezas de diferentes enfoques.

CAPÍTULO I: INTRODUCCIÓN

1.1 Contexto del proyecto

La predicción del rendimiento de consultas (QPP) ha emergido como una herramienta prometedora en los sistemas de recuperación de información (IR). La capacidad de predecir la calidad de los resultados de búsqueda antes de la ejecución de la consulta permite tanto optimizar los recursos como al mismo tiempo mejorar la experiencia de los usuarios. No obstante, la eficacia de los métodos QPP varía significativamente según el dominio, el tipo de consulta, e incluso los modelos de recuperación utilizados, algo que se evidencia especialmente en búsquedas ad-hoc. Esta variabilidad subraya la necesidad de evaluaciones robustas y reproducibles, que permitan comparar y contrastar diferentes enfoques de tal forma que se pueda establecer una línea base clara para futuras investigaciones.

La complejidad del problema de QPP se magnifica por la diversidad de escenarios de aplicación y la heterogeneidad de los datos en diferentes dominios. Los sistemas de recuperación de información modernos deben manejar consultas que varían desde preguntas simples hasta construcciones complejas en lenguaje natural, cada una con sus propios desafíos de predicción de rendimiento. Además, la calidad de los resultados puede verse afectada por factores como la ambigüedad del lenguaje, la especificidad de la consulta, y la cobertura del tema en la colección de documentos.

La motivación sobre el campo de Query Performance Prediction (QPP) ha aumentado en los últimos años debido a los avances en el campo de la inteligencia artificial, específicamente en el área del procesamiento de lenguaje natural (NLP), donde nuevos modelos de lenguaje como BERT, GPT entre otros han demostrado ser muy efectivos en tareas de recuperación de información mediante el uso de técnicas especializadas como RAG (Retrieval augmented generation). Bajo esta premisa se abre un nuevo paradigma de métodos QPP basados en consultas conversacionales, donde la interacción entre el usuario y el sistema de recuperación de información se da de forma más natural.

Este trabajo busca establecer una línea base sobre los enfoques tradicionales para asegurar un avance en las futuras investigaciones de métodos QPP, mediante la implementación de un benchmark abierto y reproducible, disponible en GitHub.¹

1.2 Objetivo General

Evaluar comparativamente métodos de Query Performance Prediction (QPP) para búsquedas Ad-hoc utilizando métricas de correlación.

¹<https://github.com/emerssn/QPP-Benchmark>

1.3 Objetivos Específicos

1. Revisar la literatura sobre métodos de QPP en búsquedas ad-hoc sin el uso de inteligencia artificial.
2. Identificar y describir los principales métodos QPP utilizados en la actualidad.
3. Implementar y evaluar métodos QPP no basados en inteligencia artificial utilizando un conjunto de datos estandarizados y un marco de evaluación común.
4. Analizar y documentar el rendimiento de los métodos QPP implementados para establecer una línea base para futuras comparaciones.
5. Identificar fortalezas y debilidades de diferentes enfoques, proporcionando ideas para futuras investigaciones en métodos QPP.

1.4 Estructura del trabajo de título

El presente trabajo se compone de los siguientes siete capítulos:

Capítulo I: Introducción. Presenta el contexto y motivación del proyecto, junto con los objetivos general y específicos planteados para su realización. Se describe la importancia de la predicción del rendimiento de consultas (QPP) en sistemas de recuperación de información y la necesidad de una evaluación comparativa robusta.

Capítulo II: Marco Teórico. Proporciona el marco teórico necesario para comprender el trabajo, incluyendo conceptos fundamentales sobre sistemas de recuperación de información, predicción del rendimiento de consultas, métricas de evaluación y las herramientas utilizadas en el proyecto.

Capítulo III: Trabajos Relacionados. Revisa y analiza los principales métodos QPP desarrollados en la literatura, enfocándose en aquellos no basados en inteligencia artificial. Se examinan sus características, fortalezas y limitaciones, estableciendo el estado del arte en el campo.

Capítulo IV: Diseño de la Evaluación Comparativa. Define la metodología experimental, incluyendo la selección de métodos QPP, datasets, métricas de evaluación y el entorno experimental. Se detalla la configuración técnica y los procedimientos para garantizar la reproducibilidad de los experimentos.

Capítulo V: Implementación. Describe en detalle la implementación del sistema, la configuración del entorno experimental y los procesos de validación. Se incluyen aspectos técnicos sobre la integración de herramientas y la ejecución de experimentos.

Capítulo VI: Análisis de Resultados. Presenta y analiza los resultados obtenidos en la evaluación comparativa, examinando el rendimiento de cada método QPP en diferentes escenarios y datasets. Se discuten las implicaciones de los hallazgos y se comparan con resultados previos de la literatura.

Capítulo VII: Conclusiones y Trabajo Futuro. Resume los principales hallazgos y contribuciones del proyecto, estableciendo la línea base para futuras investigaciones en QPP. Se identifican limitaciones del estudio y se proponen direcciones para investigaciones futuras.

CAPÍTULO II: MARCO TEÓRICO

2.1 Sistemas de Recuperación de Información (IR)

El campo de la Recuperación de Información (IR) se centra en el estudio de métodos y sistemas que permiten localizar, dentro de grandes colecciones de documentos, aquellos que respondan de mejor forma a una necesidad informativa expresada por el usuario a través de una consulta o *query*. Este proceso implica identificar, clasificar y ordenar documentos según su grado de relevancia, apoyándose en modelos matemáticos y estadísticos que describen la relación entre las palabras de la consulta y el contenido del corpus. En la práctica, los sistemas de recuperación de información sustentan desde buscadores web hasta repositorios científicos y bases de datos digitales [1].

Cabe mencionar que, en el contexto de IR se entiende por documento cualquier unidad de información almacenada en el sistema, como puede ser un artículo científico, una página web o un informe técnico.

El conjunto completo de documentos disponibles para ser buscados se denomina corpus o colección. Por otra parte, la consulta o *query* corresponde a la expresión, generalmente breve, con la que el usuario comunica su necesidad de información, esta puede estar compuesta por palabras clave, frases o descripciones más amplias.

En los sistemas de evaluación, estas consultas se agrupan junto con sus documentos y juicios de relevancia en lo que se conoce como colecciones de referencia o *query logs*, las cuales permiten medir objetivamente el rendimiento de distintos modelos de recuperación. Así mismo, en este trabajo la relevancia se entenderá como el grado en que un documento satisface la necesidad informativa planteada en la consulta. De forma complementaria, se denomina ruido a los documentos que, aun siendo recuperados, no aportan información útil respecto al tema consultado. Por lo tanto, un sistema de recuperación efectivo es aquel que maximiza los documentos relevantes y minimiza el ruido, priorizando la calidad de los resultados.

El propósito fundamental de un sistema IR consiste en maximizar la relevancia de los resultados y minimizar el ruido, es decir, la cantidad de documentos menos pertinentes dentro del conjunto de datos recuperado. Esta función se ha vuelto crítica frente al crecimiento exponencial de la información que disponemos en formato digital, donde la eficiencia en las búsquedas y la organización del conocimiento determinan la calidad de la experiencia informativa. Además, como se menciona en [2], la efectividad de un sistema IR no depende únicamente del modelo de recuperación utilizado, sino también de la formulación de la consulta y de la naturaleza del corpus.

El desarrollo de la Recuperación de Información se remonta a mediados del siglo XX, con los primeros sistemas booleanos aplicados en bibliotecas digitales. Con el avance de la informática y el Internet, el volumen de datos textuales creció de forma exponencial,

impulsando el surgimiento de modelos estadísticos y probabilísticos capaces de manejar grandes colecciones de documentos.

Actualmente, el campo ha evolucionado hacia el uso de modelos híbridos, que integran principios clásicos de IR con técnicas de aprendizaje automático y modelos de lenguaje, permitiendo una comprensión más profunda de la intención del usuario [3].

En la actualidad, estos modelos se utilizan en motores de búsqueda, asistentes conversacionales y sistemas de recomendación, demostrando que la IR se ha convertido en un componente transversal dentro del procesamiento de la información digital.

En este sentido, la Recuperación de Información no solo constituye la base de los sistemas de búsqueda automatizada, sino también establece un punto de partida para la comprensión del comportamiento de las consultas, el análisis de su dificultad y la estimación del rendimiento, siendo estos los aspectos centrales para la presente investigación, cuyo objetivo se orienta en evaluar distintos métodos de predicción sobre el desempeño de consultas en modelos clásicos de recuperación de información.

2.1.1 Modelos de recuperación de información.

Los modelos de recuperación de información constituyen el núcleo de un sistema IR, ya que estos definen cómo se mide la relevancia entre una consulta y los documentos del corpus. Estos modelos, además de definir formalmente la manera en que los términos de una consulta se comparan con las representaciones internas de los documentos, permiten calcular una puntuación o ranking de relevancia. Es así que, a lo largo de los años, se han desarrollado tres enfoques principales: el modelo booleano, el modelo vectorial y el modelo probabilístico, cada uno con sus propias ventajas y limitaciones [2, 4].

El modelo booleano fue el primero en ser implementado y se basa en la lógica clásica de operadores como AND, OR y NOT. En este enfoque, un documento es recuperado únicamente si cumple con las condiciones lógicas impuestas por la consulta realizada, sin establecer grados intermedios de relevancia. Si bien, este modelo es eficiente en contextos cerrados debido a su simplicidad, carece de una capacidad para ordenar los resultados, lo que limita su utilidad en escenarios de búsquedas más complejos [1].




Figura 2.1: Diagrama de Venn del Modelo Booleano.

Por otra parte, el modelo vectorial introdujo una representación algebraica tanto para los documentos como para las consultas, tratándolos como vectores en un espacio multidimensional, en el que cada dimensión corresponde a un término y los pesos asignados reflejan su importancia relativa. La similitud entre consulta y documento se mide, por lo general, mediante el coseno entre los vectores. Este particular enfoque permitió establecer rankings de relevancia y representó un avance significativo en la precisión de los sistemas IR [4].




Figura 2.2: Representación geométrica del Modelo Vectorial.

Por último, el modelo probabilístico se basa en estimar la probabilidad de relevancia de un documento a través de una consulta, en donde su versión más consolidada, el BM25 (abreviatura de “Best Match 25”, refiriéndose a la iteración número 25 de la función de ranking), calcula dicha probabilidad a partir de la frecuencia de los términos en el documento y su frecuencia inversa en el corpus, normalizando además por la longitud del texto, como se puede ver en la Figura 3. En este aspecto, BM25 ofrece equilibrio entre simplicidad, interpretabilidad y desempeño, razón por la cual es el modelo base en la mayoría de los experimentos y benchmarks actuales de IR [4].




Figura 2.3: Componentes estructurales del modelo BM25.

Además de los modelos clásicos, se han desarrollado extensiones que buscan optimizar la precisión y la capacidad de generalización. Entre ellas, el BM25F incorpora información estructural de los documentos, el RM3 introduce retroalimentación mediante expansión de consultas, y los modelos neuronales de recuperación (Neural IR) utilizan representaciones distribuidas del texto para capturar relaciones semánticas más complejas [3]. Estas variantes reflejan la evolución del campo hacia un paradigma híbrido, en el que los modelos tradicionales siguen siendo la base para experimentos controlados y reproducibles.

Tabla 2.1: Modelos de recuperación de información y su propósito dentro de un sistema IR.

Modelo	Principio de funcionamiento	Ventajas	Limitaciones o uso típico
Booleano	Recupera documentos que cumplen exactamente la condición lógica (AND, OR, NOT).	Simple, interpretable, útil en colecciones controladas.	No entrega ranking ni grados de relevancia; poca flexibilidad en consultas reales.
Vectorial	Representa documentos y consultas como vectores	Permite ranking, ponderación de términos	Sensible al vocabulario y sinónimos; re-

Modelo	Principio de funcionamiento	Ventajas	Limitaciones o uso típico
	ponderados y mide similitud.	nos (TF-IDF) y mejora de precisión.	quiere buen preprocesamiento.
Probabilístico / BM25	Estima probabilidad de relevancia según frecuencia de término, rareza en el corpus y longitud del documento.	Equilibrio entre desempeño y simplicidad; estándar en benchmarks.	Requiere calibración de parámetros; asume independencia de términos.
Extensiones (BM25F, RM3, Neural IR)	Incorporan la estructura del documento, retroalimentación o las representaciones distribuidas.	Mejoran recuperación en dominios complejos o semánticos.	Mayor costo computacional; suelen usarse como capa superior o en escenarios específicos.

El resultado final que entrega un sistema IR se presenta como un ranking de documentos, es decir, una lista ordenada de mayor a menor relevancia estimada. Este refleja la manera en que los usuarios perciben la utilidad del sistema, ya que la mayoría solo revisa los primeros resultados, lo que convierte la posición del documento en un factor crítico de evaluación. En este trabajo se adopta principalmente el escenario de recuperación clásica, basado en BM25 y colecciones estándar, dado que la mayoría de los métodos de predicción de rendimiento han sido propuestos y validados en este contexto, y porque permite la comparación directa con estudios previos como los reportados en QPP-TK y benchmarks recientes de QPP [4].

2.1.2 Componentes de un sistema de recuperación de información.

Para que la búsqueda sea eficiente en colecciones grandes, los sistemas IR no recorren todos los documentos cada vez que se hace una consulta, sino que utilizan estructuras de datos especializadas, siendo la más común el índice invertido, que almacena, para cada término,

la lista de documentos en los que aparece. De esta forma, el sistema puede ir directamente a los documentos candidatos sin revisar toda la colección.

Es así que un sistema de recuperación de información se compone de diversas etapas que trabajan de forma conjunta para transformar documentos sin estructura en resultados relevantes para el usuario. En términos generales, estas etapas son la indexación, la representación de los documentos y consultas, el modelo de recuperación y la evaluación del sistema [5, 6].

La indexación constituye el proceso inicial, encargado de convertir los documentos en representación internas que se puedan manipular. Para ello, se aplican distintas técnicas de preprocesamiento, como la *tokenización*, que consiste en dividir el texto en unidades mínimas llamadas *tokens*; la eliminación de palabras vacías o *stopwords*, es decir, términos muy frecuentes que aportan poca información; y el *stemming* o lematización, que reduce las palabras a su forma canónica con el objetivo de unificar variantes morfológicas. El resultado es una estructura conocida como índice invertido, que permite localizar rápidamente qué documentos contienen un término específico y con qué frecuencia. Este componente es esencial para la eficiencia del sistema, ya que permite búsquedas rápidas en grandes volúmenes de información.

La eficiencia de estas estructuras es fundamental para la escalabilidad del sistema, especialmente cuando el corpus crece hasta millones de documentos como ocurre en los benchmarks modernos.




Figura 2.4: Componentes fundamentales de un sistema de Recuperación de Información.

Por otra parte, la representación de documentos y consultas determina cómo se describen los textos dentro del sistema, asignando un peso a cada término para indicar su importancia relativa. En los sistemas clásicos, la representación más extendida es el modelo de espacio

vectorial, en el cual tanto los documentos como las consultas se representan mediante vectores cuyas dimensiones corresponden a los términos del vocabulario.

El cálculo de estos pesos sigue criterios estadísticos, en donde la técnica estándar es el *esquema TF-IDF*, que combina dos componentes: *la frecuencia del término (TF)* que mide cuántas veces aparece un término dentro de un documento y *la frecuencia inversa de documento (IDF)* que indica cuán raro o discriminativo es el término dentro del corpus completo. De esta forma, se otorga mayor importancia a palabras que son relevantes dentro de un documento pero poco frecuentes en la colección, mejorando la capacidad del sistema para distinguir documentos pertinentes [5].

Posteriormente, el modelo de recuperación se encarga de comparar las representaciones de las consultas con las de los documentos, generando así una puntuación de similitud o probabilidad de relevancia. Es a partir de estas puntuaciones que el sistema construye un ranking de resultados, donde los documentos se ordenan de mayor a menor relevancia, siendo este ranking la salida final que recibe el usuario [4].

Por último, la evaluación del sistema mide el desempeño del proceso de recuperación. En esta etapa, se utilizan juicios de relevancia (*qrels*) para determinar si los documentos recuperados son pertinentes o no. Los *qrels* son listas que asocian cada consulta con los identificadores de los documentos que fueron marcados como relevantes por evaluadores humanos, funcionando como estándar de comparación para medir la efectividad de un modelo.

Tabla 2.2: Recursos y métricas comunes para la evaluación de sistemas IR y de métodos de predicción de rendimiento.

Recurso / métrica	Qué mide	Cuándo se usa	Notas
Qrels (juicios de relevancia)	Listado de documentos marcados como relevantes para cada consulta.	Base de toda evaluación offline (TREC, Cranfield, Antique).	Pueden ser binarios o graduados; dependen de evaluador humano.
Precision / Recall	Exactitud y cobertura de los documentos recuperados.	Tareas simples o colecciones pequeñas.	No consideran orden del ranking.

Recurso / métrica	Qué mide	Cuándo se usa	Notas
MAP (Mean Average Precision)	Precisión promedio sobre todas las posiciones relevantes.	Comparar sistemas en búsquedas Ad-hoc.	Promedia sobre consultas; sensible a consultas difíciles.
nDCG	Relevancia graduada ponderada por la posición en el ranking.	Cuando hay distintos niveles de relevancia o se valora el orden.	Muy usada en benchmarks modernos.
Kendall's τ / Pearson r	Asociación entre valores predichos y rendimiento real.	Evaluar métodos de QPP.	Necesitan pares (predicho, observado) por consulta.

En la evaluación de sistemas IR suele asumirse que los juicios de relevancia son correctos y completos, sin embargo, distintos estudios demuestran que la calidad de estos juicios depende en gran medida de la experticia del evaluador y del dominio temático de la colección. Cuando los evaluadores no son especialistas en el área o cuando la tarea es muy abierta, pueden aparecer discrepancias entre jueces, lo que introduce ruido en las métricas obtenidas y, por extensión, en la evaluación de los métodos de predicción de rendimiento [7, 8].

Esta situación es particularmente relevante para trabajos como el presente, donde el objetivo es correlacionar el valor entregado por un predictor con la efectividad real de la consulta, por ende, si los juicios de relevancia son incompletos o poco consistentes, la correlación observada puede reflejar las limitaciones de la colección más que las del método evaluado. De esta forma, los componentes de un sistema de recuperación de información funcionan como partes de un ciclo continuo, la indexación estructura, la representación abstrae, el modelo de recuperación calcula y la evaluación retroalimenta el proceso.

2.1.3 Consultas, tópicos y búsquedas Ad-hoc

Es importante distinguir entre consulta y tópico, la primera es la expresión que el usuario introduce en el sistema, mientras que el tópico representa la necesidad informativa

completa, que puede incluir una descripción y una narrativa que detalla qué se considera relevante.

Las consultas son la forma en la cual los usuarios expresan su necesidad de información dentro de un sistema IR. Por lo general, estas son breves, ambiguas o incompletas, lo que genera variabilidad en el rendimiento de los sistemas [9].

A cada consulta se le asocia un tópico, entendido como el contexto o tema subyacente que representa la intención informativa del usuario. En los benchmarks tradicionales, cada tópico incluye una descripción breve de la necesidad informativa y una lista de documentos considerados relevantes. Esta estructura permite establecer condiciones experimentales controladas para evaluar el rendimiento de distintos sistemas y analizar la variabilidad entre consultas.

Este esquema responde al denominado *paradigma Cranfield*, en el cual se define un conjunto fijo de consultas, se construye un conjunto de documentos candidatos y se recolectan juicios de relevancia humanos para cada consulta. A partir de esta configuración es posible comparar distintos modelos de recuperación bajo las mismas condiciones y, sobre todo, repetir los experimentos en el tiempo, lo que explica por qué colecciones como *TREC*, *Cranfield* o *Antique* se utilizan de forma recurrente en trabajos de evaluación y en investigaciones sobre QPP [9, 10].

Dentro del campo de IR, el término búsqueda Ad-hoc hace referencia a una tarea en la que se intenta recuperar los documentos más relevantes de un corpus dado una consulta única y sin contexto previo. A diferencia de otras búsquedas, como la interactiva o conversacional, la búsqueda Ad-hoc no cuenta con realimentación del usuario ni refinamiento iterativo. Por ello, el desempeño del sistema depende en gran medida de qué tan bien logra interpretar los términos de la consulta y relacionarlos con los documentos del corpus [6].

Los estudios sobre rendimiento en sistemas IR han demostrado que la dificultad de una consulta está estrechamente vinculada con su capacidad de discriminar documentos relevantes, por ejemplo, las consultas cortas o con términos frecuentes en el corpus tienden a recuperar documentos menos específicos, reduciendo la efectividad. En contraste, las consultas con términos raros o especializados suelen dar resultados más concentrados y relevantes [5]. Este comportamiento explica la necesidad de métricas y métodos de predicción de la dificultad, que permitan estimar la calidad esperada de la recuperación antes de disponer de juicios humanos.

En los últimos años, el concepto de búsqueda Ad-hoc se ha extendido hacia escenarios más complejos, como la búsqueda conversacional o multiturno, en los que la consulta forma parte de un diálogo progresivo con el sistema. Estas nuevas modalidades introducen desafíos adicionales, como el seguimiento de contexto o la reformulación dinámica de la intención informativa [9].

No obstante, el paradigma Ad-hoc sigue siendo el marco experimental más utilizado para la evaluación de métodos QPP, ya que permite controlar las variables de consulta y corpus, proporcionando resultados comparables entre diferentes modelos de recuperación.

2.2 Predicción de Rendimiento de Consultas (QPP)

La predicción del rendimiento de consultas (QPP, Query Performance Prediction), también conocida como estimación de la dificultad de la consulta (QDE, Query Difficulty Estimation), representa una rama de investigación en el campo de la Recuperación de Información (IR) que se enfoca en predecir la calidad de los resultados de búsqueda para una consulta dada, recuperados por un sistema de recuperación específico, **sin necesidad** de información de relevancia proporcionada por un operador humano. Este desafío surge de la observación de que los sistemas de búsqueda a menudo fallan en responder eficazmente a ciertas consultas, lo que se asocia directamente con la noción de **dificultad de la consulta** [5].

La diversidad en el rendimiento de las consultas y entre diferentes sistemas ha impulsado esta área, buscando mitigar la variabilidad en la efectividad de la recuperación. En este sentido, QPP cumple un rol netamente preventivo: anticipar la dificultad para activar ajustes selectivos (expansión, elección de parámetros o flujos alternativos) antes de observar fallos, reduciendo la variabilidad y mejorando la experiencia del usuario.

2.2.1 Dificultad y rendimiento de las consultas

La **dificultad de una consulta**, en el ámbito de la Recuperación de Información (IR), se asocia principalmente con la incapacidad de un sistema para responder de manera efectiva a una necesidad de información específica. Una consulta se considera **difícil** cuando el sistema de búsqueda obtiene un rendimiento deficiente en términos de sus medidas de efectividad. Este concepto es fundamental, ya que los fallos del sistema suelen estar directamente relacionados con la complejidad inherente o contextual de la consulta, lo que subraya la importancia de su predicción en la mejora continua de los sistemas de IR. La noción de dificultad de la consulta no es universal, y su interpretación puede variar dependiendo del contexto, el corpus, la ambigüedad de la consulta y el sistema de recuperación utilizado.

En contraste, el **rendimiento de una consulta** se define como una forma de estimar la dificultad inherente de la misma, mediante diversos experimentos de recuperación que generan a la vez múltiples métricas relacionadas con la calidad de los resultados obtenidos por el sistema. Estas métricas, obtenidas a través de experimentos que evalúan el resultado de la recuperación contra juicios de relevancia humana (*Qrels*), incluyen nDCG, Recall, AP y MAP, entre otras. Cada experimento de recuperación produce estas métricas simultáneamente sobre la misma lista ordenada de documentos, permitiendo una evaluación multidimensional de la efectividad del sistema. Un alto rendimiento en estas métricas indica

una consulta **fácil** con baja dificultad inherente, mientras que valores bajos sugieren una consulta **difícil** que desafía la capacidad del sistema para satisfacer la necesidad informativa del usuario. La predicción de este rendimiento, es por tanto, el núcleo de la predicción de rendimiento de consultas (*QPP*), buscando estimar estas métricas sin requerir juicios humanos de relevancia.

La interdependencia entre la dificultad y el rendimiento de las consultas es fundamental. Una **consulta** inherentemente **difícil**, ya sea por su **ambigüedad**, **la escasez de documentos relevantes en el corpus**, o **la formulación ineficaz**, tenderá a producir un bajo rendimiento en la mayoría de los sistemas de IR. Por lo tanto, estimar la dificultad de la consulta es, en esencia, **un intento de predecir el rendimiento que un sistema específico logrará para esa consulta en el contexto de un corpus específico**. Esta predicción permite a los sistemas anticipar posibles fallos y aplicar estrategias correctivas de manera proactiva, mejorando la experiencia del usuario y la eficiencia general del sistema.

Los **factores** que contribuyen a la dificultad de una consulta son variados y complejos. Pueden estar relacionados con la expresión misma de la consulta, como la ambigüedad léxica o semántica, o con su longitud y especificidad. Otro conjunto de factores se deriva del conjunto de datos o corpus, incluyendo su heterogeneidad, la distribución de términos y la cantidad de documentos relevantes disponibles. Finalmente, el método de recuperación empleado también influye en la dificultad percibida, ya que diferentes algoritmos pueden manejar la misma consulta con distintos niveles de éxito. Esta fuerte dependencia en múltiples factores hace que la predicción de la dificultad sea un desafío significativo incluso cuando se trata de predicciones realizadas por jueces expertos en el área [1, 11].

La **generalidad** de la dificultad de una consulta es un aspecto clave a considerar. Una consulta puede ser difícil para un sistema de recuperación particular, pero no para otros, o puede ser consistentemente difícil a través de una variedad de sistemas y colecciones. Esta generalidad se mide a menudo promediando el rendimiento predicho de la consulta a través de múltiples métodos de recuperación y diversas colecciones de documentos. Comprender esta variabilidad es esencial para desarrollar y evaluar predictores de dificultad que sean robustos y aplicables en diferentes escenarios de búsqueda, más allá de un único contexto sistema-colección [8].

Recientemente la literatura ha propuesto varias estrategias formales para definir la **dificultad** de una consulta q en particular. Todas parten del valor $m_{S_i}(q)$; la puntuación que entrega una métrica de efectividad M (p. ej., $nDCG$, AP) cuando se evalúa la lista recuperada para q por un sistema de recuperación S_i . Este valor sintetiza el rendimiento del sistema en esa consulta (cuanto menor es $m_{S_i}(q)$, más difícil resultó q para S_i). y es la variable base con la que se etiquetan las clases de dificultad. Estas estrategias se resumen en la Tabla 2.3:

1. **Percentiles:** Particiona la distribución de la métrica M por consulta mediante percentiles. En el caso binario, como se muestra en la Ecuación (2.1), una consulta q se

considera **difícil** para un sistema S_i si su valor $m_{S_i}(q)$ es menor o igual que un percentil p_x , es decir, si aproximadamente $x\%$ de las consultas tienen un valor inferior. En el caso de desear una **dificultad graduada**, se utilizan $N - 1$ percentiles para definir N clases ordenadas de dificultad, donde la primera clase agrupa las consultas más difíciles y la última las más fáciles.

$$p_x : \text{dificultad}(q) = 1_{\{m_{S_i}(q) \leq p_x\}} \quad (2.1)$$

En estas expresiones, $\text{dificultad}(q)$ es una función **indicadora** que toma el valor 1 cuando la consulta q se etiqueta como **difícil** y 0 en caso contrario. El parámetro p_x corresponde al percentil x -ésimo de la distribución de M sobre todas las consultas, de modo que $1_{\{m_{S_i}(q) \leq p_x\}}$ marca como **difíciles** aquellas cuyo rendimiento cae en el $x\%$ inferior de la distribución.

$$q \in \begin{cases} D_1 & \text{si } m_{S_i}(q) \leq p_1 \\ D_i, \forall_i = 2, \dots, N-2 & \text{si } P_{i-1} < m_{S_i}(q) \leq P_i \\ D_N & \text{si } m_{S_i}(q) > P_{N-1} \end{cases} \quad (2.2)$$

)

En el caso graduado Ecuación (2.2), los símbolos $D_1, \dots, D_N$ representa **clases ordenadas de dificultad** (por ejemplo, **muy difícil, difícil, fácil, muy fácil**), mientras que $P_1, \dots, P_{N-1}$ son percentiles crecientes que dividen la distribución de M en N segmentos. Cada consulta q se asigna a una clase D_k en función del intervalo en el que cae su valor $m_{S_i}(q)$ con respecto a estos cortes percentilares.

2. **Umbrales:** Fija cortes absolutos sobre la métrica para definir clases de dificultad. En el caso binario, como se expresa en la Ecuación (2.3), una consulta q es **difícil** para S_i si $m_{S_i}(q)$ es menor o igual que un umbral T (por ejemplo, consultas con $P@10 \leq 0.1$). Para el caso graduado, se emplea un conjunto de umbrales $T_1, \dots, T_{N-1}$ que inducen N clases de dificultad ordenadas.

$$T : \text{dificultad}(q) = 1_{\{m_{S_i}(q) \leq T\}} \quad (2.3)$$

Generalmente existen dos configuraciones típicas:

En la definición por umbrales, T es un **corte absoluto** fijado directamente sobre la escala de la métrica M . De nuevo, $\text{dificultad}(q)$ es una función indicadora que vale 1 si el rendimiento $m_{S_i}(q)$ de la consulta cae por debajo o en el propio umbral T (es decir, si la consulta no alcanza un mínimo de efectividad considerado aceptable) y 0 en caso contrario.

- **Umbral único:** Se define un solo punto de corte. Por ejemplo, las consultas con $P@10 \leq 0.1$ se consideran **difíciles** y el resto **no difíciles**, creando una clasificación binaria.

- **Pares de umbrales:** Se usan dos umbrales para aislar los extremos. Por ejemplo, con el par $(0.1, 0.9)$, las consultas con $AP \leq 0.1$ son **muy difíciles** y aquellas con $AP \geq 0.9$ son **muy fáciles**. Las consultas intermedias se ignoran o se les asigna una clase intermedia, creando un margen que facilita la predicción al enfocarse solo en los casos más claros [1].

En la versión graduada, una secuencia ordenada de umbrales $T_1 < \dots < T_{\{N-1\}}$ permite definir varias clases de dificultad a partir de rangos absolutos de M : por ejemplo, **muy difícil** para $m_{\{S_i\}}(q) \leq T_1$, **difícil** para $T_1 < m_{\{S_i\}}(q) \leq T_2$, y así sucesivamente, hasta una última clase que agrupa las consultas con mejores valores de la métrica.

3. **Combinada:** Combina ambos criterios: percentiles y por umbral. En el caso binario, presentado en la Ecuación (2.4), una consulta se considera **difícil** si es clasificada como difícil tanto por la definición basada en percentiles como por la basada en umbrales (es decir, si $m_{S_i}(q) \leq T$ y $m_{S_i}(q) \leq p_x$). Para dificultad graduada, la clase asignada a una consulta corresponde a la intersección de las clases obtenidas con cada una de las dos estrategias anteriores.

$$\text{dificultad}(q) = 1_{\{m_{s_i}(q) \leq T \ \& \ m_{s_i}(q) \leq p_x\}} \tag{2.4}$$

En la definición combinada, la función $\text{dificultad}(q)$ solo toma el valor 1 cuando **simultáneamente** se cumplen las dos condiciones anteriores: el rendimiento de la consulta está por debajo del percentil p_x y, al mismo tiempo, por debajo del umbral absoluto T . La notación $1_{\{A \wedge B\}}$ indica la función indicadora del evento intersección entre A y B : vale 1 únicamente cuando ambas desigualdades se satisfacen, y 0 en cualquier otro caso.

Estas estrategias pueden plantearse en un enfoque **centrado en un único sistema**, donde la dificultad se define respecto de un sistema S_i específico, o bien respecto de un **conjunto de sistemas** $S = \{S_1, \dots, S_K\}$, reemplazando el conjunto de valores $\{m_{S_1}(q), \dots, m_{S_K}(q)\}$ por su promedio $\frac{1}{K} \sum_{i=1}^K m_{S_i}(q)$ sobre todos los sistemas considerados. La evidencia empírica muestra que las definiciones por umbrales con una separación marcada entre clases (p. ej., **muy difíciles** vs. **muy fáciles**) suelen producir sets de entrenamiento más contrastados y por ende, predicciones más estables y con mayores verdaderos positivos que las definiciones puramente percentilares o combinadas [1].

Tabla 2.3: Formas de definir la dificultad de una consulta.

Definición	Descripción	Notas/Configuración típica
Percentiles	Particiona la distribución de la métrica M por consulta mediante percentiles para inducir	Caso binario: difícil si $m_{S_i}(q) \leq p_x$. Caso graduado: $N - 1$ percentiles definen

Definición	Descripción	Notas/Configuración típica
	clases de dificultad (por ejemplo, de muy difícil a muy fácil).	N clases ordenadas; sensibilidad fuerte al dataset.
Umbrales	Fija cortes absolutos sobre la métrica para definir clases de dificultad, típicamente enfocadas en consultas muy difíciles o muy fáciles.	Caso binario: difícil si $m_{S_i}(q) \leq T$ (ej: P@10 ≤ 0.1). Caso graduado: umbrales $T_1, \dots, T_{N-1}$ inducen N clases; configuraciones habituales con umbral único o pares de umbrales para aislar extremos.
Combinada	Combina criterios percentilares y de umbrales, asignando dificultad sólo cuando ambas definiciones coinciden.	Menos estable empíricamente que los esquemas basados sólo en umbrales con brechas marcadas entre clases.
Ámbito	Definición respecto de un sistema específico o de un conjunto de sistemas de recuperación.	Centrada en un sistema S_i o sobre un conjunto S , promediando la métrica entre sistemas.

2.2.2 Soluciones al Problema de la Dificultad de las Consultas

La dificultad inherente de ciertas consultas ha impulsado el desarrollo de técnicas robustas para mejorar la efectividad de los sistemas de recuperación de información. A lo largo del tiempo, las soluciones han evolucionado desde métodos estadísticos clásicos hasta arquitecturas neuronales avanzadas, buscando siempre mitigar los fallos de recuperación asociados a consultas ambiguas, complejas o con desajuste de vocabulario.

Una de las primeras y más influyentes soluciones fue el desarrollo de **modelos de relevancia**. En lugar de depender exclusivamente de los términos de la consulta original, esta técnica utiliza un proceso de dos etapas para refinar la búsqueda.

Primero, se realiza una recuperación inicial y se asume que los documentos mejor clasificados son relevantes (un concepto conocido como *pseudo-relevance feedback*). A partir

de este conjunto de documentos, se construye un modelo probabilístico que estima la distribución de términos que probablemente aparecerían en documentos verdaderamente relevantes. Los términos con alta probabilidad en este modelo, que pueden no haber estado en la consulta original, se utilizan para expandir o reestructurar la consulta.

Finalmente, esta nueva “consulta expandida” se utiliza para realizar una segunda recuperación, que a menudo produce un ranking de resultados mucho más preciso, resolviendo problemas comunes como la sinonimia y la polisemia [12].




Figura 2.5: Flujo de un sistema de recuperación basado en Modelos de Relevancia.

En la Figura 5 se ilustra el flujo típico de expansión mediante modelos de relevancia: una consulta inicial se ejecuta con un ranker léxico (BM25) para obtener los *top-K* documentos; a partir de ese conjunto pseudo-relevante se estima un modelo que induce nuevos términos y pesos; con la consulta expandida resultante se realiza una segunda recuperación, cuyo objetivo es reordenar con mayor precisión y producir un ranking final de documentos más alineado con la intención de la consulta.

Más recientemente, la llegada de los **Modelos extensos del lenguaje** (LLMs) ha supuesto un avance significativo en el panorama de la recuperación de información. Sin embargo, uno de sus mayores problemas es que su conocimiento se “congela” en el momento del entrenamiento, lo que **limita su acceso a información reciente** y los hace propensos a “**alucinar**” o generar contenido incorrecto.

Para superar estas limitaciones, ha surgido el paradigma de la **Generación Aumentada por Recuperación** (RAG). Los modelos RAG combinan un recuperador de información con un LLM generativo en un proceso de dos fases:

1. **Recuperación:** Un sistema de recuperación busca en una base de conocimiento (por ejemplo, una colección de documentos) para encontrar fragmentos de texto relevantes para la consulta.
2. **Generación:** Estos fragmentos recuperados se proporcionan como contexto a un LLM junto con la consulta original. El LLM sintetiza una respuesta coherente y factual, fundamentada en la evidencia extraída.

Este enfoque ancla las respuestas del LLM en información verificable, reduciendo las alucinaciones y permitiendo que el conocimiento del sistema se actualice simplemente actualizando la base de conocimiento documental. Es una técnica especialmente poderosa para consultas de conocimiento intensivo que demandan respuestas precisas y actualizadas [3].

A pesar de su efectividad, estas soluciones avanzadas (desde la expansión de consultas hasta *pipelines LLM + RAG*) suelen tener un costo computacional elevado. No es eficiente ni necesario aplicarlas a todas las consultas, especialmente a aquellas que son simples y pueden ser respondidas adecuadamente por un sistema de recuperación estándar.

Por otro lado la **Predicción del Rendimiento de Consultas (QPP)** busca destacar especialmente en este area. Los predictores funcionan como una herramienta de diagnóstico que estima de antemano la efectividad esperada de un sistema para una consulta dada, sin necesidad de utilizar juicios de relevancia humanos. Al predecir si una consulta será “fácil” o “difícil”, un sistema de IR puede tomar decisiones proactivas y selectivas. Para una consulta predicha como “fácil”, se puede utilizar un método de recuperación rápido y eficiente. En cambio, si una consulta se predice como “difícil”, el sistema puede activar mecanismos más eficaces y costosos, como la expansión de consultas, el uso de modelos de relevancia o la activación de un *pipeline* de *RAG* para garantizar una respuesta de alta calidad. Por ende, QPP permite a los sistemas de recuperación gestionar estratégicamente sus recursos, mejorando la robustez y la eficiencia general al tiempo que se mitigan los fallos en las consultas más desafiantes [5].

2.2.3 Taxonomías en QPP

La literatura distingue dos categorías principales de predictores de rendimiento de consulta según el momento en que extraen información: métodos *pre-retrieval* y *post-retrieval*. Los primeros formalmente se caracterizan por actuar antes de ejecutar la búsqueda utilizando únicamente la consulta y estadísticas del índice; los segundos explotan señales observadas en la lista recuperada a partir de un modelo de recuperación de información (p. ej., patrones en las puntuaciones y funciones de ranking) [13].

En paralelo, al adentrarnos en el campo de la inteligencia artificial, podemos encontrar otras categorías de clasificación por ejemplo, **régimen de aprendizaje (no supervisados frente a supervisados)** y por **entorno (búsqueda ad-hoc y conversacional utilizando**

modelos extensos del lenguaje), cuyas elecciones suponen compromisos entre costo computacional, latencia y capacidad para modelar fenómenos como ambigüedad, variación temática y distribuciones de consultas [9, 14].

2.2.3.1 Predictores *pre-retrieval*

Los predictores *pre-retrieval* estiman la dificultad de una consulta a priori, sin ejecutar recuperación. Se apoyan en propiedades intrínsecas de la consulta y en estadísticas globales de la colección disponibles en tiempo de indexación. De forma general, caracterizan la especificidad y ambigüedad de la consulta, así como su potencial discriminativo en la colección, a partir de medidas o estadísticas resumidas que capturan propiedades léxicas de la consulta (longitud, diversidad o concentración de términos) y el patrón con que dichos términos aparecen en la colección (frecuencia y variabilidad entre documentos). Su atractivo radica en el bajo costo computacional y en que permiten decisiones de control (expansión, selección de sistema o ajuste de parámetros) antes de observar una lista recuperada [15, 16].

2.2.3.2 Predictores *post-retrieval*

Los predictores *post-retrieval* se estiman una vez disponible la lista recuperada para la consulta determinada y se apoyan en señales observables en dicha lista. En términos generales, se agrupan en cuatro familias:

1. El comportamiento de las puntuaciones devueltas por el ranker
2. La coherencia y consistencia semántica de los documentos en la cima del ranking
3. La estabilidad del ranking ante perturbaciones controladas (robustez)
4. El consenso con variantes del sistema o de la consulta.

Estas familias de señales buscan captar indicios de dificultad a partir de la respuesta del sistema para la consulta concreta.

Tabla 2.4: Factores y señales típicas en predictores post-retrieval

Factor	Descripción	Ejemplos de señales
Puntuaciones del ranker	Patrones en las puntuaciones devueltas (magnitud, dispersión, forma y separabilidad entre tope y cola).	Varianza y distribución de puntajes, diferencias en el top-1 vs top-10
Coherencia del tope	Consistencia semántica entre los documentos top-K y con la consulta.	Similaridad promedio entre top-K, comparación de modelos de lenguaje de los resultados y el dataset (clarity score)
Robustez del ranking	Estabilidad del ranking ante perturbaciones controladas del sistema, de los datos y de la consulta.	Sensibilidad a ruido/perturbación, estabilidad al remover/alterar top-K
Consenso entre variantes	Acuerdo con variantes del sistema o de la consulta.	Correlación de rangos entre el ranking original y variantes (por ejemplo, con stemming, con expansión de consulta).

Los enfoques *post-retrieval* pueden ser no supervisados (agregan señales derivadas de la propia lista devuelta) o supervisados (aprenden a mapear representaciones de consulta-lista a una estimación de rendimiento). Su efectividad depende del tipo de recuperador (léxico o denso), de la profundidad considerada (top-k frente a listas profundas) y de las propiedades de la colección, dado que distintas distribuciones de puntuaciones y estructuras de ranking favorecen señales diferentes. Aunque su costo es mayor que el de los métodos pre-retrieval, suelen proporcionar estimaciones más informadas al incorporar evidencia del resultado concreto de recuperación [13, 17, 18].

2.2.4 Aplicaciones de QPP en IR

La capacidad de predecir el rendimiento de una consulta abre un amplio abanico de aplicaciones prácticas que permiten a los sistemas de recuperación de información (IR) operar de manera más inteligente, robusta y eficiente. En lugar de tratar todas las consultas de la misma manera, los sistemas pueden utilizar los predictores de QPP para adaptar dinámicamente su comportamiento. Sin embargo, la utilidad de estas aplicaciones depende

críticamente de la calidad del predictor: **se requiere una correlación moderadamente alta** entre el rendimiento predicho y el real para que estas estrategias mejoren de manera fiable la efectividad del sistema [10].

- **Activación selectiva de mecanismos avanzados:** Como se mencionó anteriormente, técnicas como la expansión de consultas mediante modelos de relevancia o el uso de arquitecturas complejas como RAG son computacionalmente costosas. Sobre este punto, QPP funciona como una herramienta de diagnóstico que estima de antemano la efectividad esperada. Si una consulta se predice como **difícil**, el sistema puede activar estos mecanismos más potentes para garantizar una respuesta de alta calidad. En cambio, para una consulta predicha como **fácil**, se puede utilizar un método de recuperación estándar, optimizando así el uso de recursos sin sacrificar la calidad en los casos necesarios [5].
- **Expansión selectiva de consultas:** La retroalimentación de pseudo-relevancia (*pseudo-relevance feedback*, PRF) es una técnica común para expandir consultas, pero su aplicación indiscriminada tiene consecuencias negativas. Si los documentos mejor clasificados iniciales no son relevantes, los términos añadidos pueden desviar el enfoque de la consulta original, un fenómeno conocido como *query drift*. Este desvío a menudo degrada el rendimiento en lugar de mejorarlo. Los predictores QPP permiten una aplicación más segura de esta técnica. Si se predice que una consulta tendrá un bajo rendimiento, se considera como una buena candidata para la expansión, ya que el potencial de mejora es elevado y el riesgo de empeorar un resultado ya pobre es negligible. Por el contrario, si se predice que una consulta ya es efectiva, aplicar la expansión podría ser innecesario o incluso perjudicial. De este modo, la predicción actúa como un guardián, aplicando la expansión solo cuando es probable que sea beneficiosa [17].
- **Búsqueda federada y metabúsqueda:** En entornos donde los resultados provienen de múltiples colecciones o motores de búsqueda, la QPP es fundamental para la fusión inteligente de resultados. En la **metabúsqueda**, se consultan varios motores de búsqueda, mientras que en la **búsqueda federada**, se busca en múltiples colecciones con un solo motor. En ambos casos, en lugar de combinar los rankings basándose únicamente en los puntajes de cada fuente, se puede predecir el rendimiento de la consulta en cada una de ellas de forma independiente. Los resultados de las fuentes donde se predice un alto rendimiento pueden recibir una mayor ponderación en el ranking final. Esta estrategia ha demostrado mejorar significativamente la calidad de los resultados combinados, aunque su éxito también depende de la fiabilidad del predictor utilizado [5, 10].
- **Retroalimentación al usuario y al sistema:** La QPP también se utiliza para proporcionar retroalimentación directa. Un sistema puede informar al usuario que su

consulta es probablemente “difícil” y que los resultados pueden ser de baja calidad, sugiriendo reformulaciones o términos alternativos. A nivel de administración del sistema, el análisis de las consultas predichas como difíciles en los registros de búsqueda (*query logs*) puede ayudar a identificar **contenido faltante** en la colección, guiando así los esfuerzos para enriquecer la base de conocimiento y cubrir las brechas de información detectadas [5].

2.2.5 Supuestos, limitaciones y amenazas a la validez

A pesar de su potencial, la efectividad y la evaluación de los métodos de QPP se basan en un conjunto de supuestos y están sujetas a limitaciones importantes que deben ser consideradas para interpretar correctamente sus resultados.

La evaluación y la aplicación de los métodos de QPP descansan sobre varios supuestos centrales. Un supuesto extendido sostiene que una alta correlación (Pearson, Kendall, Spearman) entre las predicciones y una métrica de efectividad (AP, nDCG) se traduce en utilidad práctica; sin embargo, la evidencia empírica muestra que la correlación, **aun siendo estadísticamente significativa**, no garantiza por sí sola una mejora operativa, pues la utilidad real depende de cómo la predicción informa decisiones concretas dentro del sistema [10].

A ello se suma una fuerte dependencia de los juicios de relevancia (*Qrels*) como “suelo de verdad”. Este supuesto es particularmente frágil, ya que la calidad de los *Qrels* está sujeta a la variabilidad inherente al juicio humano. La evaluación de la relevancia no es un proceso mecánico; está influenciada por **la experiencia y el conocimiento del dominio del evaluador**. Se ha demostrado que los evaluadores no expertos (“generalistas”) tienden a producir juicios menos precisos y más superficiales en comparación con los expertos del dominio, recurriendo con frecuencia a la simple coincidencia de palabras clave en lugar de a una comprensión profunda de la **intención** de la consulta. Esta discrepancia introduce una fuente potencialmente significativa de sesgo en los resultados de evaluación, lo que significa que un predictor de QPP puede estar siendo interpretado incorrectamente para replicar los juicios de un tipo particular de evaluador, en lugar de una noción objetiva de relevancia [7].

La validez de las evaluaciones también está modulada por las características de los conjuntos de datos y de las muestras de consulta empleados. El rendimiento observado de un predictor depende en gran medida del **tipo de colección**: resultados alentadores en corpus limpios y homogéneos (p. ej., noticias) no necesariamente se sostienen en colecciones provenientes de la web más **ruidosas y heterogéneas**; por ello, las conclusiones de benchmarks deben interpretarse con cautela y no extrapolarse sin verificación a contextos productivos [8]. A ello se añade la sensibilidad a tamaños muestrales reducidos de consultas, frecuentes en campañas de evaluación: con pocas consultas, las estimaciones son más

inestables y los intervalos de confianza se amplían, dificultando discernir si las diferencias entre predictores reflejan efectos genuinos o artefactos de muestreo. La composición de la muestra (por ejemplo, una sobre-representación de consultas fáciles o difíciles) puede, además, sesgar las métricas y favorecer ciertas familias de predictores.

2.3 Métricas de Evaluación de Rendimiento y Correlación

Las **métricas de evaluación** cuantifican la calidad de un ranking y permiten contrastar, de forma objetiva, lo que un sistema recupera con lo que se espera encontrar. En el contexto de *QPP*, operan como punto de comparación para juzgar si las predicciones se alinean con el rendimiento observado a nivel de consulta y de colección. La base de todo cualquier métrica de evaluación son los **juicios de relevancia**, que fijan qué documentos del corpus se consideran relevantes para una consulta dada.

Sobre esa referencia se calculan medidas ampliamente utilizadas como ***Precision***, ***AP***, ***MAP*** y ***nDCG***. Estas métricas capturan distintos aspectos del rendimiento: exactitud en los tope del ranking, cobertura de documentos relevantes, calidad promedio a lo largo de la lista y sensibilidad a las relevancias graduadas. Su valor depende del orden de los resultados y de parámetros como la profundidad de corte (k), por lo que deben interpretarse en función del escenario de uso.

Para la evaluación de *QPP* se utiliza un protocolo experimental que utiliza las métricas de efectividad calculadas por consulta (por ejemplo, *AP*, *MAP*, *nDCG*) correlacionandolas directamente con el valor del predictor para la misma consulta. La comparación emplea **coeficientes de correlación de rangos** y se acompaña de **pruebas de significancia e intervalos de confianza** para estimar la robustez. De este modo, la utilidad del predictor se juzga por la magnitud y la estabilidad de las correlaciones y por su capacidad para guiar decisiones.

2.3.1 Juicios de relevancia (*Qrels*)

Los juicios de relevancia (*Qrels*) son las etiquetas que, para cada consulta, indican qué elementos del corpus son relevantes y con qué grado (binario o multigrado). Operan como referencia objetiva para calcular métricas de efectividad a nivel de consulta y de colección y, por tanto, constituyen el “suelo de verdad” o “*ground truth*” frente al cual se contrastan sistemas de recuperación y estimadores de rendimiento. Su definición y disponibilidad condicionan de forma directa la interpretación de resultados y la comparabilidad entre trabajos.

La obtención humana de *Qrels* suele realizarse mediante campañas de evaluación con anotadores expertos o capacitados, frecuentemente apoyadas en la técnica de *pooling*: es decir se agregan los resultados *top-k* resultantes de múltiples sistemas y se juzga ese subconjunto. Este procedimiento permite cubrir un espacio de resultados amplio con costos controlados,

pero introduce incompletitud (no todos los elementos relevantes son juzgados) y sesgos de cobertura ligados a los sistemas incluidos y a la profundidad del *pool*. La **calidad** de los juicios depende de guías de anotación, formación y control de calidad (p. ej., acuerdo entre anotadores medido con coeficientes como el K de Cohen) y de la escala de relevancia empleada; estos factores por ende tienen un impacto directo en la estabilidad de las métricas [7, 11, 19].

2.3.2 Métricas de evaluación clásicas en IR

En términos formales, una métrica de evaluación asigna a cada consulta un valor escalar que resume el rendimiento de un sistema a partir del ranking devuelto y de los juicios de relevancia (*Qrels*) asociados a sus documentos. A partir de estas puntuaciones por consulta se definen luego versiones agregadas a nivel de sistema, promediando sobre un conjunto de consultas: por ejemplo, **Precision@n(R)** corresponde a la media de las precisiones por consulta al corte n para el sistema R .

Entre las métricas más utilizadas se encuentran la **Precision** y la **Exhaustividad (Recall)**, sobre las cuales se construyen medidas más complejas como la **Precisión Media (AP)**, su promedio sobre consultas (*MAP*) y la **Ganancia Acumulada Descontada Normalizada (nDCG)**, que difieren en si asumen relevancia binaria o graduada y en la forma en que penalizan posiciones más profundas en el ranking [20].

La **Precisión (Precision)**, definida en la Ecuación (2.5), mide la fracción de documentos recuperados que son relevantes. Responde a la pregunta: “¿Qué proporción de los resultados que mostré son realmente útiles?”. Es un indicador de la exactitud de la búsqueda y requiere que los juicios de relevancia sean binarizados (es decir, un documento es relevante o no lo es, sin grados intermedios).

$$\text{Precision@n(R)} = \frac{1}{Q} \sum_{i=1}^Q \left[\frac{1}{n} \sum_{j=1}^n \text{rel}^b(d_j^i) \right] \quad (2.5)$$

Donde Q es el número de consultas del conjunto de evaluación, R denota el sistema o algoritmo de recuperación evaluado, n es la profundidad de corte (el número de primeras posiciones consideradas en el ranking) y d_j^i es el documento en la posición j de la lista devuelta por R para la consulta q_i ; finalmente, $\text{rel}^b(d_j^i)$ es la relevancia **binarizada** del documento d_j^i , devolviendo 1 si es relevante y 0 en caso contrario.

Una variante común es la **Precisión en K (Precision@K)**, que calcula la precisión considerando únicamente los primeros K resultados del ranking. Es especialmente útil porque refleja la experiencia del usuario, quien raramente explora más allá de la primera página de resultados [20].

La **Precisión Media** (*Average Precision, AP*) es una métrica que evalúa la calidad de un ranking para una única consulta combinando estas dos ideas. Se calcula promediando la precisión en cada posición donde se encuentra un documento relevante. *AP* favorece a los sistemas que no solo recuperan muchos documentos relevantes (alta exhaustividad), sino que también los clasifican en las primeras posiciones (alta precisión). Para evaluar un sistema en un conjunto de consultas, se utiliza la **Precisión Media Promedio** (*Mean Average Precision, MAP*), que es simplemente el promedio de los valores de *AP* de todas las consultas [5].

$$\text{MAP@n(R)} = \frac{1}{Q} \sum_{i=1}^Q \left[\frac{1}{n_i} \sum_{j=1}^n \text{rel}^b(d_j^i) * \text{AP@j(R, } q_i) \right] \quad (2.6)$$

En la Ecuación (2.6), n_i corresponde al número de documentos relevantes para la consulta q_i según los *Qrels* y $\text{AP@j(R, } q_i)$ denota el valor de *AP* calculado hasta la posición j del ranking para la consulta q_i , manteniendo la misma convención de índices i (consulta) y j (posición) y la misma función de relevancia binarizada $\text{rel}^b(d_j^i)$ empleadas en la fórmula de Precisión.

La **Ganancia Acumulada Descontada Normalizada (Normalized Discounted Cumulative Gain, nDCG)** es una métrica más sofisticada que, a diferencia de la Precisión, sí tiene en cuenta los diferentes niveles de relevancia (por ejemplo, “relevante”, “muy relevante”). A nivel de consulta, puede verse como la razón entre la DCG obtenida por el sistema y la mejor DCG posible para esa misma consulta (IDCG), es decir:

$$\text{nDCG}_i = \frac{\text{DCG}_i}{\text{IDCG}_i} \quad (2.7)$$

La idea central es que los documentos altamente relevantes son más valiosos que los marginalmente relevantes, y la relevancia de un documento disminuye cuanto más abajo aparece en la lista de resultados.

Para ello, se asigna una ganancia a cada documento que crece exponencialmente con su nivel de relevancia (*rel*) derivado de los juicios de relevancia. Luego, esta ganancia se descuenta logarítmicamente según la posición del documento (j). Finalmente, el valor se normaliza dividiéndolo por un factor N_i , que representa la ganancia ideal para esa consulta (IDCG), para obtener una puntuación entre 0 y 1.

La fórmula general para calcular nDCG con un corte en n (nDCG@n), promediado sobre un conjunto de Q consultas, se define en la Ecuación (2.8) como:

$$\text{nDCG@n} = \frac{1}{Q} \sum_{i=1}^Q \left[\frac{1}{N_i} \sum_{j=1}^n \frac{2^{\text{rel}(d_j^i)} - 1}{\log_2(j + 1)} \right] \quad (2.8)$$

Donde $\text{rel}(d_j^i)$ es ahora la relevancia **graduada** asignada al documento d_j^i (por ejemplo, 0, 1, 2, ... según el nivel de relevancia) y $\log_2(j + 1)$ es el factor de descuento logarítmico que penaliza posiciones más profundas en el ranking, manteniendo la misma notación anterior para Q, n, i y j . En esta formulación, N_i cumple exactamente el papel de la **DCG ideal** para la consulta q_i : se corresponde con la **máxima DCG posible** dada la información disponible en los *Qrels*, obtenida ordenando idealmente los documentos conocidos como relevantes antes de calcular la suma interna; por tanto, N_i coincide con la **IDCG** clásica y permite escribir $\text{nDCG}_i = \frac{\text{DCG}_i}{\text{IDCG}_i}$ en el rango $[0, 1]$. El nDCG es una de las métricas más comunes en la evaluación de IR y QPP debido a su capacidad para manejar juicios de relevancia graduados y su sensibilidad al orden de los resultados [20].

2.3.3 Protocolos de evaluación de QPP y diseño experimental

La evaluación de los predictores de QPP sigue por lo general un protocolo experimental específico para garantizar que los resultados sean fiables, comparables e interpretables. El objetivo principal de este protocolo es medir qué tan bien las puntuaciones predichas por un método de QPP se correlacionan con el rendimiento real de un sistema de IR, medido por métricas como AP o nDCG.

Un diseño experimental típico implica varios componentes clave. Primero, se utiliza un conjunto de **colecciones de documentos** y **conjuntos de consultas** estandarizados, como los proporcionados por campañas de evaluación como TREC. Como se discutió anteriormente, el rendimiento de un predictor depende fuertemente del **tipo de colección** y de su nivel de “ruido” [8].

Las consultas se ejecutan utilizando uno o más **sistemas de recuperación de información** (o rankers), como BM25 o modelos neuronales. La efectividad real de cada consulta se calcula utilizando los juicios de relevancia (*Qrels*) disponibles y, en paralelo, se obtiene la puntuación predicha por el método de *QPP*. Sin embargo, como señala [2], el rendimiento observado para una consulta no se debe a una única causa, sino a la interacción de varios efectos. Por una parte, influye la **tarea o necesidad informativa** asociada al tópico: hay temas que, por la abundancia y claridad de los documentos relevantes, resultan intrínsecamente más fáciles que otros. También interviene la **formulación concreta de la consulta**, ya que dos variantes que expresan la misma necesidad pueden producir listas de resultados muy distintas según la elección de términos, su longitud o su ambigüedad. Finalmente, el propio **sistema de recuperación** introduce su efecto, puesto que distintos rankers responden de forma diferente ante la misma combinación de tarea y consulta. Si no se tienen en cuenta estos componentes, un predictor de *QPP* puede aparentar funcionar bien simplemente porque discrimina tareas fáciles y difíciles, sin capturar realmente la dificultad específica de una formulación de consulta para un sistema dado.

Finalmente, se comparan las dos listas de puntuaciones (la real y la predicha) utilizando métricas de correlación. Un marco de evaluación robusto no se basa en estimaciones puntuales, sino que a menudo utiliza técnicas como los análisis de significancia también como análisis de varianza (*ANOVA*) para modelar el rendimiento del predictor como una distribución, lo que permite un análisis estadístico más detallado y conclusiones más fiables [21].

2.3.4 Métricas de correlación para evaluar métodos QPP

El método estándar para cuantificar la efectividad de un predictor de QPP es medir la correlación entre la lista de puntuaciones de rendimiento predichas y la lista de puntuaciones de rendimiento reales (por ejemplo, AP o nDCG) para un conjunto de consultas. Dado que no se puede asumir que estas puntuaciones sigan una relación lineal o una distribución de probabilidad específica, se prefieren los **coeficientes de correlación de rangos**. Estos miden el grado de acuerdo entre dos ordenamientos, respondiendo a la pregunta: “¿si el predictor A es mejor que el predictor B, ¿se corresponde esto con un mejor rendimiento real?”.

Los tres coeficientes más comunes en la literatura de QPP son:

1. **Coeficiente de correlación de Pearson (r):** Es el único coeficiente paramétrico de los tres. Mide la **fuerza de la relación lineal** entre dos variables cuantitativas. Aunque es muy conocido, su uso en *QPP* debe ser cuidadoso. Es sensible a la magnitud de las diferencias y a los valores atípicos (*outliers*), y asume que los datos siguen una distribución normal bivariada. Como las métricas de rendimiento raramente cumplen con este supuesto, su aplicación requiere tests de normalidad previos para validar su aplicación. En términos formales, para un conjunto de n pares (x_i, y_i) con $i = 1, \dots, n$, se define en la Ecuación (2.9) como:

$$r = \frac{\sum_{i=1}^n (x_i - m_x)(y_i - m_y)}{\sqrt{\sum_{i=1}^n (x_i - m_x)^2 \sum_{i=1}^n (y_i - m_y)^2}} \quad (2.9)$$

Aquí, x_i y y_i representan las observaciones emparejadas de dos variables aleatorias (por ejemplo, altura y peso de una misma persona), mientras que m_x y m_y corresponden a sus medias muestrales.

2. **Coeficiente de correlación de rangos de Spearman (ρ):** Es una alternativa no paramétrica a Pearson. En lugar de usar los valores brutos, primero los convierte en rangos y luego calcula el coeficiente de Pearson sobre esos rangos. Por ello, mide la **fuerza de una relación monotónica** (es decir, si una variable tiende a aumentar cuando la otra lo hace, sin que la relación tenga que ser lineal). Es menos sensible a los *outliers* que Pearson, pero puede ser afectado por la presencia de muchos rangos empatados. En la práctica, ρ se obtiene aplicando la misma fórmula de Pearson sobre los rangos

$(R(x_i), R(y_i))$; cuando no hay empates, admite además la forma cerrada clásica presentada en la Ecuación (2.10):

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (2.10)$$

donde d_i representa, para cada observación i , la diferencia entre los rangos asignados a x_i e y_i , es decir, cuánto se desplaza la posición relativa del elemento i entre ambos ordenamientos. Cuando las dos listas coinciden perfectamente en su orden (máxima concordancia), todas las diferencias de rango valen cero y la suma de d_i^2 es nula, lo que produce $\rho = 1$; a medida que las posiciones relativas divergen, las diferencias de rango crecen, aumenta la suma de d_i^2 y el valor de ρ disminuye, reflejando menor acuerdo entre los rankings.

3. Coeficiente de correlación de rangos de Kendall (τ): Es una medida no paramétrica que se considera la más robusta de las tres para la evaluación de *QPP*. En lugar de considerar la magnitud o el rango, τ se basa en el número de **pares concordantes** y **discordantes** entre los dos rankings. Un par de observaciones (x_i, y_i) y (x_j, y_j) es concordante si el orden relativo de x_i y x_j coincide con el de y_i y y_j , y discordante si dicho orden se invierte. Debido a que se basa en conteos, no asume ninguna distribución de los datos, es robusta frente a valores atípicos y maneja bien los empates en los rankings. Su interpretación también es más directa: representa la diferencia entre la probabilidad de que dos elementos estén en el mismo orden y la probabilidad de que estén en órdenes diferentes. La variante τ_b de Kendall, que corrige por empates en ambas listas y es la que se utiliza habitualmente en *QPP*, se define en la Ecuación (2.11) como:

$$\tau_b = \frac{P - Q}{\sqrt{(P + Q + T)(P + Q + U)}} \quad (2.11)$$

Aquí, P y Q denotan el número de pares concordantes y discordantes entre los dos rankings, mientras que T y U cuentan los pares empatados solo en la primera o solo en la segunda lista, respectivamente. De este modo, τ_b mide el balance neto entre concordancias y discordancias, normalizado para corregir el efecto de los empates y mantener el coeficiente en el intervalo $[-1, 1]$.

En la práctica, Spearman y Kendall son generalmente preferidos sobre Pearson en la investigación de *QPP* por su naturaleza no paramétrica. Kendall's τ es a menudo el preferido por su robustez y su interpretación probabilística, aunque Spearman's ρ también se reporta comúnmente [22]

Finalmente, es crucial entender que una correlación estadísticamente significativa no siempre implica una mejora práctica. La investigación ha demostrado que una correlación, aunque sea alta (p. ej., > 0.5), puede no ser suficiente para que una aplicación como la expansión selectiva de consultas mejore de manera fiable el rendimiento del sistema. La utilidad real depende de la magnitud de esa correlación y del contexto de la aplicación, y

muchos predictores existentes no alcanzan el umbral de fiabilidad necesario en escenarios reales [10, 22].

CAPÍTULO III: TRABAJOS RELACIONADOS

La predicción del rendimiento de consultas (QPP) es un área de investigación importante dentro de los sistemas de recuperación de información, puesto que permite anticipar la calidad de los resultados de una consulta sin necesariamente ejecutarla de forma completa. Es así, que a lo largo de los años se han desarrollado numerosos métodos QPP con diferentes características y aptos para distintas situaciones, los que han sido evaluados exhaustivamente en una larga cantidad de estudios. Estos estudios no solo han definido métricas y herramientas para medir la efectividad de los métodos QPP, sino que también han desarrollado análisis comparativos (benchmarks) que sirven como referencia en el estado del arte dentro del área.

A continuación, se revisan estudios relevantes relacionados con la predicción del rendimiento de consultas, presentando los principales métodos utilizados en la literatura, para posteriormente, analizar el uso de datasets y entornos de experimentación para la comparación de métodos, destacando investigaciones previas que han servido como base para el diseño experimental de este proyecto.

3.1 Métodos de Predicción de Rendimiento de Consultas (QPP)

En el contexto de este proyecto, se priorizó la revisión de métodos de Query Performance Prediction que no dependen de enfoques basados en inteligencia artificial (IA), los cuales, clasificados como pre-retrieval y post-retrieval, son altamente valorados por su simplicidad y robustez en la predicción del rendimiento de consulta sirviendo como base para métodos QPP más complejos.

Es así como, durante la revisión de la literatura, se identificaron trabajos claves que evaluaron y desarrollaron diferentes métodos QPP en diferentes contextos, como búsquedas ad-hoc y benchmarks de recuperación de información, proporcionando métricas importantes para evaluar la calidad de las consultas, los cuales se presentan a continuación.

3.1.1 IDF (Frecuencia Inversa de Documentos)

El predictor Inverse Document Frequency (IDF), ampliamente utilizado en el área, puede de igual manera funcionar como predictor pre-retrieval en sistemas de recuperación de información, este mide que tan específicos son los términos de una consulta dentro de un corpus. En el documento [15], se profundiza su relevancia como un componente clave en la predicción del rendimiento de consultas (QPP), específicamente su capacidad para identificar términos altamente selectivos, es decir, aquellos que aparecen en pocos docu-

mentos (menos comunes) y, por ende, aportan mayor discriminación en la búsqueda. El IDF también puede ser utilizado en su variante IDF-Max, donde el término con la mayor frecuencia inversa dentro de una consulta sirve como indicador principal de su efectividad. Este indicador, que se basa en estadística, se adoptó rápidamente como una herramienta esencial en la predicción del rendimiento de consultas (QPP) pre-retrieval, siendo incorporada en otros esquemas y modelos probabilísticos de búsqueda.

La fórmula comúnmente utilizada del IDF en sistemas modernos, debido a su suavizado y estabilidad matemática, se define como:

$$IDF(t) = \ln\left(1 + \frac{N}{f_t}\right) \quad (3.1)$$

Donde N es el número total de documentos en el corpus y f_t es el número de documentos que contienen el término t , y se añade 1 para evitar divisiones por cero o valores indefinidos. En el artículo [16], el autor señala que el IDF asigna pesos más bajos a los términos frecuentes debido a su limitado poder discriminatorio, mientras que otorga pesos más altos a los términos menos comunes, los cuales poseen mayor capacidad para distinguir documentos relevantes, asegurando que los términos poco frecuentes, pero informativos, tengan un mayor impacto en el cálculo de relevancia. Además, se destaca que, aunque la formulación exacta del algoritmo puede variar según los autores, su utilidad general permanece sólida en una amplia gama de aplicaciones prácticas, incluyendo la recuperación de información y otros contextos relacionados con el análisis de datos.

De esta forma, el IDF ha sido ampliamente utilizado debido a su robustez y simplicidad. En el artículo [16], el autor argumenta que el IDF equilibra de forma eficaz la especificidad y la relevancia, permitiendo su aplicación en diferentes contextos, tales como recuperación de textos, análisis de lenguaje natural e incluso en recuperación de medios no textuales.

En cuanto a su relevancia para el presente proyecto de evaluación de métodos de QPP, el IDF resulta relevante, ya que su capacidad para capturar la especificidad de los términos yace de manera tacita en otros predictores QPP, además, como se menciona en el artículo [6], su integración en distintas métricas proporciona una línea base confiable para la comparación con métodos más avanzados, validando su referencia tanto de forma heurística como de herramienta teórica sólida y bien fundamentada.

3.1.2 SCQ (Similitud entre consulta y colección)

El método SCQ (Similarity Between a Query and a Collection), es un predictor pre-retrieval propuesto por Ying Zhao, Falk Scholer y Yohannes Tsegay. En el artículo [15] los autores

explican que el SCQ calcula un puntaje de similitud entre una consulta y la colección de documentos, utilizando la frecuencia de términos en la colección y la frecuencia inversa de documentos (IDF) como evidencias para determinar la relevancia. Siendo una de sus principales ventajas que se basa en estadísticas disponibles durante el proceso de indexado, eliminando la necesidad de realizar búsquedas previas.

La fórmula matemática que define al SCQ es la siguiente:

$$SCQ = \sum_{t \in Q} \left((1 + \ln(f_{c,t})) \cdot \ln \left(1 + \frac{N}{f_t} \right) \right) \quad (3.2)$$

Donde Q es el conjunto de términos de la consulta, $f_{c,t}$ corresponde a la frecuencia del término t en la colección, f_t es el número de documentos en los que aparece el término t , y finalmente N es el número total de documentos de la colección.

Como se menciona, el SCQ mide la similitud mediante una representación vectorial, donde tanto las consultas como los documentos son tratados como vectores. La proximidad entre estos vectores se interpreta como un indicador de relevancia que permite identificar consultas que potencialmente obtendrán un mejor rendimiento en la recuperación de información. Además, este predictor puede ajustarse mediante la normalización por longitud de la consulta o evaluarse en función del valor máximo de SCQ alcanzado por los términos individuales.

Es así como, gracias a su balance entre la simplicidad y precisión, el SCQ promete ser una herramienta útil para sistemas de recuperación de información que manejan grandes volúmenes de datos en tiempo real, en donde su capacidad para establecer relaciones entre las características de las consultas y su rendimiento lo convierte en una contribución importante para tareas que involucran una alta variabilidad en las consultas, posicionándose como un estándar en evaluaciones pre-retrieval.

Por lo tanto, para el presente proyecto, el SCQ es particularmente relevante porque permite analizar consultas en dominios complejos y heterogéneos, estableciendo una relación clara entre las características de las consultas y su rendimiento esperado, lo que facilita una evaluación comparativa de métodos.

3.1.3 NQC (Normalized Query Commitment)

El método NQC ("Normalized Query Commitment") fue propuesto por Anna Shtok, Oren Kurland y David Carmel como un predictor post-retrieval que evalúa la efectividad de una consulta midiendo la dispersión de los puntajes de recuperación entre los documentos más relevantes. En el artículo [17], los autores destacan que una menor dispersión temática en

los documentos recuperados está directamente asociada con una mayor efectividad de las consultas, lo cual se refleja en la distribución de los puntajes de recuperación.

Por lo tanto, el enfoque de NQC se centra en medir la desviación estándar de los puntajes de recuperación normalizados por el promedio del corpus, lo que permite identificar consultas cuyos documentos recuperados son consistentes en términos de relevancia, sugiriendo un buen desempeño de la consulta. Además, los autores explican que los documentos con puntajes significativamente superiores al promedio son menos propensos a exhibir desviaciones temáticas, lo que se traduce en un menor grado de “query drift” y un mejor rendimiento de recuperación.

El método NQC se define matemáticamente como:

$$NQC(q, M) = \frac{\sqrt{\frac{1}{k} \sum_{d \in D[k]_q} (Score(d) - \mu)^2}}{Score(D)} \quad (3.3)$$

En donde q corresponde a la consulta, M al modelo de recuperación, $D[k]_q$ a la lista de los k documentos mejor rankeados, μ al promedio de los puntajes de recuperación en $D[k]_q$ y $Score[D]$ al puntaje de recuperación del corpus considerado como un único documento concatenado.

NQC resulta especialmente útil en el ámbito de la recuperación de información debido a su capacidad para capturar la consistencia en documentos relevantes y su adaptabilidad a diferentes modelos de recuperación, siendo su diseño simple lo que permite aplicarlo de manera eficiente, incluso en escenarios complejos donde se requiere alta precisión en los resultados.

Para el presente proyecto, NQC es relevante al proporcionar una métrica que permite evaluar la calidad de las consultas al correlacionar la dispersión de los puntajes con la efectividad esperada, lo que es fundamental para analizar consultas en dominios con alta variabilidad y establecer comparaciones confiables entre los diferentes métodos de predicción.

3.1.4 Clarity Score (CS)

El método Clarity Score (CS) fue desarrollado por Steve Cronen-Townsend, Yun Zhou y W. Bruce Croft como un predictor post-retrieval que analiza la claridad o coherencia de las consultas en sistemas de recuperación de información. En el artículo [6], los autores explican que el CS se basa en la comparación entre un modelo de lenguaje generado a partir de una consulta y el modelo de lenguaje global del corpus, utilizando la divergencia

de Kullback-Leibler como herramienta matemática que permite calcular la distancia entre ambos modelos.

La lógica detrás de CS implica que consultas con términos más claros y específicos generarán modelos de lenguaje que se diferencian significativamente del modelo del corpus, obteniendo puntajes más altos. Estos términos, al estar menos expuestos a interpretaciones ambiguas, tienden a recuperar documentos más relevantes y precisos. Por otro lado, las consultas con puntajes más bajos suelen reflejar una mayor ambigüedad o dispersión temática, lo que puede afectar negativamente la precisión de los resultados recuperados.

Como se menciona, el CS se calcula como la divergencia de Kullback-Leibler entre el modelo de lenguaje de la consulta y el modelo de lenguaje de la colección:

$$CS(Q) = \sum_{w \in V} \left(P(w | Q) \log 2 \frac{P(w | Q)}{P_{coll}(w)} \right) \quad (3.4)$$

En donde w es un término en el vocabulario V , $P(w | Q)$ es la probabilidad del término w en el modelo de lenguaje de la consulta y $P_{coll}(w)$ es la probabilidad del término w en el modelo de lenguaje de la colección.

En términos prácticos, el CS demuestra ser una herramienta valiosa en el campo de la Recuperación de Información por varias razones fundamentales. En primer lugar, su capacidad para cuantificar la claridad de una consulta a través de la divergencia KL proporciona una medida objetiva de la especificidad de los términos de búsqueda. Además, al basarse en la comparación con el modelo de lenguaje de la colección completa, el método captura efectivamente las peculiaridades y la distribución del vocabulario en el dominio específico. Sin embargo, es importante señalar que su efectividad puede variar según las características del corpus y la naturaleza de las consultas, siendo particularmente útil en colecciones donde la ambigüedad terminológica representa un desafío significativo para la recuperación de información.

Finalmente, en el contexto del presente proyecto, el Clarity Score es relevante por su capacidad para proporcionar un indicador temprano sobre la calidad de las consultas, permitiendo evaluar cómo estas interactúan con el corpus y qué tan bien pueden desempeñarse en términos de recuperación efectiva, resultando crucial en escenarios donde la variabilidad y complejidad de las consultas pueden influir significativamente en los resultados esperados.

3.1.5 WIG (Weighted Information Gain)

El método Weighted Information Gain (WIG) fue desarrollado por Yun Zhou y W. Bruce Croft como un predictor post-retrieval diseñado para abordar los desafíos de la predicción del rendimiento de consultas en entornos de búsqueda web. En el artículo [14], los autores

destacan que WIG mide la contribución promedio de los documentos mejor clasificados a la calidad del rendimiento de la consulta, basándose en el análisis de las características individuales de los términos y su proximidad, lo que permite evaluar la efectividad de las consultas en colecciones grandes y heterogéneas.

El cálculo de WIG se realiza comparando el cambio en la información entre un estado inicial, representado por un documento promedio del corpus, y el estado posterior, que corresponde a los resultados obtenidos tras la recuperación de los documentos relevantes. Este enfoque utiliza conceptos como la ganancia de información ponderada y distribuciones de probabilidad para estimar la calidad de la consulta, lo que lo convierte en una herramienta robusta para analizar el desempeño en escenarios complejos.

En cuanto a su fórmula, WIG se define como la diferencia entre la entropía ponderada de los documentos mejor clasificados y la entropía del modelo de lenguaje de la colección, lo que es igual a:

$$WIG(Q) = \frac{1}{k} \sum_{d \in D_k} \left(P(Q | d) \log \frac{P(Q | d)}{P(Q | C)} \right) \quad (3.5)$$

En donde Q es la consulta, D_k es el conjunto de los k documentos mejor clasificados, $P(Q | d)$ es la probabilidad de la consulta Q dado el documento d , y $P(Q | C)$ es la probabilidad de la consulta Q dado el modelo de lenguaje de la colección.

Es así que, WIG es especialmente relevante debido a su capacidad para adaptarse a distintos tipos de consultas y colecciones, incluyendo aquellas con gran diversidad en calidad y estilo de los documentos, resultando crucial para evaluar la efectividad de las consultas, proporcionando una métrica sólida para comparar métodos avanzados de predicción del rendimiento y asegurando un análisis confiable en dominios variados.

3.1.6 UEF (Utility Estimation Framework)

El Utility Estimation Framework (UEF) fue desarrollado por Anna Shtok, Oren Kurland y David Carmel como un enfoque post-retrieval que utiliza principios de la teoría estadística de decisiones para predecir el rendimiento de consultas. En el artículo [18] los autores explican que este método evalúa la calidad de un ranking de documentos basándose en su utilidad estimada con respecto a la necesidad de información representada en la consulta, proceso que se realiza al medir la similitud esperada entre el ranking generado y los rankings inducidos por modelos de relevancia.

El marco UEF permite una gran flexibilidad al emplear diferentes métricas de similitud, como el coeficiente de correlación de Pearson, y al estimar modelos de relevancia utilizando pseudo-relevance feedback. Esta combinación proporciona una base teórica sólida

para predecir el rendimiento de consultas, ya que integra la precisión de los modelos de relevancia con un enfoque estructurado que captura las características del ranking generado por la consulta.

A continuación se observa la fórmula general del UEF:

$$U(\pi_M(q; D)) = \int_{R_q} Sim(\pi_M(R_q; D))p(R_q | I_q)dR_q \quad (3.6)$$

En donde, $\pi_M(q; D)$ corresponde al ranking generado por el modelo M , R_q al modelo de relevancia estimado basado en la consulta q , Sim es la medida de similitud entre rankings y $p(R_q | I_q)$ a la probabilidad de que R_q represente la necesidad de información subyacente I_q .

El UEF destaca por su fundamentación teórica en la teoría estadística de decisiones, lo que le permite estimar de manera robusta la utilidad esperada de un ranking. Su diseño matemático incorpora explícitamente la incertidumbre inherente en la estimación de relevancia a través de la distribución de probabilidad $p(R_q | I_q)$, mientras que la función de similitud Sim cuantifica la concordancia entre el ranking original y los rankings generados por los modelos de relevancia estimados.

Es así que el UEF representa un avance significativo en la predicción del rendimiento de consultas al proporcionar un marco teórico sólido que unifica diferentes aspectos de la recuperación de información. Su formulación matemática rigurosa, basada en principios estadísticos, permite una evaluación sistemática de la calidad de los rankings, considerando tanto la estructura de los resultados como la incertidumbre en la estimación de relevancia.

3.2 Estudios comparativos similares

En cuanto a la investigación de trabajos relacionados, también se identificaron estudios comparativos que evaluaron diferentes métodos QPP en escenarios diversos, los cuales son claves para establecer un marco comparativo que permita validar los resultados finales de este proyecto, además estos trabajos no solo permiten identificar fortalezas y debilidades de cada enfoque, sino que también establecen líneas base estandarizadas para validar nuevos métodos y enfoques más experimentales.

A continuación, se presentan los estudios relevantes que evaluaron métodos QPP como IDF, SCQ, Clarity Score, entre otros, destacando sus aportes al estado del arte del área y su influencia en el diseño de este proyecto.

3.2.1 QPPTK en TIREx

Un reciente estudio relevante para el presente proyecto es el desarrollado por Zendel, Fröbe y Faggioli en 2024, que proporciona una referencia fundamental al implementar y evaluar un marco de predicción del rendimiento de consultas (QPP) utilizando el Query Performance Prediction Toolkit (QPPTK) dentro de la plataforma TIREx. En este trabajo [4], los autores analizaron el desempeño de 12 métodos de predicción en combinación con diversos modelos de recuperación de información y 23 conjuntos de datos, incluyendo benchmarks reconocidos como TREC Robust04 y MS MARCO, por lo que, la amplitud de la evaluación y su enfoque en la reproducibilidad de los experimentos lo convierten en un recurso valioso para este proyecto.

Como se menciona, el estudio incluye una evaluación exhaustiva de métodos pre-retrieval, como IDF y SCQ, y post-retrieval, como NQC y Clarity Score, además, se demuestra cómo la evaluación cruzada en múltiples benchmarks permite identificar patrones de rendimiento y validar la generalización de los métodos seleccionados, enfoque que se destaca por la importancia de utilizar plataformas estandarizadas, como TIREx, que no solo permiten configurar entornos experimentales reproducibles, sino que también minimizan los sesgos potenciales en los resultados al estandarizar la configuración y los parámetros de los experimentos.

Una de las contribuciones clave del trabajo es la integración de QPPTK en TIREx, lo que facilita la realización de experimentos reproducibles, lo que se logra mediante la utilización de índices preconstruidos y configuraciones consistentes que garantizan estabilidad en las pruebas. Así mismo, los resultados generados son compartidos abiertamente, promoviendo su reutilización en futuros estudios, enfoque que resulta relevante para este proyecto, donde la reproducibilidad y la estandarización son fundamentales para garantizar la validez de las comparaciones entre métodos.

Es así que, los hallazgos de los autores, proporcionan métricas clave, como correlaciones entre predictores y métricas clásicas de recuperación, esenciales para validar los métodos implementados en este proyecto, además, su metodología y diseño experimental sirven como referencia directa para configurar los experimentos, asegurando que las evaluaciones sigan estándares establecidos en la literatura.

En resumen, este estudio no solo se destaca por la profundidad de su análisis, sino también por su contribución al establecimiento de prácticas experimentales reproducibles, que es en donde radica su relevancia para el proyecto presentado, ya que propone un diseño experi-

mental y proporciona un marco sólido para evaluar métodos de predicción del rendimiento de consultas en entornos complejos.

3.2.2 An Enhanced Evaluation Framework for Query Performance Prediction (2021)

Otro estudio destacado y relevante para el presente proyecto es el realizado por Guglielmo Faggioli et al. en 2021, quienes desarrollaron un marco de evaluación mejorado para la predicción del rendimiento de consultas (QPP), el cual aborda limitaciones clave de los enfoques tradicionales mediante la integración de análisis estadísticos avanzados y métricas diseñadas para evaluar, no solo la precisión, sino también la variabilidad y robustez de los métodos QPP en diferentes escenarios. Este marco supera las limitaciones de las evaluaciones basadas únicamente en correlaciones, como la dificultad para interpretar valores agregados únicos y la incapacidad para identificar consultas específicas donde los métodos fallan.

Es así que, en el artículo [21], los autores proponen un enfoque innovador que incluye métricas basadas en errores, como el Scaled Absolute Rank Error (SARE) y el Scaled Mean Absolute Rank Error (sMARE), las cuales permiten medir el error de predicción de manera distribuida por consulta. Además, incorporan técnicas estadísticas avanzadas, como el análisis de varianza (ANOVA) y pruebas post hoc para evaluar las diferencias entre métodos con mayor detalle. Estas herramientas permiten no solo comparar la precisión de los predictores, sino también analizar la influencia de factores como el tema de la consulta, el método de recuperación y la configuración de stemming en el rendimiento del QPP.

Como se menciona, el artículo se destaca por su enfoque en la medición de errores distribuidos por consulta, lo que permite un análisis más granular del desempeño de los métodos, en donde se realizaron experimentos en conjuntos de datos estándar como TREC Robust-04, utilizando métodos pre-retrieval, como MaxIDF y SCQ, y post-retrieval, como NQC y Clarity Score, cuyos resultados revelaron que factores como el modelo de recuperación, la configuración de stemming y “stoplists”, y la naturaleza de las consultas influyen significativamente en el rendimiento del QPP. Por ejemplo, se observó que los métodos post-retrieval, como NQC y Clarity, tienden a tener una correlación más alta con la precisión promedio (AP), mientras que los métodos pre-retrieval, como MaxIDF, pueden ser más robustos en ciertos escenarios. Estos hallazgos proporcionan información valiosa para optimizar estos sistemas y seleccionar el método más adecuado según la situación.

En el contexto del presente proyecto, el marco propuesto por los autores es importante, ya que introduce prácticas de evaluación reproducibles y detalladas, alineadas con estándares modernos, además de que, sus hallazgos sobre la interacción de factores experimentales y el rendimiento del QPP sirven como guía directa para configurar experimentos que sean

estadísticamente sólidos y representativos en escenarios reales. Por ejemplo, el uso de ANOVA y pruebas post hoc permite identificar no solo qué métodos son superiores en general, sino también en qué condiciones específicas (como ciertos tipos de consultas o configuraciones) un método puede ser mejor que otro, lo que es particularmente útil en aplicaciones prácticas donde la variabilidad de las consultas y los documentos es alta, como en motores de búsqueda web y sistemas de recomendación.

En resumen, el trabajo de los autores, no solo proporciona un marco metodológico avanzado para la evaluación de QPP, sino que también ofrece insights prácticos sobre cómo optimizar estos sistemas en función de factores contextuales, lo que lo convierte en una referencia clave para el presente proyecto, especialmente en la fase de diseño experimental y evaluación de métodos de predicción de rendimiento de consultas.

CAPÍTULO IV: DISEÑO DE LA EVALUACIÓN COMPARATIVA

El diseño de esta evaluación comparativa no solo tiene como propósito validar la implementación técnica de los métodos QPP seleccionados, sino también establecer líneas base que permitan analizar sus fortalezas y limitaciones en contextos variados propios de los sistemas de recuperación de información. Para ello, se consideraron criterios sólidos y alineados con las mejores prácticas del estado del arte, garantizando la representatividad y el rigor del análisis comparativo.

La necesidad de un diseño comparativo sólido radica en la creciente complejidad de los sistemas de recuperación de información y la diversidad de escenarios en los que estos se aplican. Como señala [4], uno de los desafíos fundamentales en la investigación de QPP radica en la falta de reproducibilidad y estabilidad de los resultados experimentales, debido en parte a la variabilidad en las configuraciones de los sistemas de recuperación y en los conjuntos de datos utilizados. Esta variabilidad justifica la adopción de un marco experimental que utilice múltiples datasets representativos de diferentes dominios y tipos de consultas, emplee herramientas estandarizadas que garanticen la reproducibilidad, y aplique métricas de evaluación ampliamente aceptadas en la literatura. El diseño experimental propuesto sigue las recomendaciones de estudios recientes que enfatizan la importancia de establecer líneas base estables y reproducibles para futuras comparaciones. [4, 21]

En el presente proyecto, el diseño de la evaluación comparativa no solo busca responder preguntas específicas sobre el rendimiento de los métodos seleccionados, sino también contribuir al avance del estado del arte en QPP, estableciendo un marco que promueva prácticas experimentales reproducibles, transparentes y aplicables a diversos contextos, garantizando que los hallazgos obtenidos sean relevantes tanto para la comunidad científica como para la práctica en sistemas de recuperación de información.

4.1 Protocolo de evaluación experimental

En esta sección se describe el protocolo de evaluación desarrollado para llevar a cabo la evaluación comparativa de los métodos de Query Performance Prediction (QPP). A continuación se presenta el flujo general de los experimentos, las métricas empleadas para la evaluación, y las configuraciones técnicas específicas del entorno experimental.

El entorno experimental está diseñado para garantizar la reproducibilidad, flexibilidad y transparencia. Para lograrlo, se ha implementado un entorno basado en capas, y reproducible en Docker, que permite ejecutar los experimentos de manera consistente y controlada, sin depender de configuraciones específicas de hardware o software.

4.1.1 Paradigma de evaluación de métodos QPP

Antes de describir el flujo del sistema, es fundamental formalizar el paradigma de evaluación estándar utilizado en la literatura para cuantificar la calidad de los métodos de Query Performance Prediction (QPP). Este marco conceptual constituye la base teórica del diseño experimental.

El paradigma de evaluación se modela a partir de los siguientes componentes fundamentales:

1. **Contexto de Recuperación:** En la Ecuación (4.2), $\mathcal{C}$ es una colección de documentos y $\mathcal{Q} = \{q_1, \dots, q_n\}$ un conjunto de n consultas de evaluación. Dado un sistema de recuperación S (ranker), la ejecución de una consulta $q_i \in \mathcal{Q}$ sobre el corpus genera una lista ordenada de documentos L_i :

$$L_i = S(q_i, \mathcal{C}) \quad (4.2)$$

2. **Ground Truth (Efectividad Real):** Para cada consulta q_i , existe un conjunto de juicios de relevancia R_i (qrels). Como se define en la Ecuación (4.4), la efectividad real del sistema para dicha consulta, denotada como $m_S(q_i)$, se obtiene aplicando una métrica de evaluación $\mathcal{M}$ (como AP o nDCG) sobre la lista recuperada:

$$m_S(q_i) = \mathcal{M}(L_i, R_i) \quad (4.4)$$

El conjunto de valores de efectividad para todas las consultas conforma el vector de desempeño real $\vec{m}_S \in \mathbb{R}^n$:

$$\vec{m}_S = [m_S(q_1), m_S(q_2), \dots, m_S(q_n)]^\top \quad (4.6)$$

3. **Predicción de Rendimiento:** Un método QPP se define como una función estimadora φ que asigna un puntaje a cada consulta, intentando aproximar su dificultad. Según la Ecuación (4.8), el vector de predicciones $\vec{\varphi} \in \mathbb{R}^n$ se construye calculando:

$$\vec{\varphi} = [\varphi(q_1), \varphi(q_2), \dots, \varphi(q_n)]^\top \quad (4.8)$$

Dependiendo del tipo de predictor, la función $\varphi(q_i)$ puede depender solo de la consulta y el corpus (pre-retrieval) o también de la lista recuperada L_i (post-retrieval).

4. **Evaluación de la Calidad:** Finalmente, la calidad del predictor P se cuantifica midiendo la asociación estadística entre el desempeño real y el predicho. Esto se formaliza en la Ecuación (4.10) mediante una función de correlación (típicamente Pearson ρ o Kendall τ):

$$\text{Calidad}(P) = \text{Corr}(\vec{m}_S, \vec{\varphi}) \quad (4.10)$$

El objetivo experimental es, por tanto, encontrar un predictor φ^* tal que maximice esta correlación, tal como se expresa en la Ecuación (4.12):

$$\varphi^* = \arg \max_{\varphi} \text{Corr}(\vec{m}_S, \vec{\varphi}) \tag{4.12}$$

Una alta correlación positiva indica que el predictor es capaz de ordenar las consultas de manera similar a su rendimiento real, permitiendo distinguir fiablemente entre consultas “difíciles” y “fáciles” par el sistema S . [17]

Formalmente, el protocolo implementado ejecuta este flujo:

- Se obtiene $\vec{m}_S$ ejecutando las consultas en BM25 y evaluando con AP@1000.
- Se obtiene $\vec{\varphi}$ para cada uno de los 12 predictores seleccionados.
- Se calcula ρ y τ entre ambos vectores para determinar la validez de cada método.

4.1.2 Flujo del sistema




Figura 4.1: Diagrama de componentes del entorno de evaluación

Como se puede apreciar en la Figura 4.1, el diseño experimental sigue un flujo bien definido en el contexto de la recuperación de información, garantizando su entendimiento, reproducibilidad y el análisis riguroso de los resultados. El flujo incluye los siguientes pasos principales:

- **Preparación de Datasets:** Los datasets seleccionados, como Cranfield o Antique, se descargan de manera completa utilizando la librería *ir_datasets* y se preprocesan en el entorno *Docker*, este proceso incluye la extracción de consultas, preparación de los juicios de relevancia (*Qrels*) y el formateo adecuado para su uso con *PyTerrier*.

- **Indexado de Datasets:** Los datasets se indexan utilizando *PyTerrier*, creando estructuras de datos eficientes para la recuperación de información. Es también en este paso donde se guardan metadatos de los datasets, como la frecuencia de los términos en los documentos como la frecuencia de estos en la colección. Además, se hace uso del “*Stemmer*” de *Snowball* sobre los documentos y consultas, para conseguir resultados más precisos en la evaluación.
- **Configuración de Modelos de Recuperación:** Configuración de modelos de recuperación como estándar como *BM25* en *PyTerrier* con parámetros predefinidos, asegurando una base consistente para la evaluación de los métodos *QPP*.
- **Implementación de los métodos *QPP*:** Los métodos seleccionados, como, por ejemplo, *IDF*, *SCQ* o *NQC*, se implementan mediante scripts en *Python* dentro del contenedor *Docker*, todos estos utilizan una interfaz similar dentro del sistema, permitiendo una ejecución estandarizada de los métodos.
- **Ejecución de los métodos de predicción:** Los experimentos se realizan mediante un script principal que realiza múltiples iteraciones por método y dataset, asegurando estabilidad y fiabilidad de los resultados.
- **Evaluación utilizando juicios de relevancia (*Qrels*):** Se realiza una evaluación del rendimiento de las consultas utilizando la librería de *ir_measures* sobre el sistema de recuperación implementado, esto es el “*ground truth*” del rendimiento de la consulta en el sistema de recuperación implementado. Posteriormente los resultados se almacenan en formato estructurado para su posterior análisis.
- **Evaluación utilizando métricas de correlación:** Se realiza una evaluación de la correlación entre los puntajes de los predictores y las métricas IR, utilizando la librería de *Scipy*, para obtener una medida de la efectividad de los predictores *QPP* con relación al “*ground truth*”.
- **Documentación y Almacenamiento:** Los resultados, configuraciones y scripts de ejecución se almacenan en directorios organizados dentro del contenedor *Docker*, garantizando su fácil acceso y análisis.

Entre los componentes de la Figura 4.1, se puede discernir la capa de datos, de indexación y recuperación. Estos componentes funcionan completamente dentro de la librería *Pyterrier*, el cual funciona como un *wrapper* para la librería *Terrier*, la cual es ampliamente utilizada en la literatura de recuperación de información para la realización de experimentos similares. [23]

4.1.3 Configuración técnica

- **Entorno *Docker*:** Al permitir encapsular todas las dependencias necesarias en un entorno reproducible, se evitan problemas de compatibilidad y configuración entre máquinas, asegurando que los experimentos puedan ser ejecutados de manera uni-

forme y reproducible. Esta decisión de diseño se alinea con las recomendaciones del QPPTK, cuya arquitectura permite delegar aspectos secundarios como la configuración del sistema de recuperación o el procesamiento del corpus a salidas cacheadas, permitiendo que los investigadores se enfoquen exclusivamente en el desarrollo y evaluación de métodos QPP. [4]

El sistema utiliza una imagen base de *Python 3.9* con *Java 11* instalado para soportar PyTerrier.

- Parámetros del Modelo de Recuperación:** El sistema utiliza el modelo de recuperación *BM25* (*Best Match 25*) como método principal de recuperación. La elección de *BM25* como modelo base sigue la práctica estándar en la literatura de QPP, donde los análisis experimentales comúnmente emplean *BM25* para garantizar la comparabilidad con estudios previos. [4, 17] Esta decisión permite que los resultados obtenidos puedan ser directamente contrastados con trabajos anteriores y establece una línea base estable para la evaluación de los predictores. Los parámetros han sido mantenidos en su configuración por defecto, como se observa en la Tabla 4.1

Tabla 4.1: Parámetros principales de BM25

Parámetro	Descripción	Justificación de Aplicación	Valor
k1	Factor de saturación de término. Controla cómo el score de un documento aumenta con cada ocurrencia adicional de un término de la consulta. Un valor más alto significa que se da más importancia a la frecuencia del término.	Crucial para colecciones con documentos que contienen repeticiones significativas de términos. Afecta directamente el cálculo de scores en métodos QPP post-recuperación como WIG.	1.2
b	Factor de normalización de longitud del documento. Determina cuánto se penalizan los documentos más largos. Un valor más alto significa una normalización más agresiva de la longitud.	Especialmente importante en colecciones heterogéneas como <i>ANTIQUE</i> donde la longitud de los documentos varía significativamente. Impacta el cálculo de NQC al normalizar los scores.	0.75

Otros estudios han propuesto la utilización de otros parámetros para BM25, como el parámetro k_1 , el cual controla la saturación de términos en los documentos, sobretodo al utilizar métodos de clustering, tales experimentos han demostrado que un valor de k_1 mayor a 1.2 puede mejorar el rendimiento de la recuperación. Sin embargo, en este estudio se mantendrán los parámetros por defecto de PyTerrier, ya que se ha demostrado que estos proporcionan un rendimiento adecuado para la mayoría de las tareas de recuperación de información, pero se puede realizar un estudio futuro sobre la utilización de estos parámetros en la evaluación de métodos QPP. [24]

- **Ejecución de los métodos y scripts de evaluación:**La Tabla 4.2 sistema permite una configuración flexible de la ejecución de la evaluación a través de diversos parámetros que controlan tanto el proceso de recuperación como la evaluación QPP. La configuración se realiza principalmente mediante argumentos de línea de comandos y variables de entorno.

Tabla 4.2: Parámetros principales de configuración

Parámetro	Descripción	Valor por defecto
-datasets	Datasets a evaluar (e.g., antique_test, trec_covid, msmarco_dl20_judged)	Todos los datasets
-max-queries	Límite de consultas a procesar	None (todas)
-list-size	Tamaño de lista para métricas de ranking	10
-wig-list-size	Tamaño de lista para el predictor WIG	5
-nqc-list-size	Tamaño de lista para el predictor NQC	200
-num-results	Número máximo de resultados por consulta	1000
-metrics	Métricas de evaluación (e.g., ndcg@10, ap)	nDCG@10, AP
-correlations	Coeficientes de correlación a calcular (Kendall, Spearman, Pearson)	kendall
-use-uef	Habilita las variantes utilizando el marco UEF (Utility Estimation Framework)	True
-skip-plots	Omite la generación de visualizaciones	False
-output-dir	Directorio de salida para los resultados	None

La ejecución se puede realizar tanto directamente a través de Python como mediante contenedores *Docker*, donde los parámetros se configuran a través de variables de entorno. El sistema utiliza valores por defecto seleccionados para garantizar una evaluación robusta incluso con configuración mínima.

- **Almacenamiento de Resultados:**

Los resultados de la evaluación se almacenan en una estructura organizada dentro del directorio del proyecto. Las métricas de IR (nDCG, AP) se guardan por consulta en archivos de texto plano, mientras que las correlaciones entre predictores QPP y métricas se almacenan en formato tabular, acompañadas de visualizaciones (diagramas de caja y de dispersión) generadas automáticamente.

La evaluación final integra estos resultados mediante un análisis bidimensional: Primero midiendo la efectividad del sistema de recuperación base, medida a través de las métricas IR por consulta, y luego midiendo la capacidad predictiva de los métodos QPP, cuantificada mediante coeficientes de correlación por rangos entre los puntajes de los predictores y las métricas IR. Una mayor correlación significa que los puntajes de los predictores son confiables para predecir el rendimiento del sistema de recuperación.

- **Métricas Utilizadas:**

Para el desarrollo de esta evaluación se optó por el uso de métricas de evaluación que cuentan con una presencia amplia en la literatura, por un lado se decantó por el uso nDCG y MAP, las cuales son ampliamente utilizadas en tareas de ranking y precisión proporcionan una medida del rendimiento del sistema de recuperación. Por otro lado, se decantó por el uso de métricas de correlación para la predicción de rendimiento de consultas, como el coeficiente de correlación de Kendall y Spearman, las cuales son ampliamente utilizadas en la literatura y proporcionan una medida de la efectividad de los predictores QPP. [22]

En el contexto de la evaluación de sistemas de recuperación de información, las métricas binarias como Average Precision (**AP**) requieren una distinción clara entre documentos relevantes y no relevantes. Para lograr esto, se establece un umbral binario sobre los niveles de relevancia originales del dataset, donde los documentos con un nivel de relevancia igual o superior al umbral se consideran relevantes, mientras que aquellos por debajo se consideran no relevantes. Este enfoque permite evaluar el rendimiento del sistema en términos de su capacidad para distinguir entre documentos relevantes y no relevantes.

Por otro lado, las métricas graduadas como el Normalized Discounted Cumulative Gain (nDCG) aprovechan la naturaleza multi-nivel de los juicios de relevancia mediante valores de ganancia. Estos valores representan la utilidad o importancia relativa de cada nivel de relevancia, donde un valor más alto indica una mayor relevancia del documento. La asignación de valores de ganancia es crucial ya que influye directamente en cómo la métrica

evalúa la calidad del ranking, penalizando más severamente cuando documentos altamente relevantes (con mayor valor de ganancia) aparecen en posiciones más bajas del ranking. En la Tabla 4.3 se detalla la configuración específica de relevancia y valores de ganancia para cada dataset:

Tabla 4.3: Configuración de métricas por dataset

Dataset	Configuración	Justificación
Cranfield Collection	• Relevancia: 5 niveles (-1 a 4) • Umbral binario: ≥ 1 • Valores de ganancia: ▸ Nivel -1: 0 (Sin interés) ▸ Nivel 1: 1 (Interés mínimo) ▸ Nivel 2: 2 (Referencia útil) ▸ Nivel 3: 3 (Alta relevancia) ▸ Nivel 4: 4 (Respuesta completa)	Escala graduada clásica que permite distinguir desde documentos sin interés hasta respuestas completas. Ideal para experimentos controlados.
ANTI- QUE	• Relevancia: 4 niveles (1-4) • Umbral binario: ≥ 3 • Valores de ganancia: ▸ Nivel 1: 0 (Fuera de contexto) ▸ Nivel 2: 1 (No relevante) ▸ Nivel 3: 2 (Marginal) ▸ Nivel 4: 3 (Altamente relevante)	Escala granular para preguntas subjetivas. Los niveles 1-2 se consideran no relevantes para métricas binarias.
TREC- COVID	• Relevancia: 4 niveles (-1 a 2) • Umbral binario: ≥ 1 • Valores de ganancia: ▸ Nivel -1: 0 (No evaluado/negativo) ▸ Nivel 0: 0 (No relevante) ▸ Nivel 1: 1 (Relevante) ▸ Nivel 2: 2 (Altamente relevante)	Incluye nivel -1 para documentos no evaluados. Permite distinguir información COVID-19 de alta relevancia.
MS MAR- CO Passa-	• Relevancia: 4 niveles (0-3) • Umbral binario: ≥ 2	Umbral binario en ≥ 2 siguiendo la práctica oficial

ge (TREC DL 2020)	• Valores de ganancia: ▸ Nivel 0: 0 (Irrelevante) ▸ Nivel 1: 1 (Relacionado) ▸ Nivel 2: 2 (Altamente relevante) ▸ Nivel 3: 3 (Perfectamente relevante)	de TREC. Escala graduada para nDCG.
TREC CAR	• Relevancia: 6 niveles (-2 a 3) • Umbral binario: ≥ 1 • Valores de ganancia: ▸ Nivel -2: 0 (Basura) ▸ Nivel -1: 0 (No relevante) ▸ Nivel 0: 0 (No relevante, tema cercano) ▸ Nivel 1: 1 (Puede mencionarse) ▸ Nivel 2: 2 (Debería mencionarse) ▸ Nivel 3: 3 (Debe mencionarse)	Escala detallada con juicios manuales. Incluye niveles negativos para contenido basura o irrelevante.

Para el análisis de correlación, el sistema implementa tres coeficientes (τ -Kendall, ρ -Spearman, r -Pearson), pero prioriza τ -Kendall por:

- **Interpretabilidad:** Mide directamente la proporción de pares concordantes vs discordantes
- **Robustez:** Menos sensible a valores atípicos y transformaciones monótonas
- **Normalización:** Rango consistente $[-1,1]$ independiente de la distribución
- **Significancia:** Mejor comportamiento con muestras pequeñas

La elección de estas métricas de correlación está fundamentada en las prácticas estándar del campo de QPP. Como documentan Shtok et al. [17], existen dos medidas de evaluación comúnmente utilizadas en el marco de predicción de rendimiento de consultas: el coeficiente de correlación de Pearson (ρ), que se calcula entre los valores de Average Precision reales y los valores asignados por el método de predicción, y el coeficiente de correlación τ de Kendall, que se calcula entre un ranking de consultas ordenadas por su AP real y un ranking inducido por los valores del predictor. Para ambas métricas, valores de correlación más altos indican una mayor calidad de predicción. [17]

De igual forma, Tao y Wu [13] validan este enfoque metodológico al evaluar la calidad de predicción mediante ambos coeficientes: la correlación de Pearson mide la correlación lineal entre dos variables en un rango de $[-1,1]$, mientras que τ de Kendall mide la asociación entre dos cantidades medidas, donde 1 denota que los dos rankings son idénticos y -1 indica que uno es el inverso del otro.

Además, dentro de la literatura se ha discutido sobre el rendimiento e interpretabilidad de otros coeficientes, como el coeficiente de correlación de Pearson, el cual es menos robusto que τ -Kendall y Spearman, y su uso ha sido desestimado en favor de las anteriormente mencionadas. [8] El marco de evaluación mejorado propuesto por Faggioli et al. [21] sugiere además modelar el rendimiento de QPP como una distribución en lugar de depender de estimaciones puntuales, lo que proporciona implicaciones estadísticas importantes y supera limitaciones del enfoque tradicional basado únicamente en correlaciones.

La implementación utilizará la librería `ir_measures` para garantizar cálculos estandarizados de las métricas IR, mientras que Scipy proporciona implementaciones eficientes de los coeficientes de correlación. El sistema maneja automáticamente casos especiales como queries sin resultados o scores QPP indefinidos, asegurando una evaluación robusta incluso en condiciones no ideales.

4.2 Selección de conjuntos de datos

La selección de datasets es parte fundamental para garantizar una evaluación comparativa robusta y representativa de los métodos *QPP*, es por ello, que se seleccionaron datasets reconocidos en la literatura, priorizando los que ofrecen juicios de relevancia *Qrels* y métricas estandarizadas, permitiendo así validar el desempeño de los métodos seleccionados en escenarios variados.

Además, investigaciones como [17] han validado sus metodologías utilizando colecciones *TREC* ampliamente reconocidas incluidas en esta evaluación, las cuales han sido empleadas en numerosos estudios de predicción de rendimiento de consultas, permitiendo un análisis profundo de la calidad de predicción y el estudio de diversos factores que afectan a los predictores. Este enfoque garantiza no solo la robustez de los resultados, sino también su generalización a futuros trabajos relacionados con QPP.

4.2.1 Criterios de inclusión

En la Tabla 4.4 se presentan los criterios aplicados en la selección de datasets, detallando su importancia en el contexto del proyecto.

Tabla 4.4: Criterios de inclusión de datasets

Criterio	Descripción	Importancia para el proyecto
Disponibilidad pública	Datasets de acceso abierto y bien documentados, sin restricciones para su uso.	Garantiza la reproducibilidad y facilita la implementación en diversos contextos.
Diversidad de escenarios	Representación de diferentes tipos de consultas (informacionales, navegacionales y transaccionales) y dominios.	Asegura la evaluación integral de los métodos en múltiples contextos.
Uso en el estado del arte	Amplio uso en investigaciones previas de recuperación de información y QPP.	Respalda la validez y comparabilidad de los resultados obtenidos.
Tamaño adecuado	Incluye tanto datasets pequeños como grandes.	Permite evaluar el comportamiento de los métodos en diferentes escalas de datos.
Relevancias conocidas (Qrels)	Incluyen juicios de relevancia establecidos previamente.	Facilitan la evaluación precisa y objetiva del desempeño de los métodos QPP.

- **Disponibilidad pública** : Es fundamental seleccionar datasets de acceso abierto que estén bien documentados, ya que esto garantiza la transparencia y la reproducibilidad de los experimentos, la disponibilidad pública también asegura que los resultados puedan ser validados por otros investigadores, fomentando la colaboración y el avance en el campo del QPP.
- **Diversidad de escenarios**: Incluir datasets con diferentes tipos de consultas es crucial para evaluar cómo se desempeñan los métodos QPP en escenarios reales, por ejemplo de consultas informacionales: preguntas abiertas donde el usuario busca adquirir conocimiento general; consultas navegacionales: consultas donde el objetivo es encontrar una página específica; y consultas transaccionales: consultas

orientadas a completar una acción. Esta diversidad asegura que los métodos sean efectivos en una variedad de tareas de recuperación, desde búsquedas generales hasta necesidades específicas.

- **Uso en el estado del arte:** Seleccionar datasets ampliamente utilizados en investigaciones previas permite que los resultados del proyecto sean comparables con estudios existentes, lo que refuerza la validez del análisis comparativo y asegura que las metodologías empleadas cumplan con estándares científicos.
- **Tamaño adecuado:** La inclusión de datasets de diferentes tamaños permite evaluar el comportamiento de los métodos en escenarios con distintos volúmenes de datos, en donde los datasets pequeños son ideales para pruebas controladas y rápidas, mientras que los grandes, son útiles para analizar la escalabilidad y robustez de los métodos. Este enfoque asegura que los métodos QPP seleccionados sean evaluados en condiciones que reflejen tanto la simplicidad como la complejidad de los sistemas de recuperación de información modernos.
- **Relevancias conocidas (qrels):** Los juicios de relevancia son esenciales para evaluar el desempeño de los métodos de manera objetiva, al incluir datasets con qrels bien establecidos, se garantiza que los resultados estén basados en un marco estandarizado, facilitando su interpretación y comparación

Es así como la aplicación de estos criterios garantiza que los datasets seleccionados sean adecuados para el análisis comparativo de los métodos QPP, de igual forma, al priorizar la diversidad, relevancia y representatividad, este proyecto establece una base sólida para evaluar el desempeño de los métodos en diferentes contextos y escalas, contribuyendo al avance del estado del arte en predicción del rendimiento de consultas.

4.2.2 Justificación de los conjuntos de datos seleccionados

Como se ha mencionado, los datasets seleccionados para el proyecto fueron escogidos cuidadosamente para garantizar que cubran una amplia gama de escenarios y dominios representativos, por lo que se alinean con los criterios de inclusión previamente establecidos, aportando características únicas que permiten evaluar el rendimiento de QPP en contextos diversos, asegurando resultados generalizables y relevantes para investigaciones futuras, además de contribuir al avance del estado del arte.

Un criterio fundamental en la selección fue la preferencia por datasets con juicios de relevancia multi-nivel (*graded relevance judgments*). Esta decisión se fundamenta en las siguientes ventajas:

- **Anotaciones manuales de alta calidad:** Los qrels de múltiples niveles son típicamente anotados por evaluadores expertos o jueces especializados, lo que garantiza una mayor precisión y consistencia en los juicios de relevancia.
- **Significado semántico por nivel:** Cada nivel de relevancia tiene un significado específico y definido (por ejemplo, “no relevante”, “parcialmente relevante”, “altamente relevante”), lo que permite una evaluación más matizada del rendimiento.
- **Compatibilidad con métricas graduadas:** Los juicios multi-nivel permiten el uso de métricas con factores de ganancia como nDCG que aprovechan la granularidad de las anotaciones, proporcionando una evaluación más completa del sistema de recuperación.

A continuación, se presenta la Tabla 4.5 con los datasets seleccionados, seguida de la Tabla 4.6 que detalla los metadatos técnicos de cada colección, incluyendo el origen de sus consultas y juicios de relevancia.

Tabla 4.5: Tabla de datasets y sus criterios de inclusión

Dataset	Descripción	Contribución al proyecto	Razón de inclusión
Cranfield Collection	Dataset clásico con resúmenes científicos y consultas pre-determinadas de tamaño reducido.	Facilita pruebas rápidas y controladas para la comparación directa de métodos QPP.	Simplicidad y diseño compacto lo hacen ideal para experimentos iniciales y controlados.
ANTIQUE	Dataset centrado en la recuperación de preguntas y respuestas subjetivas basadas en opiniones.	Evalúa el desempeño de los métodos frente a consultas subjetivas y no factuales.	Introduce complejidad adicional al incorporar preguntas subjetivas difíciles de modelar.
TREC-COVID	Parte del benchmark BEIR, centrado en la recuperación de información médica sobre COVID-19.	Permite evaluar los métodos QPP en un dominio altamente especializado y relevante.	Su enfoque en consultas científicas lo hace adecuado para escenarios de alta especificidad.
MS MARCO Passage (TREC DL 2020)	Subconjunto del MS MARCO Passage utilizado en TREC	Proporciona un entorno realista para evaluar la aplicabili-	Refleja el contexto de búsqueda cotidiana con anotaciones

Dataset	Descripción	Contribución al proyecto	Razón de inclusión
	Deep Learning 2020 con juicios oficiales.	dad práctica de los métodos.	de relevancia detalladas.
TREC CAR	Dataset del TREC CAR v1.5 Year 1 con juicios de relevancia manuales.	Proporciona evaluación con juicios humanos detallados en escala graduada.	Incluye juicios negativos explícitos que permiten un análisis más profundo.

Tabla 4.6: Metadatos técnicos de los datasets seleccionados

Dataset	Variante ir_datasets	Documen- tos	Consultas	Qrels	Origen de Anotaciones
Cranfield	cranfield	1,400	225	1,837	Expertos en aerodinámica (1960s)
ANTIQUE	antique/ test	403,666	200	6,589	Crowdworkers (Amazon MTurk)
TREC-COVID	beir/trec-covid	171,332	50	66,336	Asesores NIST (expertos médicos)
MS MARCO DL 2020	msmarco-passage/trec-dl-2020/judged	8,841,823	54	11,386	Asesores NIST (TREC DL 2020)
TREC CAR	car/v1.5/trec-y1/manual	29,678,367	2,287	29,571	Asesores NIST (juicios manuales)

A continuación se presenta un análisis detallado de cada dataset, incluyendo información sobre el origen de sus documentos, consultas y juicios de relevancia:

Cranfield Collection

La colección Cranfield representa uno de los hitos fundacionales en la historia de la recuperación de información. Desarrollada entre 1958 y 1966 en el Cranfield Institute of Technology (actualmente Cranfield University) en el Reino Unido, bajo la dirección de Cyril Cleverdon, constituye el primer intento sistemático de evaluar sistemas de recuperación de información bajo condiciones controladas.

- **Documentos:** La colección consta de 1,400 resúmenes científicos en el dominio de la aerodinámica. Cada documento incluye campos de identificador, título, texto del abstract, autor y referencia bibliográfica.
- **Consultas:** Las 225 consultas fueron formuladas en lenguaje natural por investigadores del área, representando necesidades de información reales del dominio científico.
- **Origen de Qrels:** Los juicios de relevancia fueron anotados manualmente por expertos en aerodinámica, estableciendo una escala de 5 niveles (-1 a 4). Estos juicios introdujeron el concepto de “relevance judgments” que se convertiría en estándar para la evaluación de IR. La distribución incluye: 225 juicios de nivel -1, 128 de nivel 1, 387 de nivel 2, 734 de nivel 3, y 363 de nivel 4.
- **Importancia histórica:** Los experimentos de Cranfield establecieron el “paradigma Cranfield” que incluye una colección de documentos, un conjunto de consultas con juicios de relevancia asociados, y evaluación basada en precisión y recall, metodología que posteriormente adoptaría TREC.

ANTIQUE (A Non-factoid Question Answering Benchmark)

ANTIQUE es un benchmark diseñado específicamente para la recuperación de respuestas no factuales, desarrollado por investigadores de la Universidad de Massachusetts Amherst y publicado en 2019 [25].

- **Documentos:** La colección contiene 403,666 pasajes cortos de respuestas extraídos de Yahoo! Answers (Webscope L6), un servicio de preguntas y respuestas comunitario donde usuarios formulaban preguntas de diversa índole.
- **Consultas:** El conjunto de test incluye 200 preguntas no factuales de dominio abierto, caracterizadas por ser subjetivas y basadas en opiniones, donde no existe una única respuesta “correcta”. Las preguntas provienen de categorías diversas como consejos, recomendaciones y experiencias personales.
- **Origen de Qrels:** Los 6,589 juicios de relevancia del conjunto de test fueron recolectados mediante crowdsourcing en Amazon Mechanical Turk. Los anotadores evaluaron todas las respuestas disponibles para cada pregunta utilizando una escala de 4 niveles: nivel 1 (fuera de contexto), nivel 2 (no relevante), nivel 3 (marginal-

mente relevante), y nivel 4 (altamente relevante). La distribución incluye: 1,642 juicios de nivel 1, 2,417 de nivel 2, 1,196 de nivel 3, y 1,334 de nivel 4.

- **Objetivo:** Este dataset introduce complejidad adicional para los sistemas de recuperación debido a la naturaleza subjetiva de las consultas, donde la relevancia depende de factores contextuales y de opinión difíciles de modelar estadísticamente.

TREC-COVID

TREC-COVID fue una iniciativa colaborativa entre el Allen Institute for Artificial Intelligence (AI2), el National Institute of Standards and Technology (NIST), la National Library of Medicine (NLM), Oregon Health & Science University (OHSU), y la University of Texas Health Science Center at Houston (UTHealth) [26].

- **Documentos:** La colección utiliza el corpus CORD-19 (COVID-19 Open Research Dataset) mantenido por Semantic Scholar. La versión BEIR contiene 171,332 artículos científicos representados por sus títulos y abstracts, incluyendo campos como identificador, texto, título, URL y PubMed ID.
- **Consultas:** Las 50 consultas representan necesidades de información reales de científicos, clínicos, responsables de políticas públicas y otros profesionales que necesitaban navegar la creciente literatura científica sobre COVID-19 durante la pandemia. Cada consulta incluye un título conciso, una descripción expandida y una narrativa que especifica qué documentos serían considerados relevantes.
- **Origen de Qrels:** Los 66,336 juicios de relevancia fueron creados por asesores de NIST con experiencia biomédica, provenientes de NLM, OHSU y UTHealth. La evaluación se realizó en cinco rondas consecutivas durante 2020, acumulando juicios de relevancia profundos (“deep relevance judgments”). La escala incluye: nivel -1 (no evaluado o documento eliminado, 2 juicios), nivel 0 (no relevante, 41,661 juicios), nivel 1 (relevante, 10,456 juicios), y nivel 2 (altamente relevante, 14,217 juicios).
- **Objetivos:** El track buscó evaluar algoritmos de búsqueda para ayudar a gestionar el corpus de literatura científica sobre COVID-19 y descubrir métodos aplicables a futuras crisis biomédicas globales.

MS MARCO Passage (TREC Deep Learning 2020)

MS MARCO (Microsoft MACHine Reading COMprehension) es una colección a gran escala desarrollada por Microsoft Research, utilizada como base para el TREC Deep Learning Track desde 2019 [27].

- **Documentos:** El corpus completo contiene 8,841,823 pasajes extraídos de documentos web reales indexados por Bing. Cada pasaje consiste en un identificador y el texto del pasaje.

- **Consultas:** Las consultas del TREC DL 2020 fueron muestreadas del conjunto de evaluación de MS MARCO. Originalmente, estas consultas provienen de preguntas reales y anónimas formuladas por usuarios del motor de búsqueda Bing, lo que garantiza que representan necesidades de información auténticas y cotidianas. El subconjunto “judged” contiene 54 consultas que fueron evaluadas por asesores de NIST.
- **Origen de Qrels:** A diferencia de los juicios de relevancia escasos de MS MARCO original (donde típicamente solo un documento es marcado como relevante por consulta), el TREC DL 2020 proporciona 11,386 juicios de relevancia detallados creados por asesores de NIST. La escala de 4 niveles incluye: nivel 0 (irrelevante, 7,780 juicios), nivel 1 (relacionado, 1,940 juicios), nivel 2 (altamente relevante, 1,020 juicios), y nivel 3 (perfectamente relevante, 646 juicios). El umbral binario oficial de TREC es ≥ 2 .

TREC CAR (Complex Answer Retrieval)

TREC CAR es una colección de recuperación de pasajes ad-hoc construida a partir de Wikipedia, diseñada para abordar necesidades de información complejas que requieren respuestas extensas y estructuradas [28].

- **Documentos:** El corpus v1.5 contiene 29,678,367 pasajes extraídos de Wikipedia (dump de diciembre 2016). Cada documento incluye un identificador único y el texto del pasaje.
- **Consultas:** Las 2,287 consultas del Year 1 (2017) fueron derivadas de la estructura jerárquica de artículos de Wikipedia. Cada consulta incluye un identificador, texto completo, título del artículo y la jerarquía de encabezados que representa la sección específica. Las consultas fueron seleccionadas manualmente de temas de ciencia popular y medio ambiente, inspiradas en noticias de actualidad y temas de interés general.
- **Origen de Qrels:** La versión “manual” (car/v1.5/trec-y1/manual) contiene 29,571 juicios de relevancia creados por seis asesores de NIST utilizando pools de documentos contruidos a partir de las entregas de los participantes. La escala graduada de 6 niveles es la más detallada entre los datasets seleccionados:
 - Nivel -2: Basura/spam (42 juicios)
 - Nivel -1: No relevante (12,785 juicios)
 - Nivel 0: No relevante pero tema cercano (9,219 juicios)
 - Nivel 1: Podría mencionarse (3,094 juicios)
 - Nivel 2: Debería mencionarse (1,970 juicios)
 - Nivel 3: Debe mencionarse (2,461 juicios)
- **Diferencia con qrels automáticos:** TREC CAR también ofrece qrels automáticos derivados de la estructura de Wikipedia, pero para este proyecto se utiliza exclusi-

vamente la versión con juicios manuales por su mayor fiabilidad y la inclusión de juicios negativos explícitos.

Además, todos los datasets utilizados son de acceso abierto en repositorios públicos y están bien documentados debido a que son ampliamente reconocidos en la comunidad de recuperación de información, lo que asegura que cualquier investigador pueda acceder a ellos sin restricciones para replicar los experimentos. Todos los datasets son accesibles a través de la librería *ir_datasets*, garantizando un proceso estandarizado de carga y preprocesamiento. Es así que, la utilización de datasets de acceso abierto garantiza que los resultados del proyecto sean reproducibles y accesibles para futuras investigaciones, fomentando el entorno colaborativo y transparente, evitando problemas legales o éticos relacionados con el uso de datos restringidos o privados.

De esta forma, la selección de datasets con características bien definidas asegura una evaluación diversa y representativa de los métodos QPP seleccionados, ya que este enfoque cubre dominios especializados, tareas cotidianas y casos complejos, estableciendo una base sólida para validar la efectividad y aplicabilidad de los métodos en diferentes contextos de recuperación de información.

4.3 Selección de métodos de QPP

La selección de métodos QPP resulta crucial en el diseño de este proyecto, ya que determina la relevancia y la validez del análisis comparativo.

Para garantizar que los enfoques evaluados sean representativos y estén alineados con los objetivos del estudio, se establecieron criterios rigurosos basados en la literatura científica revisada, los cuales priorizan la inclusión de métodos reconocidos en el estado del arte, con fundamentos estadísticos sólidos y un alto grado de reproducibilidad.

A continuación, se describen los criterios aplicados en el proceso de selección, así como los métodos QPP finalmente escogidos para la posterior evaluación comparativa.

4.3.1 Criterios de selección

Como se ha mencionado, la selección de métodos de Query Performance Prediction (QPP) es un proceso fundamental para garantizar que los métodos evaluados sean representativos, robustos y relevantes en el contexto de los sistemas de recuperación de información. Con este propósito, se definieron criterios específicos que permiten abordar el problema desde una perspectiva teórica sólida y práctica aplicable, los que aseguran la validez de la evaluación comparativa y su alineación con los objetivos del proyecto.

Tabla 4.7: Criterios de selección de métodos de QPP

Criterio	Descripción	Importancia para el proyecto
Base estadística y simplicidad	Métodos con fundamentos sólidos y fácilmente comprensibles.	Facilita la reproducibilidad y asegura resultados confiables.
Uso en estudios previos	Métodos comúnmente implementados en investigaciones recientes.	Garantiza relevancia científica y comparabilidad con investigaciones previas
Diversidad de enfoques	Cobertura de métodos pre-retrieval y post-retrieval, cada uno enfocado en aspectos distintos del rendimiento.	Permite una evaluación integral que abarca múltiples aspectos del rendimiento de consultas.
Relevancia en el estado del arte	Métodos no basados en inteligencia artificial y ampliamente reconocidos por su efectividad teórica y práctica.	Asegura un marco comparativo que no depende de tecnologías supervisadas y promueve análisis no sesgados.

La Tabla 4.7 resume los criterios definidos para la selección de los métodos de QPP, en donde cada criterio cumple un rol específico para garantizar que los métodos seleccionados no solo sean estadísticamente sólidos, sino también relevantes y diversificados en su enfoque, asegurando que el análisis comparativo resultante sea exhaustivo y útil para evaluar las fortalezas y limitaciones de los métodos elegidos.

- **Base estadística y simplicidad:** Se seleccionan métodos que se basan en conceptos matemáticos fundamentales, como la frecuencia de términos en el corpus y su relación con la consulta, ya que estos métodos son ampliamente reconocidos por su sencillez y su capacidad para ser implementados y replicados sin necesidad de recursos computacionales avanzados. Este criterio asegura que los métodos elegidos puedan ser utilizados como referencia en investigaciones futuras, promoviendo la reproducibilidad de los experimentos y el entendimiento teórico de los predictores.
- **Uso en estudios previos:** Se buscan métodos que han sido recurrentemente evaluados en trabajos recientes que analizan sistemas de recuperación de información, ya que no solo garantiza que los resultados del proyecto sean comparables con investigaciones previas, sino que también asegura que los métodos seleccionados representan soluciones probadas y bien documentadas.

- **Diversidad de enfoques:** Se seleccionan métodos tanto pre-retrieval como post-retrieval para capturar diferentes aspectos del problema, mientras que unos se enfocan en estimar la calidad de una consulta basándose únicamente en estadísticas del corpus, los otros evalúan la calidad considerando los documentos recuperados. Este enfoque integral permite analizar el rendimiento de consultas desde múltiples perspectivas, proporcionando una visión más completa de sus fortalezas y debilidades.
- **Relevancia en el estado del arte:** Se priorizan métodos no basados en inteligencia artificial, ya que estos garantizan un análisis más transparente y menos sesgado en comparación con tecnologías supervisadas, además, de esta forma, los métodos seleccionados han sido ampliamente reconocidos en la literatura por su aplicabilidad en sistemas de recuperación de información y su capacidad para ser implementados sin depender de datasets de entrenamiento o modelos complejos.

Por otra parte, la decisión de priorizar métodos no basados en inteligencia artificial tiene varias razones claves:

- **Transparencia y simplicidad:** Los métodos no basados en inteligencia artificial, ofrecen interpretaciones claras de cómo se calculan y qué factores influyen en su desempeño, esto contrasta con los métodos supervisados, cuya complejidad en ocasiones dificulta la comprensión de su funcionamiento interno.
- **Reproducibilidad:** Al no depender de datasets de entrenamiento o modelos complejos, los métodos no basados en IA pueden ser implementados en cualquier entorno sin necesidad de recursos adicionales, lo que asegura que los experimentos realizados sean replicables por otros investigadores.
- **Independencia del contexto:** Los métodos seleccionados son independientes de los dominios específicos y los cambios en las colecciones de datos, mientras que los métodos supervisados tienden a ser altamente sensibles a las características del dataset de entrenamiento.
- **Contribución al estado del arte:** Este enfoque se alinea con el objetivo de establecer líneas base sólidas para evaluar nuevos métodos, permitiendo que futuros desarrollos en QPP se comparen con estándares bien establecidos.

4.3.2 Métodos seleccionados

Siguiendo los criterios establecidos en la sección anterior y tras un análisis exhaustivo de la literatura, se seleccionaron seis métodos de Query Performance Prediction (QPP) para la evaluación comparativa, los cuales representan enfoques diversos e incluyen estrategias pre-retrieval y post-retrieval, lo que asegura una cobertura de los aspectos clave del rendimiento de consultas en sistemas de recuperación de información. Además, como se ha mencionado, cada método fue elegido por su relevancia en el estado del arte, su fundamento

teórico y su impacto demostrado en investigaciones previas, ofreciendo un marco robusto para analizar su efectividad y aplicabilidad en contextos variados.

Tabla 4.8: Métodos de QPP seleccionados

Método QPP	Clasificación	Descripción
1. IDF (Inverse Document Frequency)	Pre-retrieval	Mide la rareza de los términos en un corpus mediante la frecuencia inversa de documentos.
2. SCQ (Similarity between a Query and a Collection)	Pre-retrieval	Calcula la similitud entre los términos de la consulta y la colección basándose en frecuencias y pesos.
3. NQC (Normalized Query Commitment)	Post-retrieval	Evalúa la dispersión de los puntajes de relevancia en los documentos recuperados para predecir la calidad de la consulta.
4. Clarity Score (SC)	Post-retrieval	Mide la divergencia entre el modelo de lenguaje de los documentos recuperados y el modelo de la colección.
5. WIG (Weighted Information Gain)	Post-retrieval	Estima la calidad de la consulta mediante la ganancia de información ponderada basada en los documentos recuperados.
6. UEF (Utility Estimation Framework)	Post-retrieval	Utiliza modelos de relevancia y teoría de decisión estadística para estimar la utilidad de los rankings generados.

En cuanto al análisis de las fortalezas y debilidades de cada método seleccionado en la Tabla 4.8:

- IDF (Inverse Document Frequency): Es un método simple, eficiente y ampliamente utilizado, su capacidad para medir la especificidad de los términos lo convierte en una herramienta básica para estimar la calidad de las consultas. Por otra parte, depende

exclusivamente de estadísticas del corpus, lo que limita su precisión en escenarios donde la calidad de los documentos recuperados influye de forma significativa.

- SCQ (Similarity between a Query and a Collection): Proporciona una evaluación más detallada al considerar la similitud entre la consulta y la colección en su conjunto, lo que resulta útil en contextos con consultas de longitud variada. Por otra lado, puede ser menos efectivo en colecciones con alta heterogeneidad temática debido a su dependencia de estadísticas globales.
- NQC (Normalized Query Commitment): Evalúa la consistencia de los puntajes de relevancia en los documentos recuperados, lo que lo hace efectivo para identificar consultas problemáticas, pero requiere ejecutar consultas y recuperar documentos, lo que implica un costo computacional más alto en comparación con métodos pre-retrieval.
- Clarity Score (CS): Mide la coherencia del lenguaje de los documentos recuperados, lo que lo hace efectivo en consultas específicas con temas bien definidos, pero es sensible a consultas cortas o ambiguas, donde la divergencia entre el modelo de lenguaje y el corpus puede ser menos clara.
- WIG (Weighted Information Gain): Integra múltiples características de los documentos recuperados, como términos y proximidad, proporcionando una evaluación integral, aunque puede ser afectado por colecciones con sesgos en los documentos más relevantes, disminuyendo su precisión en escenarios específicos.
- UEF (Utility Estimation Framework): Ofrece un marco flexible y adaptable, utilizando modelos de relevancia para capturar tanto la utilidad como la precisión de los rankings generados, pero su complejidad estadística puede dificultar su implementación en sistemas con recursos limitados o en contextos donde se prioriza la simplicidad.

Los métodos seleccionados abarcan una gama de enfoques y fundamentos teóricos, lo que garantiza una evaluación comparativa exhaustiva y representativa, en donde la inclusión de métodos tanto pre-retrieval como post-retrieval asegura que se cubran múltiples facetas del problema, proporcionando una base sólida para analizar su desempeño en diferentes contextos, resultando en un diseño experimental robusto que refuerza la validez del estudio y su contribución al avance del estado del arte en predicción de rendimiento de consultas.

4.4 Relación entre diseño experimental y objetivos

El diseño experimental anteriormente expuesto se encuentra directamente alineado con los objetivos planteados, garantizando que cada etapa contribuya de forma directa al cumplimiento de las metas establecidas. Es por ello que, en esta sección, se describe la relación entre los elementos del diseño experimental y los objetivos general y específicos, resaltando cómo estos interactúan entre sí para alcanzar los resultados de análisis buscados.

4.4.1 Relación con el objetivo general

Como se ha mencionado en capítulos anteriores, el objetivo general del proyecto consiste en evaluar comparativamente métodos de Query Performance Prediction (QPP) para búsquedas Ad-hoc utilizando métricas de correlación. En alineación con este objetivo, el diseño se ha organizado en las siguientes etapas:

- **Selección de Métodos QPP:** Se han seleccionado seis métodos QPP no basados en inteligencia artificial (IDF, SCQ, NQC, Clarity Score, WIG y UEF) que son ampliamente reconocidos en la literatura y representan enfoques tanto pre-retrieval como post-retrieval.
- **Selección de Datasets:** Se han elegido cinco datasets (Cranfield Collection, ANTI-QUE, TREC-COVID, MS MARCO Passage (TREC DL 2020) y TREC CAR) que cubren una amplia gama de dominios y tipos de consultas con juicios de relevancia multi-nivel, asegurando que los resultados sean generalizables.
- **Implementación y Evaluación:** Los métodos QPP se implementan en un entorno controlado utilizando herramientas como PyTerrier, Docker e ir_datasets, por lo que la evaluación se realiza mediante métricas de correlación y juicios de relevancia.
- **Análisis de Resultados:** Los resultados obtenidos se comparan con estudios previos para determinar la efectividad de los métodos y establecer una línea base para futuras investigaciones.

La Tabla 4.9 resume la relación entre el diseño experimental y cómo contribuye al objetivo general.

Tabla 4.9: Relación entre diseño experimental y objetivos

Etapa del diseño experimental	Contribución al objetivo general
Selección de Métodos QPP	Garantiza que los métodos evaluados sean representativos y relevantes para búsquedas Ad-hoc.
Selección de Datasets	Permite evaluar los métodos en diferentes contextos y dominios, asegurando la generalización de los resultados.
Implementación y Evaluación	Proporciona una evaluación comparativa robusta utilizando métricas de correlación estandarizadas.
Análisis de Resultados	Establece una línea base para futuras comparaciones con nuevos enfoques.

4.4.2 Alineación con los Objetivos Específicos

A continuación, se describe cómo cada objetivo específico se relaciona con el diseño experimental:

a) Revisar la literatura sobre métodos de QPP en búsquedas Ad-hoc sin el uso de inteligencia artificial.

Este objetivo se aborda mediante una revisión exhaustiva de trabajos y artículos académicos y experimentales relevantes, priorizando métodos no basados en IA que han sido ampliamente estudiados y documentados, lo que asegura que los métodos seleccionados sean representativos y relevantes para el contexto de búsquedas Ad-hoc.

b) Comparar los resultados de los métodos QPP con estudios previos.

Se utilizan métricas de correlación estandarizadas y juicios de relevancia para evaluar el rendimiento de los métodos QPP. Estas métricas son ampliamente aceptadas en la literatura y permiten una comparación directa con estudios previos.

c) Implementar métodos QPP en búsquedas Ad-hoc sin inteligencia artificial para su evaluación utilizando métricas estandarizadas.

La implementación de los métodos se realiza en un entorno experimental controlado utilizando contenedores Docker, que aseguran la replicabilidad y la consistencia en la ejecución de los experimentos con ayuda de scripts en Python, lo que permite una evaluación precisa y reproducible.

d) Evaluar los resultados obtenidos de los métodos QPP implementados, determinando su efectividad en función de los resultados descritos en el estado del arte.

La evaluación se realiza comparando las predicciones generadas por los métodos seleccionados con los juicios de relevancia (qrels) asociados a cada dataset, utilizando métricas de correlación como Kendall's Tau. Este análisis permite determinar las fortalezas y limitaciones de cada método en contextos específicos.

e) Analizar y documentar el rendimiento de los métodos QPP implementados para establecer una línea base para futuras comparaciones con nuevos enfoques.

Los resultados obtenidos se documentan detalladamente, incluyendo las métricas de correlación obtenidas para cada método QPP en cada dataset. Esta documentación sirve como una línea base para futuras investigaciones, permitiendo que otros investigadores comparen nuevos métodos con los resultados obtenidos en este proyecto.

Tabla 4.10: Relación entre diseño experimental y objetivos

Objetivo específico	Elemento del diseño experimental
a)	Revisión de literatura y selección de métodos representativos
b)	Selección de datasets reconocidos y herramientas de evaluación estandarizadas.
c)	Implementación de métodos QPP en entornos replicables.
d)	Evaluación de predicciones mediante métricas de correlación y juicios de relevancia.
e)	Documentación y análisis de resultados en función de los objetivos del proyecto.

Como se observa en la Tabla 4.10, el diseño experimental del proyecto está cuidadosamente alineado con los objetivos del proyecto, en donde la selección de métodos QPP, la elección de datasets, la implementación en un entorno controlado y el uso de métricas de correlación estandarizadas garantizan que los resultados sean robustos, reproducibles y relevantes para el campo de la predicción del rendimiento de consultas, resultando en un enfoque que no solo cumple con los objetivos del proyecto, sino que también establece una base sólida para futuras investigaciones en QPP.

CAPÍTULO V: IMPLEMENTACIÓN

La implementación del entorno de evaluación representa la materialización del diseño experimental previamente descrito. Este capítulo detalla los aspectos técnicos y prácticos del desarrollo, abordando desde la configuración del entorno hasta la implementación específica de cada componente del sistema.

El desarrollo se fundamenta en tres pilares principales: el sistema de recuperación de información, la implementación de los métodos QPP, y el framework de evaluación. Como se puede observar en la Tabla 5.1, cada uno de estos componentes requiere consideraciones técnicas específicas y se integran para formar un sistema cohesivo y reproducible.

Tabla 5.1: Componentes principales del sistema implementado

Componente	Consideraciones principales
Sistema de recuperación	• Implementación de BM25 como algoritmo base • Indexación eficiente de documentos • Procesamiento de consultas
Métodos QPP	• Implementación de predictores pre y post-retrieval • Manejo de dependencias entre componentes • Cálculo eficiente de estadísticas
Framework de evaluación	• Procesamiento de juicios de relevancia • Cálculo de métricas de evaluación • Análisis de correlaciones • Generación de visualizaciones

La implementación se realizó priorizando la modularidad y la reproducibilidad, utilizando herramientas y bibliotecas ampliamente reconocidas en el campo de la recuperación de información. El sistema se desarrolló completamente en Python, aprovechando un conjunto de bibliotecas especializadas cuyas funciones principales se detallan en la Tabla 5.2. Estas herramientas fueron seleccionadas por su madurez, documentación y amplia adopción en la comunidad de recuperación de información.

Tabla 5.2: Stack tecnológico principal

Aspecto	Herramienta/Biblioteca	Propósito
Recuperación	PyTerrier	Indexación y búsqueda de documentos
Datasets	ir_datasets	Acceso a colecciones estándar
Evaluación	ir_measures	Cálculo de métricas IR
Estadísticas	scipy, numpy	Análisis de correlaciones
Visualización	matplotlib, seaborn	Generación de gráficos

A continuación, se detallan los aspectos específicos de la implementación, comenzando con la configuración del entorno experimental y continuando con la implementación de cada componente del sistema.

5.1 Configuración del entorno experimental

El entorno experimental se encuentra configurado para ser ejecutado en un variedad de entornos debido a la utilización de Docker, el cual permite la ejecución de entornos virtuales en diferentes sistemas operativos. De manera general y para preservar la reproducibilidad de los resultados, se ha configurado el entorno experimental para ser ejecutado en un sistema operativo Linux, utilizando Python 3.9.21 y PyTerrier 0.13.0.

Tabla 5.3: Configuración del entorno experimental

Componente	Descripción	Versión
Docker	Contenedor de entornos virtuales	25.0.5
Python	Lenguaje de programación	3.9.21
PyTerrier	Librería de recuperación de información	0.13.0 más snapshot para el soporte de modelos de relevancia
IR-datasets	Librería de conjuntos de datos	0.5.9

Como se puede apreciar en la Tabla 5.3, se ha optado por implementar el entorno experimental en componentes de software con versiones específicas y estables, esperando lograr la mayor reproducibilidad posible de los resultados. La ejecución también es posible en sistemas operativos Windows y MacOS, pero estas cuentan con procesos de instalación y configuración mas complejos.

5.1.1 Docker y dependencias

Docker es la principal herramienta que permite la ejecución del entorno experimental, esta cuenta con una amplia gama de herramientas que permiten la ejecución de entornos virtuales en diferentes sistemas operativos. Para los propósitos de este trabajo, se ha optado por imágenes de docker basados en la versión Slim Buster de Debian, la cual destaca en su ligereza y velocidad de ejecución.

Dockerfile

```
1 # Imagen Debian optimizada para Python
2 FROM python:3.9-slim-buster
3
4 # Configuraciones de entorno
5 ENV LANG=C.UTF-8
6 ENV LC_ALL=C.UTF-8
7 ENV JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
8 ENV PATH="$JAVA_HOME/bin:$PATH"
9
10 # Instalación de Java y otras dependencias
11 RUN apt-get update && \
12     apt-get install -y openjdk-11-jdk && \
13     apt-get install -y --no-install-recommends \
14     build-essential \
15     && apt-get clean && \
16     rm -rf /var/lib/apt/lists/*
17 ...
```

Figura 5.1: Dockerfile para la configuración del entorno experimental

La Figura 5.1 muestra el archivo Docker utilizado para la configuración del entorno experimental, este Dockerfile se encuentra disponible en el repositorio de GitHub del proyecto. En este se especifican las principales dependencias y configuraciones de entorno necesarias para la ejecución del entorno experimental.

Tabla 5.4: Componentes principales del Dockerfile

Componente	Descripción
Imagen base	Python 3.9 slim-buster - Versión ligera de Debian optimizada para Python
Configuración UTF-8	Establece codificación UTF-8 para el manejo correcto de caracteres especiales y términos en diferentes idiomas presentes en los datasets, esto en la practica es necesario para evitar errores de procesamiento de tokens.
JDK 11	Java Development Kit necesario para PyTerrier, ya que este utiliza componentes Java para el procesamiento e indexación de documentos
Build essentials	Herramientas básicas de compilación necesarias para algunas dependencias de Python

La Tabla 5.4 muestra los componentes esenciales para la configuración y ejecución del entorno experimental. Diversos errores fueron enfrentados debido a la codificación de caracteres durante las primeras pruebas del entorno, especialmente al procesar términos con caracteres especiales o diacríticos presentes en los datasets. La configuración explícita de UTF-8 en el contenedor Docker resultó fundamental para asegurar el correcto procesamiento de los documentos y consultas, evitando problemas de codificación que podrían afectar la calidad de la indexación y, por ende, los resultados de la evaluación.

5.1.2 Integración de conjuntos de datos

Como se explicó anteriormente, los conjuntos de datos utilizados en este trabajo se encuentran disponibles en la librería IR-datasets, la cual cuenta con una amplia gama de conjuntos de datos tanto clásicos como modernos de recuperación de información junto a sus consultas y respectivos juicios de relevancia.

Cada dataset cuenta con una cantidad de documentos y consultas disponibles para realizar la evaluación, por otro lado los juicios de relevancia o “Qrels” suponen un desafío extra para la implementación de la evaluación, puesto que cada dataset cuenta con distintos niveles de relevancia para las consultas, lo cual si no se maneja adecuadamente puede alterar drásticamente los resultados de la correlación.

Esto es así puesto a que la evaluación clásica de métodos IR se basa en el cálculo de métricas como nDCG, AP, MAP, etc, las cuales dependen de los juicios de relevancia actuando como *ground truth* para su cálculo.

```
1 DATASET_FORMATS = {
2     "antique_test": {
3         "relevance_levels": {
4             1: "Out of context/nonsensical",
5             2: "Not relevant but on topic",
6             3: "Marginally relevant",
7             4: "Highly relevant"
8         },
9         "binary_threshold": 3, # Puntajes >= 3 son considerados
10            relevantes para las métricas binarias
11         "gain_values": { # Valores de ganancia para nDCG
12             1: 0,
13             2: 1,
14             3: 2,
15             4: 3
16         }
17     }
18 }
```

Figura 5.2: Configuración de formato de dataset

La Figura 5.2 muestra la configuración específica para el dataset antique_test, donde se definen cuatro niveles de relevancia (1-4) con sus respectivas descripciones semánticas. Esta configuración es importante por dos razones principales: primero, establece un umbral binario en 3 para las métricas que requieren juicios binarios (como Precision y Recall), considerando como relevantes solo los documentos con puntuaciones de 3 o 4. Segundo, define valores de ganancia específicos para el cálculo de nDCG, donde se asigna diferentes valores de ganancia en cada nivel.

Esta diferenciación en el manejo de los niveles de relevancia es fundamental para obtener evaluaciones precisas, ya que un manejo inadecuado de estos valores podría llevar a distorsiones significativas en el cálculo de las métricas de evaluación y, consecuentemente, afectar la correlación con los predictores QPP. Por ejemplo, si no se estableciera el umbral binario adecuadamente o se asignaran valores de ganancia incorrectos, documentos marginalmente relevantes podrían tener el mismo peso que documentos altamente relevantes en el cálculo de las métricas, lo que no reflejaría fielmente la calidad real de los resultados de búsqueda.

5.1.3 Indexación y consultas

El proceso de indexación utilizado para la evaluación es el estándar de PyTerrier mediante la construcción de un índice invertido a partir de un corpus de documentos. Este índice invertido es utilizado para la recuperación de documentos relevantes para una consulta,

utilizando el algoritmo BM25. Durante el tiempo de indexado, se realiza la tokenización de los documentos y consultas, aplicando un algoritmo de stemming y eliminación de “stopwords” para la normalización de los datos.

5.2 Implementación de métodos QPP

La implementación de los métodos QPP difiere en las dos categorías en la que se dividen los “métodos”, pre-retrieval y post-retrieval, el primer caso solo cuenta con una dependencia para su implementación, la cual es el índice invertido generado a partir de un corpus de documentos. Mientras que en el segundo caso, cuenta con dos, el índice invertido generado a partir de un corpus de documentos y los resultados de un sistema de recuperación de información en respuesta a una consulta.

```
1 # Creación del factory de métodos QPP
2 qpp_factory = QPPMethodFactory(
3     index_builder=index_builder,
4     retrieval_results=retrieval_results,
5     rm_results=rm_results_df,
6     dataset_name=dataset_path
7 )
8
9 # Compuo de los puntajes de los métodos QPP
10 qpp_scores = qpp_factory.compute_all_scores(
11     queries=queries,
12     list_size_param=args.list_size
13 )
```

Figura 5.3: Código de implementación del factory de métodos QPP




Figura 5.4: Diagrama de la capa de métodos QPP

Para cumplir con los requisitos de los métodos QPP, se ha implementado un factory, el cual se encarga de la creación y computo de los puntajes de los métodos QPP. Este factory se

encarga de tomar las dependencias necesarias y entregarlas a los métodos QPP, para que estos puedan ser computados.

Para la implementación de los métodos QPP, se ha utilizado como base código abierto pero con mejoras y modificaciones propias para satisfacer las necesidades de la evaluación a realizar. Todo el código externo utilizado se encuentra disponible en el repositorio de GitHub de el usuario **Zendelo**.²

5.2.1 Métodos pre-retrieval

En esta categoría se implementaron dos de los métodos más utilizados en las evaluaciones de la literatura, por un lado se encuentra el método IDF, el cual se basa en la frecuencia de los términos en los documentos, y por otro lado se encuentra el método SCQ, el cual se basa en la similitud de la consulta a los documentos de la colección.

Ambos métodos cuentan con variaciones, ya sea el valor promedio de los términos de la consulta, o alternativamente el valor máximo de los términos de la consulta. Estas variaciones son utilizadas en diferentes evaluaciones y se ha optado por implementar ambas en el entorno experimental.

5.2.2 Métodos post-retrieval

En esta categoría se considero una mayor gama de predictores, desde métodos seminales del campo como Clarity, hasta frameworks mas recientes como UEF. Estos métodos requieren de una dependencia extra, la cual es el resultado de un sistema de recuperación de información en respuesta a una consulta.

```
1 def calc_wig(self, list_size_param):
2     """
3     Calculates the WIG score following Zhou and Croft's method.
4     Y. Zhou and W. B. Croft. Query performance prediction in web
5     search environments
6     """
7     scores_vec = self.scores_vec[:list_size_param]
8     if self.corpus_score == 0:
9         print("Corpus score is zero; returning WIG score as 0.0 to
10            avoid division by zero.")
11         return 0.0
12     wig_score = (scores_vec.mean() - self.ql_corpus_score) /
13     np.sqrt(len(self.query_terms))
14     return wig_score
```

Figura 5.5: Implementación del método WIG

²<https://github.com/Zendelo/QPP-EnhancedEval/tree/qpptk-dev>

La Figura 5.5 muestra la implementación del método post-retrieval WIG, en este podemos identificar tanto el uso del índice invertido como el resultado de el puntaje del modelo de recuperación de información frente a toda la colección como se puede apreciar en la Ecuación (3.5). Adicionalmente se puede observar parámetros como el tamaño de la lista de documentos a considerar, el cual fue definido como 5 para WIG y en 200 para NQC bajo la recomendación de la literatura y nuestros propios experimentos. [13, 14, 17] Para finalizar, también cabe mencionar que todas los puntajes fueron considerando el puntaje promedio de los 1000 primeros documentos de la lista de resultados.

5.3 Implementación de la evaluación

La implementación de la evaluación de los métodos QPP se realiza mediante un analizador de correlaciones que permite calcular y visualizar las relaciones entre los puntajes de predicción y las métricas de rendimiento real del sistema. Este analizador está diseñado para procesar los resultados de múltiples métodos QPP y métricas de recuperación, generando análisis estadísticos y visualizaciones que facilitan la interpretación de los resultados.

5.3.1 Cálculo de correlaciones

El análisis se basa principalmente en el cálculo de coeficientes de correlación entre los puntajes QPP y las métricas de recuperación (nDCG y AP). Se implementaron tres tipos de correlaciones:

- Correlación de Pearson: Mide la relación lineal entre las variables
- Correlación de Spearman: Evalúa la relación monótona entre variables usando rangos
- Correlación de Kendall (τ): Mide la ordinalidad entre pares de observaciones

La significancia estadística de las correlaciones se verifica mediante pruebas de hipótesis, considerando un nivel de significancia de $\alpha \leq 0.05$. Las correlaciones no significativas son registradas pero marcadas apropiadamente en los reportes.

5.3.2 Visualización de resultados

Para facilitar la interpretación de los resultados, se implementaron tres tipos principales de visualizaciones como se puede observar en la Tabla 5.5, siguiendo la línea de otras evaluaciones. [4, 8, 21]

Tabla 5.5: Tipos de visualizaciones implementadas

Tipo de gráfico	Descripción
Mapas de calor	Muestran la matriz de correlaciones entre todos los métodos QPP y las métricas de evaluación, utilizando una escala de colores para representar la fuerza y dirección de las correlaciones
Diagramas de dispersión	Visualizan la relación entre cada método QPP y una métrica específica, incluyendo líneas de regresión para mejor interpretación
Diagramas de caja	Presentan la distribución de las correlaciones para cada método QPP, permitiendo comparar su estabilidad y rendimiento general

5.4 Pruebas de validación

La validación exhaustiva del sistema implementado se realizó mediante una suite completa de pruebas unitarias, diseñada para verificar el correcto funcionamiento de cada componente del entorno de evaluación. Se desarrolló un framework de pruebas automatizado que permite la ejecución sistemática de casos de prueba y la generación de informes detallados.

5.4.1 Estructura de las pruebas

Las pruebas unitarias se organizaron en siete módulos principales, cada uno enfocado en un componente específico del sistema:

Tabla 5.6: Módulos principales de pruebas unitarias

Módulo de prueba	Aspectos evaluados
QPPCorrelationAnalyzer	Análisis de correlaciones, generación de visualizaciones y reportes estadísticos
Evaluator	Cálculo de métricas de evaluación (nDCG, AP)
Clarity	Implementación del predictor Clarity, incluyendo cálculos de KL-divergence
NQC	Funcionalidad del predictor NQC y cálculos de scores normalizados
WIG	Implementación del predictor WIG y procesamiento de scores
IDF	Cálculos de IDF y variantes de agregación
SCQ	Implementación del predictor SCQ y manejo de términos

5.4.2 Metodología de validación

La validación se realizó mediante un enfoque sistemático que incluye:

- **Pruebas de casos límite:** Verificación del comportamiento del sistema ante consultas vacías, términos desconocidos y valores extremos.
- **Validación de consistencia:** Comprobación de la coherencia en el procesamiento de términos y el stemming.
- **Pruebas de integración:** Verificación de la correcta interacción entre componentes, especialmente en el análisis de correlaciones.
- **Validación de métricas:** Comprobación de cálculos de nDCG y AP contra valores conocidos.

5.4.3 Resultados de la validación

La ejecución completa de la suite de pruebas, que comprende 50 casos de prueba distribuidos entre los diferentes módulos, demostró la robustez del sistema implementado. Como se evidencia en los resultados:

- Tasa de éxito del 100% en todos los módulos de prueba
- Tiempo total de ejecución de 11.27 segundos
- Cobertura completa de todos los componentes críticos del sistema

Tabla 5.7: Resultados de ejecución por componente

Componente	Pruebas ejecutadas	Tiempo de ejecución (s)
QPPCorrelationAnalyzer	10	8.25
Evaluator	6	0.05
Clarity	8	0.03
NQC	6	0.01
WIG	7	0.01
IDF	7	0.01
SCQ	6	0.01

La validación exhaustiva realizada confirma la fiabilidad y precisión del entorno de evaluación implementado, proporcionando una base sólida para los experimentos subsiguientes. El sistema demostró ser robusto ante diversos escenarios de prueba, manteniendo la consistencia en el procesamiento de consultas y el cálculo de métricas de evaluación.

CAPÍTULO VI: ANÁLISIS DE RESULTADOS

A través de la literatura se ha establecido de manera casi unánime el análisis del rendimiento de los métodos QPP mediante el uso de métricas de correlación. Entre los primeros trabajos se puede encontrar el de E.M Voorhees en la conferencia TREC-6, donde se presenta el primer análisis de la capacidad de expertos en predecir el rendimiento de las consultas, donde se pudo observar que la mayor correlación lineal entre los resultados de los expertos fue de solo 0.26. [11].

El campo de la predicción del rendimiento de consultas se ha desarrollado a lo largo de los años, y se ha establecido el uso de juicios de relevancia y métricas como el tau de Kendall para la evaluación de los predictores. En este sentido, se encuentran dos puntos de interés, por un lado la evaluación del sistema de recuperación subyacente, y por otro la evaluación de los predictores utilizando como pre-requisito la evaluación del sistema de recuperación. La configuración general utilizada para el experimento se presenta en la Figura 6.1:




Figura 6.1: Diagrama de flujo del análisis de resultados

Donde se puede observar que el proceso de evaluación involucra métricas de evaluación de recuperación clásicas como nDCG o AP, y más adelante, métricas de correlación de predictores como el tau de Kendall, el cual debido a su naturaleza no lineal, se presenta como una métrica más fuerte frente a otras métricas como el coeficiente de Pearson.

6.1 Resultados obtenidos en conjuntos de datos

Como se mencionó anteriormente, previo a la evaluación de los métodos QPP, es necesario evaluar el sistema de recuperación subyacente, en este caso BM25 utilizando el conjunto

de datos *antique test* y sus 4 niveles de relevancia para sus cerca de 200 consultas proporcionadas.




Figura 6.2: Diagrama de caja para las métricas nDCG y AP

En un primer vistazo a los resultados del experimento tenemos que la Figura 6.2 muestra que el sistema de recuperación BM-25 presenta un rendimiento mayor en la métrica nDCG@10 frente a las métrica AP. Ambos experimentos presentan un rango de resultados similar, desde el 0 y sin sobrepasar el 0.8 en ninguno de los casos.

Es posible observar la existencia de *outliers* en los resultados de la métrica AP, los cuales sobresalen muy por encima en comparación del ultimo cuartil de los resultados. Esto se puede interpretar a que ciertas consultas consiguen resultados muy altos en comparación a las demás, debido a ser frecuentemente representadas en los juicios de relevancia y en la colección de documentos.

La media de las métricas nDCG y AP se puede observar en la Figura 6.3, donde se puede observar que el sistema de recuperación BM-25 presenta un rendimiento mucho mayor en la métrica nDCG@10 frente a los resultados de AP. Específicamente tenemos una media de 0.36 para nDCG@10 y 0.18 para AP, lo que evidencia la capacidad del sistema para rankear documentos en las 10 primeras posiciones sobre la precisión de la completitud de los documentos recuperados.




Figura 6.3: Media de las métricas nDCG y AP

La Figura 6.4 sirve para complementar la información anterior dando una perspectiva más detallada de los resultados obtenidos. Se puede observar que para nDCG@10 tenemos una distribución ligeramente bimodal, una en 0.2-0.3 y otra en 0.5-0.7, esto se puede interpretar como dos grupos intrínsecamente distintos de consultas, el primero de ellos muestra un rendimiento de nuestro sistema de recuperación más bajo, mientras que el segundo es satisfactoriamente rankeado. Estos hallazgos pueden llevar evaluar que características de las consultas en estos grupos las hacen más fácil o difícil de rankear.




Figura 6.4: Histogramas de las métricas nDCG y AP

La Figura 6.5 muestra el gráfico de dispersión de los valores de nDCG@10 y AP, donde

principalmente se puede apreciar la fuerte correlación ($r=0.84$) que existe entre ambas métricas, lo cual sugiere una calidad de recuperación similar entre ambos experimentos. Por otra parte, algo interesante a tener en cuenta es el patrón “palo de hockey” que se forma entre las dos métricas. Esto apunta a que:

- En el rango inferior($nDCG@10 < 0.4$) tenemos rendimientos mas dispersos, donde una valor de $nDCG@10$ alto no necesariamente implica un valor de AP alto.
- En el rango superior($nDCG@10 > 0.6$) la relación se vuelve mas predecible. Cuando nuestro sistema de recuperación presenta un rendimiento alto en $nDCG@10$, el rendimiento en AP tiende a ser alto igualmente.

Finalmente el rango intermedio tenemos la ocurrencia de algunos *outliers*, como se mencionó anteriormente, $nDCG@10$ presenta resultados mayores a AP, y en algunos casos estos pueden llegar a contar una diferencia significativa (0.6 vs 0.1).




Figura 6.5: Gráfico de dispersión de $nDCG@10$ vs AP

6.2 Comparación de métodos QPP

Los métodos QPP evaluados en esta sección fueron contrastados directamente con los resultados de la evaluación del sistema de recuperación utilizando el coeficiente de correlación tau de Kendall. La evaluación se realizó sobre cinco conjuntos de datos distintos: *antique test* (180 consultas), *cranfield* (91 consultas), *trec_covid* (50 consultas), *msmarco_dl20_judged* (51 consultas) y *car_vl5_trec_vl_manual* (699 consultas). Esta

diversidad de colecciones permite evaluar la robustez y generalización de los métodos QPP en diferentes contextos y tamaños de corpus, desde colecciones pequeñas y especializadas hasta grandes colecciones web.

La Figura 6.6 muestra el resultado general de la correlación en el tau de Kendall para los métodos QPP a través de las dos métricas nDCG@10 y AP en el conjunto de datos *antique test*. Empezando por el lado izquierdo del mapa de correlación tenemos los dos métodos pre-retrieval IDF y SCQ en sus variantes promedio y máximo, a posteriori, el resto de los métodos son de tipo post-retrieval, terminando por las variantes UEF de estos.




Figura 6.6: Correlación de los métodos QPP - tau de Kendall

También fueron computadas las correlaciones con el coeficiente de Pearson y Spearman en todos los datasets, pero no se presentan en esta sección debido a que no presentan resultados significativamente distintos a los obtenidos en el tau de Kendall. Estos resultados se encuentran en el Anexo.

Se observa que la menor de las correlaciones la presenta el método IDF, el cual presenta una correlación no mayor de 0.05 en todas sus variantes. Este resultado viene fuertemente ligado al preprocesado tanto de los documentos como de las consultas, puesto que anteriormente el pipeline de procesado utilizaba el *stemmer* incorporado por pyterrier, el cual es el clásico *Porter Stemmer*. Los resultados de este fueron puestos bajo la lupa para corroborar su buen funcionamiento dando los siguientes resultados:

Tabla 6.1: Muestra de términos Porter vs Snowball Stemmers

Porter (pyterrier)	Frecuencia	Snowball(nltk)	Frecuencia
0	753	small	5891
00	45	group	3578
000	50	politician	625
0001	16	believ	12362

Los resultados encontrados en la Tabla 6.1 muestran que el stemmer de Snowball presenta un rendimiento mayor en la frecuencia de los términos, esto se puede atribuir a que el stemmer de Snowball es más agresivo en la eliminación de sufijos y prefijos, lo cual puede llevar a una mayor cantidad de términos que son relevantes para la recuperación de información. Por otra parte, la pobre calidad en el procesado entregado por el stemmer de porter justifico su reemplazo por el de Snowball. En consecuencia, este cambio tuvo un impacto directo a la correlación del método IDF en $nDCG@10$, con una disminución de 0.146 a 0.05. La causa principal de este efecto no ha sido investigada profundamente, pero puede deberse a que el *Stemmer* original procesaba una mayor gamma de tokens comunes en el dataset pero que no se correspondían con ninguna palabra, sino con números o caracteres especiales, que podrían ser abundantes en el corpus. Un estudio mas profundo sobre la calidad de los conjuntos de datos podría ayudar a comprender este efecto de mejor forma.




Figura 6.7: Correlación de los métodos QPP - tau de Kendall

Por otro lado, el método SCQ muestra un rendimiento significativamente superior al IDF, presentando correlaciones moderadas positivas en el rango de 0.18-0.26 para ambas métricas de evaluación. Este contraste en el rendimiento entre ambos métodos pre-retrieval resulta particularmente interesante, ya que SCQ incorpora tanto la frecuencia de documentos (df) como la frecuencia en la colección (cf) en su cálculo, mientras que IDF se limita únicamente a la frecuencia de documentos.

La superioridad de SCQ se hace más evidente en su variante máxima, alcanzando correlaciones de 0.2596 con $nDCG@10$ y 0.2663 con AP. Estos resultados sugieren que

la incorporación de estadísticas adicionales de la colección proporciona una visión más matizada de la importancia de los términos y, por ende, una mejor capacidad predictiva del rendimiento de las consultas. Es notable cómo estos patrones de correlación se mantienen consistentes tanto para $nDCG@10$ como para AP, lo que indica que la efectividad de estos predictores no está sesgada hacia una métrica de evaluación particular.

Si bien una correlación de aproximadamente 0.26 no podría considerarse extremadamente fuerte, representa una mejora significativa sobre el método IDF y sugiere que SCQ captura señales más significativas sobre el potencial rendimiento de las consultas. Este hallazgo tiene implicaciones relevantes para el diseño de sistemas de predicción de rendimiento de consultas, indicando que la incorporación de estadísticas más completas de la colección puede conducir a predicciones más confiables.

La Figura 6.8 muestra el diagrama de caja asociado a cada correlación, como se mencionó anteriormente, el método IDF es el que presenta una menor correlación, mientras que el método UEF-NQC es el que presenta la mayor correlación del grupo con un valor de 0.42 con respecto a $nDCG@10$. Se puede apreciar que pese a que la mayoría de los métodos presentan cajas relativamente planas, lo que indica una estabilidad en sus correlaciones, algunos métodos como WIG y UEF-NQC muestran una mayor variabilidad en sus resultados. Particularmente, UEF-NQC exhibe un rango más amplio de correlaciones, con un valor promedio de 0.4 y un mínimo cercano a 0.39, lo que sugiere que su rendimiento, aunque superior, puede ser menos consistente que otros métodos. Esta variabilidad podría atribuirse a la naturaleza más compleja del método, que al incorporar más factores en su cálculo, puede ser más sensible a las características específicas de las consultas.




Figura 6.8: Diagrama de caja de correlaciones métodos QPP vs $nDCG@10$ en tau de Kendall

Los niveles de significancia presentados en la Tabla 6.2 muestran un patrón interesante en cuanto a la confiabilidad estadística de las correlaciones obtenidas. El método IDF, tanto en su variante promedio como máxima, presenta un nivel de significancia $p \geq 0.05$, lo que indica que no podemos rechazar la hipótesis nula de que no existe correlación entre las predicciones de IDF y las métricas de rendimiento. Este resultado es consistente con las bajas correlaciones observadas anteriormente y refuerza la conclusión de que IDF, en su implementación actual, no es un predictor confiable del rendimiento de las consultas en nuestro sistema.

Tabla 6.2: Niveles de significancia de las correlaciones en tau de Kendall

	nDCG@10	AP
IDF AVG	≥ 0.05	≥ 0.05
IDF-Max	≥ 0.05	≥ 0.05
SCQ-AVG	< 0.001	< 0.001
SCQ-Max	> 0.001	> 0.001
NQC	> 0.001	> 0.001
UEF-NQC	> 0.001	> 0.001
WIG	< 0.001	< 0.001
UEF-WIG	< 0.001	< 0.001
Clarity	< 0.001	< 0.001
UEF-Clarity	< 0.001	< 0.001

Por otro lado, todos los demás métodos evaluados muestran niveles de significancia $p < 0.001$, lo que indica una muy alta confianza estadística en las correlaciones observadas. Este contraste marcado entre IDF y el resto de los métodos sugiere que la falta de rendimiento de IDF no es un resultado del azar, sino una limitación inherente al método en el contexto específico de nuestro experimento.

Es particularmente notable que incluso SCQ, que también es un método pre-retrieval y comparte algunas características con IDF, logra correlaciones estadísticamente significativas. Esto refuerza la hipótesis de que la incorporación de estadísticas adicionales de la colección (como lo hace SCQ) proporciona una base más sólida para la predicción del rendimiento de las consultas.

Los métodos post-retrieval y sus variantes UEF mantienen niveles de significancia consistentemente altos ($p < 0.001$), lo que valida su superior capacidad predictiva observada en las correlaciones. Este patrón sugiere que el acceso a la información post-recuperación proporciona señales más confiables para la predicción del rendimiento de las consultas.




Figura 6.9: Gráfico de dispersión de nDCG@10 vs NQC

La Figura 6.9 muestra la relación entre las puntuaciones del predictor NQC y los valores reales de nDCG@10. El gráfico revela una correlación positiva moderada ($\tau = 0.4007$) entre las predicciones y el rendimiento real, lo que indica que NQC posee una capacidad predictiva considerable. Esta correlación se visualiza mediante la línea de tendencia naranja, que muestra una pendiente positiva consistente a lo largo del rango de predicción.

Un aspecto notable es la dispersión de los puntos alrededor de la línea de tendencia, particularmente en el rango medio de puntuaciones QPP (0.2-0.4). Esta variabilidad sugiere que la precisión del predictor no es uniforme para todas las consultas, lo cual es un comportamiento esperado en la predicción del rendimiento de consultas debido a la complejidad inherente de la tarea.

Los valores de nDCG@10 se concentran principalmente entre 0.2 y 0.6, con algunos casos excepcionales que alcanzan hasta 0.8. Esta distribución refleja la diversidad en la dificultad de las consultas en nuestra colección de prueba. Es importante notar la presencia de puntos con nDCG@10 = 0, que corresponden a consultas donde no se recuperaron documentos relevantes en las primeras 10 posiciones, casos que el método NQC maneja adecuadamente en su implementación.




Figura 6.10: Gráfico de dispersión de nDCG@10 vs UEF-NQC - tau de Kendall

La Figura 6.10 presenta la versión mejorada del predictor NQC mediante el marco UEF, mostrando un incremento en la correlación ($\tau = 0.4245$) respecto a su versión base ($\tau = 0.4007$). Esta mejora es particularmente significativa ya que refleja un patrón consistente observado en casi todos los predictores post-retrieval al aplicar el marco UEF, con la notable excepción del método WIG, el cual mostró ser más sensible a la cantidad de documentos recuperados.

La mejora en el rendimiento se puede atribuir a la capacidad del marco UEF para incorporar información de la expansión de consultas en el modelo de predicción. Esto se evidencia en la línea de tendencia ligeramente más pronunciada y en bandas de confianza más ajustadas en ciertas regiones del gráfico. El mecanismo subyacente se basa en la correlación entre las puntuaciones de recuperación originales y las de la consulta expandida, donde una alta correlación sugiere una consulta bien formulada y probablemente efectiva.

Es notable cómo UEF-NQC maneja mejor los casos extremos, particularmente en el rango superior de puntuaciones QPP (0.5-0.7), y muestra una predicción más consistente en el rango medio (0.2-0.4). Esta mejora en la capacidad predictiva sugiere que la incorporación del comportamiento de reformulación de consultas en QPP puede conducir a predicciones más confiables, especialmente en consultas desafiantes donde los predictores tradicionales podrían tener dificultades.




Figura 6.11: Gráficos de dispersión de nDCG@10 vs IDF

La Figura 6.11 presenta los gráficos de dispersión para las dos variantes del predictor IDF: promedio y máximo, los cuales presentan la mayor anomalía dentro de los resultados. Ambos gráficos revelan correlaciones extremadamente débiles con los valores de nDCG@10, con $\tau = 0.0451$ para IDF promedio y $\tau = -0.0100$ para IDF máximo. Estos resultados son consistentes con los niveles de significancia previamente discutidos ($p \geq 0.05$) y refuerzan visualmente la limitada capacidad predictiva del método IDF en nuestro experimento.

Un aspecto notable en ambas variantes es la presencia de heterocedasticidad, es decir, una variación no constante en la dispersión de los valores nDCG@10 a lo largo del rango de puntuaciones IDF. En el caso de IDF máximo, esta heterogeneidad es particularmente pronunciada en el rango medio (6-8), donde se observa una dispersión en forma de abanico que sugiere una mayor incertidumbre en las predicciones. La variante de IDF promedio muestra un patrón de varianza más estable en el rango medio (4.5-6.5), pero exhibe un incremento notable en la variabilidad alrededor de las puntuaciones 6-7.

Esta variabilidad no uniforme tiene implicaciones importantes para la fiabilidad de las predicciones: sugiere que la capacidad predictiva de IDF no es consistente a través de diferentes tipos de consultas y que la confianza en las predicciones debería ajustarse según el rango de puntuación IDF en que se encuentre la consulta. La presencia de estas regiones de alta incertidumbre, junto con las correlaciones cercanas a cero, indica que el uso directo de IDF como predictor de rendimiento podría no ser apropiado sin modificaciones sustanciales o la incorporación de características adicionales.

Estos resultados apuntan que, a pesar de ser un concepto fundamental en recuperación de información, el uso directo de IDF para la predicción del rendimiento de consultas podría requerir ser complementado con características adicionales o transformado de manera que capture mejor los aspectos cualitativos de las consultas. Esta observación se alinea con el mejor rendimiento observado en SCQ, que extiende el concepto de IDF incorporando estadísticas adicionales de la colección.

6.3 Análisis comparativo entre datasets

La evaluación de los métodos QPP en múltiples conjuntos de datos revela patrones importantes sobre la robustez y generalización de los predictores. Como se menciona en [8], el rendimiento de un predictor puede variar significativamente dependiendo de las características del corpus, incluyendo su homogeneidad, tamaño y calidad de los juicios de relevancia.

La Tabla 6.3 presenta un resumen de las correlaciones de Kendall obtenidas por el mejor método en cada dataset para la métrica $nDCG@10$. Se puede observar una variabilidad considerable en los valores de correlación, que van desde 0.1259 en *car_v15_trec_y1_manual* hasta 0.4245 en *antique test*.

Tabla 6.3: Resumen de correlaciones de Kendall (τ) para $nDCG@10$ en cada dataset

Dataset	Consultas	Mejor método	τ ($nDCG@10$)
antique test	180	UEF-NQC	0.4245
cranfield	91	UEF-NQC	0.3261
trec_covid	50	UEF-Clarity	0.3279
msmarco_dl20_judged	51	NQC	0.4080
car_v15_trec_y1_manual	699	UEF-NQC	0.1259

Un hallazgo particularmente notable es el comportamiento del método Clarity, que muestra un rendimiento excepcional en el dataset *trec_covid* ($\tau = 0.3279$ para $nDCG@10$ y $\tau = 0.4433$ para AP), superando incluso a métodos post-retrieval tradicionales como NQC y WIG. Este resultado contrasta con su desempeño en otros datasets, donde Clarity presenta correlaciones más moderadas o incluso no significativas, como en *cranfield* donde alcanza valores cercanos a cero. Esta variabilidad puede atribuirse a las características específicas del corpus de *trec_covid*, que contiene documentos científicos relacionados con COVID-19, donde la coherencia temática y la estructura del lenguaje pueden favorecer el enfoque de modelado de lenguaje que utiliza Clarity.

Por otro lado, el dataset *car_v15_trec_y1_manual* presenta las correlaciones más bajas en general, con el mejor método (UEF-NQC) alcanzando solo $\tau = 0.1259$ para $nDCG@10$. Este resultado es consistente con observaciones previas sobre la sensibilidad de los predictores a la calidad y características de los datasets [8]. A pesar de ser el dataset más grande con 699 consultas, la naturaleza heterogénea de los documentos y posiblemente la calidad de los juicios de relevancia pueden estar afectando la capacidad de los predictores para capturar señales consistentes.

En contraste, los datasets *antique test* y *msmarco_dl20_judged* muestran correlaciones más altas, con valores superiores a 0.40 para los mejores métodos. En *antique test*, UEF-

NQC alcanza $\tau = 0.4245$, mientras que en *msmarco_dl20_judged*, NQC (sin UEF) presenta $\tau = 0.4080$. Estos resultados sugieren que estos corpus, aunque diferentes en tamaño y dominio, comparten características que favorecen la capacidad predictiva de los métodos post-retrieval.

Un patrón consistente observado a través de todos los datasets es la superioridad general de los métodos post-retrieval sobre los pre-retrieval. En la mayoría de los casos, métodos como NQC, UEF-NQC, WIG y UEF-WIG superan a IDF y SCQ, aunque con variaciones en la magnitud de la diferencia. La única excepción notable es *trec_covid*, donde Clarity (un método post-retrieval basado en modelado de lenguaje) domina, pero esto puede atribuirse a las características específicas del corpus.

Respecto al marco UEF, los resultados muestran un patrón mixto. En *antique test* y *cranfield*, UEF-NQC supera consistentemente a NQC, lo que sugiere que la incorporación de información de expansión de consultas mejora la capacidad predictiva. Sin embargo, en *msmarco_dl20_judged*, NQC sin UEF presenta un rendimiento similar o ligeramente superior ($\tau = 0.4080$ para ambos en $nDCG@10$, pero $\tau = 0.5357$ vs $\tau = 0.5075$ para AP a favor de NQC). Esta variabilidad sugiere que la efectividad de UEF puede depender de las características específicas del dataset y del método base al que se aplica.

La variabilidad observada en los resultados entre datasets refuerza la importancia de evaluar los métodos QPP en múltiples colecciones, como se recomienda en la literatura [8]. Un predictor que funciona bien en un contexto puede no generalizar a otros, lo que subraya la necesidad de desarrollar métodos más robustos o de adaptar las estrategias de predicción según las características del corpus.

6.4 Discusión de los resultados

Los resultados obtenidos en este estudio revelan patrones significativos en el rendimiento de los diferentes métodos de predicción de consultas (QPP), proporcionando insights valiosos sobre su efectividad y limitaciones en el contexto de la recuperación de información.

6.4.1 Importancia de las correlaciones observadas

La evaluación de los métodos QPP en múltiples datasets mostró un rango de correlaciones que van desde valores cercanos a 0 (IDF en varios datasets) hasta aproximadamente 0.42 (UEF-NQC en *antique test*). Aunque estas correlaciones podrían parecer modestas a primera vista, es importante contextualizarlas dentro del campo de la predicción del rendimiento de consultas. Como se señala en [10], correlaciones incluso tan bajas como 0.1 pueden tener valor práctico en ciertos contextos, siendo particularmente útiles cuando superan el umbral de 0.5. En este sentido, los resultados obtenidos por métodos como UEF-

NQC ($\tau = 0.4245$ en *antique test*) y NQC ($\tau = 0.4080$ en *msmarco_dl20_judged*) se acercan a niveles de correlación que pueden considerarse prácticamente significativos.

Sin embargo, la variabilidad observada entre datasets subraya la importancia de considerar el contexto específico al interpretar estas correlaciones. Mientras que en algunos datasets como *antique test* y *msmarco_dl20_judged* se alcanzan correlaciones moderadas-altas, en otros como *car_vl5_trec_y1_manual* las correlaciones son considerablemente más bajas, lo que refleja la sensibilidad de los predictores a las características del corpus y la calidad de los juicios de relevancia.

6.4.2 Rendimiento de métodos pre-retrieval

Un hallazgo particularmente interesante emerge al analizar el comportamiento de los métodos pre-retrieval a través de todos los datasets. Como señala [2], estos métodos son especialmente atractivos debido a su eficiencia computacional, ya que no requieren ejecutar el proceso de recuperación. Sin embargo, nuestros resultados muestran una marcada diferencia entre los dos métodos pre-retrieval evaluados: mientras que IDF mostró correlaciones prácticamente nulas o muy bajas en la mayoría de los datasets (por ejemplo, $\tau \approx 0.05$ en *antique test*), SCQ alcanzó correlaciones moderadas que varían entre datasets ($\tau \approx 0.19$ - 0.26 en *antique test* y *cranfield*).

Esta disparidad sugiere que, si bien los métodos pre-retrieval pueden ser prometedores por su eficiencia, su efectividad depende crucialmente de la sofisticación de sus métricas. El mejor rendimiento de SCQ puede atribuirse a su capacidad para incorporar tanto la frecuencia de documentos como la frecuencia en la colección, proporcionando una vista más completa de la importancia de los términos.

Sin embargo, es importante notar que el rendimiento de SCQ también muestra variabilidad entre datasets. En *trec_covid* y *msmarco_dl20_judged*, SCQ presenta correlaciones más bajas o incluso no significativas, lo que sugiere que su efectividad puede depender de las características específicas del corpus. Por último cabe mencionar que el método SCQ presenta mejores resultados en su variante máxima y promedio frente a los benchmarks disponibles en la literatura en el conjunto de datos *antique test*. [4] Poniendo en evidencia la importancia del preprocesado de consultas y documentos en la predicción del rendimiento de las consultas.

6.4.3 Rendimiento de métodos post-retrieval

Los resultados demuestran consistentemente que los métodos post-retrieval, particularmente en sus variantes UEF, superan a los métodos pre-retrieval en la mayoría de los datasets evaluados. El método UEF-NQC emerge como el mejor predictor en tres de los

cinco datasets (*antique test*, *cranfield* y *car_vl5_trec_y1_manual*), alcanzando correlaciones de $\tau = 0.4245$, $\tau = 0.3261$ y $\tau = 0.1259$ respectivamente. Esta superioridad sugiere que la información adicional disponible después de la recuperación proporciona señales más confiables para la predicción del rendimiento.

Sin embargo, los resultados también revelan que el mejor método post-retrieval puede variar según el dataset. En *trec_covid*, UEF-Clarity supera a todos los demás métodos, mientras que en *msmarco_dl20_judged*, NQC (sin UEF) presenta el mejor rendimiento. Esta variabilidad sugiere que diferentes métodos post-retrieval pueden ser más efectivos dependiendo de las características del corpus, como su dominio temático, tamaño y calidad de los documentos.

En cuanto a la comparación con otras evaluaciones en la literatura, los métodos se encuentran generalmente en línea o un poco por encima de los resultados de Zendel et al. [4] en el dataset *antique test*, con la excepción de Clarity, el cual presenta un rendimiento variable: inferior en algunos datasets como *cranfield* y *msmarco_dl20_judged*, pero superior en *trec_covid*, probablemente debido a su enfoque de modelado de lenguaje que se beneficia de la coherencia temática de ese corpus específico.

6.4.4 Complejidad Inherente de la Tarea

La dificultad fundamental de predecir el rendimiento de las consultas se evidencia en estudios previos con expertos humanos [29, 30], donde incluso profesionales con conocimiento profundo de la terminología y sus ambigüedades mostraron una capacidad limitada para predecir el rendimiento de las consultas. Este contexto hace que los resultados obtenidos por los métodos automáticos, particularmente UEF-NQC, sean más apreciables, ya que logran correlaciones moderadas en una tarea inherentemente compleja.

6.4.5 Implicaciones sobre una línea base experimental

Los resultados sugieren varias implicaciones importantes. Primero, la elección entre métodos pre y post-retrieval debe considerar el balance entre eficiencia y efectividad. Mientras que SCQ ofrece un compromiso razonable, logrando correlaciones moderadas sin el costo computacional de la recuperación, los métodos post-retrieval como UEF-NQC proporcionan predicciones significativamente más confiables cuando el tiempo de procesamiento no es una limitación crítica.

Segundo, la variabilidad en el rendimiento observada en el análisis de dispersión sugiere que podría ser beneficioso desarrollar métodos híbridos que combinen las fortalezas de diferentes predictores, potencialmente adaptando la estrategia de predicción según las características específicas de la consulta.

En tercer lugar, aun con los resultados prometedores obtenidos en ciertos casos como NQC y UEF-NQC en algunos datasets, cabe recalcar que las correlaciones siguen siendo bajas para la mayoría de los métodos, especialmente cuando se consideran todos los datasets evaluados. La variabilidad observada entre datasets, con correlaciones que van desde 0.13 hasta 0.42, sugiere que la tarea de predecir el rendimiento de las consultas sigue siendo una tarea compleja y que el desarrollo de métodos más sofisticados que puedan capturar mejor los matices que afectan el rendimiento de la recuperación de información sigue siendo una tarea pendiente.

Finalmente, la evaluación multi-dataset realizada en este estudio subraya la importancia de no generalizar conclusiones basadas en un único corpus. La variabilidad en el rendimiento de los predictores entre datasets refuerza la necesidad de desarrollar métodos más robustos que puedan adaptarse a diferentes características de corpus, o de establecer estrategias de selección de predictores basadas en las propiedades del dataset en cuestión.

Tabla 6.4: Correlaciones (P-ρ, S-ρ y K-τ) entre métodos QPP y nDCG@10 en los distintos datasets evaluados

Correlaciones entre métodos QPP y nDCG@10 en múltiples datasets															
Método	antique test			cranfield			trec_covid			msmarco_dl20_judged			car_v15_trec_y1_manual		
	P-ρ	S-ρ	K-τ	P-ρ	S-ρ	K-τ	P-ρ	S-ρ	K-τ	P-ρ	S-ρ	K-τ	P-ρ	S-ρ	K-τ
IDF Promedio	0.164	0.139	0.096	0.249	0.186	0.133	0.123	0.005	-0.006	0.265	0.291	0.209	-0.019	-0.007	-0.004
IDF Máximo	0.092	0.076	0.051	0.117	0.087	0.060	0.083	0.030	0.017	0.251	0.253	0.168	0.018	0.009	0.006
SCQ Promedio	0.324	0.266	0.186	0.284	0.235	0.162	0.074	0.053	0.032	0.178	0.182	0.127	0.039	0.014	0.010
SCQ Máximo	0.379	0.383	0.260	0.310	0.276	0.196	0.062	0.089	0.055	-0.035	0.012	0.030	0.065	0.074	0.051
WIG	0.436	0.450	0.306	0.295	0.324	0.231	0.320	0.278	0.201	0.552	0.560	0.406	0.079	0.099	0.068
NQC	0.524	0.567	0.401	0.297	0.384	0.269	0.192	0.147	0.093	0.553	0.585	0.408	0.125	0.166	0.114
Clarity	0.452	0.430	0.296	-0.025	-0.018	-0.015	0.477	0.461	0.310	0.093	0.068	0.053	0.110	0.146	0.101
UEF-WIG	0.333	0.377	0.253	0.388	0.390	0.272	0.170	0.192	0.134	0.343	0.380	0.253	0.121	0.124	0.085
UEF-NQC	0.553	0.596	0.424	0.359	0.458	0.326	0.182	0.146	0.108	0.552	0.560	0.408	0.131	0.182	0.126
UEF-Clarity	0.463	0.448	0.307	0.161	0.181	0.120	0.496	0.468	0.328	0.190	0.186	0.126	0.113	0.152	0.105

CAPÍTULO VII: CONCLUSIONES Y TRABAJO FUTURO

7.1 Principales conclusiones

El presente trabajo ha abordado la evaluación comparativa de diversos métodos de Predicción del Rendimiento de Consultas (QPP) en el contexto de búsquedas Ad-hoc. A través de la implementación y análisis de métodos tanto pre-retrieval como post-retrieval, se ha logrado establecer una línea base robusta que facilita la comprensión de la efectividad y limitaciones de cada enfoque en diferentes escenarios de recuperación de información.

Los resultados obtenidos en el análisis de resultados revelan que los métodos post-retrieval, especialmente aquellos que incorporan el marco de Utility Estimation Framework (UEF) como UEF-NQC, muestran una correlación significativamente mayor con las métricas de rendimiento (nDCG@10 y AP) en comparación con métodos pre-retrieval tradicionales como IDF. Esto subraya la importancia de utilizar información adicional obtenida después de la recuperación para mejorar la precisión de las predicciones de rendimiento de consultas.

Asimismo, el método Normalized Query Commitment (NQC) demostró una capacidad predictiva considerable, consolidando su posición como uno de los métodos más efectivos dentro de los evaluados. Por otro lado, el método IDF mostró una correlación prácticamente nula, indicando su limitada utilidad en la predicción del rendimiento en el contexto específico de este estudio.

El preprocesado mediante algoritmos de stemming y stopwords, así como la implementación de métodos de normalización de los datos, resultaron ser herramientas con un impacto significativo en la precisión de los métodos QPP. Su implementación en el entorno dio lugar a resultados mixtos, con algunas mejoras significativas (SCQ, NQC, UEF-NQC) y otras que vieron mermada su efectividad (IDF, Clarity).

Finalmente, la evidencia experimental demuestra que los métodos QPP clásicos presentan una capacidad predictiva limitada en el contexto de búsquedas Ad-hoc. Los resultados se alinean con investigaciones previas como la de Hauff et al. (2010) [10], que establece que correlaciones bajas ($\tau < 0.1$) pueden ser útiles en Meta-búsquedas, correlaciones medias ($\tau \geq 0.4$) pueden ser útiles en búsquedas Ad-hoc tomando ciertas suposiciones, mientras que correlaciones más altas ($\tau \geq 0.7$) son necesarias para obtener resultados generalizables y confiables en todos los casos.

7.2 Recomendaciones para investigaciones futuras

Durante el desarrollo de este proyecto, se enfrentaron diversas dificultades, principalmente relacionadas con la gestión de datos y la implementación eficiente de los métodos QPP. La variabilidad en los niveles de relevancia de los datasets y la necesidad de adaptar las

configuraciones de los métodos a cada caso específico representaron desafíos técnicos significativos. Además, la complejidad inherente a la implementación de métodos post-retrieval demandó una profundidad de análisis y recursos computacionales que limitaron parcialmente el alcance de las evaluaciones.

Las limitaciones observadas en este estudio incluyen la restricción a métodos no basados en inteligencia artificial, lo que, si bien ha permitido una evaluación transparente y reproducible, ha excluido enfoques que podrían ofrecer mejoras sustanciales en la predicción de rendimiento. Asimismo, la dependencia de ciertos datasets y parámetros específicos configura un marco de evaluación que podría no generalizarse completamente a otros contextos o colecciones de datos.

Por lo tanto, se recomienda que futuras investigaciones consideren la inclusión de métodos basados en inteligencia artificial y aprendizaje automático, los cuales podrían capturar de manera más efectiva las complejidades y matices presentes en las consultas y colecciones de documentos. Además, la ampliación del espectro de datasets utilizados, incorporando colecciones más diversas y de mayor escala, podría proporcionar una evaluación más exhaustiva y generalizable de los métodos QPP.

7.3 Trabajo Futuro

De cara al futuro, se identifican varias líneas de investigación que podrían enriquecer y ampliar los hallazgos de este estudio:

1. **Integración de Métodos Basados en Inteligencia Artificial:** Incorporar enfoques de aprendizaje supervisado y no supervisado para desarrollar predictores QPP más sofisticados que puedan adaptarse dinámicamente a diferentes tipos de consultas y colecciones de documentos.
2. **Optimización de Parámetros y Configuraciones:** Realizar estudios detallados sobre la influencia de diversos parámetros en los métodos QPP, buscando optimizaciones que puedan mejorar significativamente la correlación con las métricas de rendimiento.
3. **Exploración de Nuevas Métricas de Evaluación:** Ampliar el análisis a métricas adicionales que puedan ofrecer perspectivas complementarias sobre la efectividad de los métodos QPP, tales como MAP, R-Precision o métricas basadas en la satisfacción del usuario.
4. **Impacto del preprocesado en los métodos QPP:** Realizar estudios sobre la influencia del preprocesado en los métodos QPP, buscando identificar las mejores prácticas para mejorar la precisión de los métodos.
5. **Desarrollo de Métodos Híbridos:** Combinar características de métodos pre-retrieval y post-retrieval en un enfoque híbrido que aproveche las fortalezas de ambos, buscando compensar sus respectivas limitaciones.

6. Estudios de Caso en Dominios Específicos: Aplicar y evaluar los métodos QPP en dominios especializados como medicina, derecho o e-commerce, donde las características particulares de las consultas y documentos podrían influir de manera distinta en el rendimiento de los predictores.

Este trabajo establece una base sólida para la evaluación comparativa de métodos QPP en búsquedas Ad-hoc, al tiempo que abre múltiples avenidas para investigaciones futuras que pueden profundizar y ampliar los conocimientos en este campo dinámico y en constante evolución.

REFERENCIAS BIBLIOGRÁFICAS


- [1] MOTHE, Josiane, Léa LAPORTE y Adrian-Gabriel CHIFU. Predicting Query Difficulty in IR: Impact of Difficulty Definition. En: *2019 11th International Conference on Knowledge and Systems Engineering (KSE)* [en línea]. 2019, p. 1–6. ISSN 2164-2508. Disponible en: doi:10.1109/KSE.2019.8919433
- [2] THOMAS, Paul, Falk SCHOLER, Peter BAILEY y Alistair MOFFAT. Tasks, Queries, and Rankers in Pre-Retrieval Performance Prediction. En: *Proceedings of the 22nd Australasian Document Computing Symposium* [en línea]. Brisbane, QLD, Australia: Association for Computing Machinery, 2017. ADCS '17. ISBN 9781450363914. Disponible en: doi:10.1145/3166072.3166079
- [3] LEWIS, Patrick, Ethan PEREZ, Aleksandra PIKTUS, Fabio PETRONI, Vladimir KARPUKHIN, Naman GOYAL, Heinrich KÜTTLER, Mike LEWIS, Wen-tau YIH, Tim ROCKTÄSCHEL y OTHERS. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in neural information processing systems*. 2020, **33**, 9459–9474.
- [4] ZENDEL, Oleg, Maik FRÖBE y Guglielmo FAGGIOLI. QPPTK@ TIREx: Simplified Query Performance Prediction for Ad-Hoc Retrieval Experiments. *WOWS 2024*. 2024, 50.
- [5] CARMEL, David y Elad YOM-TOV. Estimating the query difficulty for information retrieval. En: *Proceedings of the 33rd International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Geneva, Switzerland: Association for Computing Machinery, 2010, p. 911. SIGIR '10. ISBN 9781450301534. Disponible en: doi:10.1145/1835449.1835683
- [6] CRONEN-TOWNSEND, Steve, Yun ZHOU y W. Bruce CROFT. Predicting query performance. En: *Proceedings of the 25th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Tampere, Finland: Association for Computing Machinery, 2002, p. 299–306. SIGIR '02. ISBN 1581135610. Disponible en: doi:10.1145/564376.564429
- [7] KINNEY, Kenneth A., Scott B. HUFFMAN y Juting ZHAI. How evaluator domain expertise affects search result relevance judgments. En: *Proceedings of the 17th ACM Conference on Information and Knowledge Management* [en línea]. Napa Valley, California, USA: Association for Computing Machinery, 2008, p. 591–598. CIKM '08. ISBN 9781595939913. Disponible en: doi:10.1145/1458082.1458160
- [8] HAUFF, Claudia, Leif AZZOPARDI y Djoerd HIEMSTRA. The Combination and Evaluation of Query Performance Prediction Methods. En: Mohand BOUGHANEM, Catherine BERRUT, Josiane MOTHE y Chantal SOULE-DUPUY, eds. *Advances in Information Retrieval*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2009, p. 301–312. ISBN 978-3-642-00958-7.
- [9] MENG, Chuan, Negar ARABZADEH, Mohammad ALIANNEJADI y Maarten de RIJKE. Query Performance Prediction: From Ad-hoc to Conversational Search. En: *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Taipei, Taiwan: Association for Computing Machinery, 2023, p. 2583–2593. SIGIR '23. ISBN 9781450394086. Disponible en: doi:10.1145/3539618.3591919
- [10] HAUFF, Claudia, Leif AZZOPARDI, Djoerd HIEMSTRA y Franciska de JONG. Query Performance Prediction: Evaluation Contrasted with Effectiveness. En: Cathal GURRIN, Yulan HE, Gabriella KAZAI, Udo KRUSCHWITZ, Suzanne LITTLE, Thomas ROELLEKE, Stefan RÜGER y Keith van RIJSBERGEN, eds.

Advances in Information Retrieval. Berlin, Heidelberg: Springer Berlin Heidelberg, 2010, p. 204–216. ISBN 978-3-642-12275-0.


- [11] VOORHEES, E.M. The Sixth Text REtrieval Conference (TREC-6). *Information Processing & Management* [en línea]. 2000, **36**(1), 1–2. ISSN 0306-4573. Disponible en: doi:[https://doi.org/10.1016/S0306-4573\(99\)00042-4](https://doi.org/10.1016/S0306-4573(99)00042-4)
- [12] LAVRENKO, Victor y W. Bruce CROFT. Relevance based language models. En: *Proceedings of the 24th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. New Orleans, Louisiana, USA: Association for Computing Machinery, 2001, p. 120–127. SIGIR '01. ISBN 1581133316. Disponible en: doi:[10.1145/383952.383972](https://doi.org/10.1145/383952.383972)
- [13] TAO, Yongquan y Shengli WU. Query Performance Prediction By Considering Score Magnitude and Variance Together. En: *Proceedings of the 23rd ACM International Conference on Conference on Information and Knowledge Management* [en línea]. Shanghai, China: Association for Computing Machinery, 2014, p. 1891–1894. CIKM '14. ISBN 9781450325981. Disponible en: doi:[10.1145/2661829.2661906](https://doi.org/10.1145/2661829.2661906)
- [14] ZHOU, Yun y W. Bruce CROFT. Query performance prediction in web search environments. En: *Proceedings of the 30th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Amsterdam, The Netherlands: Association for Computing Machinery, 2007, p. 543–550. SIGIR '07. ISBN 9781595935977. Disponible en: doi:[10.1145/1277741.1277835](https://doi.org/10.1145/1277741.1277835)
- [15] ZHAO, Ying, Falk SCHOLER y Yohannes TSEGAY. Effective Pre-retrieval Query Performance Prediction Using Similarity and Variability Evidence. En: Craig MACDONALD, Iadh OUNIS, Vassilis PLACHOURAS, Ian RUTHVEN y Ryen W. WHITE, eds. *Advances in Information Retrieval*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008, p. 52–64. ISBN 978-3-540-78646-7.
- [16] ROBERTSON, Stephen. Understanding inverse document frequency: on theoretical arguments for IDF. *Journal of Documentation* [en línea]. 2004, **60**(5), 503–520. ISSN 0022-0418. Disponible en: doi:[10.1108/00220410410560582](https://doi.org/10.1108/00220410410560582)
- [17] SHTOK, Anna, Oren KURLAND, David CARMEL, Fiana RAIBER y Gad MARKOVITS. Predicting Query Performance by Query-Drift Estimation. *ACM Trans. Inf. Syst.* [en línea]. 2012, **30**(2). ISSN 1046-8188. Disponible en: doi:[10.1145/2180868.2180873](https://doi.org/10.1145/2180868.2180873)
- [18] SHTOK, Anna, Oren KURLAND y David CARMEL. Using statistical decision theory and relevance models for query-performance prediction. En: *Proceedings of the 33rd International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Geneva, Switzerland: Association for Computing Machinery, 2010, p. 259–266. SIGIR '10. ISBN 9781450301534. Disponible en: doi:[10.1145/1835449.1835494](https://doi.org/10.1145/1835449.1835494)
- [19] GANGULY, Debasis y Emine YILMAZ. Query-specific Variable Depth Pooling via Query Performance Prediction. En: *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Taipei, Taiwan: Association for Computing Machinery, 2023, p. 2303–2307. SIGIR '23. ISBN 9781450394086. Disponible en: doi:[10.1145/3539618.3592046](https://doi.org/10.1145/3539618.3592046)
- [20] RADLINSKI, Filip y Nick CRASWELL. Comparing the sensitivity of information retrieval metrics. En: *Proceedings of the 33rd International ACM SIGIR Conference on Research and Development in Information Retrieval* [en línea]. Geneva, Switzerland: Association for Computing Machinery, 2010, p. 667–674. SIGIR '10. ISBN 9781450301534. Disponible en: doi:[10.1145/1835449.1835560](https://doi.org/10.1145/1835449.1835560)

- [21] FAGGIOLI, Guglielmo, Oleg ZENDEL, J. Shane CULPEPPER, Nicola FERRO y Falk SCHOLER. An Enhanced Evaluation Framework for Query Performance Prediction. En: Djoerd HIEMSTRA, Marie-Francine MOENS, Josiane MOTHE, Raffaele PEREGO, Martin POTTHAST y Fabrizio SEBASTIANI, eds. *Advances in Information Retrieval*. Cham: Springer International Publishing, 2021, p. 115–129. ISBN 978-3-030-72113-8.
- [22] FORTHOFER, Ron N. y Robert G. LEHNEN. Rank Correlation Methods. En: *Public Program Analysis: A New Categorical Data Approach* [en línea]. Boston, MA: Springer US, 1981, p. 146–163. ISBN 978-1-4684-6683-6. Disponible en: doi:10.1007/978-1-4684-6683-6_9
- [23] MACDONALD, Craig, Nicola TONELLOTO, Sean MACAVANEY y Iadh OUNIS. PyTerrier: Declarative Experimentation in Python from BM25 to Dense Retrieval. En: *Proceedings of the 30th ACM International Conference on Information & Knowledge Management* [en línea]. Virtual Event, Queensland, Australia: Association for Computing Machinery, 2021, p. 4526–4533. CIKM '21. ISBN 9781450384469. Disponible en: doi:10.1145/3459637.3482013
- [24] WHISSELL, John S. y Charles L. A. CLARKE. Improving document clustering using Okapi BM25 feature weighting. *Inf. Retr.* [en línea]. 2011, **14**(5), 466–487. ISSN 1386-4564. Disponible en: doi:10.1007/s10791-011-9163-y
- [25] HASHEMI, Helia, Mohammad ALIANNEJADI, Hamed ZAMANI y W. Bruce CROFT. ANTIQUE: A Non-factoid Question Answering Benchmark. En: *Advances in Information Retrieval: 42nd European Conference on IR Research, ECIR 2020, Lisbon, Portugal, April 14–17, 2020, Proceedings, Part II* [en línea]. Lisbon, Portugal: Springer-Verlag, 2020, p. 166–173. ISBN 978-3-030-45441-8. Disponible en: doi:10.1007/978-3-030-45442-5_21
- [26] VOORHEES, Ellen, Tasmeer ALAM, Steven BEDRICK, Dina DEMNER-FUSHMAN, William R. HERSH, Kyle LO, Kirk ROBERTS, Ian SOBOROFF y Lucy Lu WANG. TREC-COVID: constructing a pandemic information retrieval test collection. *SIGIR Forum* [en línea]. 2021, **54**(1). ISSN 0163-5840. Disponible en: doi:10.1145/3451964.3451965
- [27] NGUYEN, Tri, Mir ROSENBERG, Xia SONG, Jianfeng GAO, Saurabh TIWARY, Rangan MAJUMDER y Li DENG. MS MARCO: A Human Generated MACHine Reading COMprehension Dataset [en línea]. 2016. Disponible en: <https://www.microsoft.com/en-us/research/publication/ms-marco-human-generated-machine-reading-comprehension-dataset/>
- [28] NANNI, Federico, Bhaskar MITRA, Matt MAGNUSSON y Laura DIETZ. Benchmark for Complex Answer Retrieval. En: *Proceedings of the ACM SIGIR International Conference on Theory of Information Retrieval* [en línea]. Amsterdam, The Netherlands: Association for Computing Machinery, 2017, p. 293–296. ICTIR '17. ISBN 9781450344906. Disponible en: doi:10.1145/3121050.3121099
- [29] CHIFU, Adrian-Gabriel, Sébastien DÉJEAN, Stefano MIZZARO y Josiane MOTHE. Human-based query difficulty prediction. En: *Advances in Information Retrieval: 39th European Conference on IR Research, ECIR 2017, Aberdeen, UK, April 8-13, 2017, Proceedings 39*. 2017, p. 343–356.
- [30] HAUFF, Claudia, Diane KELLY y Leif AZZOPARDI. A comparison of user and system query performance predictions. En: *Proceedings of the 19th ACM International Conference on Information and Knowledge Management* [en línea]. Toronto, ON, Canada: Association for Computing Machinery, 2010, p. 979–988. CIKM '10. ISBN 9781450300995. Disponible en: doi:10.1145/1871437.1871562


ANEXOS




Anexo 7.1: Matriz de correlación horizontal Kendall




Anexo 7.2: Matriz de correlación horizontal Spearman




Anexo 7.3: Matriz de correlación horizontal Pearson




Anexo 7.4: Gráficos de cajas QPP Kendall




Anexo 7.5: Gráficos de cajas QPP Spearman




Anexo 7.6: Gráficos de cajas QPP Pearson




Anexo 7.7: Gráficos de dispersión QPP AP Kendall




Anexo 7.8: Gráficos de dispersión QPP nDCG@10 Kendall



Anexo 7.9: Valores p QPP Correlación Kendall



Anexo 7.10: Valores p QPP Correlación Spearman



Anexo 7.11: Valores p QPP Correlación Pearson